

«Логические методы классификации и регрессии»

✓ Задача 1

Пусть имеется выборка с бинарными метками ($y_i \in \{0, 1\}$). Пусть также $P(y_i = 1) = p$. Изобразить следующие функции как функции от p :

1. $G = \sum_{k=1}^K p_k \cdot (1 - p_k)$

2. $H = - \sum_{k=1}^K p_k \cdot \log_2 p_k$

3. $E = 1 - \max_{k \in K}(p_k)$

Покажите что, полученные функционалы являются значениями в точке минимума для следующих функционалов:

1. $F(R) = \min_{c_k \in \mathbb{R}, \sum_{k=1}^K c_k = 1} \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K ([y_i = k] - c_k)^2$ (Критерий Бриера)

2. $F(R) = \min_{c_k \in \mathbb{R}, \sum_{k=1}^K c_k = 1} -\frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K [y_i = k] \log(c_k)$

3. $F(R) = \min_{k \in \{1, 2, \dots, K\}} \frac{1}{|R|} \sum_{i: x_i \in R} [y_i \neq k]$

✓ Задача 2

По выборке на (Рис. 1) обучить решающее дерево с критерием деления узлов – Gini. Изобразите решающую границу для полученного дерева и




Рис. 1: Задание 2

визуализируйте дерево в виде иерархической структуры. Прodelать то же, для энтропийного критерия.

✓ Задача 3

Рассмотрим вершину t дерева и объекты R_t попавшие в эту вершину. Сопоставим этой вершине алгоритм $a(x)$, который присваивает объекту случайный класс из K с вероятностью p_{mk} (p_{mk} - доля объектов класса k в вершине R_t). Показать, что матожидание частоты ошибок алгоритма на объектах из R_t равно индексу Джинни.

✓ Задача 4

Покажите, что энтропия ограничена сверху и достигает своего максимального значения при $p_1 = \dots = p_K = \frac{1}{K}$

✓ Задача 5

1. Может ли индекс Джинни расти при разбиении листа на два? А энтропия?
2. Привести пример данных, для которых индекс Джинни равен 0, 0.5, 0.999
3. Рассматривается задача бинарной классификации. Привести пример набора данных, такого что ни одно из стартовых разбиений не снижает индекса Джинни, однако двух разбиений достаточно, чтобы безошибочно классифицировать выборку. (Подсказка: рассмотреть какое-то положение четырёх точек в двумерном пространстве)

Задача 6

Рассматривается выборка и сопоставленное ей дерево на (Рис.).




Рис. 2: Задание 6

1. Выписать в явном виде функцию правдоподобия для модели и логистическую функцию потерь.
2. Оценить w_L, w_{RL}, w_{RR} методом максимального правдоподобия.

Задача 7

Предположим, что мы решаем задачу бинарной классификации и у нас есть 3 алгоритма: $b_1(x), b_2(x), b_3(x)$, каждый из которых ошибается с вероятностью p . Мы строим две композиции базовых алгоритмов:

$$a_1(x) = \sum_{i=1}^3 w_i \cdot [b_i(x) = 0], \quad a_1(x) = \sum_{i=1}^3 w_i \cdot [b_i(x) = 1]$$

Объект x относится к классу, для которого такая сумма оказалось максимальной. Например, если первые 2 алгоритма голосуют за класс 0, а третий за класс 1, то будет принят класс 0, если $w_1 + w_2 > w_3$. Рассчитайте вероятность ошибки каждого из итоговых алгоритмов $(a_1(x), a_2(x))$, если:

1. $w_1 = 0.2, w_2 = 0.3, w_3 = 0.2$

2. $w_1 = 0.2, w_2 = 0.5, w_3 = 0.2$

✓ Задача 8

Для проблемы **XOR** постройте решающее дерево и посчитайте важности признаков.

Задача 9

Пусть категориальный признак x_j имеет множество значений $Q = \{u_1, \dots, u_q\}$, $|Q| = q$. Разобьем множество значений на два непересекающихся подмножества: $Q = Q_1 \sqcup Q_2$, и определим предикат как индикатор попадания в первое подмножество: $\beta(x) = [x_j \in Q_1]$. Таким образом, объект будет попадать в левое поддерево, если признак x_j попадает в множество Q_1 , и в правое поддерево в противном случае. Сколько существует способов разбить Q на множества Q_1 и Q_2 .

✓ Задача 10

Какая стратегия прогнозирования в листе приводит к меньшей вероятности ошибки (в случае задаче классификации):

- Выдавать в качестве прогноза самый частотный класс в листе
- Выдавать случайный прогноз из распределения с вероятностями равными пропорциям классов в листе

(Решение)

Визуализация решающего дерева из Задачи 2.




Рис. 3: Задание 2




Рис. 4: Задание 2

Задача 11

Обучить решающее дерево на [cholesterol_prediction.csv](#). В качестве целевой переменной рассмотрите "cardio".

(Решение)

Задача 12

Написать код, который для данного вектора фичей и вектора таргетов возвращает список из gain'ов при расщеплении листа по данной фиче при всех порогах. Протестируйте ваш код на наборе данных: [students.csv](#) (целевая переменная: UNS).

```
1 import numpy as np
2
3 def compute_impurity(target_vector: np.ndarray, criterion: str='gini') ->
    float:
4
5     """
6     Computes impurity of particular leaf
7     Args:
8         target_vector: target vector for objects in this leaf
9         criterion:
10             entropy: sum(-p*log2p)
11             gini: sum(p*(1-p))
12     Returns:
13         impurity (gini or entropy)
14     """
15
16     assert criterion in ['gini', 'entropy'], 'critetion could be "gini" or "
    entropy" as for now!'
17
18     pass
19
20
21 def compute_gain(target_vector: np.ndarray, feature_vector: np.ndarray,
    threshold: float, criterion: str='gini') -> float:
22
23     """
24     Computes gain of particular leaf split ( $H_R - |R_l|/|R| * H_{R_l} - |R_r|/|R| *
    H_{R_r}$ )
25     """
26
27     assert criterion in ['gini', 'entropy'], 'critetion could be "gini" or "
    entropy" as for now!'
28
29     pass
```

(Решение)

Задача 13

Как строить дерево, которое напрямую пытается оптимизировать AUC-ROC? Выведите функционал оценки расщепления листа на два. Этот функционал должен приводить к тому, что подбирая разбиения листа таким образом, что максимизируется значение этого функционала - максимизируется значения AUC-ROC.

Задача 14:

Пусть имеется выборка $\{(x_i, y_i)\}_{i=1}^n$, $x_i, y_i \in \mathbb{R}$. Хотим найти коэффициенты a, b, c такие, что Q минимально. Где

$$Q = \sum_{i=1}^n (f(x_i) - y_i)^2$$

$$f(x) = \begin{cases} a, & x \leq c \\ b, & x > c \end{cases}$$

Для этого предлагается дополнить следующий код:

```

1 import numpy as np
2 from numpy.typing import NDArray
3 from math import inf
4
5 class DecisionStump:
6     def __init__(self):
7         """
8         f(x) = a*[x <= c] + b*[x > c]
9         """
10        self.a, self.b, self.c = None, None, None
11
12    def fit(self, x: NDArray[float], y: NDArray[float]):
13        pass
14
15    def predict(self, x: NDArray[float]) -> NDArray[float]:
16        pass

```

Примеры:

```

1 x = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
2 y = np.array([3, 3, 3, 3, 3, -2, -2, -2, -2, -2])
3 a, b, c = 3, -2, 5.5 # c could be any in (5, 6)
4
5 x = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15])
6 y = np.array([-1, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1, 5, 5, 5, 5])
7 a, b, c = -1, 5, 10.5 # could be any in (10, 11)

```

(Решение)

«Решения»
(Colab notebook)

Задача 1

$$1) \left\{ \begin{array}{l} F(R) = \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K ([y_i = k] - c_k)^2 \rightarrow \min_{c_k} \\ \sum_{k=1}^K c_k = 1 \end{array} \right.$$

$$L = \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K ([y_i = k] - c_k)^2 + \lambda \cdot \left(\sum_{k=1}^K c_k - 1 \right)$$

$$L'_{c_k} = -\frac{2}{|R|} \sum_{i: x_i \in R} ([y_i = k] - c_k) + \lambda = 0$$

$$-\frac{2}{|R|} \sum_{i: x_i \in R} [y_i = k] + 2c_k + \lambda = 0$$

$$c_k = \underbrace{\frac{1}{|R|} \sum_{i: x_i \in R} [y_i = k]}_{p_k} - \frac{\lambda}{2}$$

$$\sum_{k=1}^K c_k = \underbrace{\sum_{k=1}^K p_k}_1 - \frac{K}{2} \lambda = 1 \Rightarrow \lambda = 0$$

$$\text{Итак: } c_k^* = p_k = \frac{1}{|R|} \sum_{i: x_i \in R} [y_i = k]$$

$$\text{Получаем: } F^*(R) = \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K ([y_i = k] - c_k^*)^2 = \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K \underbrace{([y_i = k])^2}_{[y_i=k]} - 2 \cdot$$

$$\begin{aligned} [y_i = k] \cdot p_k + p_k^2) &= \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K [y_i = k] - 2 \cdot \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K [y_i = k] \cdot p_k + \frac{1}{|R|} \sum_{i: x_i \in R} \sum_{k=1}^K p_k^2 \\ &= \sum_{k=1}^K \frac{1}{|R|} \sum_{i: x_i \in R} [y_i = k] - 2 \cdot \sum_{k=1}^K p_k \cdot \underbrace{\frac{1}{|R|} \sum_{i: x_i \in R} [y_i = k]}_{p_k} + \sum_{k=1}^K p_k^2 \end{aligned}$$

$$\underbrace{\frac{1}{|R|} \sum_{i: x_i \in R} 1}_1 = \sum_{k=1}^K p_k - 2 \sum_{k=1}^K p_k^2 + \sum_{k=1}^K p_k^2 = \boxed{\sum_{k=1}^K p_k \cdot (1 - p_k)}$$

$$2) \left\{ \begin{array}{l} F(R) = -\frac{1}{|R|} \sum_{i:x_i \in R} \sum_{k=1}^K [y_i = k] \cdot \log(c_k) \rightarrow \min_{c_k} \\ \sum_{k=1}^K c_k = 1 \end{array} \right.$$

$$L = -\frac{1}{|R|} \sum_{i:x_i \in R} \sum_{k=1}^K [y_i = k] \cdot \log(c_k) + \lambda \cdot \left(\sum_{k=1}^K c_k - 1 \right)$$

$$L'_{c_k} = -\frac{1}{|R|} \sum_{i:x_i \in R} \frac{[y_i=k]}{c_k} + \lambda = 0$$

$$L'_{c_k} = -\frac{p_k}{c_k} + \lambda = 0 \Rightarrow c_k^* = \frac{p_k}{\lambda}$$

$$\sum_{k=1}^K c_k^* = \frac{1}{\lambda} \cdot \sum_{k=1}^K p_k = 1 \Rightarrow \lambda = 1$$

$$\text{Итак: } c_k^* = p_k$$

$$\text{Получаем: } F^*(R) = -\frac{1}{|R|} \sum_{i:x_i \in R} \sum_{k=1}^K [y_i = k] \cdot \log(c_k^*) = -\sum_{k=1}^K \log(p_k) \cdot$$

$$\underbrace{\frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k]}_{p_k} = \boxed{-\sum_{k=1}^K p_k \cdot \log(p_k)}$$

$$3) F(R) = \frac{1}{|R|} \sum_{i:x_i \in R} \sum_{k=1}^K [y_i \neq k] \rightarrow \min_{k \in \{1,2,\dots,K\}}$$

Докажем, что минимум $F(R)$ достигается при $k = k^*$, где k^* - самый частотный класс в вершине R .

Доказательство:

$$\text{Рассмотрим выражение: } 1 = \frac{1}{|R|} \sum_{i:x_i \in R} 1 = \frac{1}{|R|} \sum_{i:x_i \in R} ([y_i \neq k^*] + [y_i = k^*]) = \frac{1}{|R|} \sum_{i:x_i \in R} [y_i \neq k^*] + \frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k^*].$$

Однако, $\forall k \in \{1, 2, \dots, K\} \setminus k^*$ верно, что $\frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k] \leq \frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k^*]$ (по определению класса k^* . Равенство может достигаться, если в листе несколько классов встречаются одинаковое число раз).

Так как $\frac{1}{|R|} \sum_{i:x_i \in R} [y_i \neq k^*] + \frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k^*] = 1$ (константа), то если

$$\frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k] \leq \frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k^*], \text{ to } \frac{1}{|R|} \sum_{i:x_i \in R} [y_i \neq k] \geq \frac{1}{|R|} \sum_{i:x_i \in R} [y_i \neq k^*]$$

$$\text{Итак: } F^*(R) = \frac{1}{|R|} \sum_{i:x_i \in R} [y_i \neq k^*] = 1 - \frac{1}{|R|} \sum_{i:x_i \in R} [y_i = k^*] = \boxed{1 - \max_{k \in \{1,2,\dots,K\}} p_k}$$

Задача 2

feature_number : 1, threshold : 1.5, criterion : gini

$N_root : 10, N_left : 3, N_right : 7$

$prob_root_0 : 0.4, prob_root_1 : 0.6$

$prob_left_0 : 0.333, prob_left_1 : 0.667$

$prob_right_1 : 0.571, prob_right_0 : 0.429$

$$Q = 0.48 - \frac{3}{10} \cdot 0.444 - \frac{7}{10} \cdot 0.49 = \mathbf{0.004}$$

feature_number : 1, threshold : 2.5, criterion : gini

$N_root : 10, N_left : 7, N_right : 3$

$prob_root_0 : 0.4, prob_root_1 : 0.6$

$prob_left_0 : 0.286, prob_left_1 : 0.714$

$prob_right_0 : 0.667, prob_right_1 : 0.333$

$$Q = 0.48 - \frac{7}{10} \cdot 0.408 - \frac{3}{10} \cdot 0.444 = \mathbf{0.061}$$

feature_number : 1, threshold : 3.5, criterion : gini

$N_root : 10, N_left : 9, N_right : 1$

$prob_root_0 : 0.4, prob_root_1 : 0.6$

$prob_left_0 : 0.444, prob_left_1 : 0.556$

$prob_right_1 : 1.0, prob_right_0 : 0.0$

$$Q = 0.48 - \frac{9}{10} \cdot 0.494 - \frac{1}{10} \cdot 0.0 = \mathbf{0.036}$$

feature_number : 2, threshold : 1.5, criterion : gini

$N_{root} : 10, N_{left} : 1, N_{right} : 9$

$prob_{root_0} : 0.4, prob_{root_1} : 0.6$

$prob_{left_1} : 1.0, prob_{left_0} : 0.0$

$prob_{right_0} : 0.444, prob_{right_1} : 0.556$

$$Q = 0.48 - \frac{1}{10} \cdot 0.0 - \frac{9}{10} \cdot 0.494 = \mathbf{0.036}$$

feature_number : 2, threshold : 2.5, criterion : gini

$N_{root} : 10, N_{left} : 4, N_{right} : 6$

$prob_{root_0} : 0.4, prob_{root_1} : 0.6$

$prob_{left_0} : 0.5, prob_{left_1} : 0.5$

$prob_{right_1} : 0.667, prob_{right_0} : 0.333$

$$Q = 0.48 - \frac{4}{10} \cdot 0.5 - \frac{6}{10} \cdot 0.444 = \mathbf{0.013}$$

feature_number : 2, threshold : 3.5, criterion : gini

$N_{root} : 10, N_{left} : 5, N_{right} : 5$

$prob_{root_0} : 0.4, prob_{root_1} : 0.6$

$prob_{left_0} : 0.4, prob_{left_1} : 0.6$

$prob_{right_1} : 0.6, prob_{right_0} : 0.4$

$$Q = 0.48 - \frac{5}{10} \cdot 0.48 - \frac{5}{10} \cdot 0.48 = \mathbf{0.0}$$

feature_number : 2, threshold : 4.5, criterion : gini

$N_{root} : 10, N_{left} : 8, N_{right} : 2$

$prob_{root_0} : 0.4, prob_{root_1} : 0.6$


$prob_{left_0} : 0.375, prob_{left_1} : 0.625$

$prob_{right_1} : 0.5, prob_{right_0} : 0.5$

$$Q = 0.48 - \frac{8}{10} \cdot 0.469 - \frac{2}{10} \cdot 0.5 = \mathbf{0.005}$$

best_split : [feature₁ < 2.5]

Текущий вид дерева:



Ищем разделение для левой вершины:

feature_number : 1, threshold : 1.5, criterion : gini

$N_{root} : 7, N_{left} : 3, N_{right} : 4$

$prob_{root_0} : 0.286, prob_{root_1} : 0.714$

$prob_{left_0} : 0.333, prob_{left_1} : 0.667$

$prob_{right_1} : 0.75, prob_{right_0} : 0.25$

$$Q = 0.408 - \frac{3}{7} \cdot 0.444 - \frac{4}{7} \cdot 0.375 = \mathbf{0.003}$$

feature_number : 2, threshold : 1.5, criterion : gini

$N_{root} : 7, N_{left} : 1, N_{right} : 6$

$prob_{root_0} : 0.286, prob_{root_1} : 0.714$

$prob_{left_1} : 1.0, prob_{left_0} : 0.0$

$prob_right_0 : 0.333, prob_right_1 : 0.667$

$$Q = 0.408 - \frac{1}{7} \cdot 0.0 - \frac{6}{7} \cdot 0.444 = \mathbf{0.027}$$

feature_number : 2, threshold : 2.5, criterion : gini

$N_root : 7, N_left : 2, N_right : 5$

$prob_root_0 : 0.286, prob_root_1 : 0.714$

$prob_left_0 : 0.5, prob_left_1 : 0.5$

$prob_right_1 : 0.8, prob_right_0 : 0.2$

$$Q = 0.408 - \frac{2}{7} \cdot 0.5 - \frac{5}{7} \cdot 0.32 = \mathbf{0.037}$$

feature_number : 2, threshold : 3.5, criterion : gini

$N_root : 7, N_left : 3, N_right : 4$

$prob_root_0 : 0.286, prob_root_1 : 0.714$

$prob_left_0 : 0.333, prob_left_1 : 0.667$

$prob_right_1 : 0.75, prob_right_0 : 0.25$

$$Q = 0.408 - \frac{3}{7} \cdot 0.444 - \frac{4}{7} \cdot 0.375 = \mathbf{0.003}$$

feature_number : 2, threshold : 4.5, criterion : gini

$N_root : 7, N_left : 5, N_right : 2$

$prob_root_0 : 0.286, prob_root_1 : 0.714$


$prob_left_0 : 0.2, prob_left_1 : 0.8$

$prob_right_1 : 0.5, prob_right_0 : 0.5$

$$Q = 0.408 - \frac{5}{7} \cdot 0.32 - \frac{2}{7} \cdot 0.5 = \mathbf{0.037}$$

best_split : [feature₂ < 2.5]

Текущий вид дерева:



Ищем разделение для правой вершины:

feature_number : 1, threshold : 3.5, criterion : gini

$N_{root} : 3, N_{left} : 2, N_{right} : 1$

$prob_{root_0} : 0.667, prob_{root_1} : 0.333$

$prob_{left_0} : 1.0, prob_{left_1} : 0.0$

$prob_{right_1} : 1.0, prob_{right_0} : 0.0$

$$Q = 0.444 - \frac{2}{3} \cdot 0.0 - \frac{1}{3} \cdot 0.0 = \mathbf{0.444}$$

feature_number : 2, threshold : 3.0, criterion : gini

$N_{root} : 3, N_{left} : 2, N_{right} : 1$

$prob_{root_0} : 0.667, prob_{root_1} : 0.333$


$prob_{left_0} : 0.5, prob_{left_1} : 0.5$

$prob_{right_0} : 1.0, prob_{right_1} : 0.0$

$$Q = 0.444 - \frac{2}{3} \cdot 0.5 - \frac{1}{3} \cdot 0.0 = \mathbf{0.111}$$


best_split : [feature₁ < 3.5]

Текущий вид дерева:



И так далее, пока не выполнится критерий останова ...

Финальное дерево будет иметь вид:



Задача 3

$$a(x_i) \sim p(x_i)$$

val	1	2	...	K
P(val)	$p_{m,1}$	$p_{m,2}$	...	$p_{m,K}$

$$err = \frac{1}{|R_m|} \sum_{i:(x_i, y_i) \in R_m} [y_i \neq a(x_i)]$$

$$\mathbb{E}(err) = \frac{1}{|R_m|} \sum_{i:(x_i, y_i) \in R_m} \mathbb{E}([y_i \neq a(x_i)]) = \frac{1}{|R_m|} \sum_{i:(x_i, y_i) \in R_m} \mathbb{P}(y_i \neq a(x_i)) =$$

$$\frac{1}{|R_m|} \sum_{i:(x_i, y_i) \in R_m} \sum_{k=1}^K \mathbb{P}(y_i = k, a(x_i) \neq k) = \frac{1}{|R_m|} \sum_{i:(x_i, y_i) \in R_m} \sum_{k=1}^K [y_i = k] \cdot$$

$$\mathbb{P}(a(x_i) \neq k) = \sum_{k=1}^K \underbrace{\mathbb{P}(a(x_i) \neq k)}_{1-p_{mk}} \cdot \underbrace{\frac{1}{|R_m|} \sum_{i:(x_i, y_i) \in R_m} [y_i = k]}_{p_{mk}} = \boxed{\sum_{k=1}^K p_{mk} \cdot (1 - p_{mk})}$$

Задача 4

$$H(R) = - \sum p_k \cdot \log p_k \Rightarrow \max_{p_k}$$

$$\sum_{k=1}^K p_k = 1$$

$$L = - \sum_{k=1}^K p_k \cdot \log p_k + \lambda \cdot \left(\sum_{k=1}^K p_k - 1 \right) \Rightarrow \max_{p_k}$$

$$L'_{p_k} = -\log p_k - \frac{p_k}{p_k} + \lambda = 0$$

$$\log p_k = \lambda - 1 \Rightarrow \text{все значения равны} \Rightarrow p_1 = \dots = p_K = \frac{1}{K}$$

Задача 5

1. Может ли индекс Джинни расти при разбиении листа на два? А энтропия?

Джини может расти. Например, всего имеется 4 объекта: 3 (х) и 1 (о).

Сначала $G = \frac{1}{4} \cdot \frac{3}{4} + \frac{3}{4} \cdot \frac{1}{4} = \frac{3}{8}$. Разбиваем на два листа (в одном оказывается два (х), в другом 1 (х) и 1 (о), для которого $G = \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2}$.

Энтропия в данном примере также будет расти.

2. Привести пример данных, для которых индекс Джинни равен 0, 0.5, 0.999

$G = 0$: все объекты принадлежат только одному классу (о).

$G = 0.5$: половина объектов одного класса (х), половина другого – (о)

$G = 0.999$: мы знаем, что максимум Джини для двух классов равен $1/2$. Что если мы рассмотрим большее количество классов и посчитаем Джини для них? Для простоты рассмотрим равенство классов и используем следующий код:

```
1 f = lambda n: np.sum([p * (1 - p) for p in [1/n for i in range(n)]])
2 [round(f(k), 3) for k in range(2, 753, 75)]
```

Получаем такой массив:

[0.5, 0.987, 0.993, 0.996, 0.997, 0.997, 0.998, 0.998, 0.998, 0.999, 0.999]


Видим, что как минимум с округлением точно найдётся такой пример. На самом деле, найдётся и такое количество классов, которое в точности даёт правильный ответ без всяких округлений, для этого можно рассмотреть формулу в общем виде в случае равенства классов:

$$\sum_{k=1}^K p_k \cdot (1 - p_k) = \sum_{k=1}^K \frac{1}{K} \cdot \left(1 - \frac{1}{K}\right) = K \cdot \frac{1}{K} \cdot \left(1 - \frac{1}{K}\right) = \frac{K-1}{K}$$

Подходящее число подберите сами)

3. Рассматривается задача бинарной классификации. Привести пример набора данных, такого что ни одно из стартовых разбиений не снижает индекса Джинни, однако двух разбиений достаточно, чтобы безошибочно классифицировать выборку.

Ответ: в качестве примера подойдёт XOR проблема:



Есть 4 объекта: 2 одного класса и 2 другого. Они расположены так, что при первом разбиении в обеих группах всегда оказываются по одному объекту каждого класса. Джинни как до, так и после равен $\frac{1}{2}$. Нужно ещё одно разбиение для безошибочной классификации.

Задача 6

Сначала, давайте определим, куда попадает каждое наблюдение (напоминание, если условие выполнено, то идём влево, если нет – вправо):

y_i	x_i	W
0	1	W_{RR}
1	4	W_L
1	2	W_{RR}
0	3	W_{RL}
1	3	W_{RL}
0	1	W_{RR}

Далее, выписываем функцию правдоподобия:

$$L = (1 - w_{RR}) \cdot w_L \cdot w_{RR} \cdot (1 - w_{RL}) \cdot w_{RL} \cdot (1 - w_{RR}) \rightarrow \max_{w_L, w_{RL}, w_{RR}}$$

Прологарифмируем:

$$\ln L = \ln(1 - w_{RR}) + \ln w_L + \ln w_{RR} + \ln(1 - w_{RL}) + \ln w_{RL} + \ln(1 - w_{RR})$$

Возьмём производные по каждому из аргументов:

$$\begin{aligned} \frac{\partial \ln L}{\partial w_L} &= \frac{1}{w_L} = 0 \iff w_L = 1 \text{ (as } w_L \rightarrow \max \text{ from } L) \\ \frac{\partial \ln L}{\partial w_{RL}} &= \frac{1}{1 - w_{RL}} \cdot (-1) + \frac{1}{w_{RL}} = 0 \iff w_{RL} = \frac{1}{2} \\ \frac{\partial \ln L}{\partial w_{RR}} &= \frac{1}{1 - w_{RR}} \cdot (-1) + \frac{1}{w_{RR}} + \frac{1}{1 - w_{RR}} \cdot (-1) = 0 \iff w_{RR} = \frac{1}{3} \end{aligned}$$

Задача 7

$$a_1(x) = \sum_{i=1}^3 w_i \cdot [b_i(x) = 1] = w_1 \cdot [b_1(x) = 1] + w_2 \cdot [b_2(x) = 1] + w_3 \cdot [b_3(x) = 1]$$

Будем считать, что классы сбалансированы: $P(C = 0) = P(C = 1) = 0.5$. Веса в первом пункте такие, что ответ композиции будет определяться всегда двумя алгоритмами, которые выберут один и тот же класс.

$$\begin{aligned} P(a_1 \text{ mistakes}) &= P(a_1 = 1, C = 0) + P(a_1 = 0, C = 1) = \\ &= P(b_i = b_j = 1, C = 0) + P(b_1 = b_2 = b_3 = 1, C = 0) + \\ &+ P(b_i = b_j = 0, C = 1) + P(b_1 = b_2 = b_3 = 0, C = 1) = \\ &= P(b_i = b_j = 1|C = 0) \cdot P(C = 0) + P(b_1 = b_2 = b_3 = 1|C = 0) \cdot P(C = 0) + \\ &+ P(b_i = b_j = 0|C = 1) \cdot P(C = 1) + P(b_1 = b_2 = b_3 = 0|C = 1) \cdot P(C = 1) = \\ &= \frac{1}{2} \cdot (3 \cdot p^2 \cdot (1 - p) + p^3 + 3 \cdot p^2 \cdot (1 - p) + p^3) = \\ &= \frac{1}{2} \cdot (2 \cdot p^3 + 6 \cdot (p^2 - p^3)) = 3 \cdot p^2 - 2 \cdot p^3 \end{aligned}$$

Веса во втором пункте такие, что определяющим всегда является второй алгоритм.

$$\begin{aligned} P(a_1 \text{ mistakes}) &= P(b_2 = 1, C = 0) + P(b_2 = 0, C = 1) = P(b_2 = 1|C = 0) \cdot \\ &\cdot P(C = 0) + P(b_2 = 0|C = 1) \cdot P(C = 1) = \frac{1}{2} \cdot (p + p) = p \end{aligned}$$

Сравним вероятности ошибок:

$$p \vee 3 \cdot p^2 - 2 \cdot p^3$$

$$p + 2 \cdot p^2 - 3 \cdot p^3 \vee 0$$

$$1 + 2 \cdot p - 3 \cdot p^2 \vee 0$$

Посчитаем дискриминант функции от p :


$$D = 1 + 9 = 10; \quad p_1 = \frac{-1+\sqrt{10}}{-3} < 0; \quad p_2 = \frac{-1-\sqrt{10}}{-3} = \frac{1+\sqrt{10}}{3} = 1.39$$

Функция вогнутая (ветви вниз), пересечения с осью $y = 0$ вне отрезка $[0, 1]$, следовательно функция больше нуля на области определения $p \in [0, 1]$. Итог, вторая композиция всегда имеет более высокий уровень ошибок.

Задача 8

XOR Truth Table

Feature 1	Feature 2	Result
0	0	0
0	1	1
1	0	1
1	1	0



Считаем критерии расщепления, нормируя на глубину дерева (думаем, что первым выбирается более важный признак, однако в этой задаче выбор, какой признак первый, не имеет значения, критерии одинаковы):

$$Q_1 = \frac{4}{4} \cdot (0.5 - \frac{2}{4} \cdot 0.5 - \frac{2}{4} \cdot 0.5) = 0$$

$$Q_{2_right} = \frac{2}{4} \cdot (0.5 - \frac{1}{2} \cdot 0 - \frac{1}{2} \cdot 0) = \frac{1}{4}$$

$$Q_{2_left} = \frac{2}{4} \cdot (0.5 - \frac{1}{2} \cdot 0 - \frac{1}{2} \cdot 0) = \frac{1}{4}$$

Считаем важность признаков:

$$FI_1 = 0; \quad FI_2 = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

Задача 9

Нам надо разбить множество на два непересекающихся подмножества, это будет эквивалентно числу возможных разбиений на группы по количеству 1 и $q-1$, 2 и $q-2$, ..., $q-1$ и 1. Однако в данном случае мы также учитываем различие множеств Q_1 и Q_2 , что в нашем случае делать не надо. Итого, нам надо посчитать, сколькими способами мы можем выбрать 1 объект, 2, ..., $q-1$ в подмножество Q_1 (остальные автоматом в Q_2), просуммировать и поделить на два. Таким образом:

$$\frac{1}{2} (C_q^1 + C_q^2 + \dots + C_q^{q-1}) = \frac{\sum_{k=0}^q C_q^k - C_q^0 - C_q^q}{2} = \frac{2^q - 2}{2} = 2^{q-1} - 1$$

Задача 10

(Условие)

Пусть есть K классов. Пусть в листе за обучение накопилось n объектов: $(n_1, n_2, \dots, n_K)$, где n_j — число объектов j -ого класса, $\sum_{j=1}^K n_j = n$, $p_j = \frac{n_j}{n}$.

Если отвечать случайно с соответствующим распределением классов, то вероятность ошибиться:

$$\mathbb{P}_1(\text{ошибки}) = \sum_{j=1}^K \mathbb{P}(\text{ошибки} | \text{класс объекта} = j) \cdot \mathbb{P}(\text{класс объекта} = j) = \sum_{j=1}^n (1 - p_j) \cdot \mathbb{P}(\text{класс объекта} = j)$$

Во втором случае вероятность ошибки будет:

$$\mathbb{P}_2(\text{ошибки}) = \sum_{j=1}^n (1 - p_*) \cdot \mathbb{P}(\text{класс объекта} = j)$$

Где p_* — самый популярный класс в листе при обучении (то есть $p_* \geq p_j, \forall j \in \{1, 2, \dots, K\}$). Так как $p_* \geq p_j, \forall j$, получаем:

$$\mathbb{P}_2(\text{ошибки}) = \sum_{j=1}^n (1 - p_*) \cdot \mathbb{P}(\text{класс объекта} = j) \leq \sum_{j=1}^n (1 - p_j) \cdot \mathbb{P}(\text{класс объекта} = j) = \mathbb{P}_1(\text{ошибки}).$$

Ответ:

С точки зрения вероятности ошибки выгоднее давать прогноз - самый частотный класс в листе.

Задача 11

(Условие)

ноутбук в колабе

Задача 12

(Условие)

```
1 import numpy as np
2
3 def compute_impurity(target_vector: np.ndarray, criterion: str='gini') ->
  float:
4
5     """
6     Computes impurity of particular leaf
7     Args:
8         target_vector: target vector for objects in this leaf
9         criterion:
10             entropy: sum(-p*log2p)
11             gini: sum(p*(1-p))
12     Returns:
13         impurity (gini or entropy)
14     """
15
16     assert criterion in ['gini', 'entropy'], 'critetion could be "gini" or "
  entropy" as for now!'
17
18     uniq_classes, counts = np.unique(target_vector, return_counts=True)
19     probas_vector = counts / counts.sum()
20
21     if criterion == 'gini':
22         return probas_vector @ (1 - probas_vector)
23     elif criterion == 'entropy':
24         return - probas_vector[probas_vector > 0] @ np.log2(probas_vector[
  probas_vector > 0])
25     else:
26         raise ValueError('critetion could be "gini" or "entropy" as for now!')
27
28
29 def compute_gain(target_vector: np.ndarray, feature_vector: np.ndarray,
  threshold: float, criterion: str='gini') -> float:
30
31     """
32     Computes gain of particular leaf split (H_R - |Rl|/|R| * H_Rl - |Rr|/|R| *
```

```


33     H_Rr)
34     """
35     assert criterion in ['gini', 'entropy'], 'critetion could be "gini" or "
36         entropy" as for now!'
37
38     n = len(target_vector)
39     n_left = sum(feature_vector < threshold)
40     n_right = sum(feature_vector >= threshold)
41     H_R = compute_impurity(target_vector=target_vector, criterion=criterion)
42     H_Rl = compute_impurity(target_vector=target_vector[feature_vector <
43         threshold], criterion=criterion)
44     H_Rr = compute_impurity(target_vector=target_vector[feature_vector >=
45         threshold], criterion=criterion)
46
47     Q = H_R - (n_left/n)*H_Rl - (n_right/n)*H_Rr
48     return Q

```

Задача 13

4ый слайд

AUC ROC: Полностью бинарный случай $a \in \{0,1\}^m$, $y \in \{0,1\}^m$



$$S = \frac{xy}{2} + \frac{(1-x)(1-y)}{2} + (1-x)y$$

$$S = \frac{1-x+y}{2}$$

$$\begin{aligned} \text{AUC} &= \frac{1 - \text{FPR} + \text{TPR}}{2} = \frac{1}{2} \left(1 - \frac{\text{FP}}{\text{FP} + \text{TN}} + \text{TPR} \right) = \\ &= \frac{1}{2} \left(1 - \frac{\text{FP}}{\text{FP} + \text{TN}} + \frac{\text{TP}}{\text{TP} + \text{FN}} \right) = \frac{1}{2} \left(\frac{\text{TN}}{\text{FP} + \text{TN}} + \frac{\text{TP}}{\text{TP} + \text{FN}} \right) \end{aligned}$$

Рис. 5:

Хотим выбрать порог (например, чёрный или зелёный на рис. 5), который приводит к максимизации AUC-ROC. На Рис. 5 выведена формула AUC-ROC в случае, когда алгоритм возвращает не вероятность принадлежности к первому классу, а один из классов ($a(x) \in \{0,1\}$).

Получаем, что $\text{AUC-ROC} = \frac{\text{Recall}_0 + \text{Recall}_1}{2}$

Введём обозначения:




Рис. 6:

n - общее число объектов в листе, n_1 - число объектов в правом подлисте, n_0 - число объектов в левом подлисте ($n = n_0 + n_1$), m - общее число объектов первого класса в листе, m_1 - число объектов первого класса в правом подлисте, m_0 - число объектов первого класса в левом подлисте ($m = m_0 + m_1$).

Тогда формула AUC-ROC при расщеплении листа по некоторому порогу выглядит так:

$$\frac{1}{2} \left(\underbrace{\frac{m_1}{m}}_{\text{Recall}_1} + \underbrace{\frac{n_0 - m_0}{n - m}}_{\text{Recall}_0} \right) = \frac{1}{2} \left(\frac{m_1}{m} + \frac{(n - n_1) - (m - m_1)}{n - m} \right) = \frac{1}{2} \left(\frac{m_1}{m} + 1 - \frac{n_1 - m_1}{n - m} \right) = \frac{1}{2} + \frac{1}{2} \left(\frac{m_1}{m} - \frac{n_1 - m_1}{n - m} \right) \rightarrow \max_{\text{threshold}}$$

Либо, если мы хотим максимизировать такую величину $|\text{AUC-ROC} - \frac{1}{2}|$ (что тоже логично), то получаем:

$$\frac{1}{2} \left(\frac{m_1}{m} - \frac{n_1 - m_1}{n - m} \right) \rightarrow \max_{\text{threshold}}$$

Отсюда имеем:

$$\frac{1}{2} \left(\underbrace{\frac{m_1 \cdot n - m_1 \cdot m - m \cdot n_1 + m \cdot m_1}{m \cdot (n - m)}}_{\text{не зависит от порога}} \right) \rightarrow \max_{\text{threshold}} \sim |m_1 \cdot n - m \cdot n_1| \rightarrow \max_{\text{threshold}}$$

Задача 14

(Условие)

```

1 from numpy.typing import NDArray
2 from math import inf
3
4 def mse(y_pred: NDArray[float], y_true: NDArray[float]) -> float:
5     return 0.5*np.sum((y_pred - y_true)**2)
6
7 class DecisionStump:
8     def __init__(self):
9         """
10         f(x) = a*[x <= c] + b*[x > c]
11         """
12         self.a, self.b, self.c = None, None, None
13
14     def fit(self, x: NDArray[float], y: NDArray[float]):
15         uniq_vals = np.unique(np.sort(x))
16         thresholds = (uniq_vals[:-1] + uniq_vals[1:]) / 2
17         best_mse = inf
18         for t in thresholds:
19             left_mean = np.mean(y[x <= t])
20             right_mean = np.mean(y[x > t])
21             if self.a is None:
22                 self.a = left_mean
23                 self.b = right_mean
24                 self.c = t
25             y_pred = left_mean*(x <= t) + right_mean*(x > t)
26             current_mse = mse(y_true=y, y_pred=y_pred)
27             if current_mse < best_mse:
28                 self.a = left_mean
29                 self.b = right_mean
30                 self.c = t
31                 best_mse = current_mse
32         return self
33
34     def predict(self, x: NDArray[float]) -> NDArray[float]:
35         assert self.a is not None, 'train DecisionStump first!'
36         return self.a*(x <= self.c) + self.b*(x > self.c)

```