

A decorative graphic in the top-left corner of the slide, consisting of a 4x4 grid of squares. The squares are colored in a pattern: the top row has a teal square in the first column; the second row has orange and brown squares in the first two columns; the third row has orange, teal, and light brown squares in the first three columns; and the bottom row has light brown, orange, red-orange, and brown squares in the first four columns.

Обучение без учителя. Кластеризация

Кластеризация

Обучение с учителем (supervised learning)

- Для каждого объекта известен ответ (класс или число)
- Даны примеры объектов с ответами
- Нужно построить модель, которая будет предсказывать ответы для новых объектов

Обучение без учителя (unsupervised learning)

- Даны объекты
- Нужно найти в них внутреннюю структуру
- Примеры:
 - Кластеризация
 - Обнаружение аномалий
 - Тематическое моделирование
 - Визуализация
 - ...
- Ближе к обучению в реальной жизни

Тематическое моделирование — это метод анализа текстовых данных, который используется для выявления скрытых тем в большом объеме текстовой информации.

Обучение с учителем и без учителя





How Much Information Does the Machine Need to Predict?

Y LeCun

■ "Pure" Reinforcement Learning (cherry)

- ▶ The machine predicts a scalar reward given once in a while.
- ▶ **A few bits for some samples**

■ Supervised Learning (icing)

- ▶ The machine predicts a category or a few numbers for each input
- ▶ Predicting human-supplied data
- ▶ **10→10,000 bits per sample**

■ Unsupervised/Predictive Learning (cake)

- ▶ The machine predicts any part of its input for any observed part.
- ▶ Predicts future frames in videos
- ▶ **Millions of bits per sample**



■ (Yes, I know, this picture is slightly offensive to RL folks. But I'll make it up)

Обучение без учителя: кластеризация

Case 2. Оптимизация воронки продаж



ШАГ I

Анализ данных,
в т.ч. транзакционных
Way4, ЦОД, кред. фабрика

ШАГ II

Выявление паттернов и
сегментация клиентов
по характеристикам

ШАГ III

Формирование
продуктовых
предложений на базе
характеристик клиента




ЭКОНОМИЧЕСКИЙ ЭФФЕКТ

- ✓ Рост эффективности воронки продаж
- ✓ Рост лояльности клиентов

МЕТОДЫ алгоритмы кластеризации, визуализация данных большой размерности с использованием LargeVis

КЛАСТЕРИЗАЦИЯ КЛИЕНТОВ ПО ХАРАКТЕРУ ТРАНЗАКЦИЙ



В ЗАВИСИМОСТИ ОТ КЛАСТЕРА
КЛИЕНТА ПРЕДЛОЖИТЬ
РЕЛЕВАНТНЫЙ ПРОДУКТ



Паттерн	Продукт
1. Частая конвертация валют	Мультивалютный счет
2. Частые перелеты Аэрофлотом	Карта «Аэрофлот Бонус»
3. Частые поездки за границу	Страховка для выезжающих за рубеж
4. Переводы в благотворительные фонды	Карта «Подари жизнь»

Кластеризация

- Дано: матрица «объекты-признаки» X
- Найти:
 1. Множество кластеров Y
 2. Алгоритм кластеризации $a(x)$, который приписывает каждый объект к одному из кластеров
- Каждый кластер состоит из похожих объектов
- Объекты из разных кластеров существенно отличаются

Отличия

Обучение с учителем

- Цель: минимизация функционала ошибки
- Множество ответов известно заранее
- Конкретные способы измерения качества

Кластеризация

- Нет строгой постановки
- Множество кластеров неизвестно
- Правильные ответы отсутствуют— сложно измерить качество

Зачем кластеризовать?

- Маркетинг: выявление типичных групп покупателей
- Модерация: проверка только одного сообщения из кластера
- UI/UX: каталогизация фотографий (по людям, по местам, ...)

Виды кластеризации


Форма кластеров




Форма кластеров




Различия в результатах работы



Исходная выборка
("Mouse" dataset)



Метод 1





Метод 2

Text
Text
Text

«Жесткая» и «мягкая» кластеризации

Кластеризация для выделения «тем»



В жесткой кластеризации каждый объект принадлежит только одному кластеру. Это означает, что объекты четко разделены на группы, и нет перекрытия между кластерами. Примеры методов жесткой кластеризации включают:

К-средних (K-means): алгоритм, который делит данные на K кластеров, минимизируя внутрикластерные расстояния.


Иерархическая кластеризация: создает дерево кластеров, где на каждом уровне можно видеть, как объекты группируются.

В мягкой кластеризации объекты могут принадлежать нескольким кластерам с определенной вероятностью или степенью принадлежности. Это позволяет более гибко учитывать неопределенности и перекрытия между кластерами. Примеры методов мягкой кластеризации включают:

Fuzzy C-means: аналог К-средних, но каждый объект имеет степень принадлежности к каждому кластеру.


Gaussian Mixture Models (GMM): предполагает, что данные распределены по нескольким гауссовым распределениям, и каждый объект имеет вероятность принадлежности к каждому из них.

Иерархическая кластеризация



Пример:

Кластеризация статей на Хабре



K-Means


K Means




Как работает K Means



Как работает K Means



Как работает K Means



Как работает K Means



Как работает K Means



K-Means

- Дано: выборка $x_1, \dots, x_\ell$
- Параметр: число кластеров K
- Начало: случайно выбрать K центров кластеров $c_1, \dots, c_K$
- Повторять по очереди до сходимости:
 - Шаг А: отнести каждый объект к ближайшему центру
$$y_i = \arg \min_{j=1, \dots, K} \rho(x_i, c_j)$$
 - Шаг Б: переместить центр каждого кластера в центр тяжести

$$c_j = \frac{\sum_{i=1}^{\ell} x_i [y_i = j]}{\sum_{i=1}^{\ell} [y_i = j]}$$



Выбор числа кластеров

- Качество кластеризации: внутрикластерное расстояние

$$J(C) = \sum_{i=1}^{\ell} \rho(x_i, c_{y_i})$$

- Зависит от K
- Нужно подобрать такое K , после которого качество меняется не слишком сильно

Выбор числа кластеров



Особенности K-Means

- Может работать с большими объёмами данных
- Подходит для кластеров с простой геометрией
- Требуется выбора числа кластеров

Силуэт как метрика качества

Для каждого объекта i рассчитываются два значения:

$a(i)$: Среднее расстояние от объекта i до всех других объектов в том же кластере. Это значение показывает, насколько близки объекты внутри одного кластера.

$b(i)$: Среднее расстояние от объекта i до всех объектов в ближайшем кластере (кластере, отличном от того, к которому принадлежит объект i). Это значение показывает, насколько близки объекты к другим кластерам.


Силуэт для объекта i рассчитывается по формуле:

$$(b - a) / \max(a, b)$$

Density-based clustering

Density-based clustering (кластеризация на основе плотности) — это метод кластеризации, который группирует данные на основе плотности распределения точек в пространстве.

Основные, граничные и шумовые точки



Основные (ядровые) точки: Это точки, которые имеют не менее заданного числа соседей (MinPts) в пределах радиуса ϵ (epsilon). Основные точки служат центрами кластеров. Они могут инициировать формирование кластера, так как вокруг них достаточно плотности точек.

Граничные точки: Это точки, которые находятся в пределах радиуса ϵ от основной точки, но не имеют достаточного количества соседей, чтобы быть основной точкой (т.е. у них меньше MinPts соседей).


Шумовые точки: Это точки, которые не являются ни основными, ни граничными. Они не имеют достаточной плотности соседей, чтобы быть частью кластера.

Параметры DBSCAN


DBSCAN (Density-Based Spatial Clustering of Applications with Noise) — это алгоритм кластеризации, основанный на плотности, который используется для выявления кластеров в данных с произвольной формой и для обработки выбросов.

- Размер окрестности (eps)
- Минимальное число объектов в окрестности — для определения основных точек


DBSCAN: результаты работы



Определение числа кластеров в DBSCAN



Определение числа кластеров в DBSCAN



Особенности DBSCAN


- Находит кластеры произвольной формы
- Может работать с большими объёмами данных
- Нужно подбирать размер окрестности (eps) и минимальное число объектов в окрестности

Иерархическая кластеризация


Виды иерархической кластеризации

- Агломеративная – на каждой итерации объединяем два меньших кластера в один побольше
- Дивизивная – на каждой итерации делим один большой кластер на два поменьше


Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Расстояния между кластерами




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация




Агломеративная кластеризация



Агломеративная кластеризация






Дендрограмма






Дендрограмма — это графическое представление иерархической кластеризации, которое показывает, как объекты группируются в кластеры на разных уровнях. Она используется для визуализации результатов кластеризации и помогает понять структуру данных.

Дендрограмма




1 3 2 4 9 10 11 12 6 8 7 5

Дендрограмма






1 3 2 4 9 10 11 12 6 8 7 5




Дендрограмма






Дендрограмма







Дендрограмма








Дендрограмма




Дендрограмма




Дендрограмма




Дендрограмма




Дендрограмма




Дендрограмма




Дендрограмма



Дендрограмма



Дендрограмма



Аггломеративная кластеризация


1. Инициализация – каждая точка = кластер
2. Самые близкие (относительно какой-то метрики) кластеры объединяются
3. Повторяем до того момента, когда все точки будут в одном кластере
4. Останавливаемся, когда достигаем фиксированного числа кластеров, либо когда расстояние между кластерами больше заданного порога

Графовые методы


Кластеризация по компонентам связности

- Граф: вершины соответствуют объектам
- Соединяем ребром объекты, расстояние между которыми меньше R
- Выделяем компоненты связности

Выделение связанных компонент




Выделение связных компонент



Кластеризация по компонентам связности

- Быстрая и простая
- Параметр — минимальное расстояние R
- Проблема: непонятно, как выбрать R , если нужно получить K кластеров

Минимальное остовное дерево



Минимальное остовное дерево

- Строим взвешенный граф, где веса ребер – расстояния между объектами
- Строим минимальное остовное дерево для этого графа
- Дерево имеет $\ell - 1$ ребро
- Удаляем $K - 1$ ребро с максимальным весом
- Получаем K компонент связности, которые интерпретируем как кластеры

Обучение без учителя и
текстовые данные

Похожие слова

- «Идти» и «шагать» — синонимы
- Для компьютера это разные строки
- Как понять, что они похожи?

Похожие слова

- «Идти» и «шагать» — синонимы
- Для компьютера это разные строки
- Как понять, что они похожи?
- На основе данных!
- Слова со схожим смыслом часто идут в паре с одними и теми же словами
- У них похожие контексты

Дистрибутивная семантика

- У похожих по смыслу слов похожие *контексты*
- Контекст — окрестность слова

...an efficient method for learning high quality distributed vector ...

The diagram shows the sentence "...an efficient method for learning high quality distributed vector ...". The words "an efficient method for" are grouped by a green bracket underneath and labeled "context". The word "learning" is highlighted in yellow and has a blue arrow pointing up to it from the label "focus word". The words "high quality distributed vector" are grouped by a green bracket underneath and labeled "context".

Векторные представления слов

Хотим представить каждое слово в виде вещественного вектора:

$$w \rightarrow \vec{w} \in \mathbb{R}^d$$

Требования к представлениям (embeddings):

- Размерность d должна быть не очень большой
- Похожие слова должны иметь близкие векторы
- Арифметические операции над векторами должны иметь смысл

Представления текста

Хотим: перевести слова в числовой вид

One-hot encoding

Создаем словарь всех слов (размера V) и нумеруем их

Rome = $[1, 0, 0, 0, 0, 0, \dots, 0]$

Paris = $[0, 1, 0, 0, 0, 0, \dots, 0]$

Italy = $[0, 0, 1, 0, 0, 0, \dots, 0]$

France = $[0, 0, 0, 1, 0, 0, \dots, 0]$

Представления текста

Хотим: перевести слова в числовой вид

One-hot encoding

Создаем словарь всех слов (размера V) и нумеруем их

Rome = $[1, 0, 0, 0, 0, 0, \dots, 0]$

Paris = $[0, 1, 0, 0, 0, 0, \dots, 0]$

Italy = $[0, 0, 1, 0, 0, 0, \dots, 0]$

France = $[0, 0, 0, 1, 0, 0, \dots, 0]$

Все вектора ортогональны друг другу $\cos_sim(w_1, w_2) = \frac{w_1^T w_2}{\|w_1\|^2 \|w_2\|^2} = 0$

Представления текста

Хотим: перевести слова в числовой вид

One-hot encoding

Создаем словарь всех слов (размера V) и нумеруем их

Rome = $[1, 0, 0, 0, 0, 0, \dots, 0]$

Paris = $[0, 1, 0, 0, 0, 0, \dots, 0]$

Italy = $[0, 0, 1, 0, 0, 0, \dots, 0]$

France = $[0, 0, 0, 1, 0, 0, \dots, 0]$

Все вектора ортогональны друг другу $\cos_sim(w_1, w_2) = \frac{w_1^T w_2}{\|w_1\|^2 \|w_2\|^2} = 0$

Представления текста

Хотим: перевести слова в числовой вид

Идея: вектора слов, которые встречаются в одном контексте, должны быть близки $\cos_sim(w_1, w_2) \approx w_1^T w_2$

_____ is the most beautiful capital city in Europe

Rome? Paris?


Представления текста

Хотим: перевести слова в числовой вид

Идея: вектора слов, которые встречаются в одном контексте, должны быть близки $\cos_sim(w_1, w_2) \approx w_1^T w_2$

expect =


$\begin{pmatrix} 0.286 \\ 0.792 \\ -0.177 \\ -0.107 \\ 0.109 \\ -0.542 \\ 0.349 \\ 0.271 \\ 0.487 \end{pmatrix}$



word2vec

Задача:

- Для каждого слова w построить вектор $\vec{w}$
- Если два слова w_1 и w_2 идут рядом, то скалярное произведение $\langle \vec{w}_1, \vec{w}_2 \rangle$ должно быть большим



word2vec

Если два слова w_1 и w_2 идут рядом, то скалярное произведение $\langle \vec{w}_1, \vec{w}_2 \rangle$ должно быть большим:

$$p(w_i | w_j) = \frac{\exp(\langle \vec{w}_i, \vec{w}_j \rangle)}{\sum_{w \in W} \exp(\langle \vec{w}, \vec{w}_j \rangle)}$$

$$\sum_{i=1}^{\ell} \sum_{j=1}^{n_i} \sum_{\substack{k=-K \\ k \neq 0}}^K \log p(\vec{w}_{j+k} | \vec{w}_j) \rightarrow \max_{\{\vec{w}\}_{w \in W}}$$



word2vec

Векторы можно прибавлять и вычитать:

- $\overrightarrow{\text{король}} - \overrightarrow{\text{мужчина}} + \overrightarrow{\text{женщина}} \approx \overrightarrow{\text{королева}}$
- $\overrightarrow{\text{медведь}} - \overrightarrow{\text{Россия}} + \overrightarrow{\text{Австралия}} \approx \overrightarrow{\text{кенгуру}}$

Можно переводить слова:

- $\overrightarrow{\text{математика}} + (\overrightarrow{\text{word}} - \overrightarrow{\text{слово}}) \approx \overrightarrow{\text{math}}$
- $\overrightarrow{\text{король}} + (\overrightarrow{\text{word}} - \overrightarrow{\text{слово}}) \approx \overrightarrow{\text{king}}$
- $\overrightarrow{\text{корова}} + (\overrightarrow{\text{word}} - \overrightarrow{\text{слово}}) \approx \overrightarrow{\text{cow}}$



Примеры представлений

- food2vec
 - Документ — названия ингредиентов из рецепта
 - Слово — один ингредиент

food2vec

Tools for cooking with machine intelligence

Food similarity tool

Type in an ingredient to see which foods are similar:

Type in a food (e.g. Apple, Peanut, Bread)

Almonds



LOOK UP SIMILAR FOODS!

Whole almonds	0.708
Slivered almonds	0.695
Chopped almonds	0.657
Blanched almonds	0.651
Chocolate	0.616
Prunes	0.602
Raisins	0.597
Toasted almonds	0.589
Dried dates	0.586

<https://altosaar.github.io/food2vec/>

Примеры представлений

- Общее семантическое пространство в Яндексе
 - В векторы переводятся страницы сайтов, изображения, видео, ...

Тематическое моделирование

- Рассматриваем каждый документ как мешок слов
- Всего K тем
- Тема — распределение на словах
- Документ — распределение на темах

Тематическое моделирование

Topics

gene	0.04
dna	0.02
genetic	0.01
...	

life	0.02
evolve	0.01
organism	0.01
...	

brain	0.04
neuron	0.02
nerve	0.01
...	

data	0.02
number	0.02
computer	0.01
...	

Documents

Seeking Life's Bare (Genetic) Necessities

COLD SPRING HARBOR, NEW YORK—How many **genes** does an **organism** need to **survive**? Last week at the genome meeting here,* two genome researchers with radically different approaches presented complementary views of the basic genes needed for **life**. One research team, using **computer** analyses to compare known **genomes**, concluded that today's **organisms** can be sustained with just 250 genes, and that the earliest life forms required a mere 128 **genes**. The other researcher mapped genes in a simple parasite and estimated that for this organism, 800 genes are plenty to do the job—but that anything short of 100 wouldn't be enough.

Although the numbers don't match precisely, those **predictions**

"are not all that far apart," especially in comparison to the 75,000 **genes** in the human genome, notes Siv Andersson at Uppsala University in Sweden, who arrived at the 800 number. But coming up with a consensus answer may be more than just a **genetic** numbers game, particularly as more and more **genomes** are completely mapped and sequenced. "It may be a way of organizing any newly **sequenced genome**," explains Arcady Mushegian, a **computational** molecular biologist at the National Center for Biotechnology Information (NCBI) in Bethesda, Maryland. Comparing an




* Genome Mapping and Sequencing, Cold Spring Harbor, New York, May 8 to 12.

Stripping down. **Computer analysis** yields an estimate of the minimum modern and ancient genomes.

SCIENCE • VOL. 272 • 24 MAY 1996

Topic proportions and assignments



Модель PLSA

- Probabilistic Latent Semantic Analysis

$$p(w|d) = \sum_{t \in T} p(w|t)p(t|d) = \sum_{t \in T} \varphi_{wt} \theta_{td}$$

- T — множество тем
- $p(w|t) = \varphi_{wt}$ — распределение слов в теме t
- $p(t|d) = \theta_{td}$ — распределение тем в документе d

Модель PLSA

- Probabilistic Latent Semantic Analysis


$$\sum_{d \in D} \sum_{w \in W} n_{dw} \log p(w|d) \rightarrow \max_{\varphi_{wt}, \theta_{td}}$$

Ограничения: $\varphi_{wt} \geq 0, \theta_{td} \geq 0, \sum_{w \in W} \varphi_{wt} = 1, \sum_{t \in T} \theta_{td} = 1$

- D — множество документов
- W — множество слов

Примеры

- Данные: сообщения с форума вегетарианцев



11 Nutrition

pre_soak
contain_40_100
carbohydrate_rich
2200_calorie
cronometer
kaiser_permanente_one
9_essential_amino_acid
ripeness
large_health_insurance
amino_acid_profile
powder1/2_tsp
nuts_nut_butter
chronometer
300_g
mineral_deficiency
1400_calorie
1600_calorie
sliced1
myfitnesspal
bmr
tigress
250_g
dry_oregano
120_calorie
200_g
managable
howdy
aid_digestion
high_carb_low_fat
page_7

12 Ingredients

over_jasmine_rice
fennel_seed
bpa
soaking_water
chop_celery
fallout
dragon_fruit
arroz
red_lentil
pourable
bean_pulse
garlic_ginger
roasted_peanut
toast_sesame_oil
23rd
finely_ground
grape_nuts
exporter
pinto
tortilla_wraps
rehydrat
kombu
finely_dice
chapati
chamomile_tea
onions
navy_bean
pyrex
chamomile
fresh_rosemary

26 Supplements

1000_mcg
dill_weed
blanch_almond
dha_epa_supplement
unsweetened_variety
ala
numbness
dha_epa
epa_dha
epa
dr_weil
stir_fried_veggie
free_sample_toy
enfamil_family_beginnings
algae_dha
conflicting_information
deva
panko
methyl
atmospheric
purchasing_decision
dha
fresher
mouse_trap
soy_milk_maker
dha_supplement
msm
£_15
chilli_sauce
wrath

34 Electronics

inny
s620
tmj
m500
mobile_sidekick_3
p3600
innie
510
e90_s
iphone_8_gb_s
mpx_300
station_2
e70
140nokia
n75
ipod_nano_4_gb
iphone_8gb
sidekick_3
xbox_360
motorola
t_mobile
razr
ericsson_w900i
itouch
us\$
v3x
=_=_=
d500
16gb
belly_button

22 Shoes

meo
conch
sizing
snowshoe
abalone
cowboy_boot
mandolin
old_bay
hike_boot
gladiator
empty_shell
reform_movement
sand_dollar
steel_toe
candle_holder
insole
versary
zappos.com
irc
snow_boot
jojoba
yesss
canvas_shoe
hiking_boot
skating
southern_accent
moo_shoes
sautéed_mushroom
rei
herb_garden

21 Dieticians

an_expert_button_locate
dietitians_new_zealand_website
freelance_dietitians_website
hand_portion
local_registered_dietitian
upper_right
local_register_dietitian_through
branding
marvel
dr_neal_barnard
by_dr_neal
nepal
personalized
nascar
oxalic_acid
disputable
vegecat
faux_fur
consignment_shop
tabling
\$_24
registered_dietitian
downloadable
chrome
tv_series
reverse_diabete
faux_fur_trim
herbivore_magazine
standardize
cress

19 Eggs

dr_greger
shill
incubate
thunder_chicken
global_population
pet_ownership
menstrual_fluid
terri
eyeliner
futon
harm_reduction
envoyé_de_mon_iphone
backyard_chicken
societal_pressure
rescue_hen
opaque
emission
t_colin_campbell
dark_spot
boy_chick
vegan?do
dha_epa
pringles
an_unfertilized_egg
local_coffee_shop
en_utilisant_tapataalk
menstruation
unfertiliz_egg
juice_feast
flashlight

Примеры

- Данные: новостные заголовки

Резюме

- Кластеризация — задача без строгой постановки и без строгих критериев качества
- Много разновидностей в подходах
- Методы: K-Means, DBSCAN, иерархическая кластеризация и т.д.