Метрики качества , BVD , отбор признаков

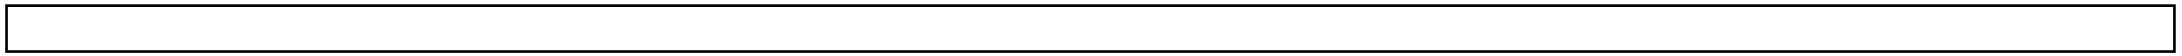

Метрики качества

- Не все алгоритмы подходят для решения задачи
- Как выбрать лучший?
- Если много способов определить, что такое «лучший»
- Метрики качества
  - Насколько алгоритм подходит для решения задачи?
  - Какой из двух алгоритмов лучше подходит?

Метрики качества регрессии

Среднеквадратичная ошибка

$$\mathrm{MSE}(a, X) = \frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2$$

- Легко минимизировать
- Сильно штрафует за большие ошибки

Средняя абсолютная ошибка

$$\mathrm{MAE}(a, X) = \frac{1}{\ell}\sum_{i=1}^{\ell}|a(x_i) - y_i|$$

- Сложнее минимизировать
- Выше устойчивость к выбросам

Средняя абсолютная ошибка

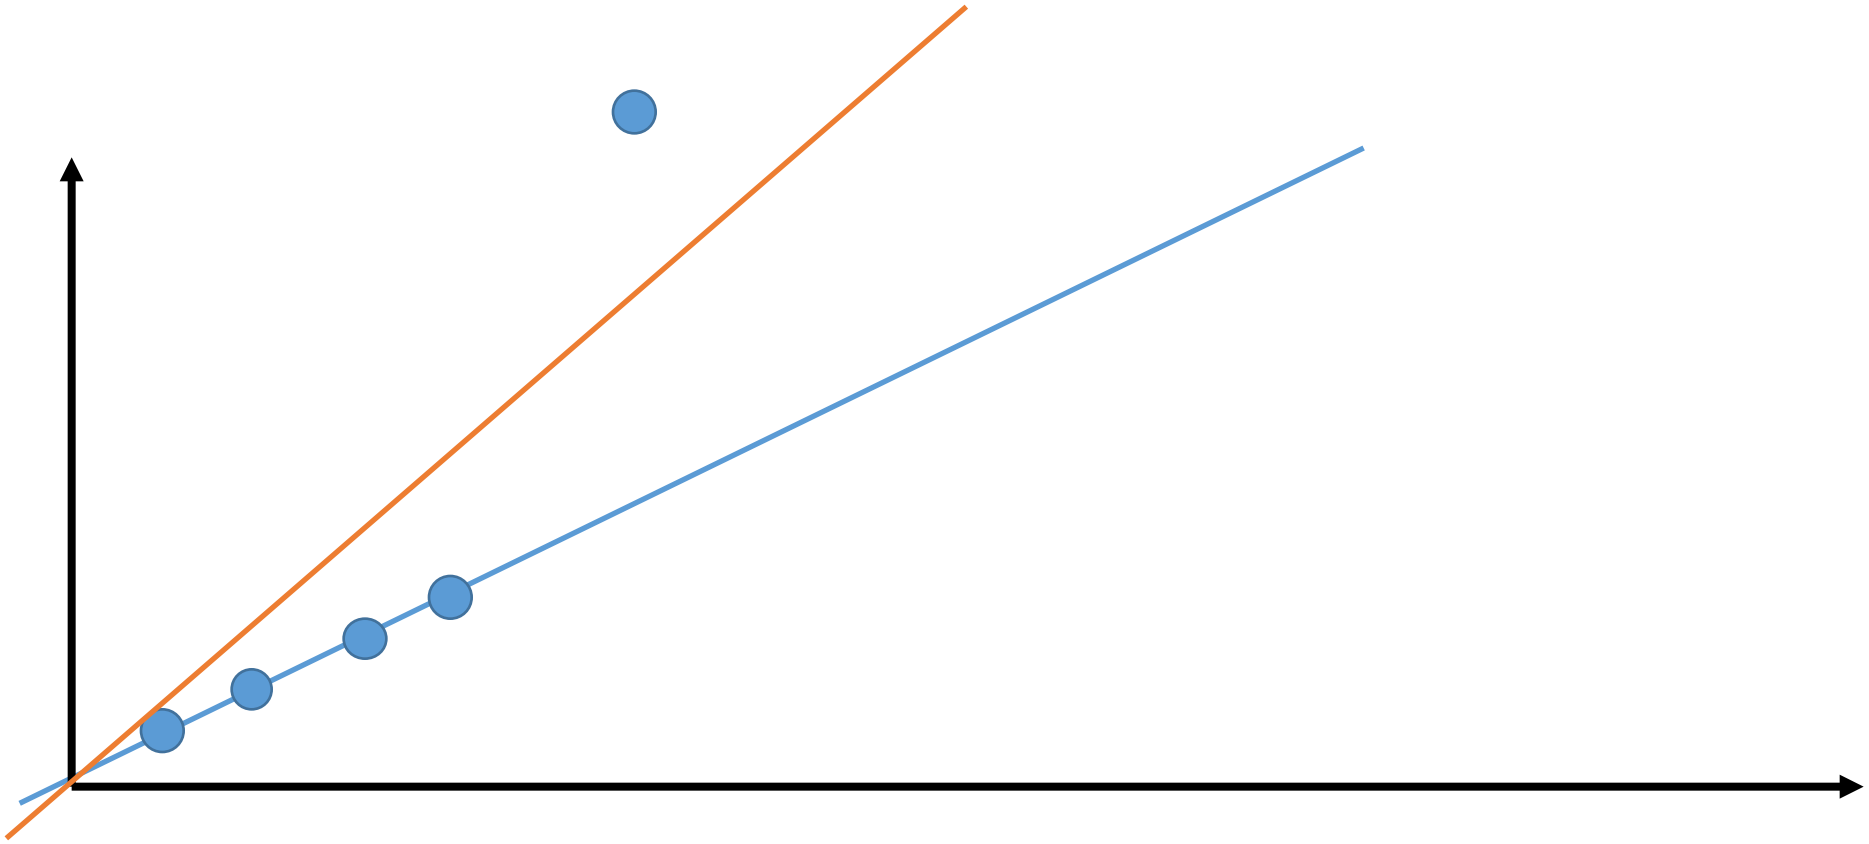

Средняя абсолютная ошибка

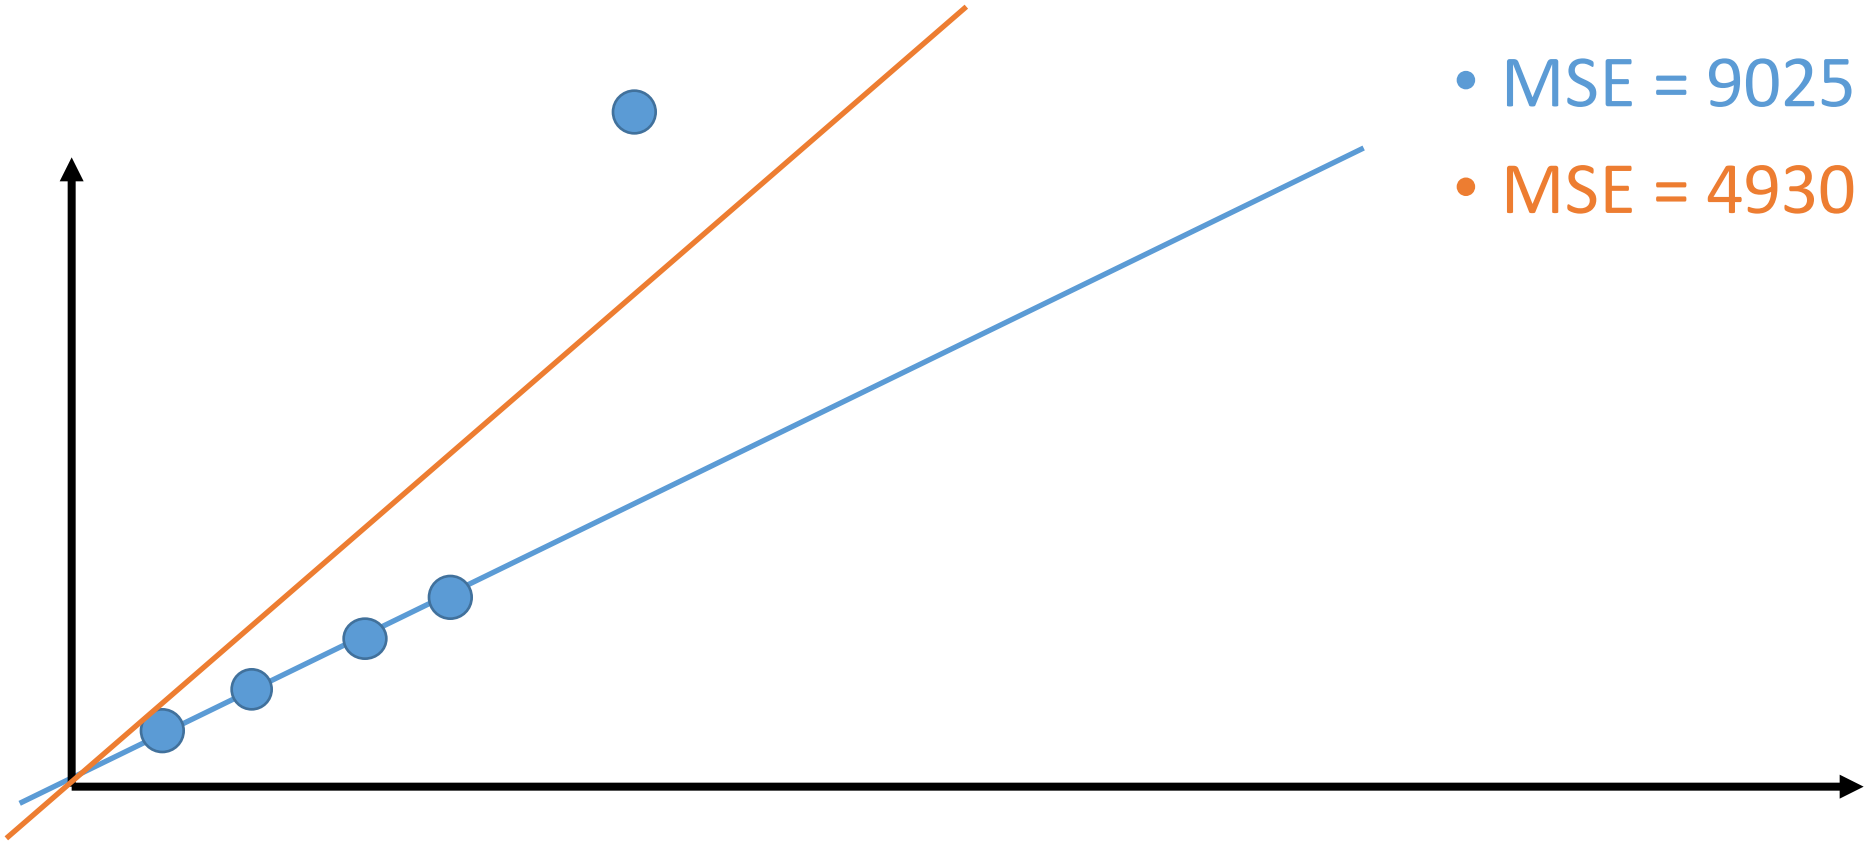

- MSE = 9025
- MSE = 4930

Средняя абсолютная ошибка

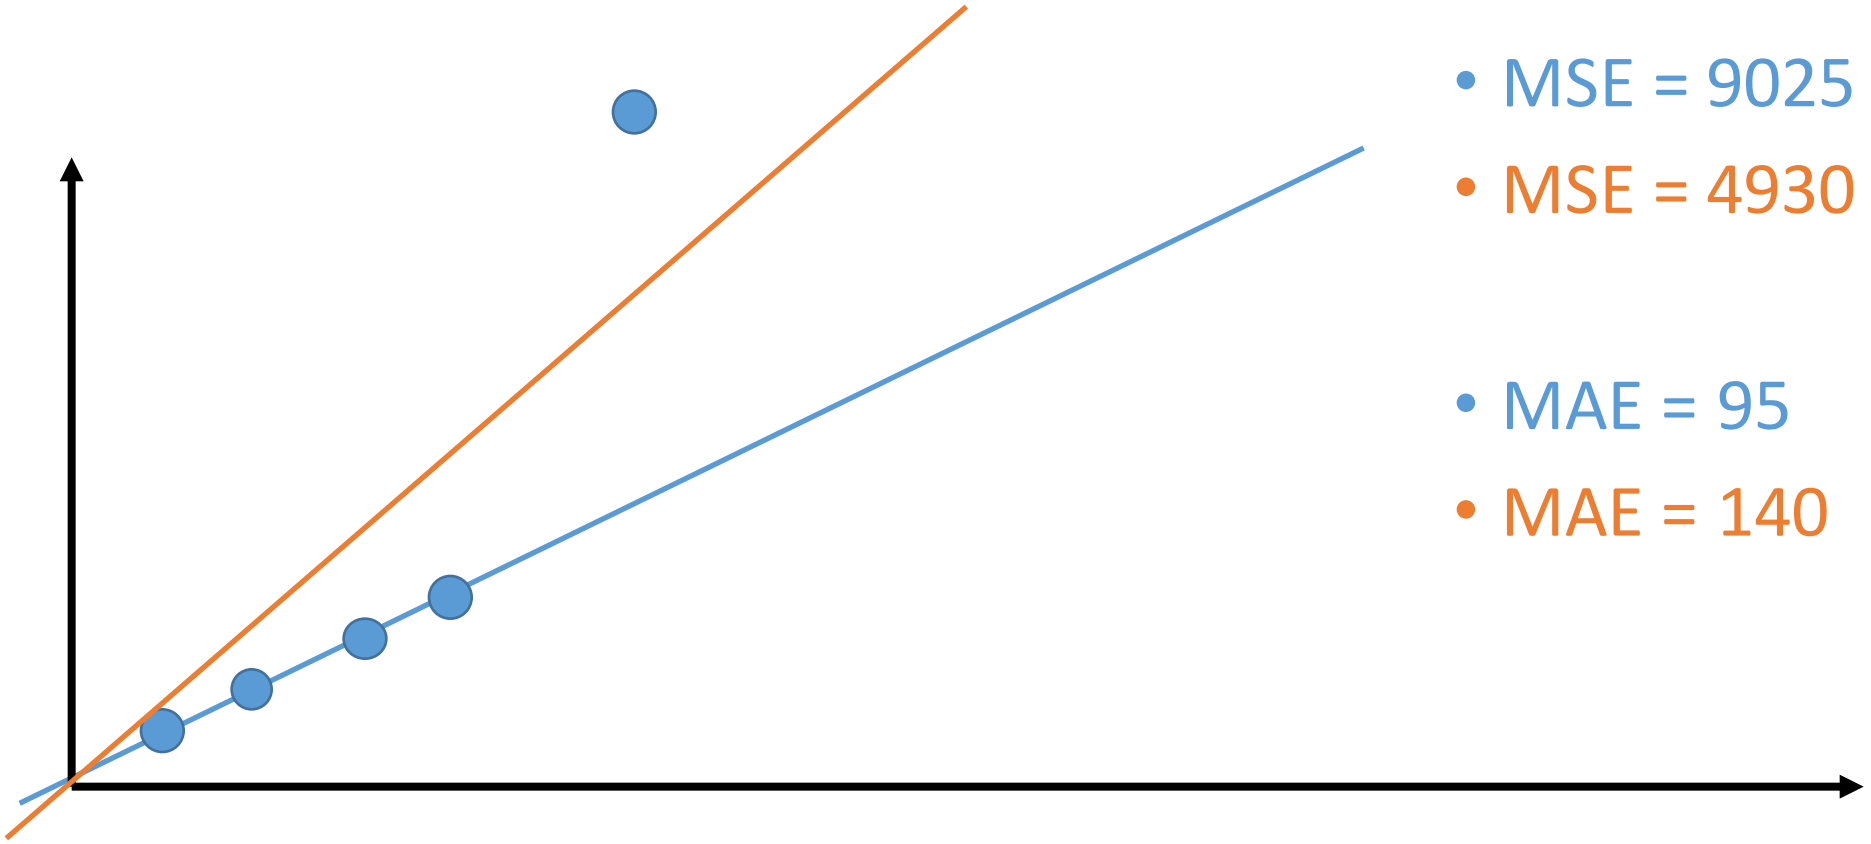

- MSE = 9025
- MSE = 4930

- MAE = 95
- MAE = 140

Устойчивые оценки

- Оценка среднего значения — матожидание
- Оценка разброса — дисперсия

Математическое ожидание

- Характеризует среднее значение случайной величины

$$\mathbb{E}\xi = \begin{cases} \sum_{i=1}^{n} x_i p_i, & \text{для дискретных величин} \\ \int_{-\infty}^{+\infty} x\, p(x) dx, & \text{для непрерывных величин} \end{cases}$$

Медиана

- Такое число m, что попасть левее и правее — равновероятно
- $P(\xi \leq m) \geq 0.5$ и $P(\xi \geq m) \geq 0.5$

Мода

- Для дискретных величин: точка с максимальной вероятностью
- Для непрерывных величин: точка максимума плотности

Центральная величина

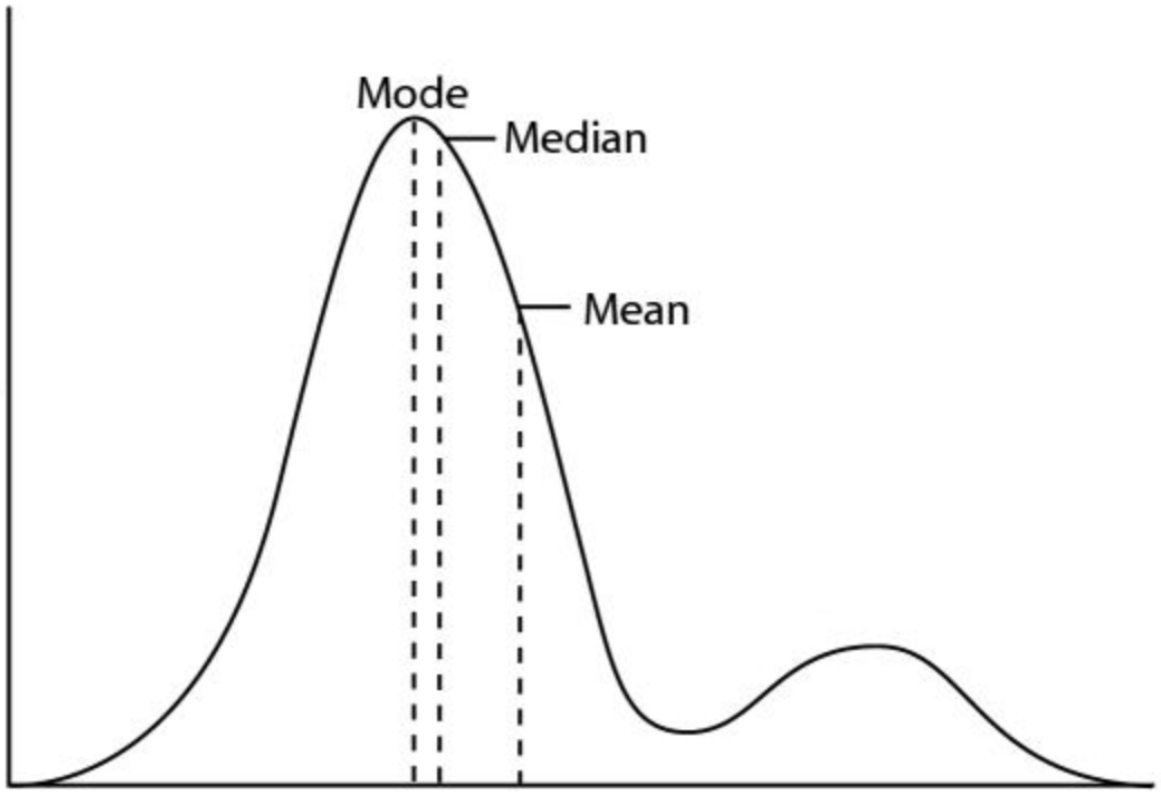

Центральная величина

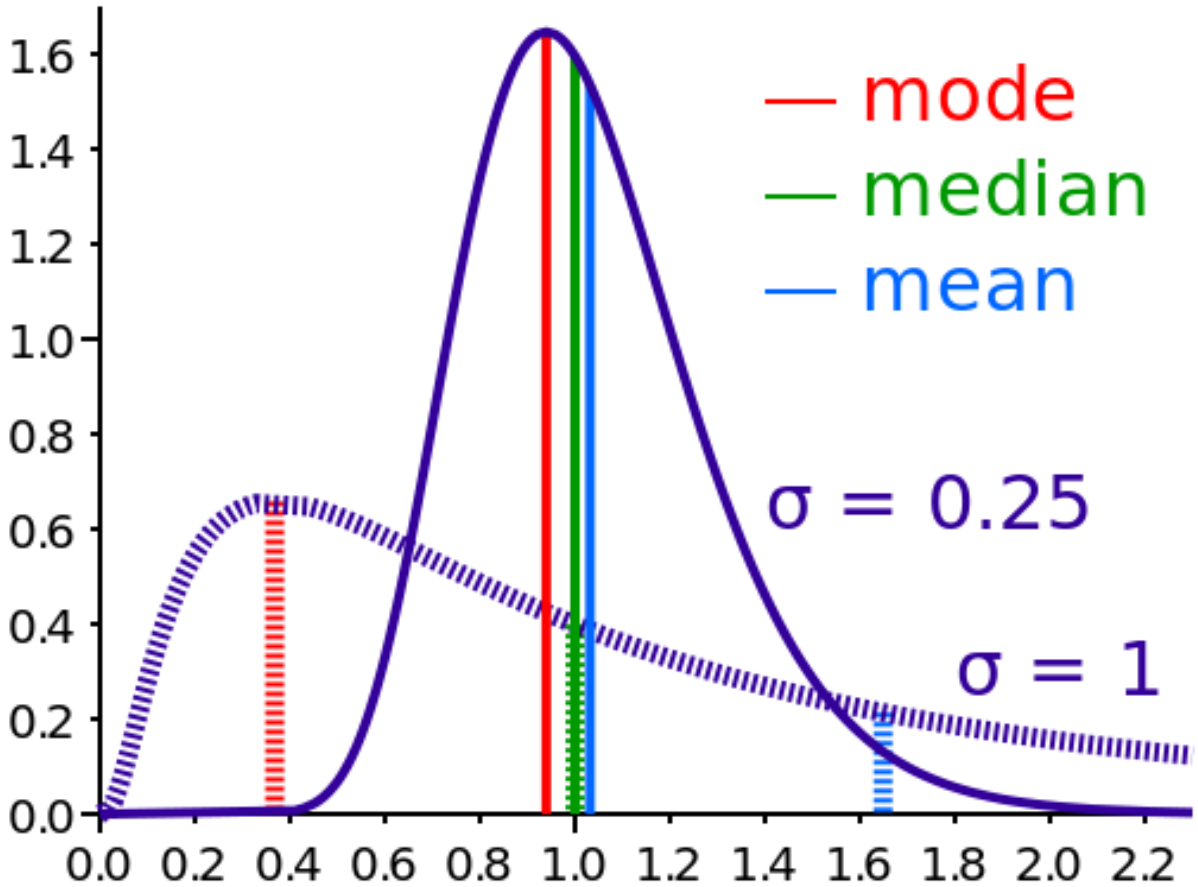

В чем разница?

- Опросили 100 человек
- 99 имеют доход 10.000 рублей
- 1 имеет доход 1.000.000 рублей
- Среднее: $\frac{99*10000+1000000}{100} = 19900$
- Медиана: 10000
- Мода: 10000

$45,000

$15,000

$10,000

← ARITHMETICAL AVERAGE

$5,700

$5,000

$3,700

← MEDIAN (the one in the middle 12 above him, 12 below)

$3,000

← MODE (occurs most frequently)

$2,000

Оптимальный прогноз

- Пусть $x_1, x_2, \ldots, x_\ell$ — выборка с ответами $y_1, y_2, \ldots, y_\ell$
- Нужно выдать один прогноз для всех объектов: $a(x) = \text{const}$
- $\arg\min_c \sum_{i=1}^{\ell} (y_i - c)^2 = \frac{1}{n} \sum_{i=1}^{\ell} y_i$
- $\arg\min_c \sum_{i=1}^{\ell} |y_i - c| = \text{median}\{y_i\}$

Дисперсия

$$\mathbb{E}(\xi - \mathbb{E}\xi)^2 \approx \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- Опросили 100 человек
- 99 имеют доход 10.000 рублей
- 1 имеет доход 1.000.000 рублей
- Дисперсия: 9702990000
- Стандартное отклонение (корень из дисперсии): ~ 98503
- Что-нибудь более устойчивое?

Квантиль

- Q_p — p-квантиль
- Такое число m, что вероятность попасть левее равна p
- Медиана — 0.5-квантиль

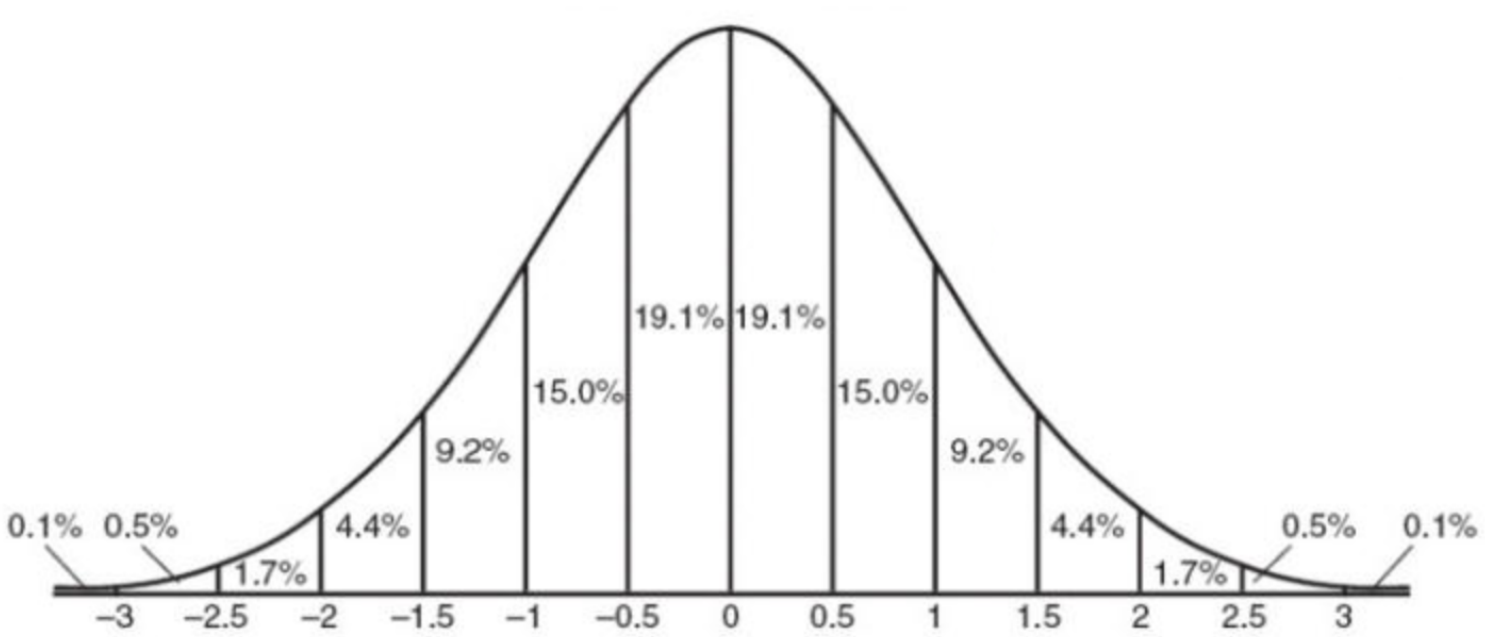

Квантиль

- $Q_{0.25}, Q_{0.75}$ — квартили
- $Q_{0.01}, \ldots, Q_{0.99}$ — перцентили

Интерквартильный размах

- Устойчивая к выбросам мера разброса:

$$IQR = Q_{0.75} - Q_{0.25}$$

- В нашем примере: $IQR = 0$

Среднеквадратичная ошибка

$$\mathrm{MSE}(a, X) = \frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2$$

- Подходит, чтобы сравнивать разные модели
- Чем меньше, тем лучше
- Не позволяет понять, хорошая ли модель получилась
- $\mathrm{MSE} = 32955$ — хорошо или плохо?

Коэффициент детерминации

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^{\ell}(a(x_i) - y_i)^2}{\sum_{i=1}^{\ell}(y_i - \bar{y})^2}$$

- $\bar{y} = \frac{1}{\ell}\sum_{i=1}^{\ell} y_i$ — средний ответ
- Доля дисперсии, объясненная моделью, в общей дисперсии ответов
- Значение можно интерпретировать

Коэффициент детерминации

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^{\ell}(a(x_i) - y_i)^2}{\sum_{i=1}^{\ell}(y_i - \bar{y})^2}$$

- $0 \leq R^2 \leq 1$ (для разумных моделей)
- $R^2 = 1$ — идеальная модель
- $R^2 = 0$ — модель на уровне константной
- $R^2 < 0$ — модель хуже константной

Метрики качества классификации

Качество классификации

- Доля правильных ответов (accuracy):

$$\frac{1}{\ell}\sum_{i=1}^{\ell}[a(x_i) = y_i]$$

Улучшение метрики

- Два алгоритма
- Доли правильных ответов: r_1 и r_2
- Абсолютное улучшение: $r_2 - r_1$
- Относительное улучшение: $\frac{r_2 - r_1}{r_1}$

Улучшение метрики

- $r_1 = 0.8$
- $r_2 = 0.9$
- $\frac{r_2 - r_1}{r_1} = 12.5\%$

- $r_1 = 0.5$
- $r_2 = 0.75$
- $\frac{r_2 - r_1}{r_1} = 50\%$

- $r_1 = 0.001$
- $r_2 = 0.01$
- $\frac{r_2 - r_1}{r_1} = 900\%$

Матрица ошибок

	$y = 1$	$y = -1$
$a(x) = 1$	True Positive (TP)	False Positive (FP)
$a(x) = -1$	False Negative (FN)	True Negative (TN)

Точность (precision)

- Можно ли доверять классификатору при $a(x) = 1$?

$$\text{precision}(a, X) = \frac{TP}{TP + FP}$$

Полнота (recall)

- Как много положительных объектов находит классификатор?

$$\text{recall}(a, X) = \frac{TP}{TP + FN}$$

Точность и полнота

- Точность — можно ли доверять классификатору при $a(x) = 1$?
- Полнота — как много положительных объектов находит $a(x)$?

- Оптимизировать две метрики одновременно очень неудобно
- Как объединить?

Арифметическое среднее

$$A = \frac{1}{2}(\text{precision} + \text{recall})$$

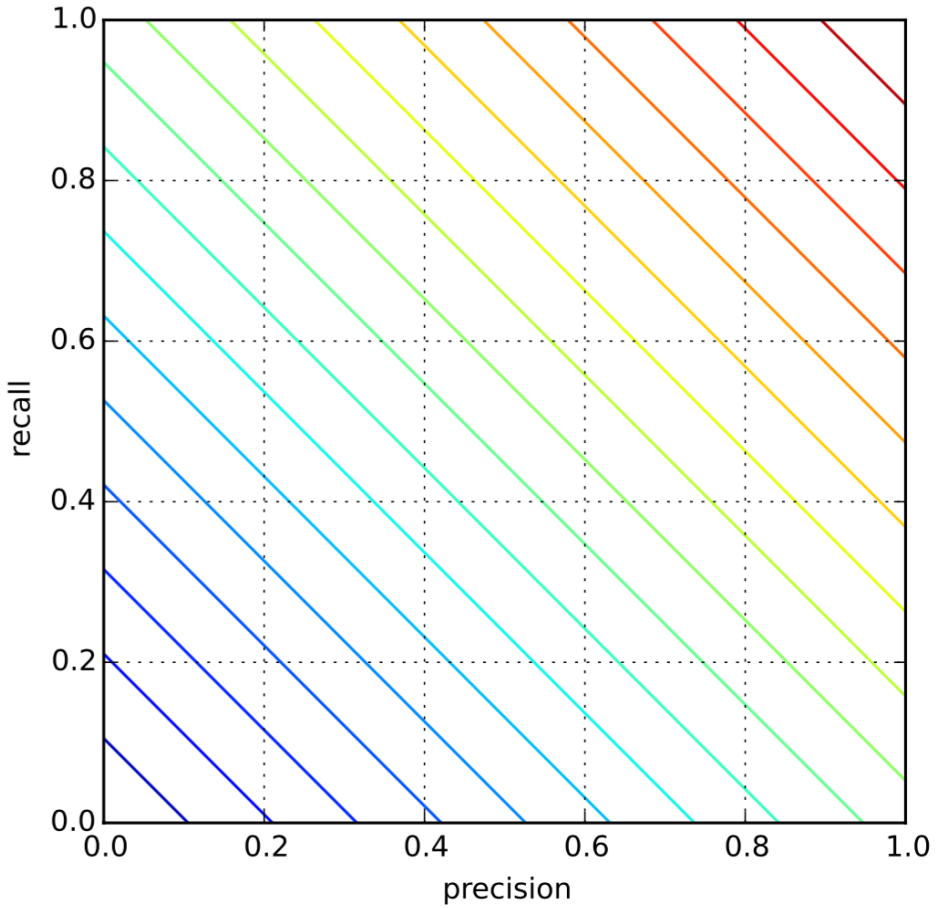

Арифметическое среднее

$$A = \frac{1}{2}(\text{precision} + \text{recall})$$

- $\text{precision} = 0.1$
- $\text{recall} = 1$
- $A = 0.55$

- Плохой алгоритм

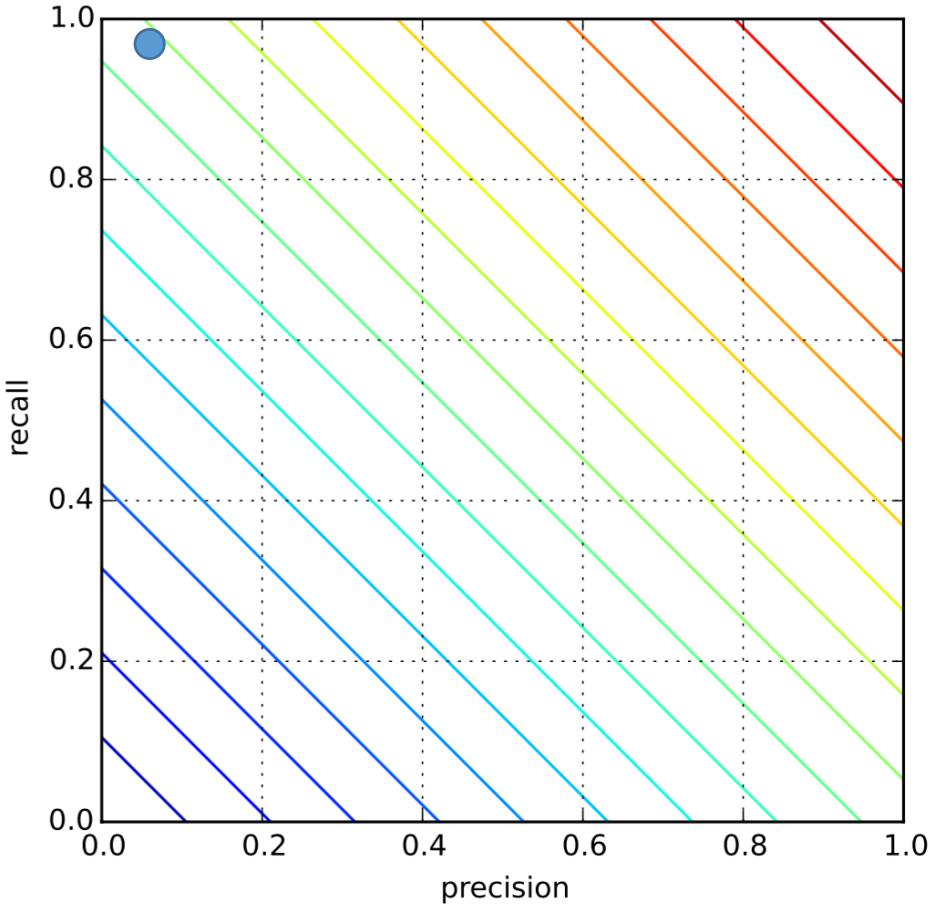

Арифметическое среднее

$$A = \frac{1}{2}(\text{precision} + \text{recall})$$

- $\text{precision} = 0.55$
- $\text{recall} = 0.55$
- $A = 0.55$

- Нормальный алгоритм
- Но качество такое же, как у плохого

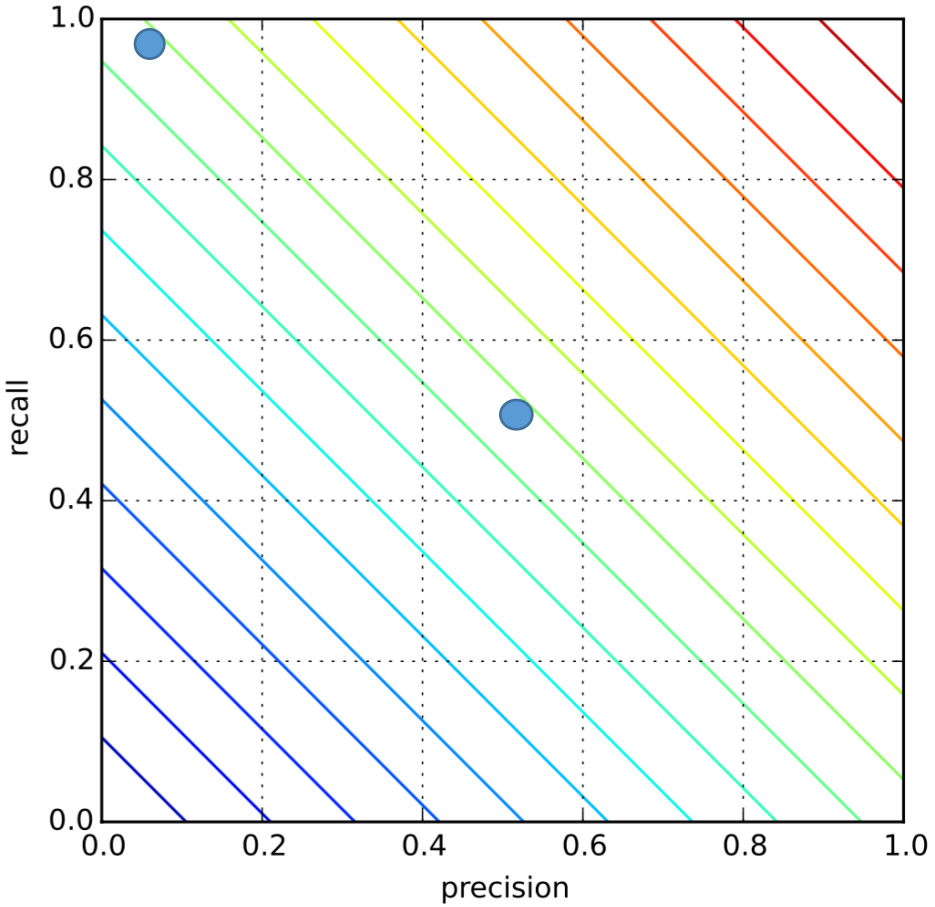

Минимум

$$M = \min(\text{precision}, \text{recall})$$

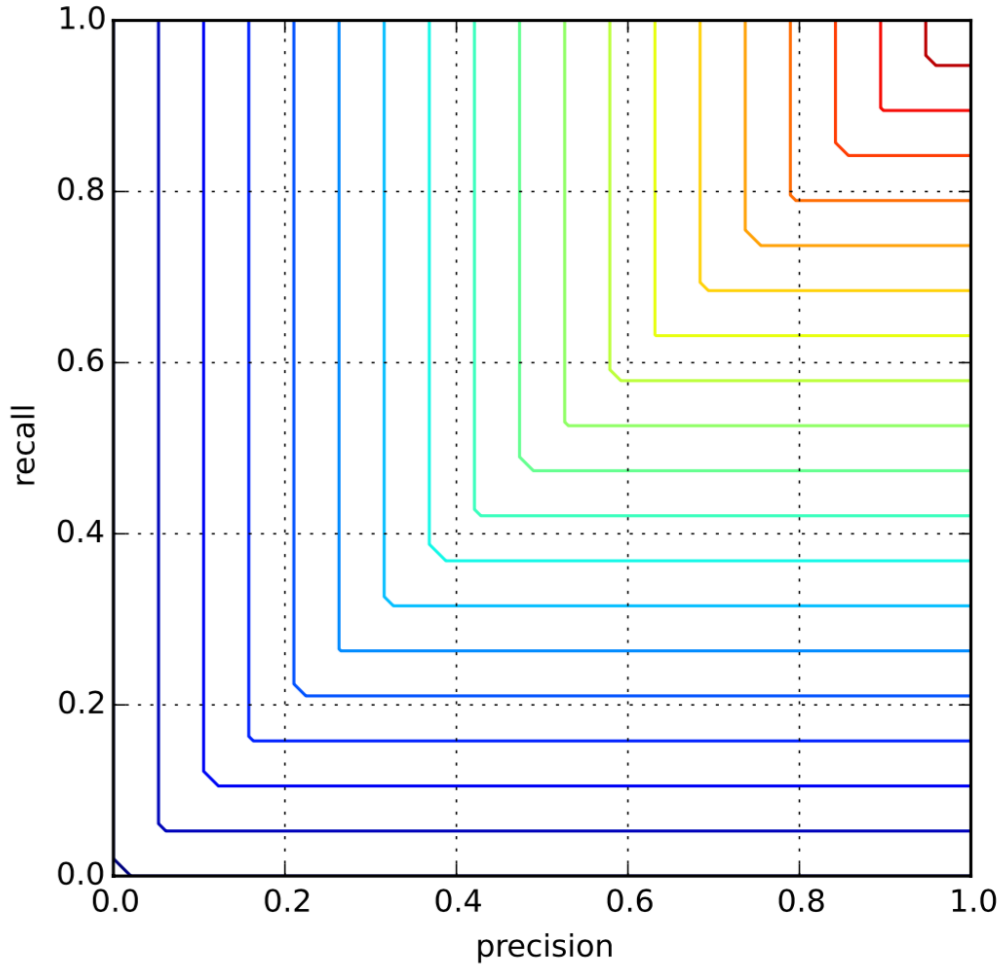

Минимум

$$M = \min(\text{precision}, \text{recall})$$

- $\text{precision} = 0.05$
- $\text{recall} = 1$
- $M = 0.05$

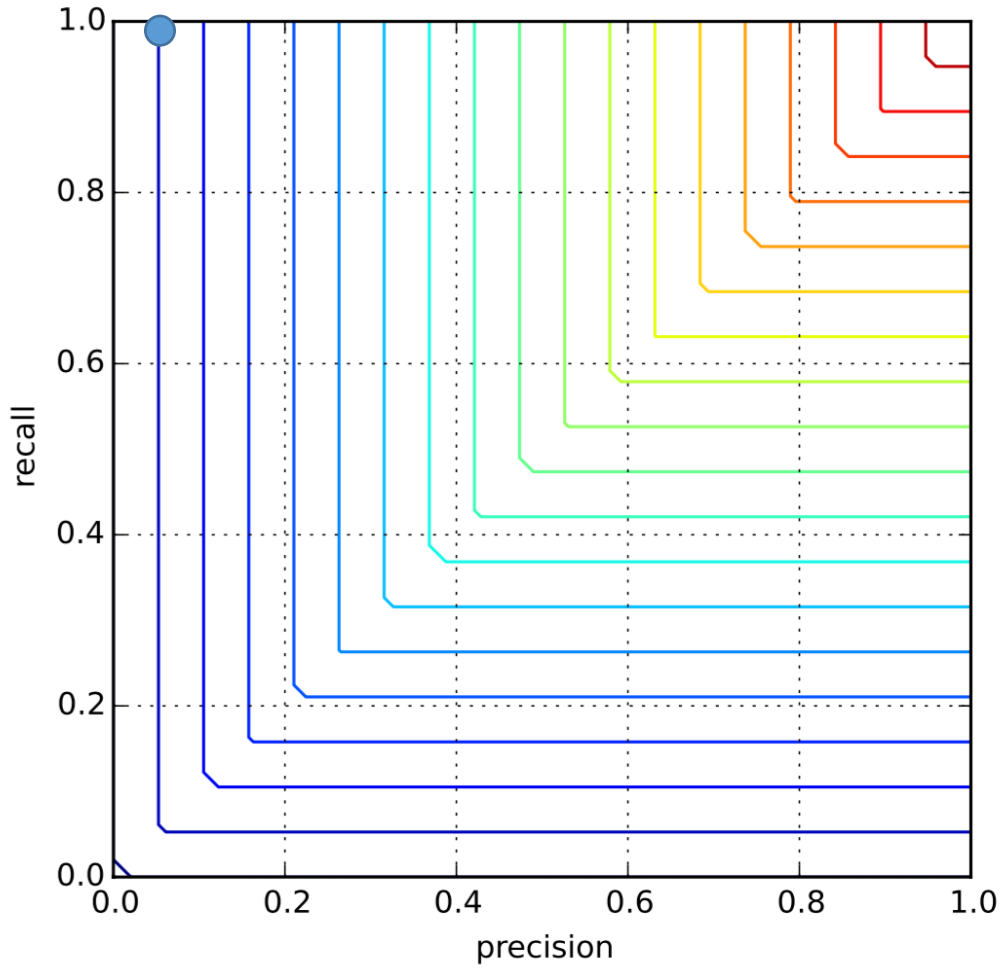

Минимум

$$M = \min(\text{precision}, \text{recall})$$

- $\text{precision} = 0.55$
- $\text{recall} = 0.55$
- $M = 0.55$

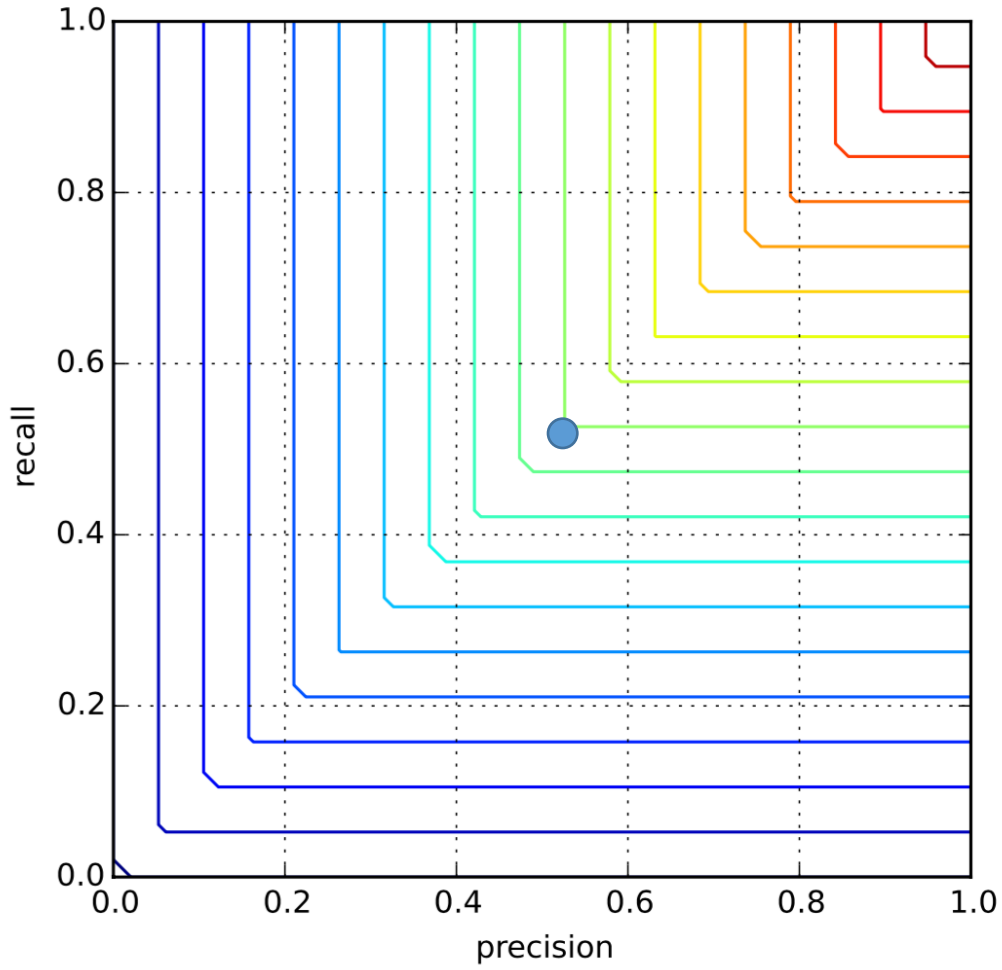

Минимум

$$M = \min(\text{precision}, \text{recall})$$

- $\text{precision} = 0.4$, $\text{recall} = 0.5$
- $M = 0.4$

- $\text{precision} = 0.4$, $\text{recall} = 0.9$
- $M = 0.4$

- Но второй лучше!

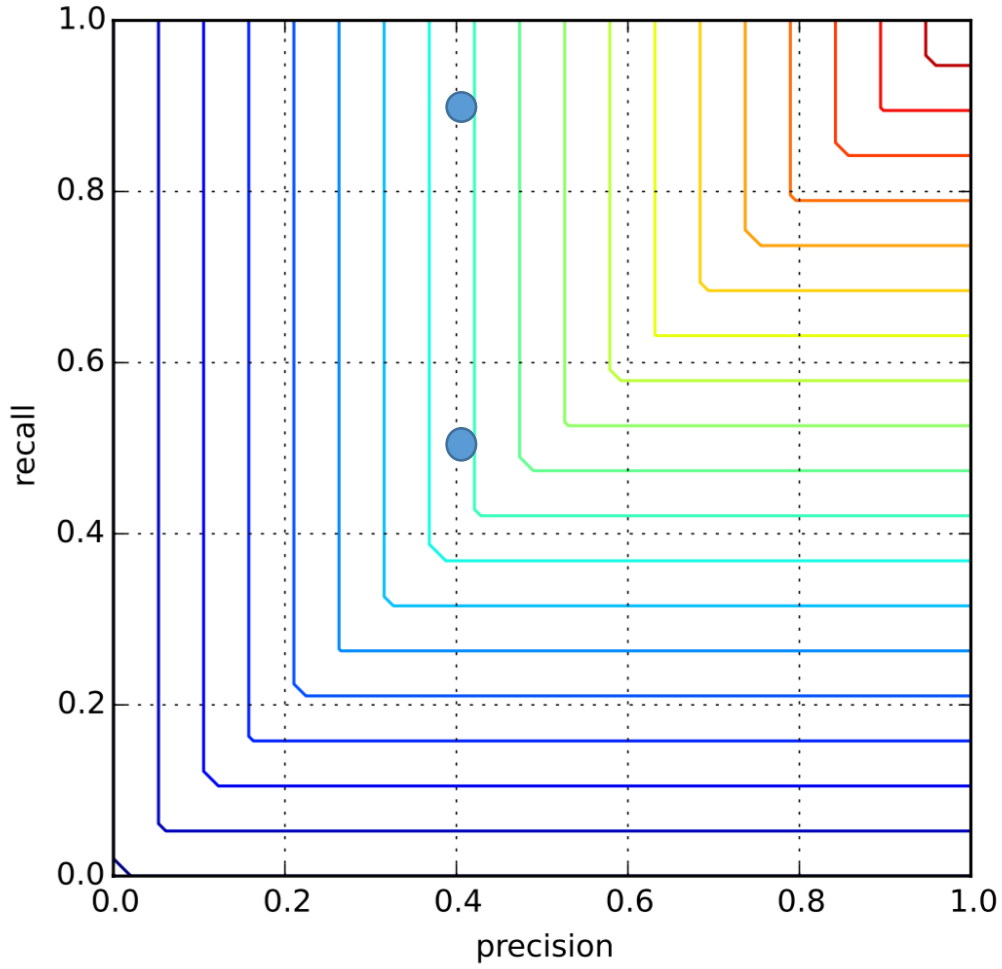

F-мера

$$F = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

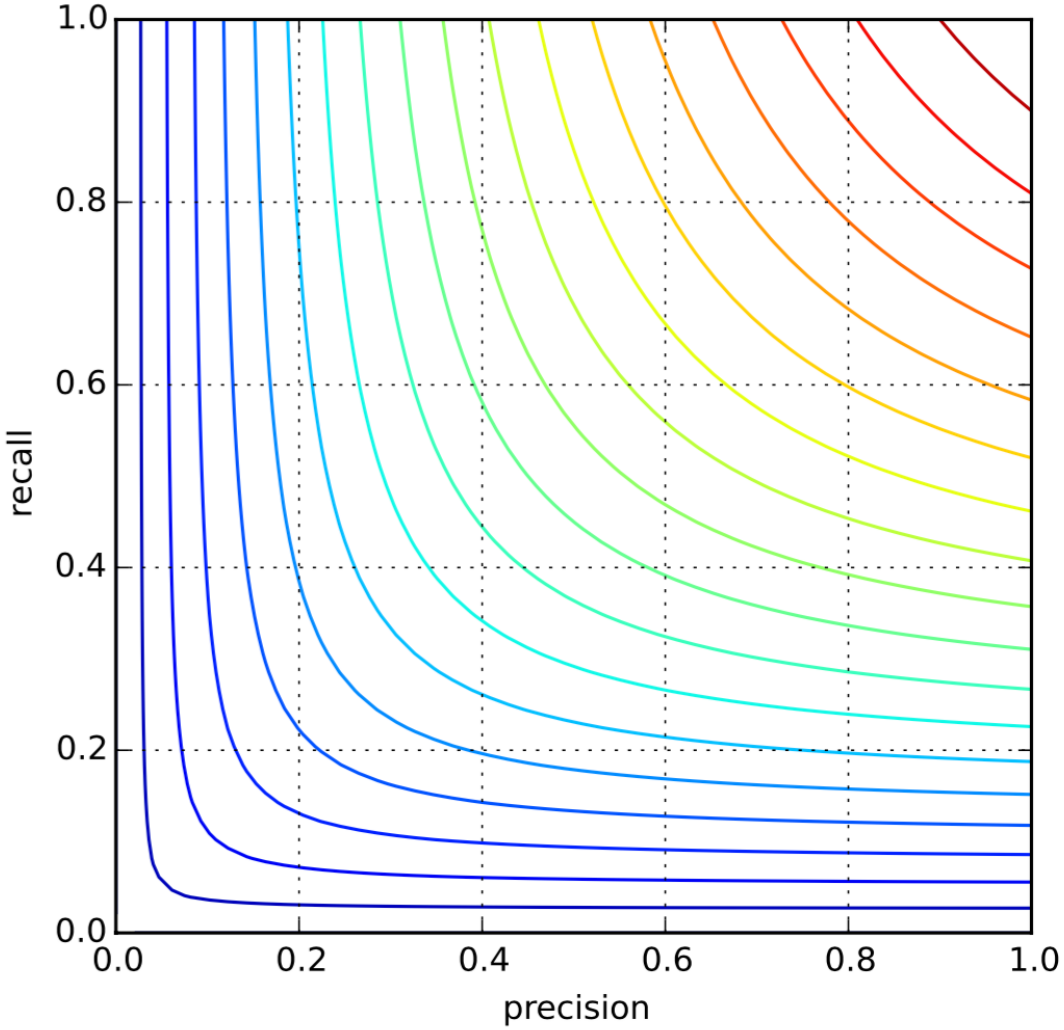

F-мера

$$F = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

- $\text{precision} = 0.4, \text{recall} = 0.5$
- $F = 0.44$

- $\text{precision} = 0.4, \text{recall} = 0.9$
- $M = 0.55$

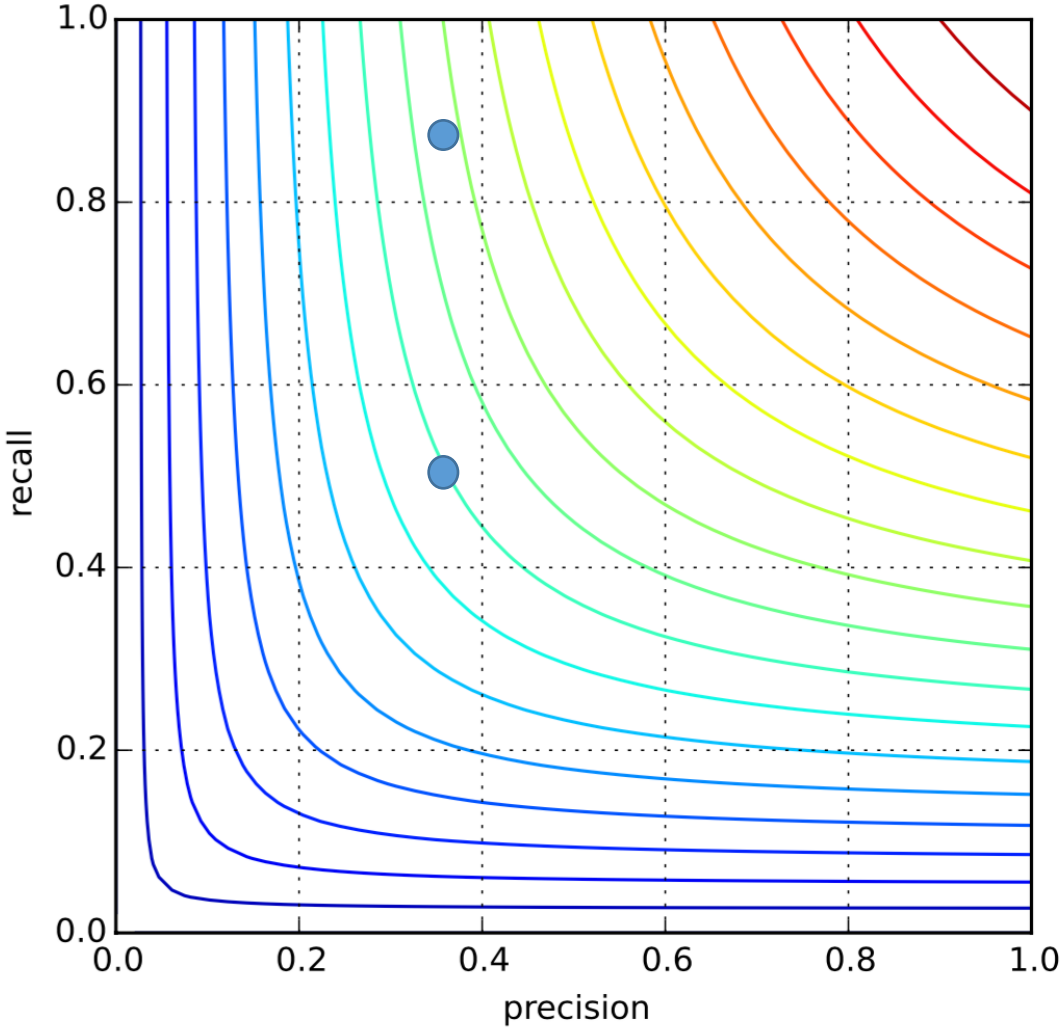

F-мера

$$F_\beta = (1 + \beta^2)\frac{\text{precision} * \text{recall}}{\beta^2 * \text{precision} + \text{recall}}$$

- $\beta = 0.5$
- Важнее полнота

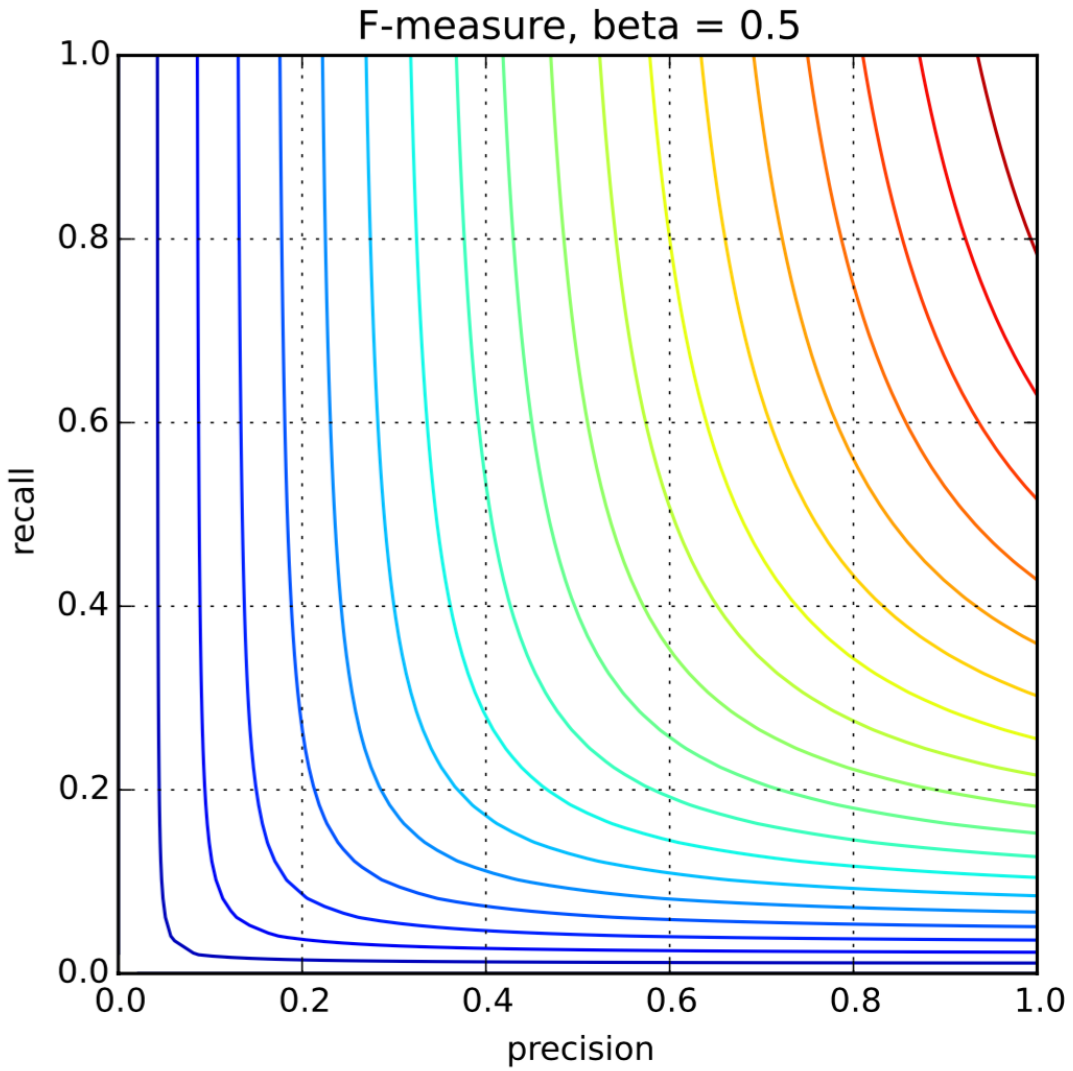

F-мера

$$F_\beta = (1 + \beta^2) \frac{\text{precision} * \text{recall}}{\beta^2 * \text{precision} + \text{recall}}$$

- $\beta = 2$
- Важнее точность

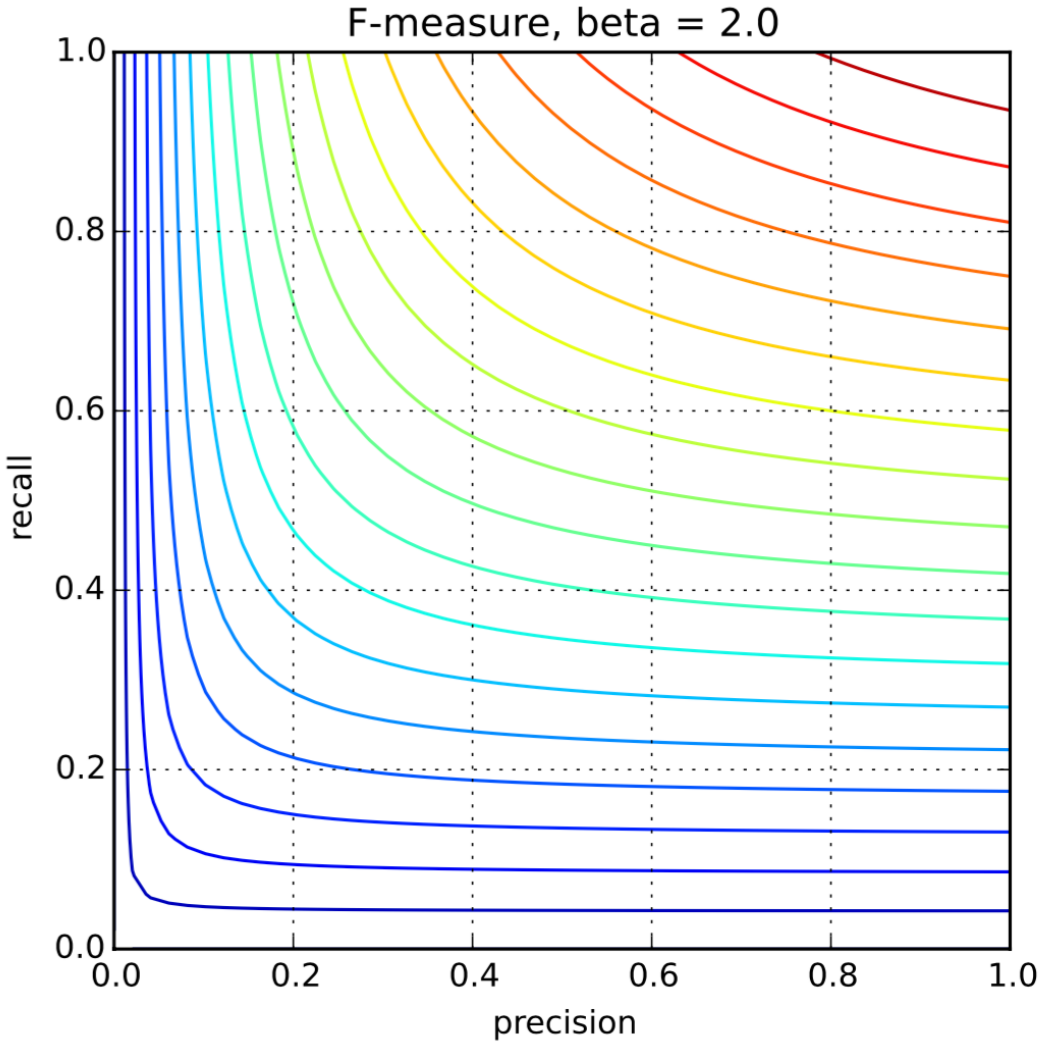

F-мера

$$F_\beta = (1 + \beta^2) \frac{\text{precision} * \text{recall}}{\beta^2 * \text{precision} + \text{recall}}$$

Оценки принадлежности классу

Классификатор

- Частая ситуация:

$$a(x) = [b(x) > t]$$

- $b(x)$ — оценка принадлежности классу +1

Линейный классификатор

$$a(x) = [\langle w, x \rangle > t]$$

- $b(x) = \langle w, x \rangle$ — оценка принадлежности классу +1
- Обычно $t = 0$

Оценка принадлежности

- Как оценить качество $b(x)$?
- Порог выбирается позже
- Порог зависит от ограничений на точность или полноту

Оценка принадлежности

- Высокий порог:
  - Мало объектов относим к +1
  - Точность выше
  - Полнота ниже
- Низкий порог:
  - Много объектов относим к +1
  - Точность ниже
  - Полнота выше

Оценка принадлежности

-1	-1	+1	-1	-1	-1	+1	+1	-1	+1
0.01	0.09	0.12	0.15	0.29	0.4	0.48	0.6	0.83	0.9

Оценка принадлежности

-1	-1	+1	-1	-1	-1	+1	+1	-1	+1
0.01	0.09	0.12	0.15	0.29	0.4	0.48	0.6	0.83	0.9

Оценка принадлежности

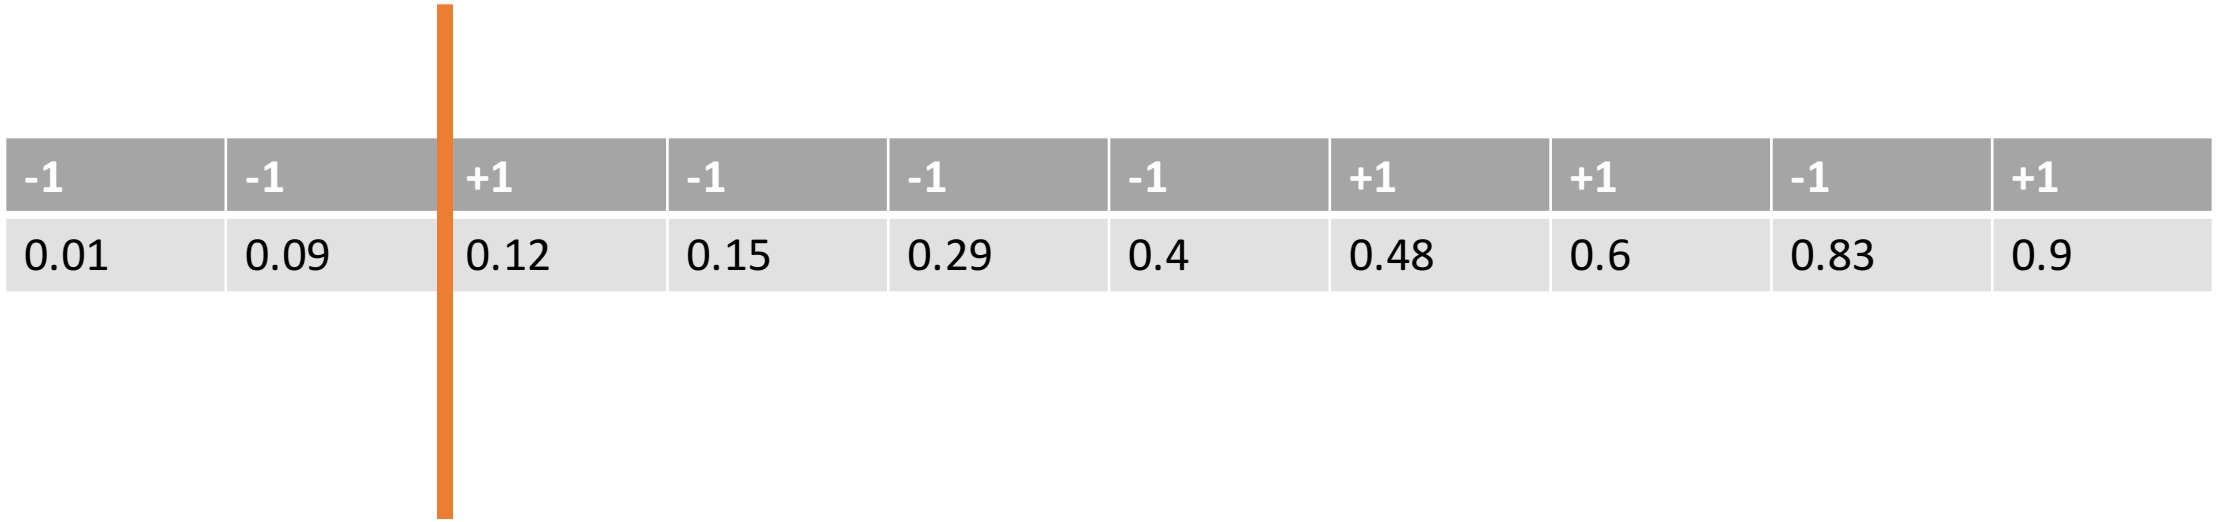

-1	-1	+1	-1	-1	-1	+1	+1	-1	+1
0.01	0.09	0.12	0.15	0.29	0.4	0.48	0.6	0.83	0.9

Оценка принадлежности

- Пример: кредитный скоринг
- $b(x)$ — оценка вероятности возврата кредита
- $a(x) = [b(x) > 0.5]$
- $\text{precision} = 0.1, \text{recall} = 0.7$
- В чем дело — в пороге или в алгоритме?

ROC-кривая

- Receiver Operating Characteristic
- Ось X — False Positive Rate

$$FPR = \frac{FP}{FP + TN}$$

- Ось Y — True Positive Rate

$$TPR = \frac{TP}{TP + FN}$$

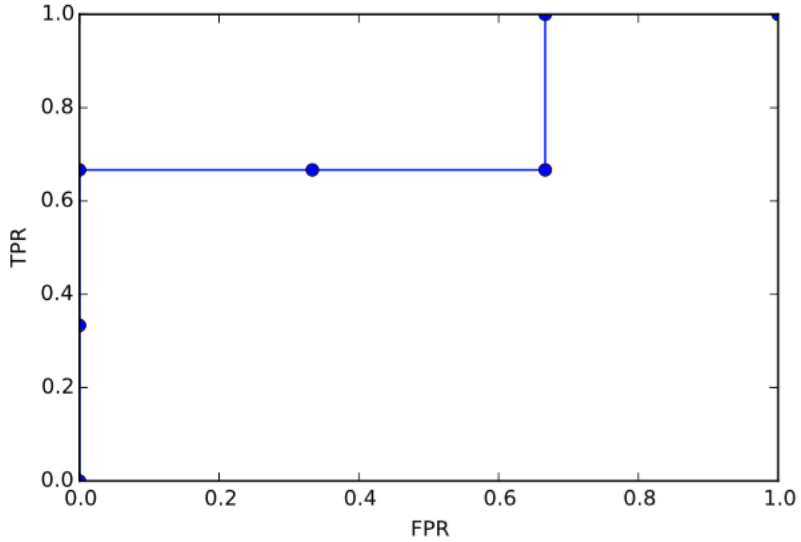

ROC-кривая

- Receiver Operating Characteristic
- Ось X — False Positive Rate

$$FPR = \frac{FP}{FP + TN}$$

Число отрицательных объектов

- Ось Y — True Positive Rate

$$TPR = \frac{TP}{TP + FN}$$

Число положительных объектов

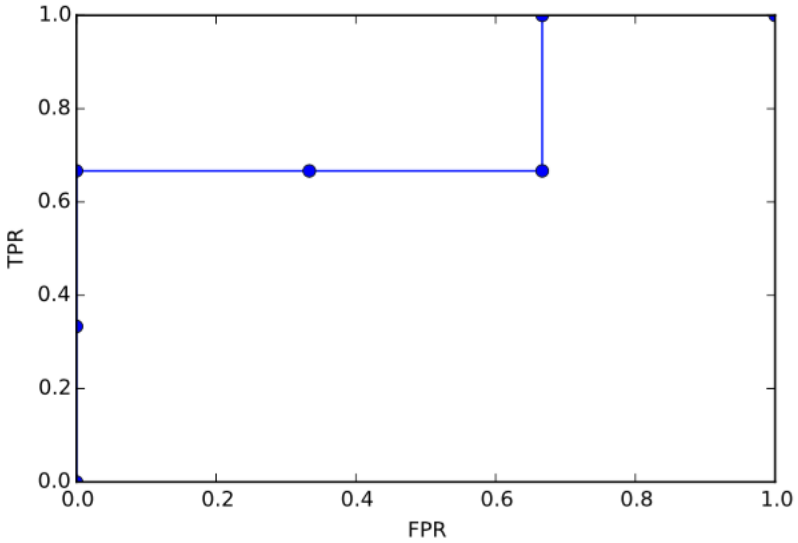

ИНТЕГРАЛЬНАЯ МЕТРИКА: ROC-AUC

Хотим измерить качество всего семейства классификаторов независимо от выбранного порога.

Для этого будем использовать метрику AUC

AUC *– Area Under ROC Curve (площадь под ROC-кривой)*

ROC-КРИВАЯ

Для каждого значения порога t вычислим:

- False Positive Rate (доля неверно принятых объектов отрицательного класса):

$$FPR = \frac{FP}{FP + TN} = \frac{\sum_i [y_i = -1][a(x_i) = +1]}{\sum_i [y_i = -1]}$$

- True Positive Rate (доля верно принятых объектов положительного класса):

$$TPR = \frac{TP}{TP+FN} =$$

$$= \frac{\sum_i [y_i = +1]\,[a(x_i) = +1]}{\sum_i [y_i = +1]}.$$

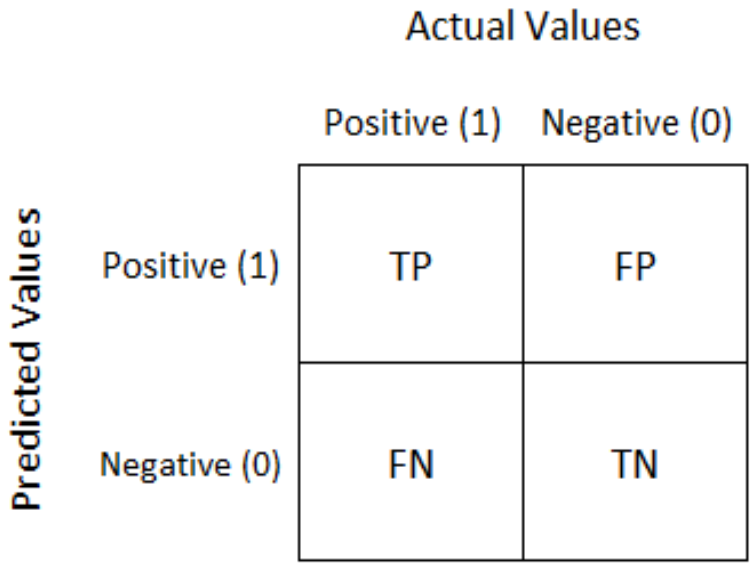

ROC-КРИВАЯ

Кривая, состоящая из точек с координатами (FPR,TPR) для всех возможных порогов – это и есть ROC-кривая.

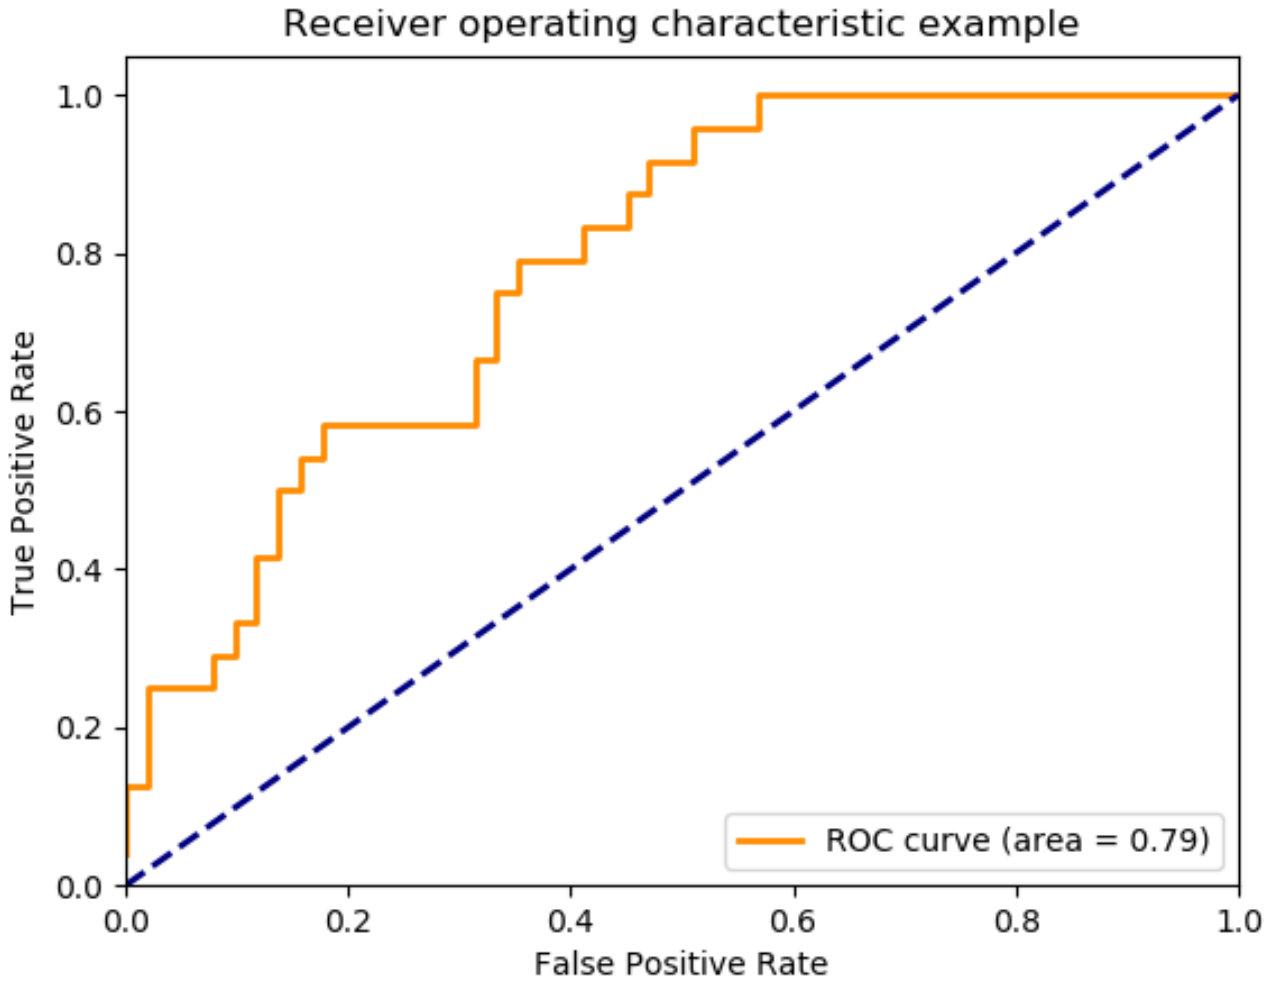

ROC-КРИВАЯ. AUC.

AUC (Area Under Curve) – площадь под ROC-кривой.

$$AUC \in [0; 1].$$

- *Чему равен AUC при идеальной классификации?*
- *Чему равен AUC при случайной классификации?*

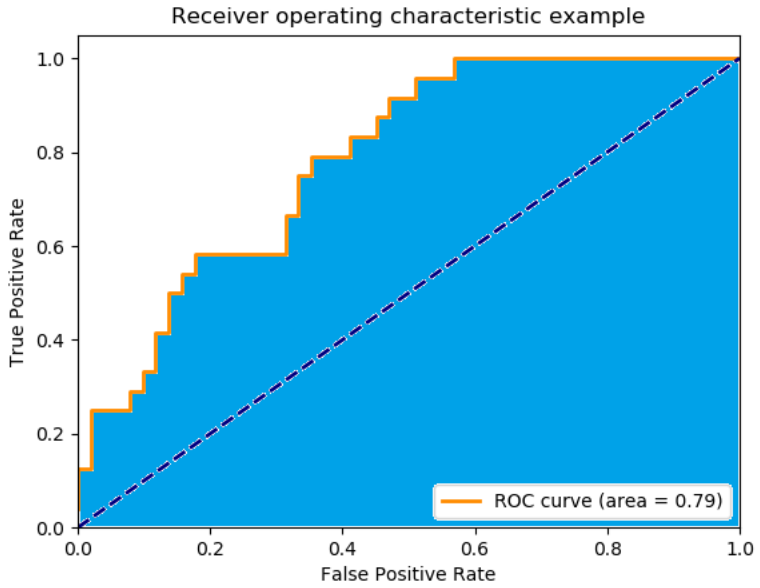

ROC-КРИВАЯ. AUC.

AUC (Area Under Curve) – площадь под ROC-кривой.

$$AUC \in [0; 1].$$

- $AUC = 1$ –

идеальная классификация

- $AUC = 0.5$ –

случайная классификация

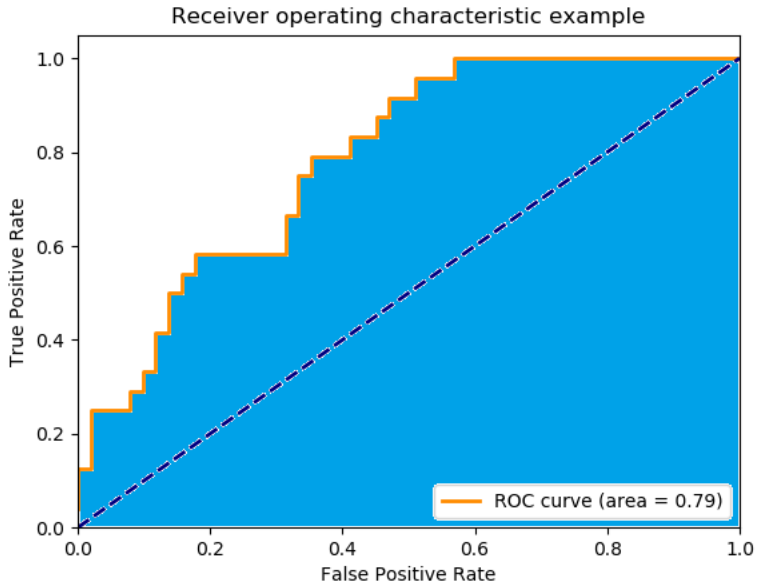

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
y	-1	$+1$	-1	$+1$	$+1$

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
y	-1	$+1$	-1	$+1$	$+1$

- Упорядочим объекты по убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

1 шаг: $t = 0.7$, то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
y	-1	$+1$	-1	$+1$	$+1$

- Упорядочим объекты по убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

1 шаг: $t = 0.7$, то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0, \quad FPR = \frac{0}{0+2} = 0.$$

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
y	-1	$+1$	-1	$+1$	$+1$

- Упорядочим объекты по убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

1 шаг: $t = 0.7$, то есть

$a(x) = [b(x) > 0.7]$

$$TPR = \frac{0}{0+3} = 0,$$

$$FPR = \frac{0}{0+2} = 0.$$

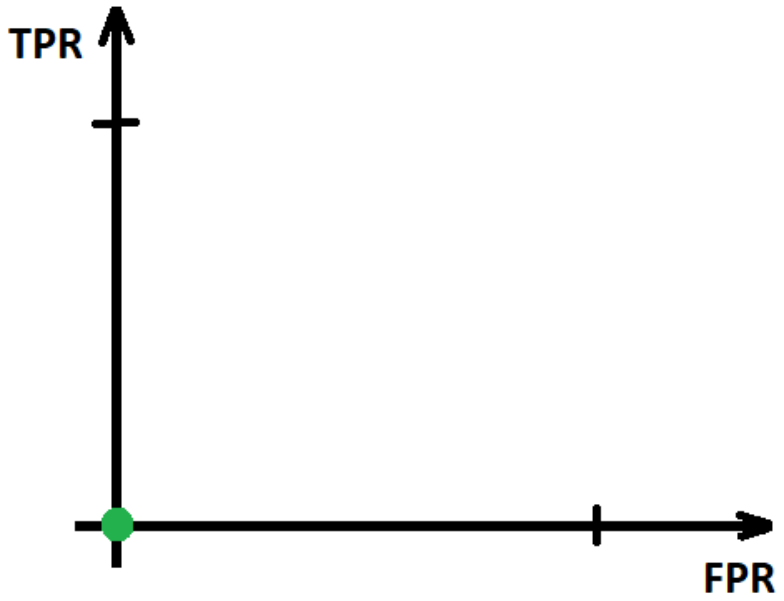

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	**0.7**	0.05
y	-1	$+1$	-1	$+1$	$+1$

- Упорядочим объекты по

убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

2 шаг: $t = 0.4$, то есть

$a(x) = [b(x) > 0.4]$

$TPR = \frac{1}{1+2} = \frac{1}{3}$,

$FPR = \frac{0}{0+2} = 0.$

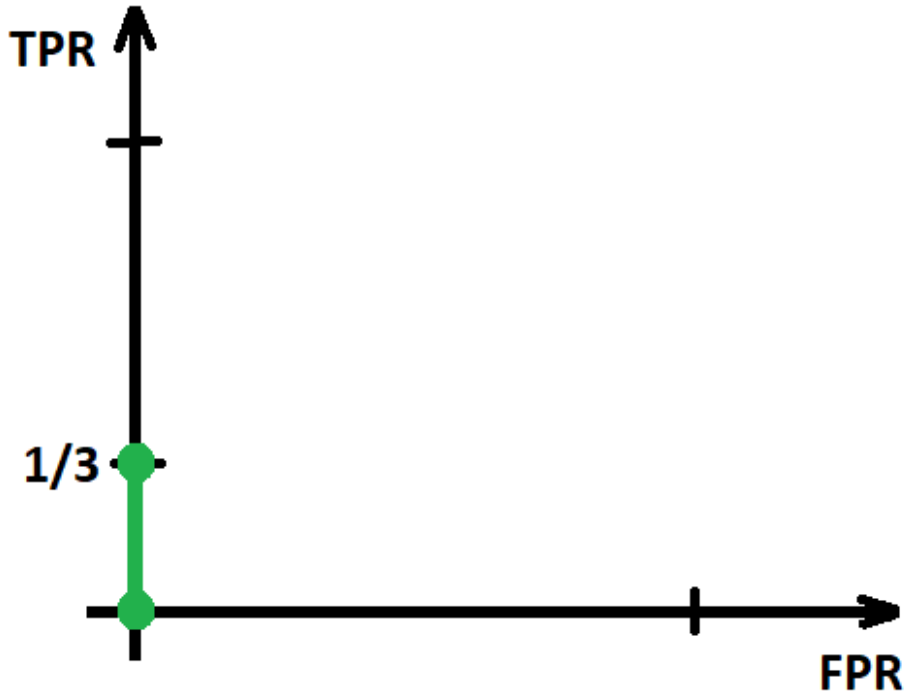

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	**0.4**	0.1	**0.7**	0.05
y	-1	$+1$	-1	$+1$	$+1$

- Упорядочим объекты по

убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

3 шаг: $t = 0.2$, то есть

$a(x) = [b(x) > 0.2]$

$TPR = \frac{2}{2+1} = \frac{2}{3}$,

$FPR = \frac{0}{0+2} = 0.$

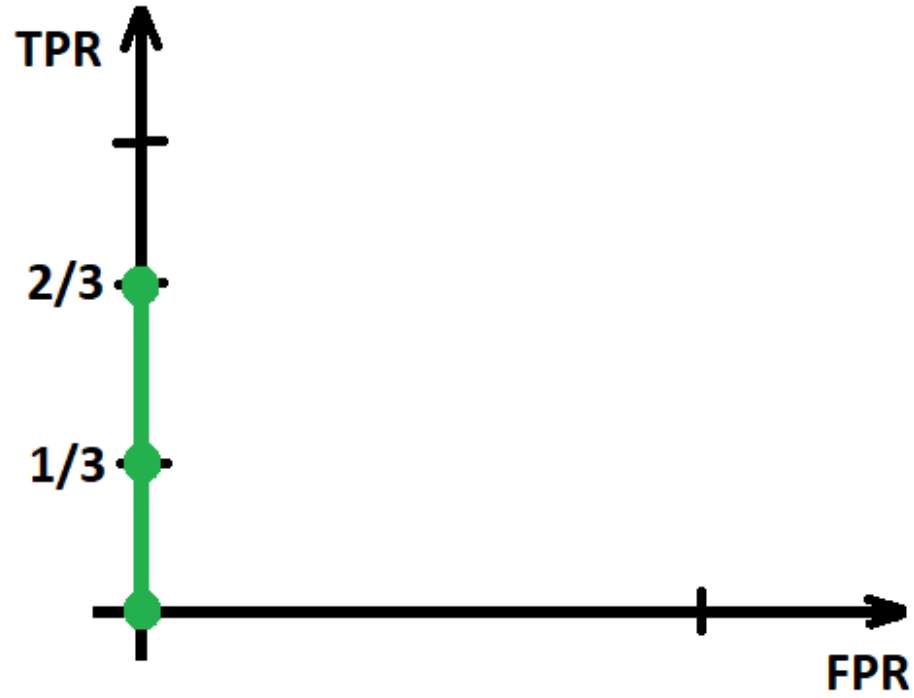

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	**0.2**	**0.4**	0.1	**0.7**	0.05
y	**−1**	**+1**	−1	**+1**	+1

- Упорядочим объекты по

убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

4 шаг: $\boldsymbol{t = 0.1}$, то есть

$a(x) = [b(x) > 0.1]$

$TPR = \frac{2}{2+1} = \frac{2}{3}$,

$FPR = \frac{1}{1+1} = \frac{1}{2}$.

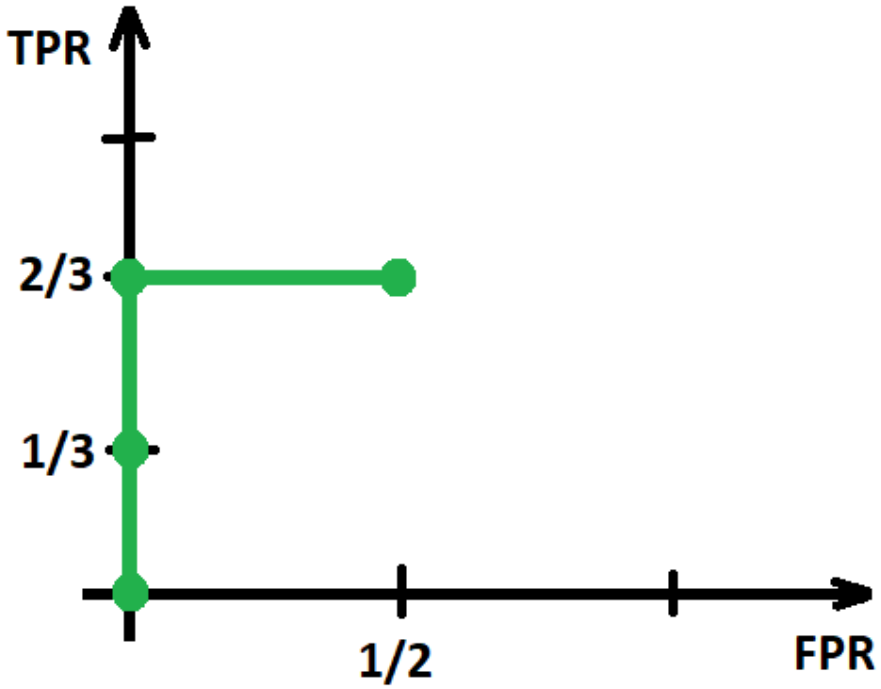

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	$\mathbf{0.2}$	$\mathbf{0.4}$	$\mathbf{0.1}$	$\mathbf{0.7}$	0.05
y	$\mathbf{-1}$	$\mathbf{+1}$	$\mathbf{-1}$	$\mathbf{+1}$	$+1$

- Упорядочим объекты по убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

5 шаг: $\boldsymbol{t = 0.05}$, то есть

$a(x) = [b(x) > 0.05]$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{2}{2+0} = 1.$$

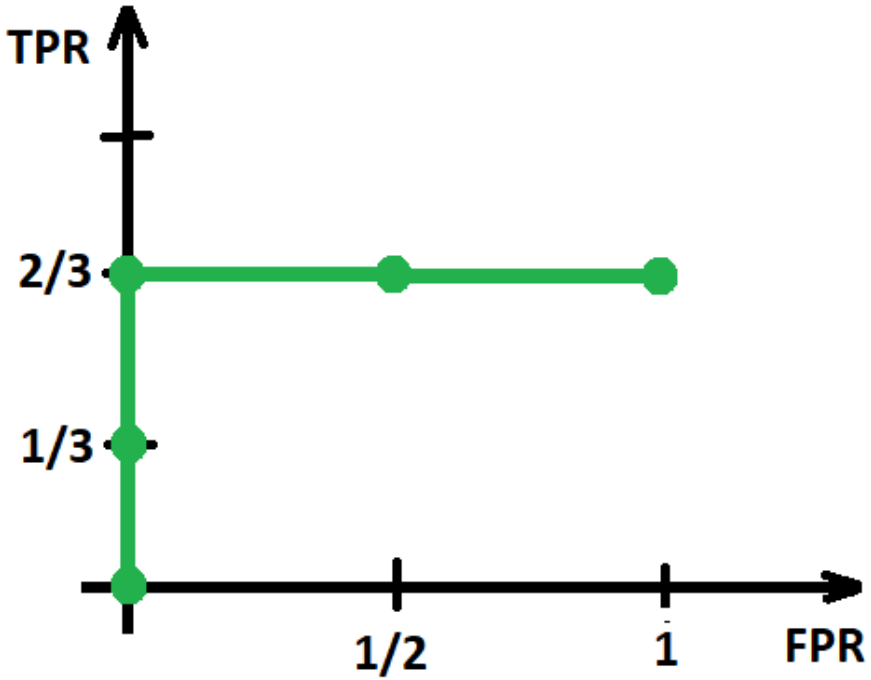

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
y	-1	$+1$	-1	$+1$	$+1$

- Упорядочим объекты по

убыванию предсказаний:

$(0.7, 0.4, 0.2, 0.1, 0.05)$

6 шаг: $t = 0$, то есть

$a(x) = [b(x) > 0]$

$$TPR = \frac{3}{3+0} = 1,$$

$$FPR = \frac{2}{2+0} = 1.$$

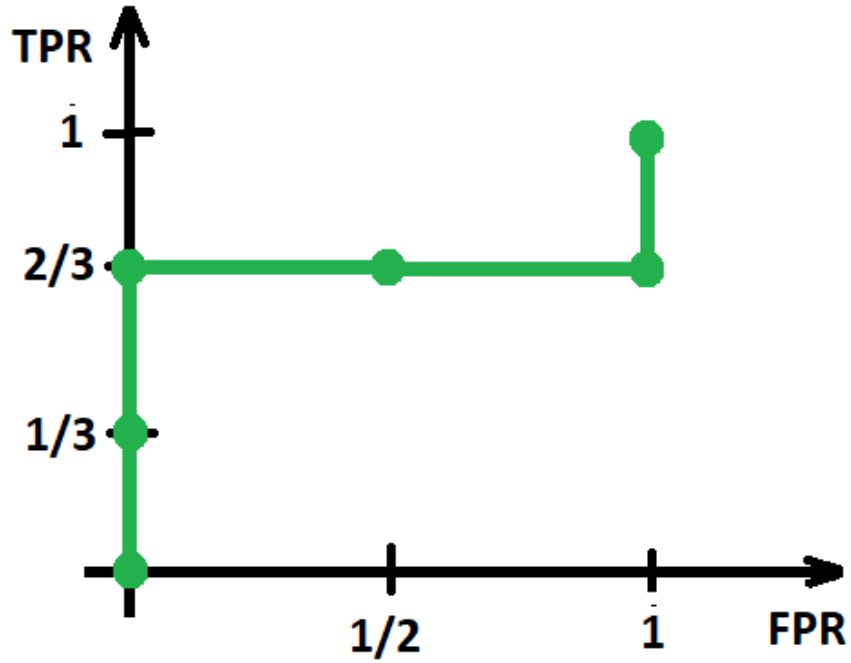

ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

$$AUC = 2/3$$

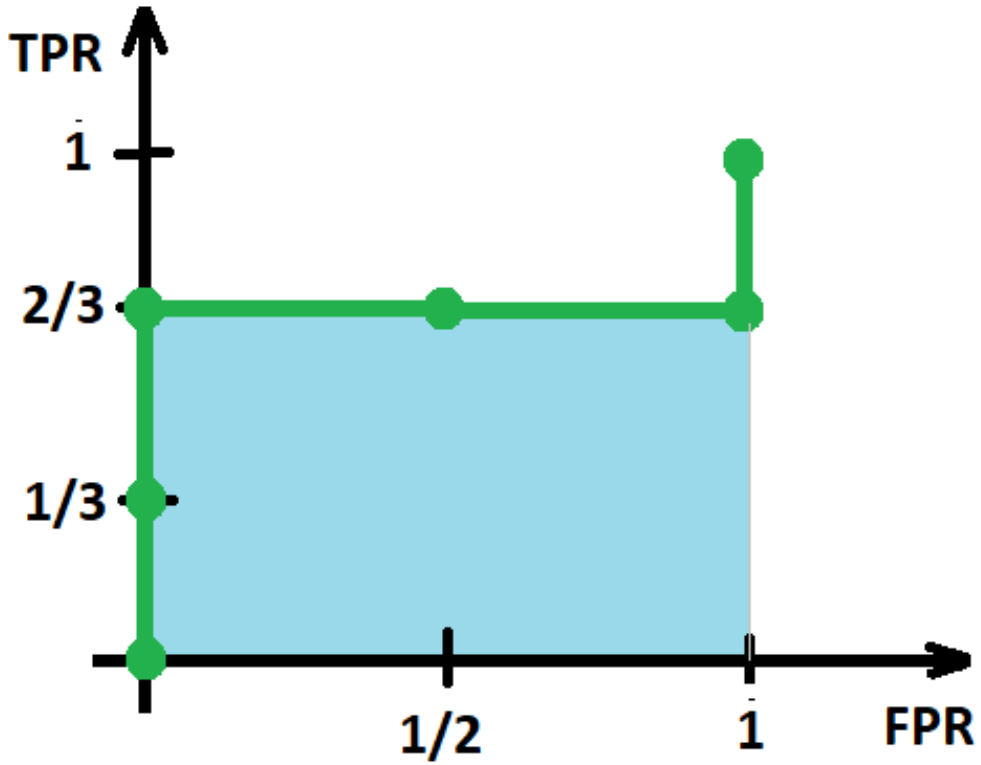

ИНДЕКС ДЖИНИ

Индекс Джини:

$$Gini = 2 \cdot AUC - 1$$

- Индекс Джини – это удвоенная площадь между главной диагональю и ROC-кривой.

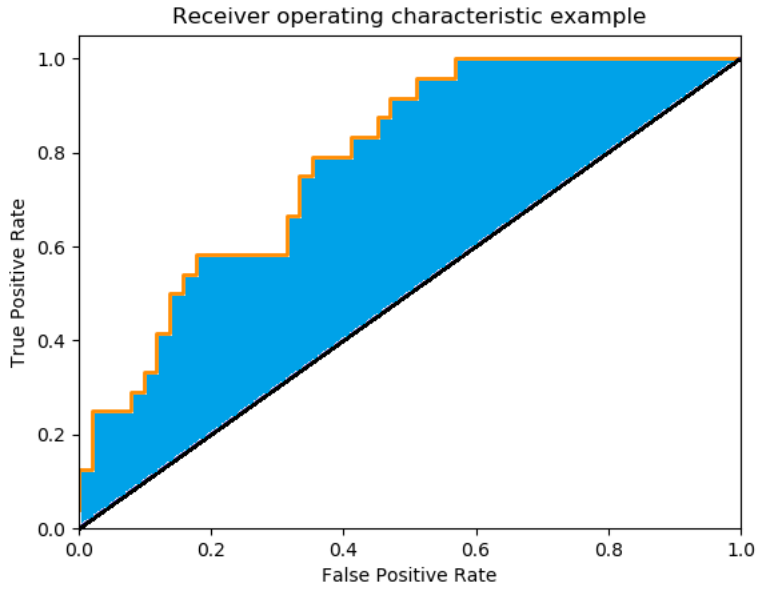

PRECISION-RECALL КРИВАЯ

- В случае малой доли объектов положительного класса AUC-ROC может давать неадекватно хороший результат

Precision-Recall кривая:

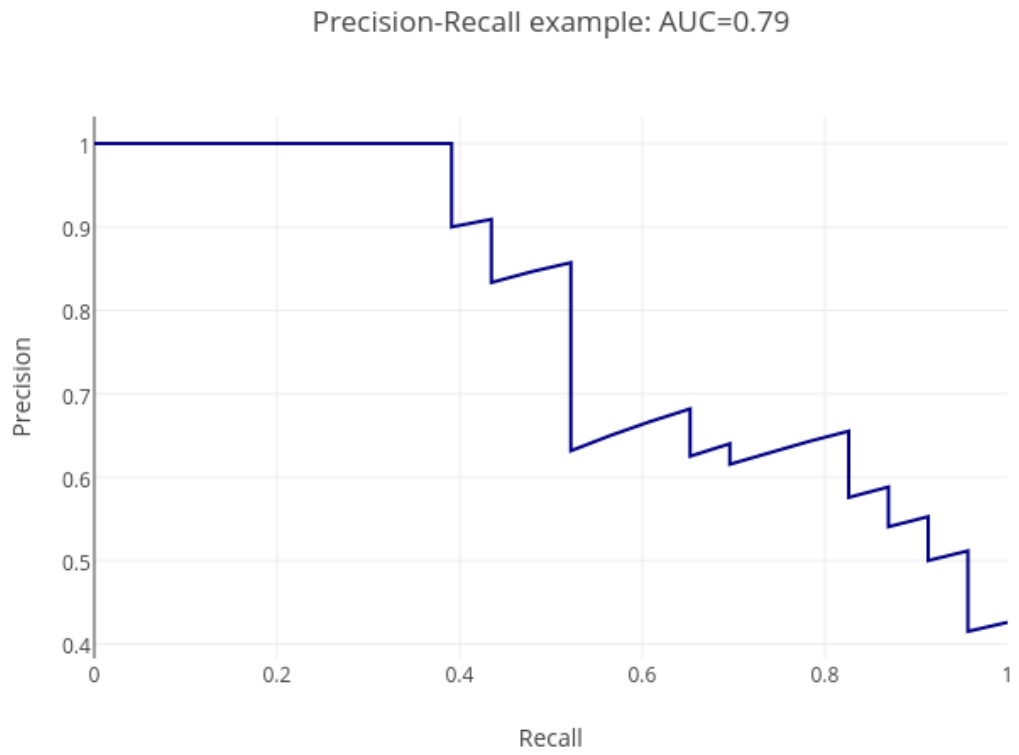

AUC-PR

AUC-PR – площадь под PR-кривой

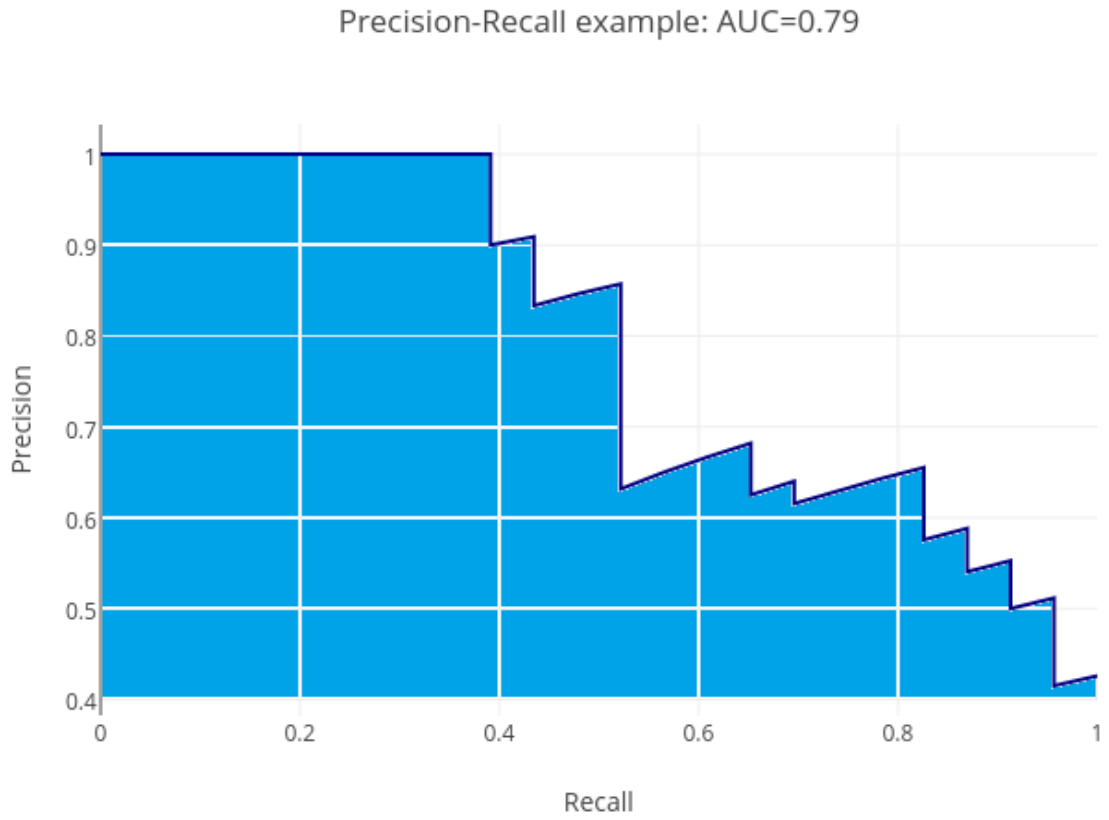

PR-кривая

- Кривая точности-полноты
- Ось X — полнота
- Ось Y — точность
- Точки — значения точности и полноты при последовательных порогах

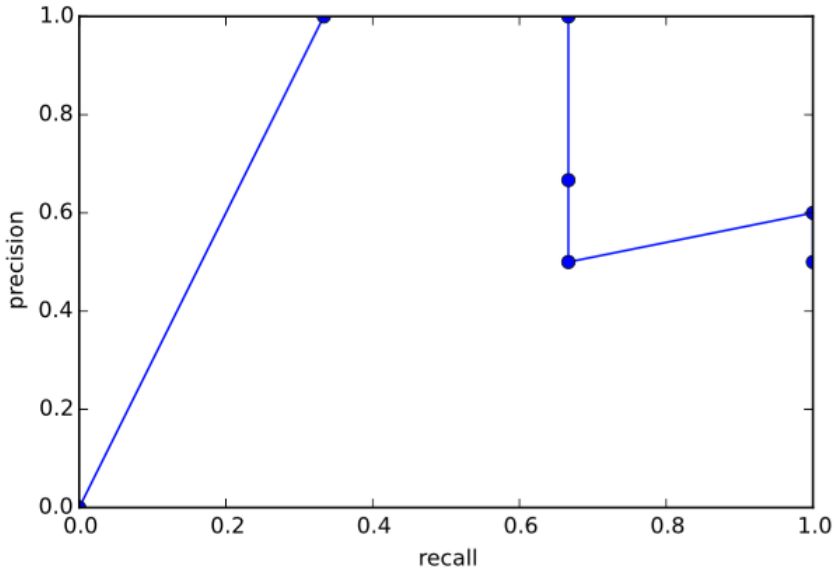

PR-кривая

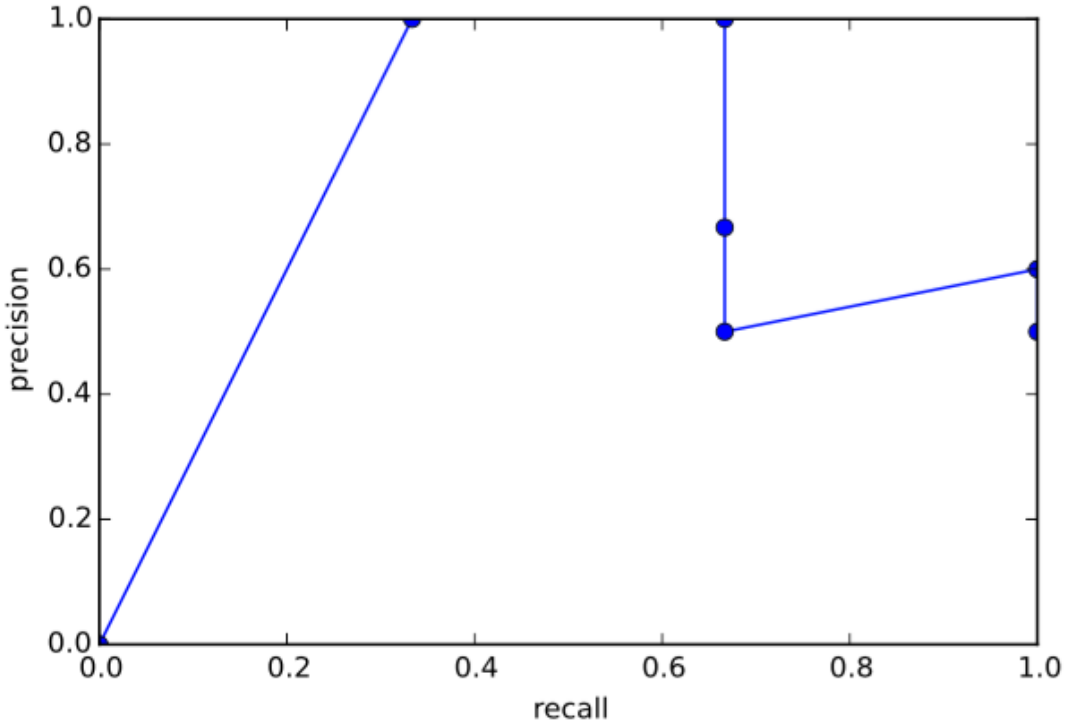

$b(x)$	0.14	0.23	0.39	0.52	0.73	0.90
y	0	1	0	0	1	1

PR-кривая

- Левая точка: (0, 0)
- Правая точка: $(1, r)$, r — доля положительных объектов
- Для идеального классификатора проходит через (1, 1)
- AUC-PRC — площадь под PR-кривой

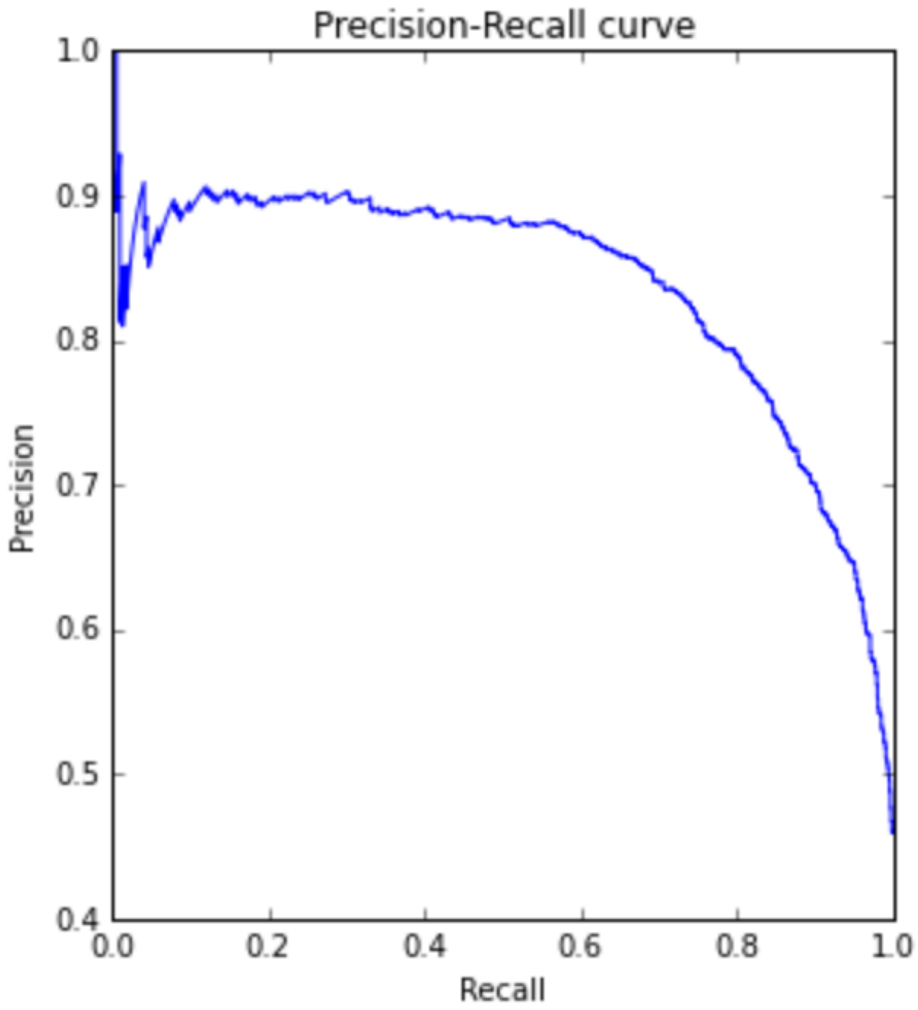

PR-кривая в реальности

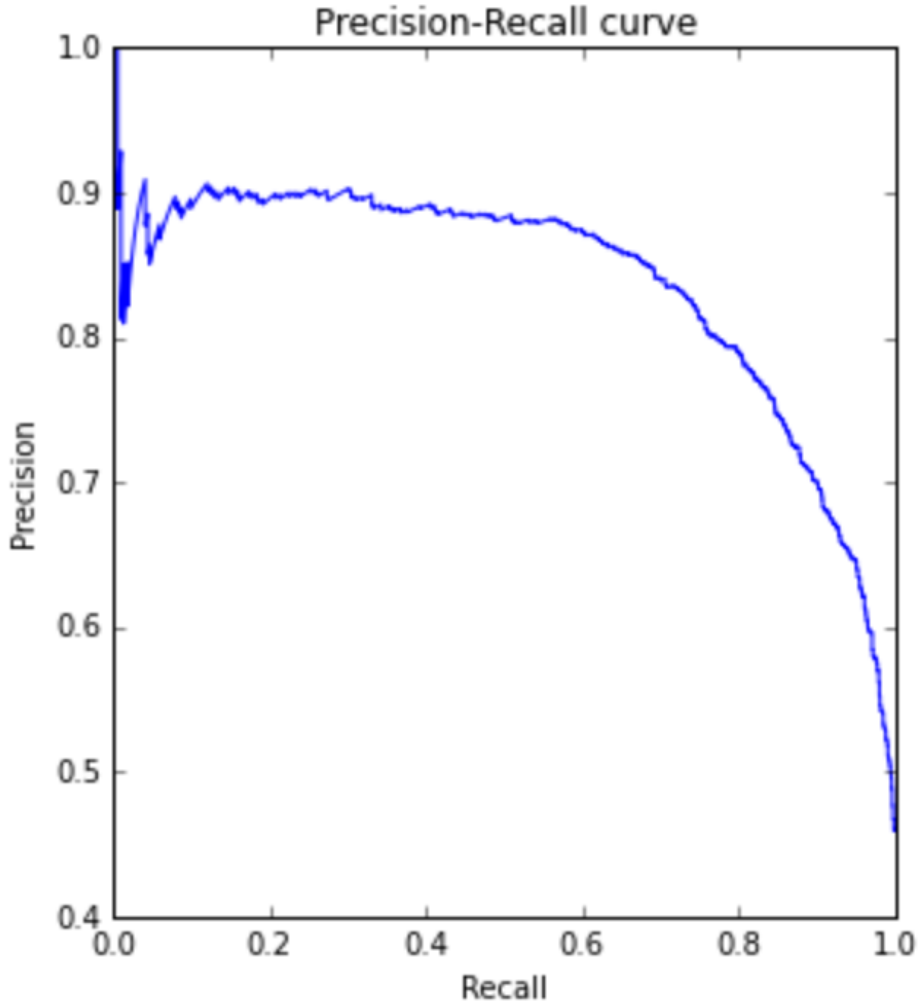

Bias-variance decomposition

$$L(\mu) = \underbrace{\mathbb{E}_{x,y}\Big[\big(y - \mathbb{E}[y \mid x]\big)^2\Big]}_{\text{шум}} +$$

$$+ \underbrace{\mathbb{E}_x\Big[\big(\mathbb{E}_X\big[\mu(X)\big] - \mathbb{E}[y \mid x]\big)^2\Big]}_{\text{смещение}} + \underbrace{\mathbb{E}_x\Big[\mathbb{E}_X\Big[\big(\mu(X) - \mathbb{E}_X\big[\mu(X)\big]\big)^2\Big]\Big]}_{\text{разброс}}$$

Bias-variance decomposition

- Можно показать, что ошибка метода обучение раскладывается на три слагаемых: шум, смещение, разброс
- Шум — как сильно ошибается лучшая модель
- Смещение — как сильно в среднем отклоняется наша модель от лучшей модели
- Разброс — как сильно может меняться модель, если немного поменять обучающую выборку

Bias-variance decomposition

Bias(a(x)) - средняя ошибка по всем возможным наборам данных – смещение.

Смещение показывает, насколько в среднем модель хорошо предсказывает целевую переменную:

✓маленькое смещение - хороший output
✓большое смещение – плохой output

Bias-variance decomposition

Var(a(x)) - дисперсия ошибки, т.е. как сильно различается ошибка при обучении на различных наборах данных – разброс.

Большой разброс означает, что ошибка очень чувствительна к изменению обучающей выборки, т.е.:

✓ большой разброс – сильно переобученная модель

Bias-variance decomposition

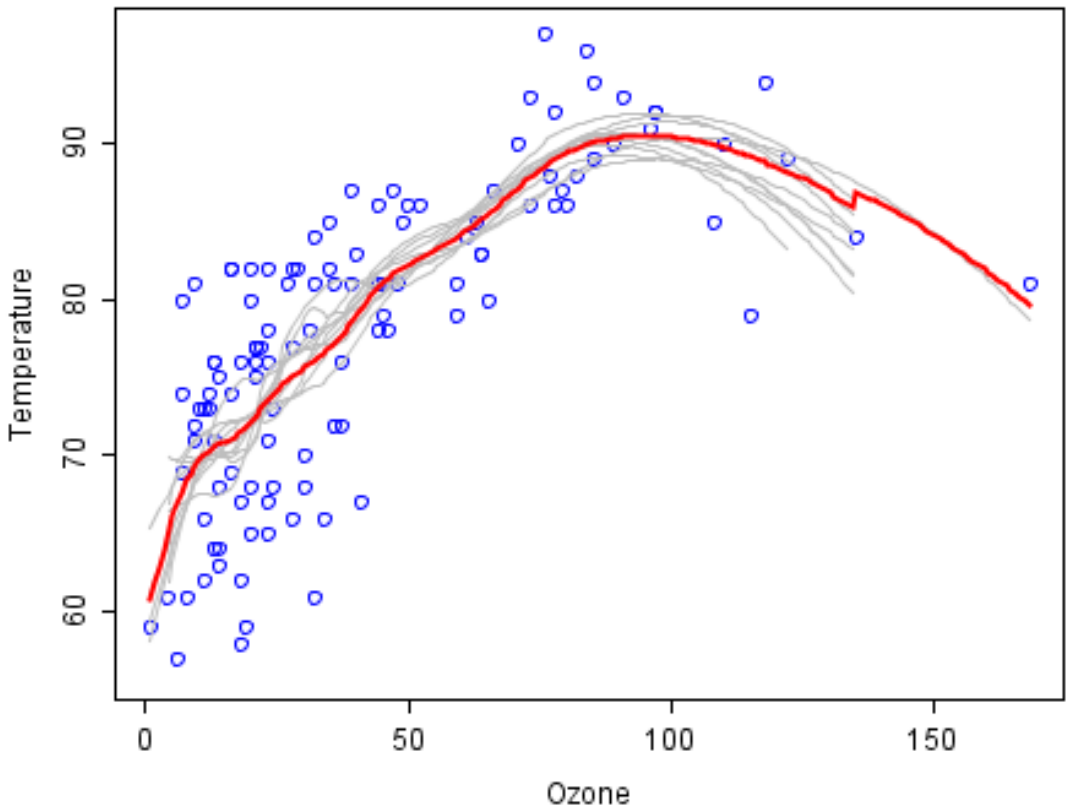

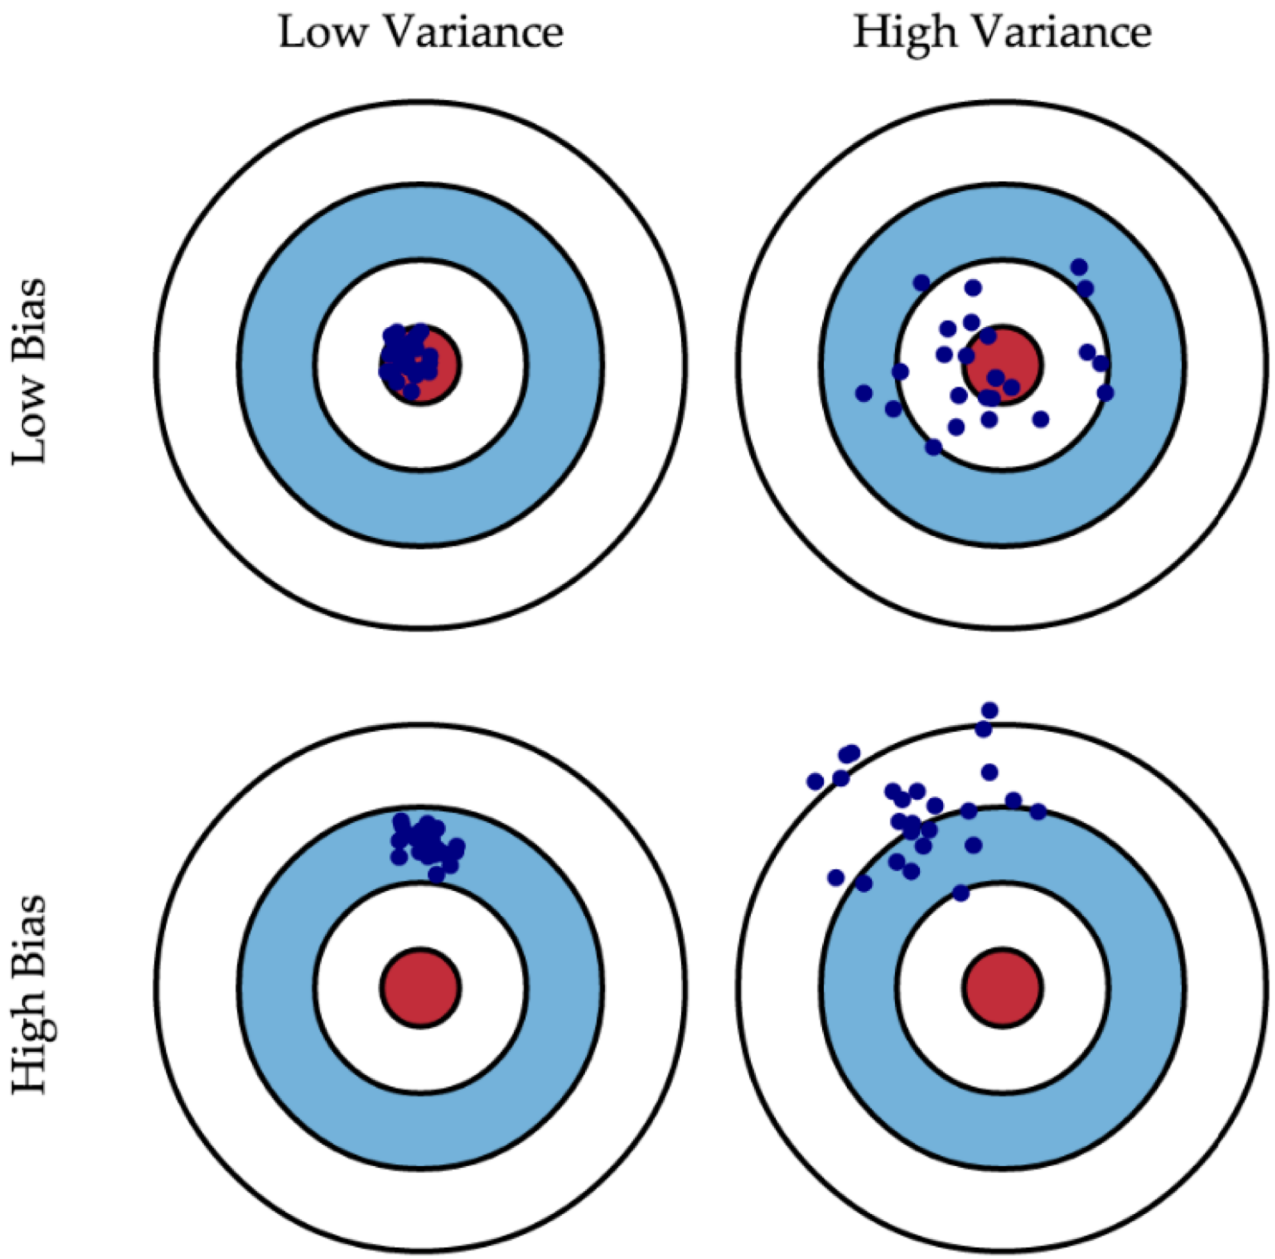
Low Variance
High Variance
Low Bias
High Bias

3. ОТБОР ПРИЗНАКОВ

VARIANCE THRESHOLD

- Можем удалить признаки, которые имеют очень маленькую дисперсию, т.е. практически константы.

ОТБОР ПРИЗНАКОВ ПО КОРРЕЛЯЦИИ С ЦЕЛЕВОЙ ПЕРЕМЕННОЙ

- Для каждого признака вычислим его корреляцию с целевой переменной. Будем выкидывать признаки, имеющие маленькую корреляцию.

БОЛЕЕ СЛОЖНЫЕ МЕТОДЫ

- Filtration methods (фильтрационные методы)
- Wrapping methods (оберточные методы)
- Model selection (встроенный в модель отбор признаков)

1. ФИЛЬТРАЦИОННЫЕ МЕТОДЫ

- **Фильтрационные методы - это отбор признаков по различным статистическим тестам.** Идея метода состоит в вычислении влияния каждого признака в отдельности на целевую переменную (с помощью вычисления некоторой статистики).

Очевидный плюс метода: скорость, так как мы вычисляем значения N статистик, где N - количество признаков.

1. ФИЛЬТРАЦИОННЫЕ МЕТОДЫ

В sklearn есть сразу несколько методов, использующих отбор по статистическим критериям. Среди них выделим следующие:

- **SelectKBest** - оставляет k признаков с наибольшим значением выбранной статистики
- **SelectPercentile** - оставляет признаки со значениями
  выбранной статистики, попавшими в заданную пользователем квантиль

1. СТАТИСТИЧЕСКИЕ ТЕСТЫ ДЛЯ ОТБОРА ПРИЗНАКОВ (ПРИМЕР)

- **Тест χ^2** используется в статистике для проверки независимости двух событий.
- Поскольку χ^2 проверяет степень независимости между двумя переменными, а мы хотим сохранить только признаки, наиболее зависимые от метки, то будем вычислять χ^2 между каждым признаком и меткой, сохраняя только признаки с наибольшими значениями.
- Критерий χ^2 можем применять только для бинарных или порядковых признаков.

1. СТАТИСТИЧЕСКИЕ ТЕСТЫ ДЛЯ ОТБОРА ПРИЗНАКОВ (ПРИМЕР)

- Статистика χ^2 вычисляется по формуле

$$\chi^2(X;Y) = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

где O_{ij} - наблюдаемая частота, E_{ij} - ожидаемая частота.

Пример: хотим выявить влияние курения на гипертонию:

	Артериальная гипертония есть (1)	Артериальной гипертонии нет (0)	**Всего**
Курящие (1)	40	30	**70**
Некурящие (0)	32	48	**80**
Всего	**72**	**78**	**150**

Вычисляем χ^2: χ^2 = (40-33.6)²/33.6 + (30-36.4)²/36.4 + (32-38.4)²/38.4 + (48-41.6)²/41.6 = 4.396.

1. СТАТИСТИЧЕСКИЕ ТЕСТЫ ДЛЯ ОТБОРА ПРИЗНАКОВ

- Статистика χ^2 вычисляется по формуле

$$\chi^2(X;Y) = \sum_{i,j} \frac{\left(O_{ij} - E_{ij}\right)^2}{E_{ij}},$$

где O_{ij} - наблюдаемая частота, E_{ij} - ожидаемая частота.

Пример: хотим выявить влияние курения на гипертонию:

	Артериальная гипертония есть (1)	Артериальной гипертонии нет (0)	**Всего**
Курящие (1)	40	30	**70**
Некурящие (0)	32	48	**80**
Всего	**72**	**78**	**150**

Вычисляем χ^2: χ^2 = (40-33.6)²/33.6 + (30-36.4)²/36.4 + (32-38.4)²/38.4 + (48-41.6)²/41.6 = 4.396.

При отборе признаков оставляем k (или заданную квантиль) признаков с наибольшим значением χ^2.

1. СТАТИСТИЧЕСКИЕ ТЕСТЫ ДЛЯ ОТБОРА ПРИЗНАКОВ

- mutual information:

для векторов X и Y статистика вычисляется по формуле

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} p(x,y) \log\left(\frac{p(x,y)}{p(x)p(y)}\right)$$

- хи-квадрат:

$$\chi^2(X;Y) = \sum_{i,j} \frac{\left(O_{ij} - E_{ij}\right)^2}{E_{ij}},$$

где O_{ij} - наблюдаемая частота, E_{ij} - ожидаемая частота.

2. ОБЕРТОЧНЫЕ МЕТОДЫ

Оберточные методы используют ***жадный отбор признаков***, т.е. последовательно выкидывают наименее подходящие по мнению методов признаки.

В sklearn есть оберточный метод - Recursive Feature Elimination (RFE).

Параметры метода:

a) алгоритм, используемый для отбора признаков (например, RandomForest)

b) число признаков, которое мы хотим оставить.

2. ЖАДНЫЙ ОТБОР ПРИЗНАКОВ

1шаг: Перебираем все признаки и убираем тот, удаление которого сильнее всего уменьшает ошибку

2 шаг: Из оставшихся признаков убираем тот, удаление которого сильнее всего уменьшает ошибку

И т.д.

3. ВСТРОЕННЫЕ В МОДЕЛЬ МЕТОДЫ

Напоминание: L_1-регуляризация умеет отбирать признаки.

$$Q(w) + \alpha \sum_{i=1}^{d} |w_j| \to \min_w$$

3. ВСТРОЕННЫЕ В МОДЕЛЬ МЕТОДЫ

Напоминание: L_1-регуляризация умеет отбирать признаки.

$$Q(w) + \alpha \sum_{i=1}^{d} |w_j| \to \min_w$$

Рассмотрим другой вариант регуляризации, которая тоже умеет отбирать признаки (L_0-регуляризация):

$$Q(w) + \alpha \sum_{i=1}^{d} [w_j \neq 0] \to \min_w$$

3. ИНФОРМАЦИОННЫЕ КРИТЕРИИ

- **Информационный критерий -** мера качества модели, учитывающая степень «подгонки» модели под данные с корректировкой (штрафом) на используемое количество параметров.
- Информационные критерии основаны на **компромиссе между точностью и сложностью модели**. Критерии различаются тем, как они обеспечивают этот баланс.

3. КРИТЕРИЙ AIC

Критерий Акаике (AIC, Akaike Information Criterion)

- Дополнительно предполагаем, что модель a – линейная.

$$AIC(a, X) = Q(a, X) + \frac{2\hat{\sigma}^2}{l} n \to min$$

Q – функционал ошибки

$\hat{\sigma}^2$ - оценка дисперсии ошибки $D(y_i - a(x_i))$

n – количество используемых признаков

l – число объектов

3. КРИТЕРИЙ AIC

Критерий Акаике (AIC, Akaike Information Criterion)

- Дополнительно предполагаем, что модель a – линейная.

$$AIC(a, X) = Q(a, X) + \frac{2\hat{\sigma}^2}{l} n \to min$$

Q – функционал ошибки

$\hat{\sigma}^2$ - оценка дисперсии ошибки $D(y_i - a(x_i))$

n – количество используемых признаков

l – число объектов

- Если Q – среднеквадратичная ошибка для линейной регрессии, и шумы нормально распределены, то

$$AIC = -\ln П + n$$

3. КРИТЕРИЙ BIC

Критерий Шварца (BIC, Bayesian Information Criterion)

$$BIC(a,X) = \frac{l}{\hat{\sigma}^2}\left(Q(a,X) + \frac{\hat{\sigma}^2 lnl}{l} n\right) \to min$$

- Если Q – среднеквадратичная ошибка для линейной регрессии, и шумы нормально распределены, то

$$BIC = -\ln П + \frac{n}{2} lnl$$

3. ОТБОР ПРИЗНАКОВ С ПОМОЩЬЮ ИНФОРМАЦИОННЫХ КРИТЕРИЕВ

- Если в модели k признаков (регрессоров), то существует 2^k всевозможных моделей
- В идеале необходимо построить все 2^k моделей, для каждой посчитать значение критерия качества (AIC, BIC) и выбрать модель, лучшую по этому критерию
- При большом количестве регрессоров используют метод включений-исключений (жадный отбор признаков)

3. ПРИМЕР

Задача предсказания уровня преступности в разных штатах по следующим признакам:

Регрессор
Нулевой коэффициент
Возраст
Южный штат(да/нет)
Образование
Расходы
Труд
Количество мужчин
Численность населения
Безработные (14-24)
Безработные (25-39)
Доход

3. ПРИМЕР: ОТБОР ПРИЗНАКОВ ПО AIC

- Мы решаем задачу линейной регрессии с предположением, что ошибки нормально распределены, поэтому $AIC = \ln \Pi(a, X) - n \to max$.

В модели с полным набором регрессоров AIC = -310.37. В порядке убывания AIC при удалении каждой из переменных равен:

Численность населения (AIC = -308), Труд (AIC = -309), Южный штат (AIC = -309), Доход (AIC = -309), Количество мужчин (AIC = -310), Безработные I (AIC = -310), Образование (AIC = -312), Безработные II (AIC = -314), Возраст (AIC = -315), Расходы (AIC = -324).

Таким образом, имеет смысл удалить переменную “Население”.

3. ПРИМЕР: ОТБОР ПРИЗНАКОВ ПО AIC

Южный штат (AIC = -308), Труд (AIC = -308), Доход (AIC = -308), Количество мужчин (AIC = -309), Безработные I (AIC = -309), Образование (AIC = -310), Безработные II (AIC = -313), Возраст (AIC = -313), Расходы (AIC = -329).

Удаляем переменные до тех пор, пока не удастся больше получить увеличения AIC.

Уровень преступности = 1.2 Возраст + 0.75 Образование + 0.87 Расходы + 0.34 Количество мужчин − 0.86 Безработные I + 2.31 Безработные II.

Параметры и гиперпараметры

Простой пример

- Максимизируем удовлетворённость студентов
- Обучающая выборка — время до сессии
- Контрольная выборка — сессия
- Параметр — продолжительность лекции
- Гиперпараметр — минимальная продолжительность лекции

Простой пример

- Максимизируем удовлетворённость студентов
- Обучающая выборка — время до сессии
- Контрольная выборка — сессия
- Параметр — продолжительность лекции
- Гиперпараметр — минимальная продолжительность лекции

- Максимальная удовлетворённость на обучении — если не ограничивать продолжительность
- Но оценки во время сессии будут ужасными

Переобучение

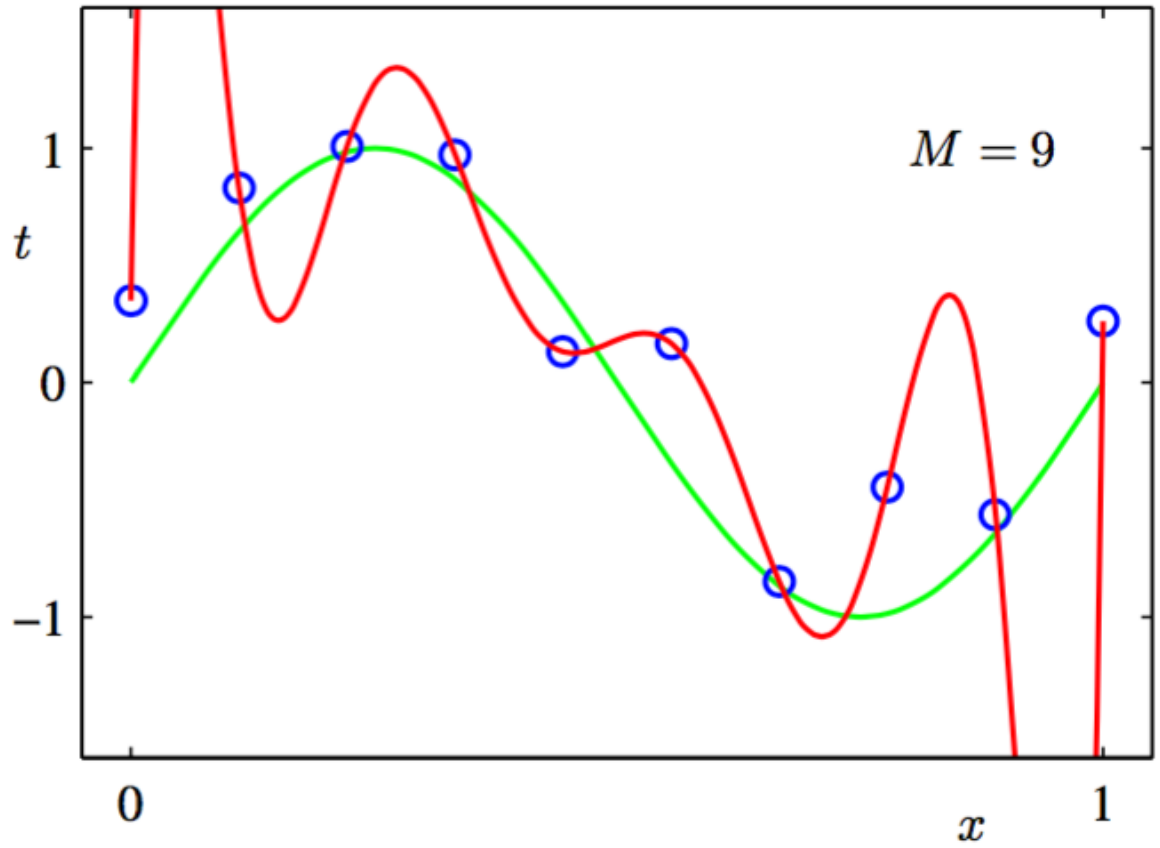

Регуляризация

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(\langle w, x_i\rangle - y_i)^2 + \lambda\|w\|^2 \to \min_w$$

Гиперпараметры

- Параметры модели — веса w
  - Позволяют подогнать модель под обучающую выборку
  - Настраиваются по обучающей выборке
- Гиперпараметр модели — коэффициент регуляризации λ
  - Определяют сложность модели
  - Лучшее качество на обучении достигается при $\lambda = 0$
  - Необходимо настраивать по другим данным

Гиперпараметры

Без регуляризации

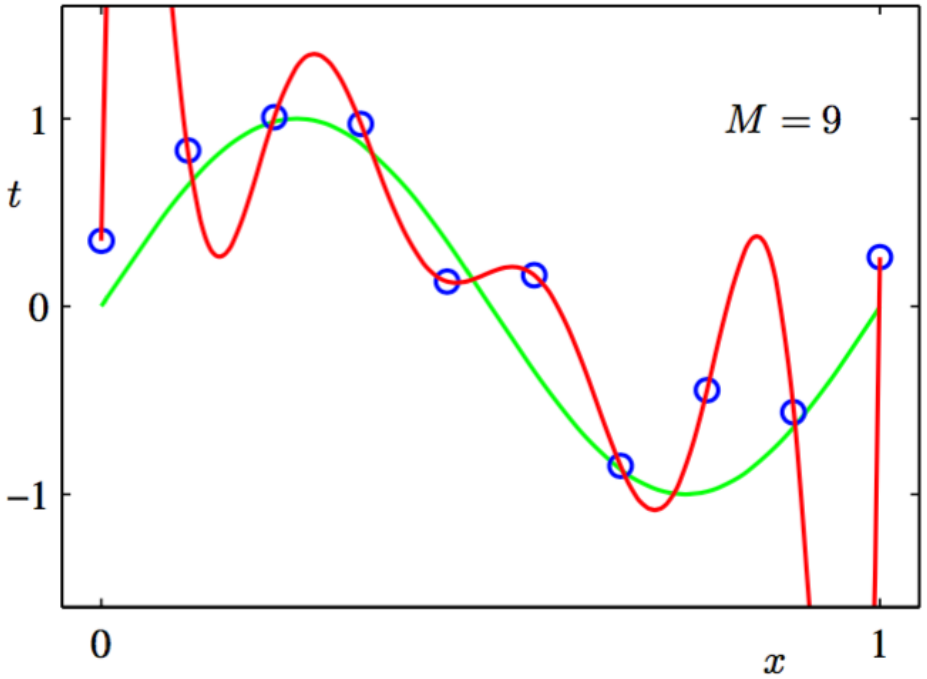

Высокое качество на обучении

С регуляризацией

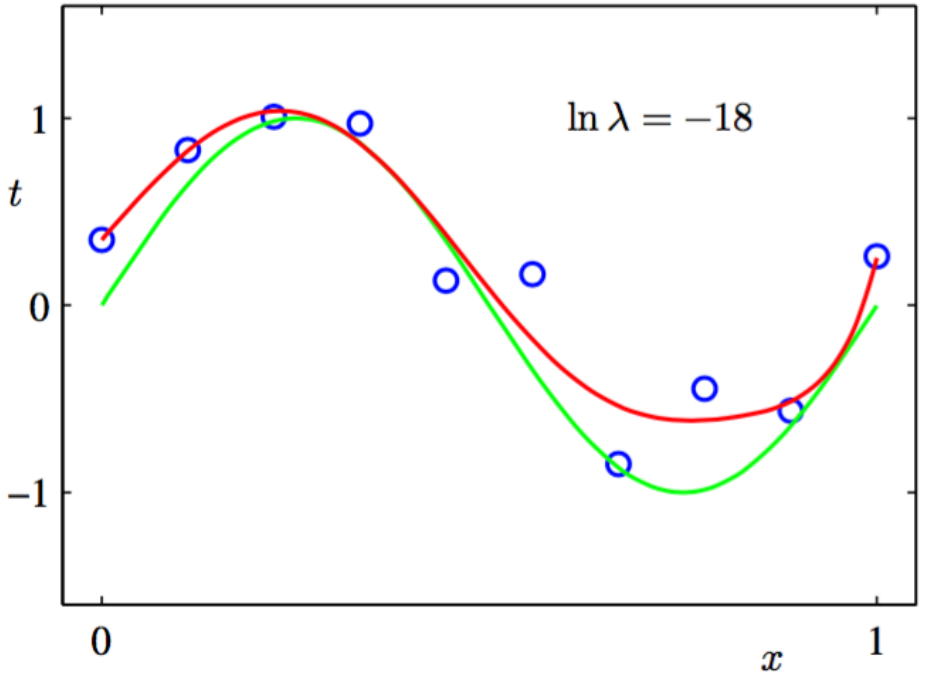

Качество на обучении ниже

Гиперпараметры

Без регуляризации

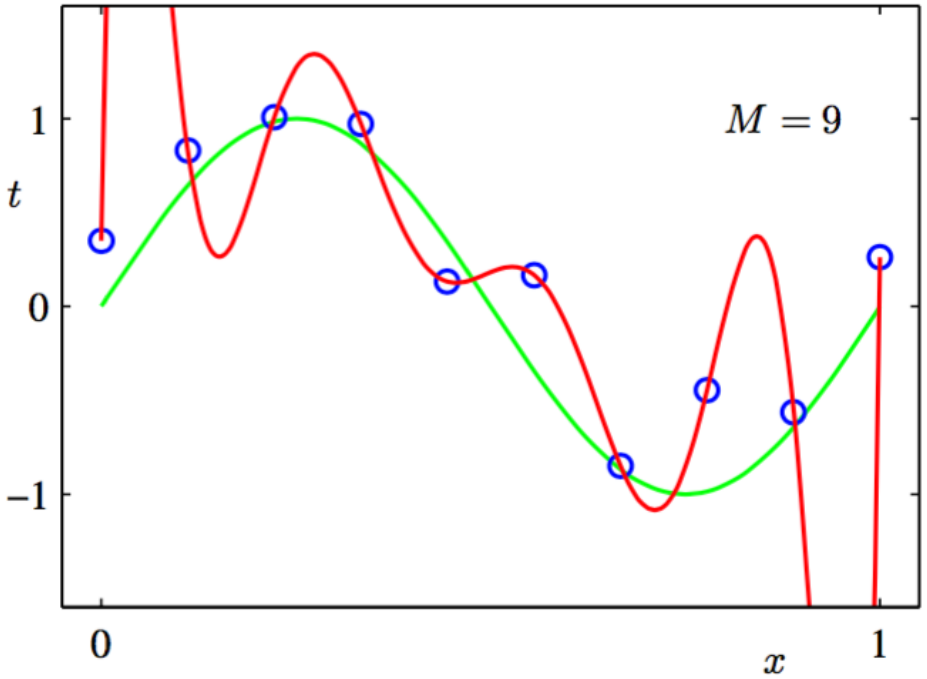

Низкая обобщающая способность

С регуляризацией

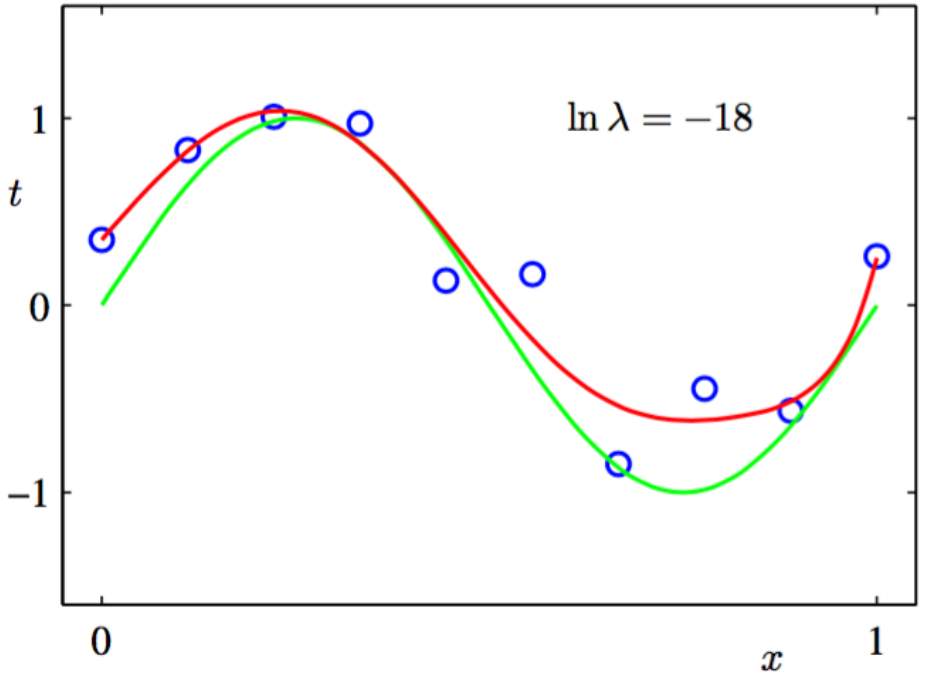

Высокая обобщающая способность