Кластеризация

Обучение с учителем (supervised learning)

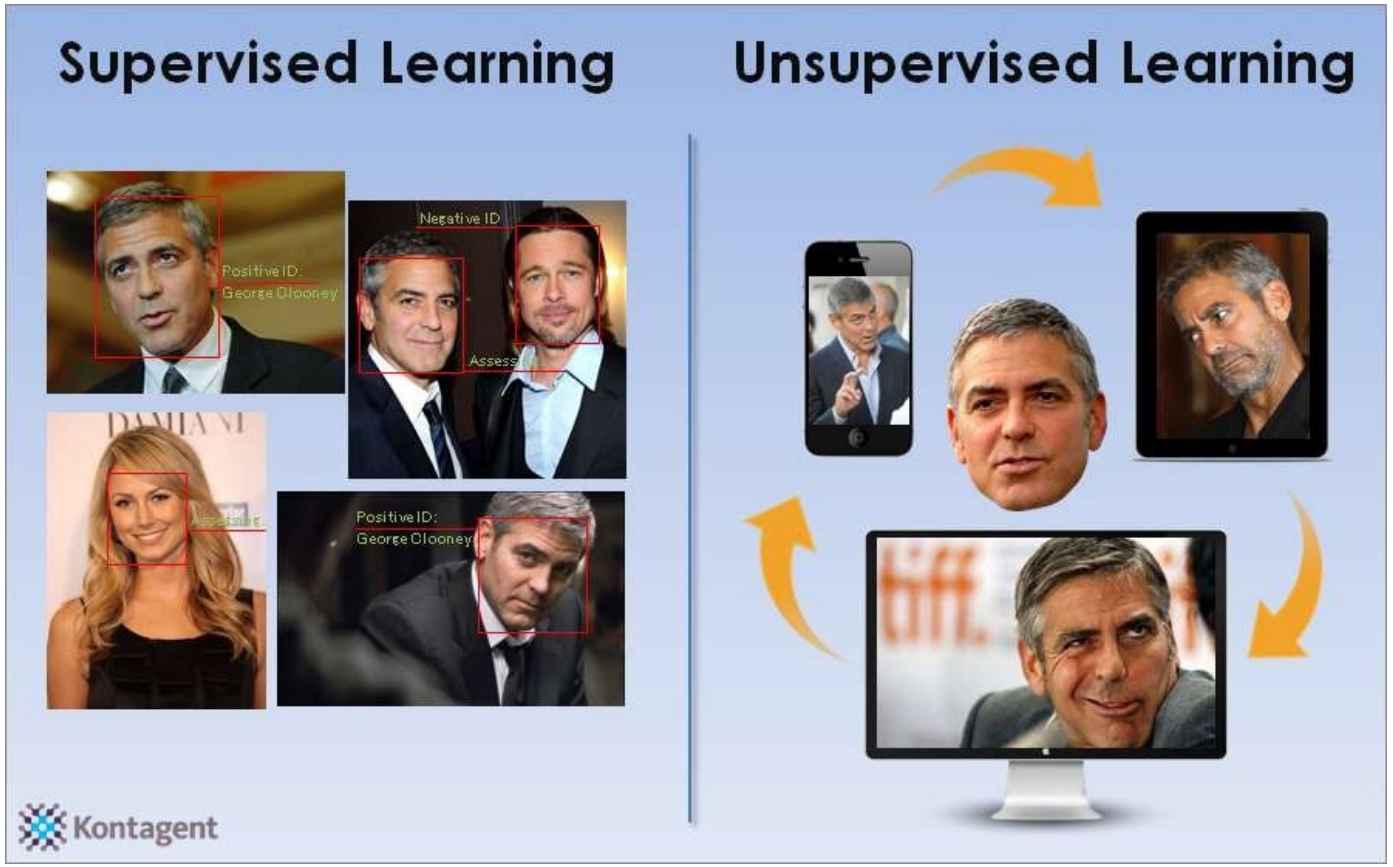
- Для каждого объекта известен ответ (класс или число)
- Даны примеры объектов с ответами
- Нужно построить модель, которая будет предсказывать ответы для новых объектов

Обучение без учителя (unsupervised learning

- Даны объекты
- Нужно найти в них внутреннюю структуру
- Примеры:
  - Кластеризация
  - Обнаружение аномалий
  - Тематическое моделирование
  - Визуализация
  - …
- Ближе к обучению в реальной жизни

Тематическое моделирование — это метод анализа текстовых данных, который используется для выявления скрытых тем в большом объеме текстовой информации.

Обучение с учителем и без учителя



Кластеризация

- Дано: матрица «объекты-признаки» X
- Найти:
  1. Множество кластеров Y
  2. Алгоритм кластеризации $a(x)$, который приписывает каждый объект к одному из кластеров

- Каждый кластер состоит из похожих объектов
- Объекты из разных кластеров существенно отличаются

Отличия

Обучение с учителем

- Цель: минимизация функционала ошибки
- Множество ответов известно заранее
- Конкретные способы измерения качества

Кластеризация

- Нет строгой постановки
- Множество кластеров неизвестно
- Правильные ответы отсутствуют— сложно измерить качество

Зачем кластеризовать?

- Маркетинг: выявление типичных групп покупателей
- Модерация: проверка только одного сообщения из кластера
- UI/UX: каталогизация фотографий (по людям, по местам, …)

Виды кластеризации

Форма кластеров

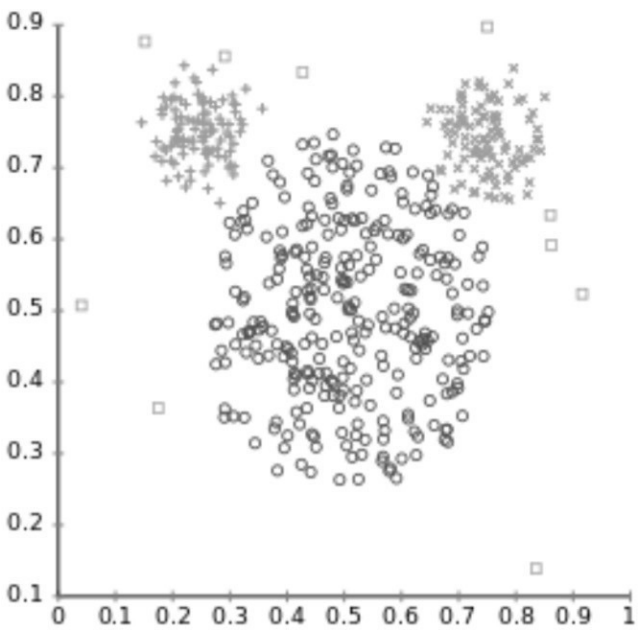


Форма кластеров

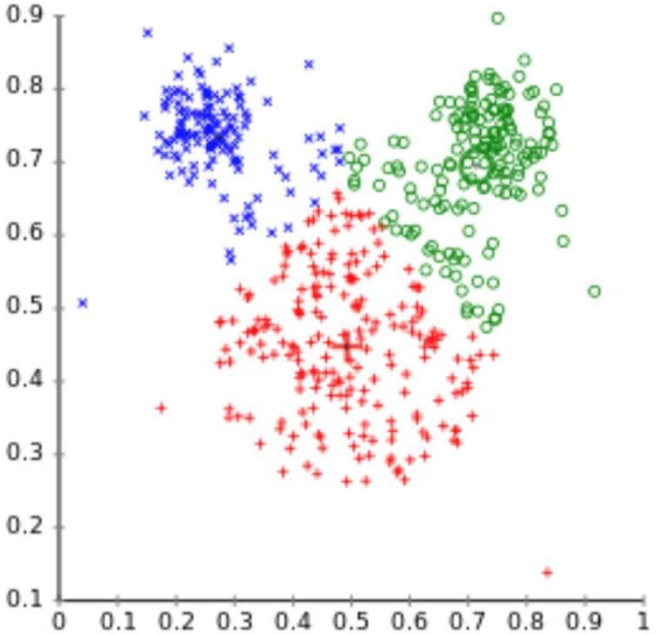




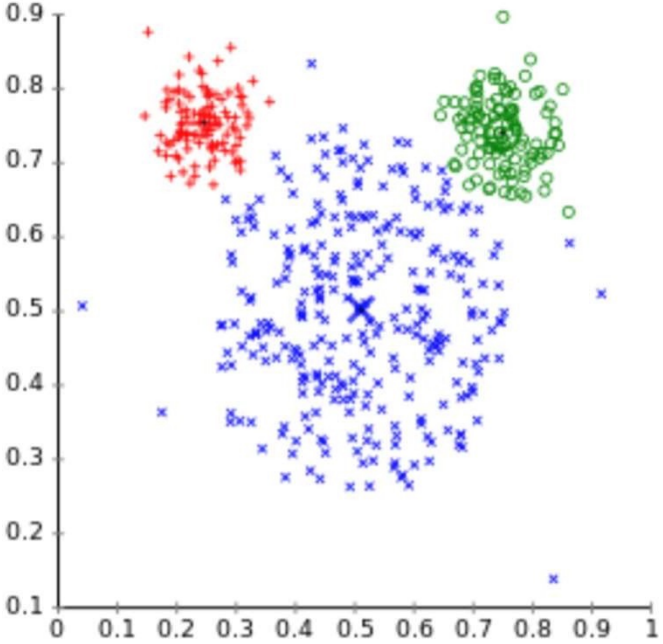
Различия в результатах работы



Исходная выборка
("Mouse" dataset)



Метод 1

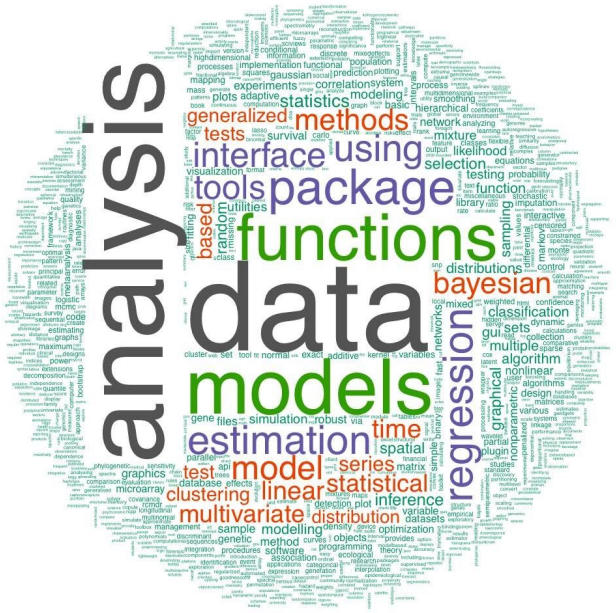


Метод 2

«Жесткая» и «мягкая» кластеризации

Кластеризация для выделения «тем»







В жесткой кластеризации каждый объект принадлежит только одному кластеру. Это означает, что объекты четко разделены на группы, и нет перекрытия между кластерами. Примеры методов жесткой кластеризации включают:

K-средних (K-means): алгоритм, который делит данные на K кластеров, минимизируя внутрикластерные расстояния.

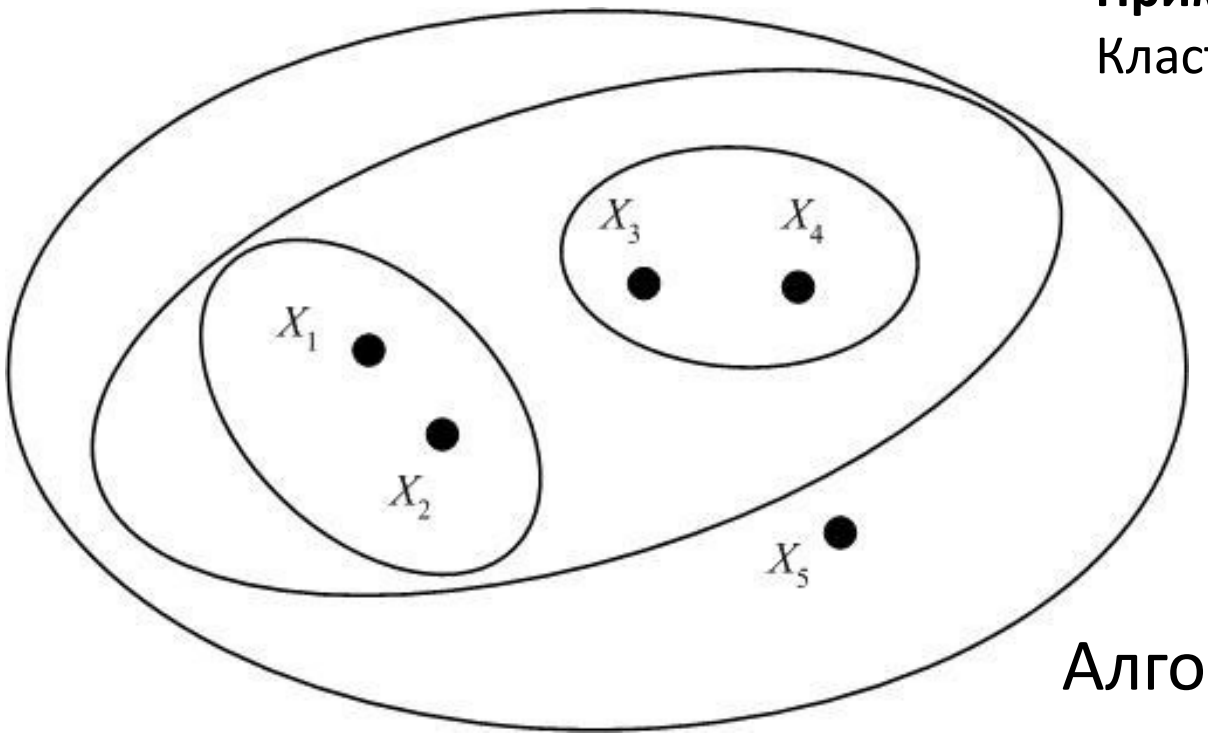
Иерархическая кластеризация: создает дерево кластеров, где на каждом уровне можно видеть, как объекты группируются.

В мягкой кластеризации объекты могут принадлежать нескольким кластерам с определенной вероятностью или степенью принадлежности. Это позволяет более гибко учитывать неопределенности и перекрытия между кластерами. Примеры методов мягкой кластеризации включают:

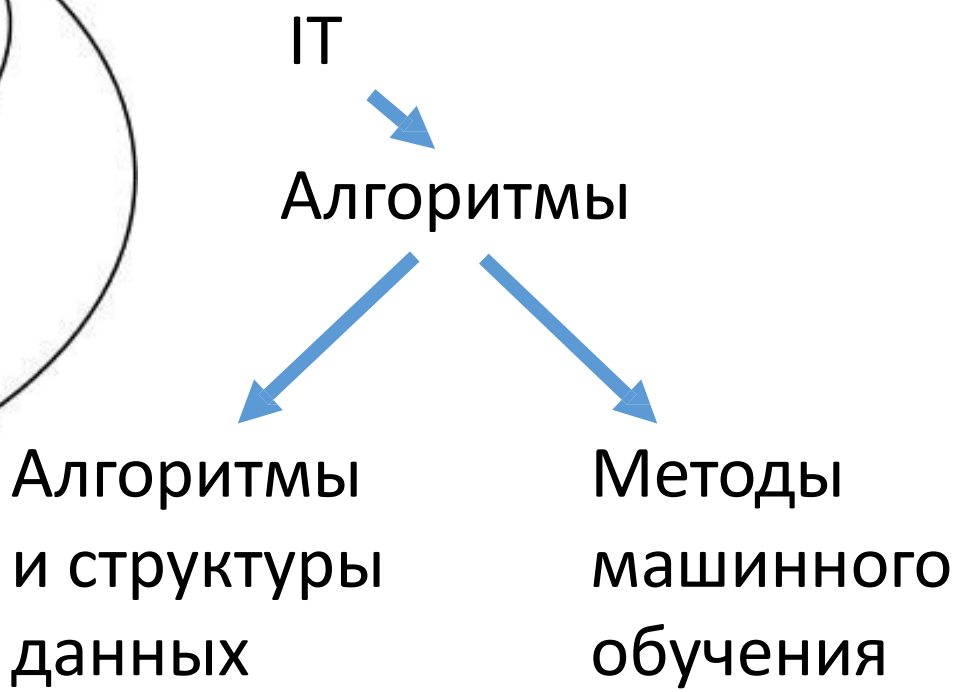
Fuzzy C-means: аналог K-средних, но каждый объект имеет степень принадлежности к каждому кластеру.

Gaussian Mixture Models (GMM): предполагает, что данные распределены по нескольким гауссовым распределениям, и каждый объект имеет вероятность принадлежности к каждому из них.

Иерархическая кластеризация



Пример:
Кластеризация статей на Хабре

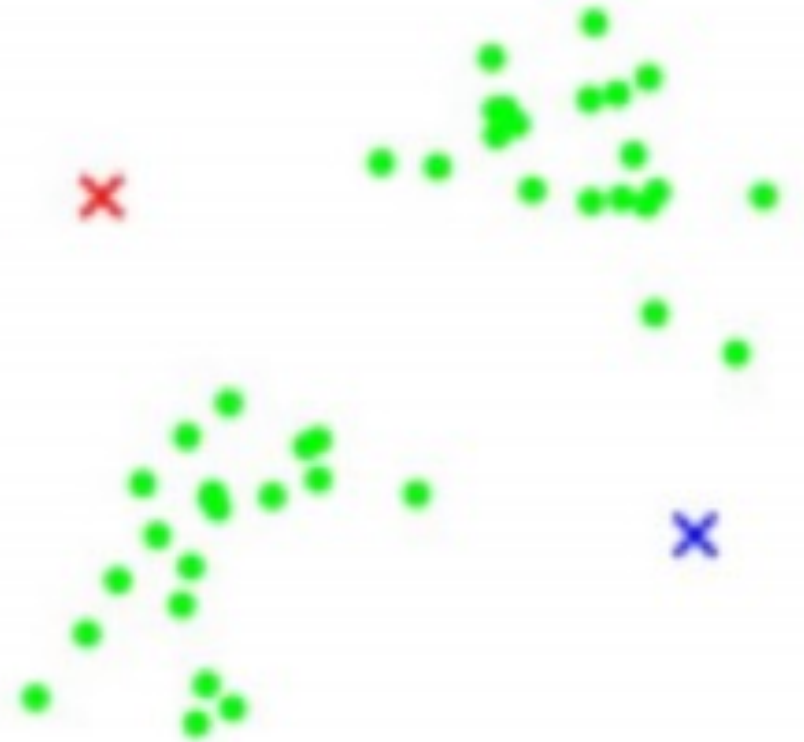


K-Means

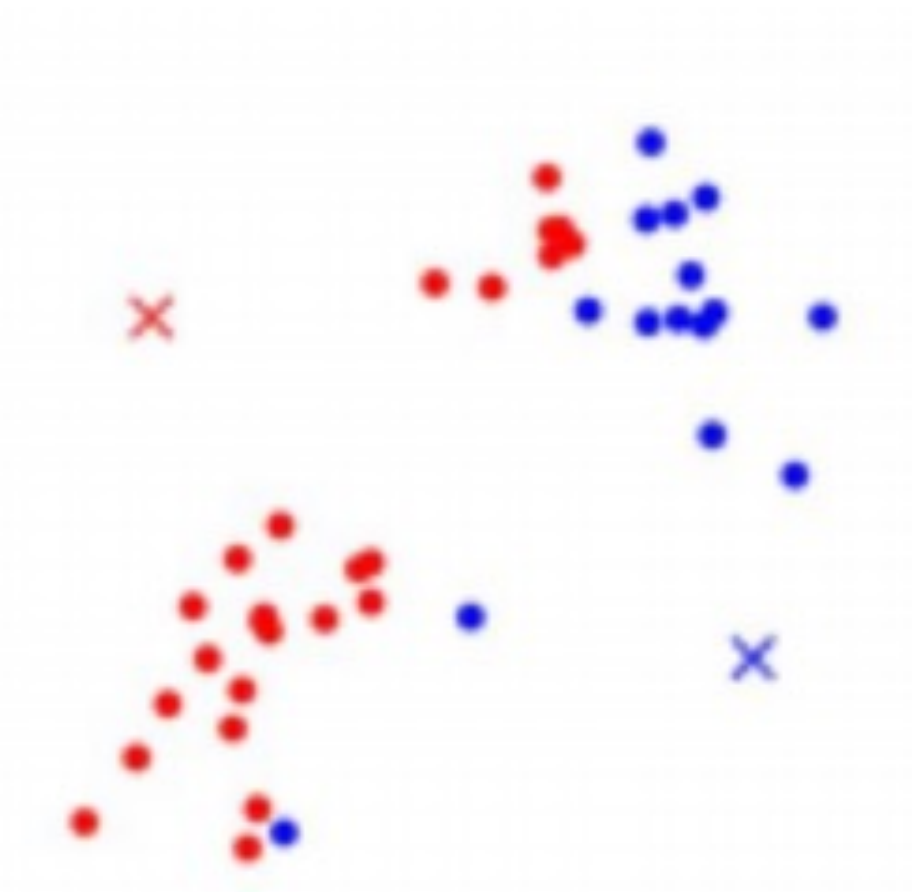
K Means



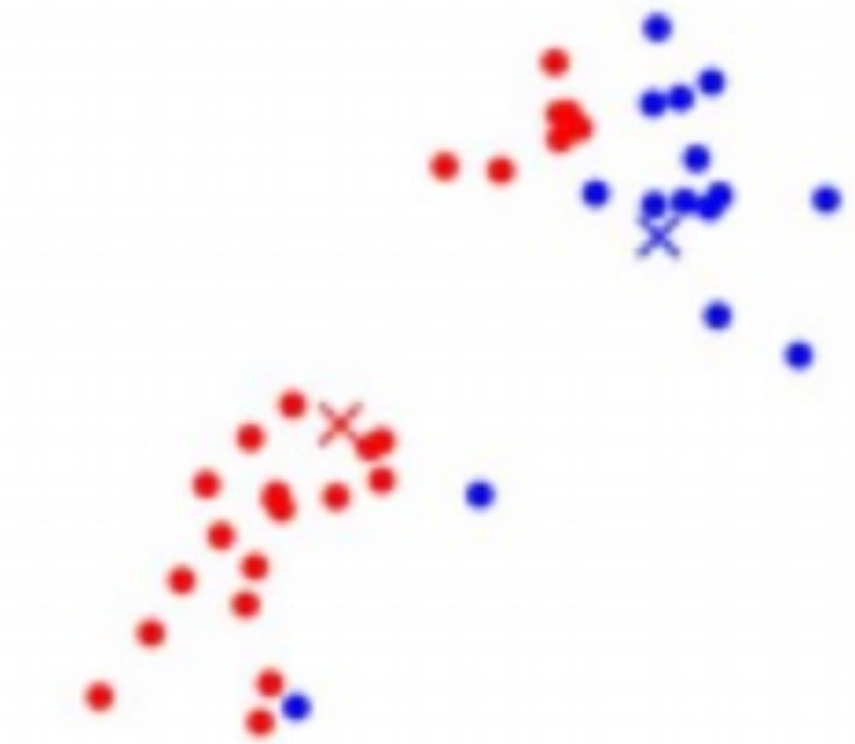
Как работает K Means



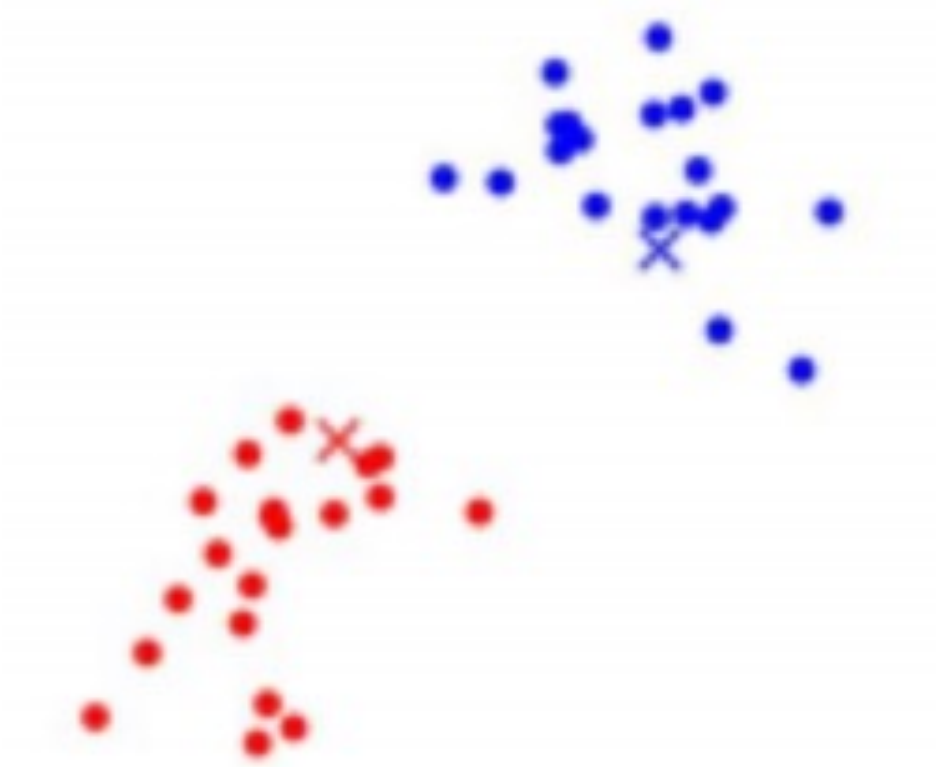
Как работает K Means



Как работает K Means



Как работает K Means



Как работает K Means



K-Means

- Дано: выборка $x_1, \dots, x_\ell$
- Параметр: число кластеров K
- Начало: случайно выбрать K центров кластеров $c_1, \dots, c_K$
- Повторять по очереди до сходимости:
  - Шаг А: отнести каждый объект к ближайшему центру

$$y_i = \arg\min_{j=1,\dots,K} \rho(x_i, c_j)$$

  - Шаг Б: переместить центр каждого кластера в центр тяжести

$$c_j = \frac{\sum_{i=1}^{\ell} x_i [y_i = j]}{\sum_{i=1}^{\ell} [y_i = j]}$$

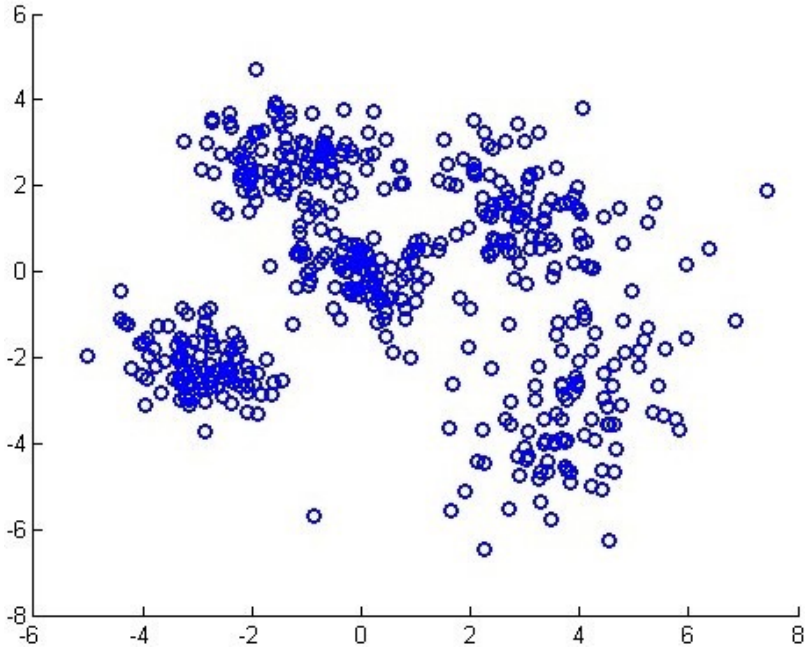
Выбор числа кластеров

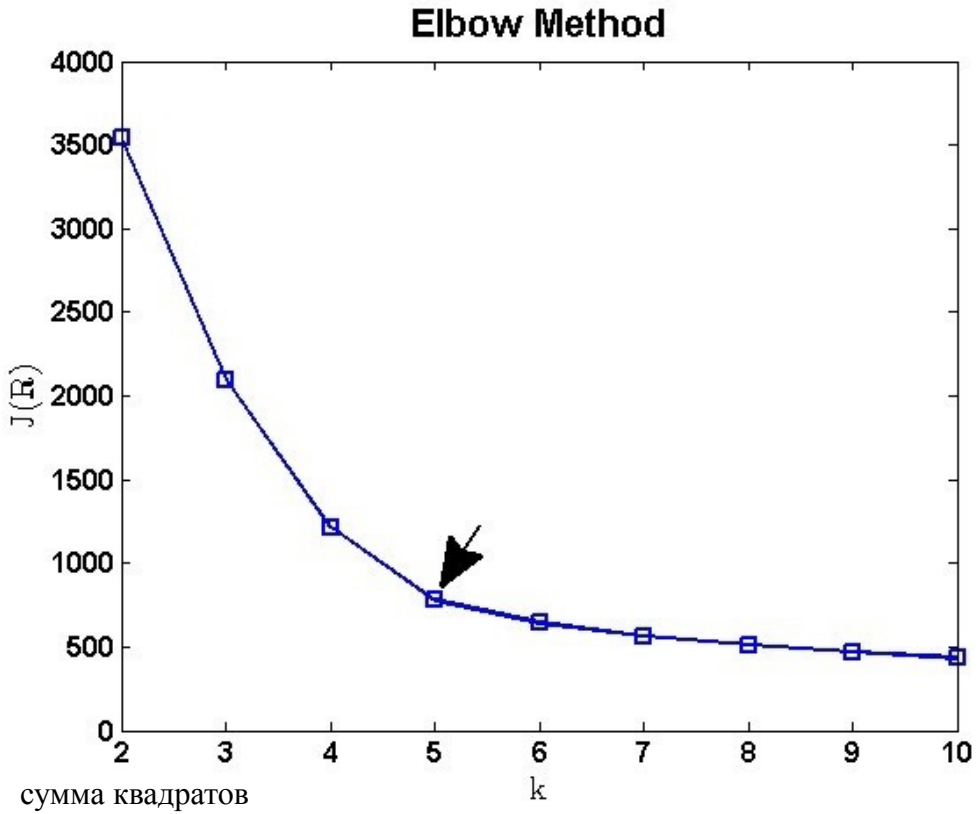
- Качество кластеризации: внутрикластерное расстояние

$$J(C) = \sum_{i=1}^{\ell} \rho\left(x_i, c_{y_i}\right)$$

- Зависит от K
- Нужно подобрать такое K, после которого качество меняется не слишком сильно

Выбор числа кластеров





сумма квадратов
внутрикластерных расстояний

Особенности K-Means

- Может работать с большими объёмами данных
- Подходит для кластеров с простой геометрией
- Требует выбора числа кластеров

Силуэт как метрика качества

Для каждого объекта i рассчитываются два значения:

a(i): Среднее расстояние от объекта i до всех других объектов в том же кластере. Это значение показывает, насколько близки объекты внутри одного кластера.

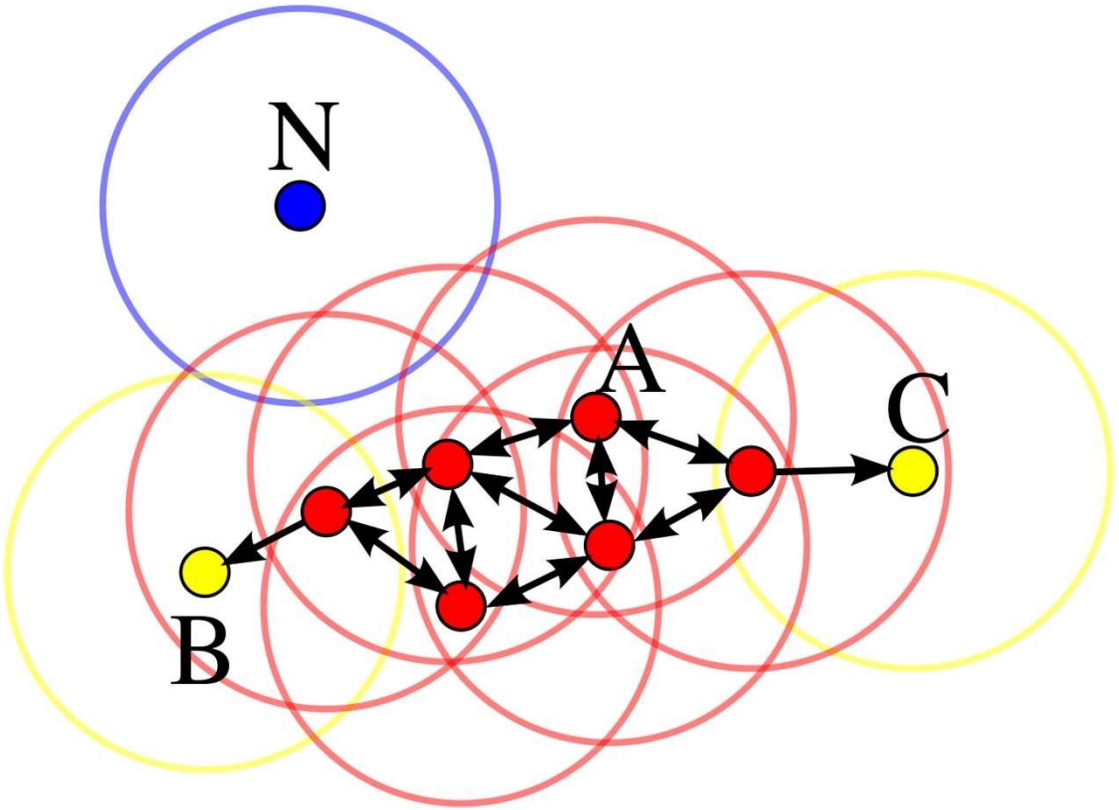
b(i): Среднее расстояние от объекта i до всех объектов в ближайшем кластере (кластере, отличном от того, к которому принадлежит объект i). Это значение показывает, насколько близки объекты к другим кластерам.

Силуэт для объекта i рассчитывается по формуле:
(b - a) / max(a, b)

Density-based clustering

Density-based clustering (кластеризация на основе плотности) — это метод кластеризации, который группирует данные на основе плотности распределения точек в пространстве.

Основные, граничные и шумовые точки



Основные (ядровые) точки: Это точки, которые имеют не менее заданного числа соседей (MinPts) в пределах радиуса ε (epsilon). Основные точки служат центрами кластеров. Они могут инициировать формирование кластера, так как вокруг них достаточно плотности точек.

Граничные точки: Это точки, которые находятся в пределах радиуса ε от основной точки, но не имеют достаточного количества соседей, чтобы быть основной точкой (т.е. у них меньше MinPts соседей).

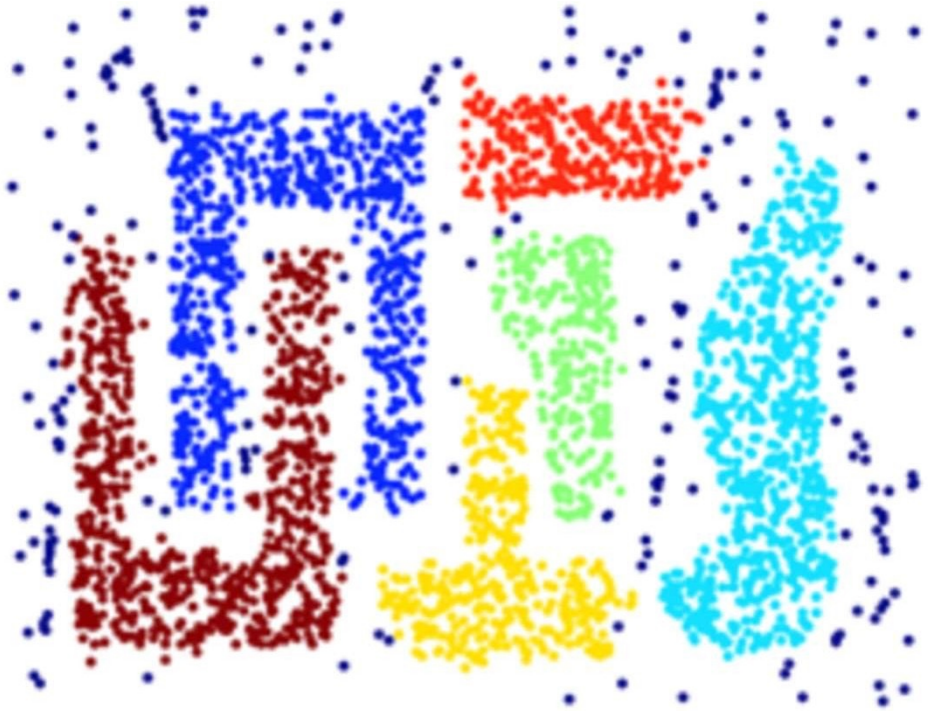
Шумовые точки: Это точки, которые не являются ни основными, ни граничными. Они не имеют достаточной плотности соседей, чтобы быть частью кластера.

Параметры DBSCAN

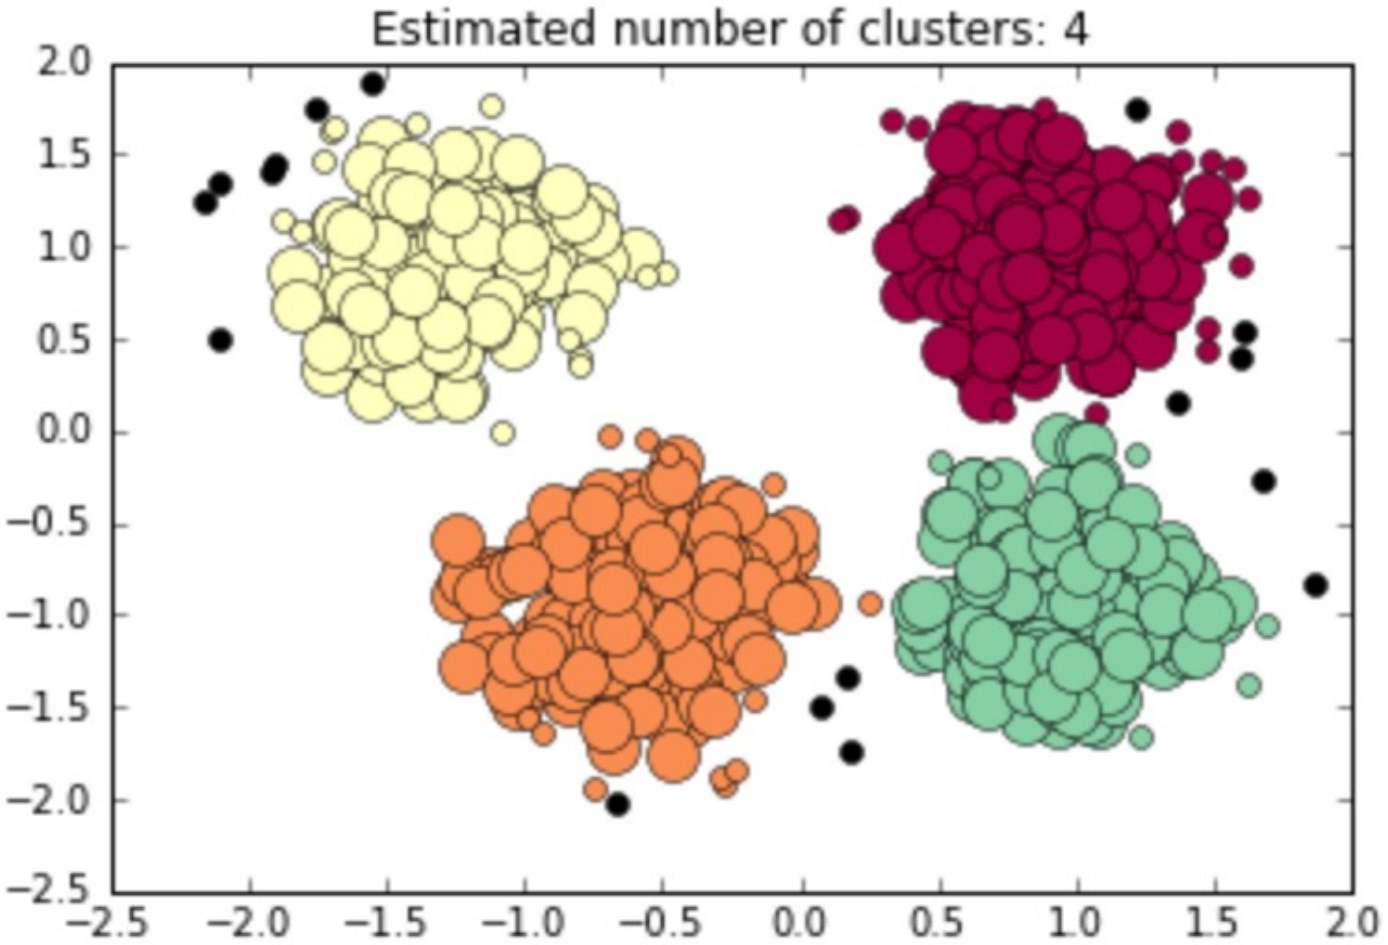
DBSCAN (Density-Based Spatial Clustering of Applications with Noise) — это алгоритм кластеризации, основанный на плотности, который используется для выявления кластеров в данных с произвольной формой и для обработки выбросов.

- Размер окрестности (eps)
- Минимальное число объектов в окрестности — для определения основных точек

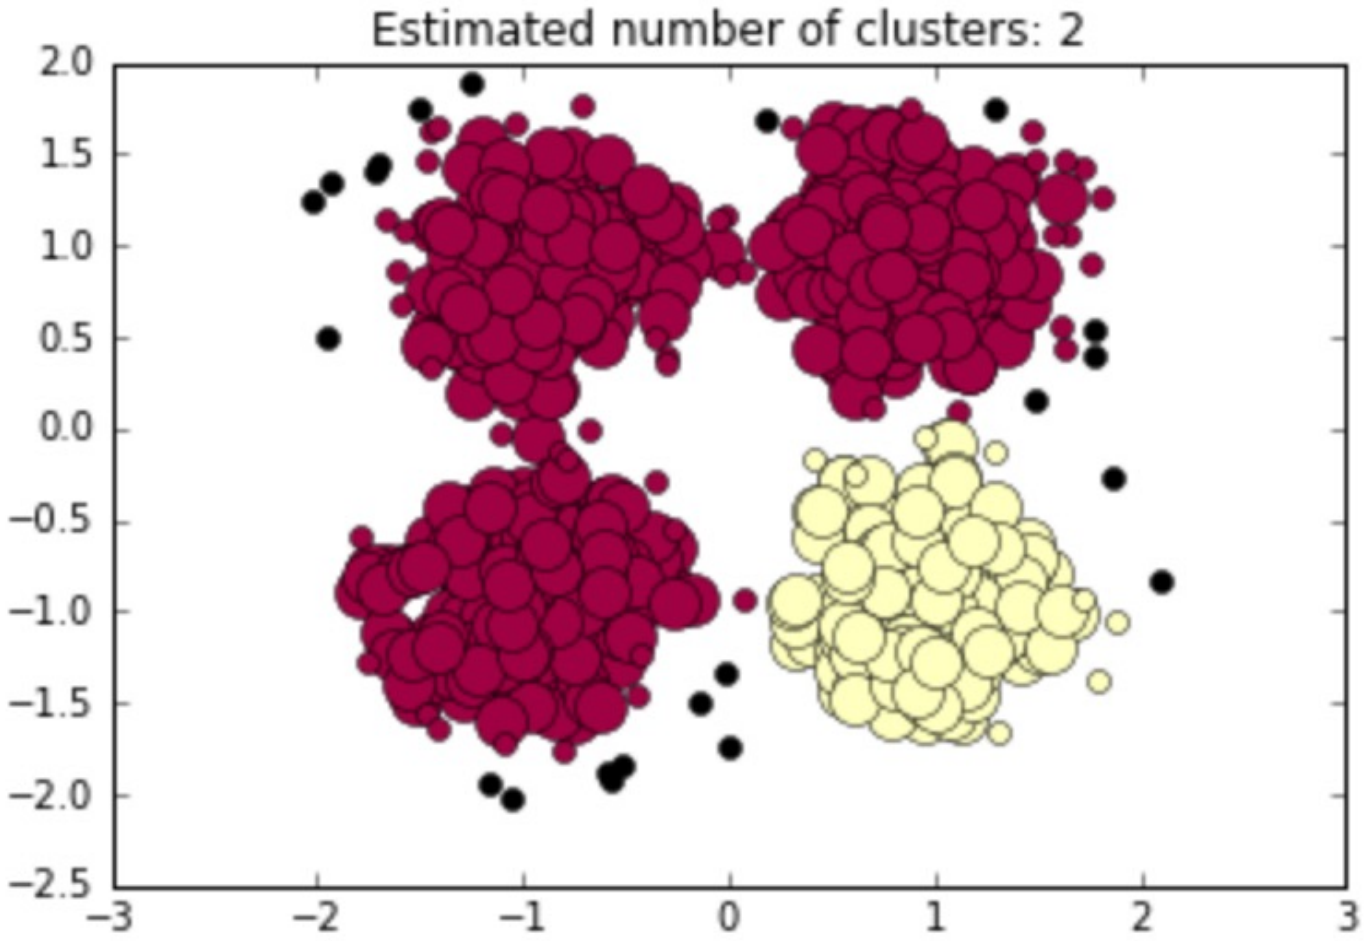
DBSCAN: результаты работы



Определение числа кластеров в DBSCAN



Определение числа кластеров в DBSCAN



Особенности DBSCAN

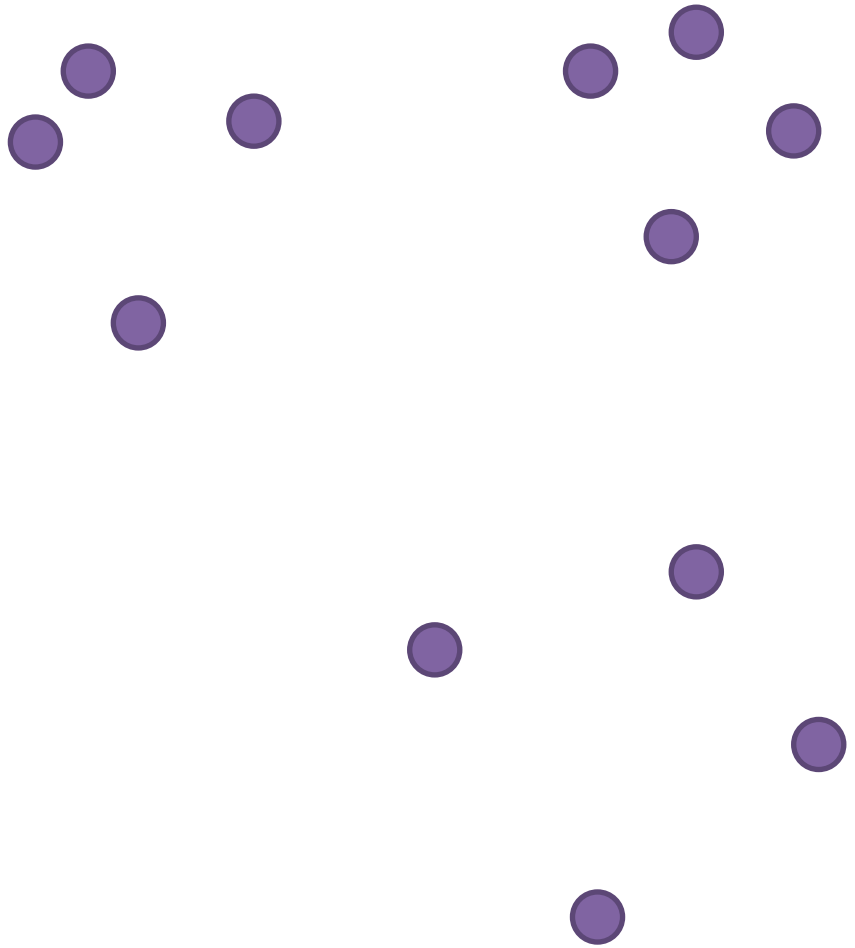
- Находит кластеры произвольной формы
- Может работать с большими объёмами данных
- Нужно подбирать размер окрестности (eps) и минимальное число объектов в окрестности

Иерархическая кластеризация

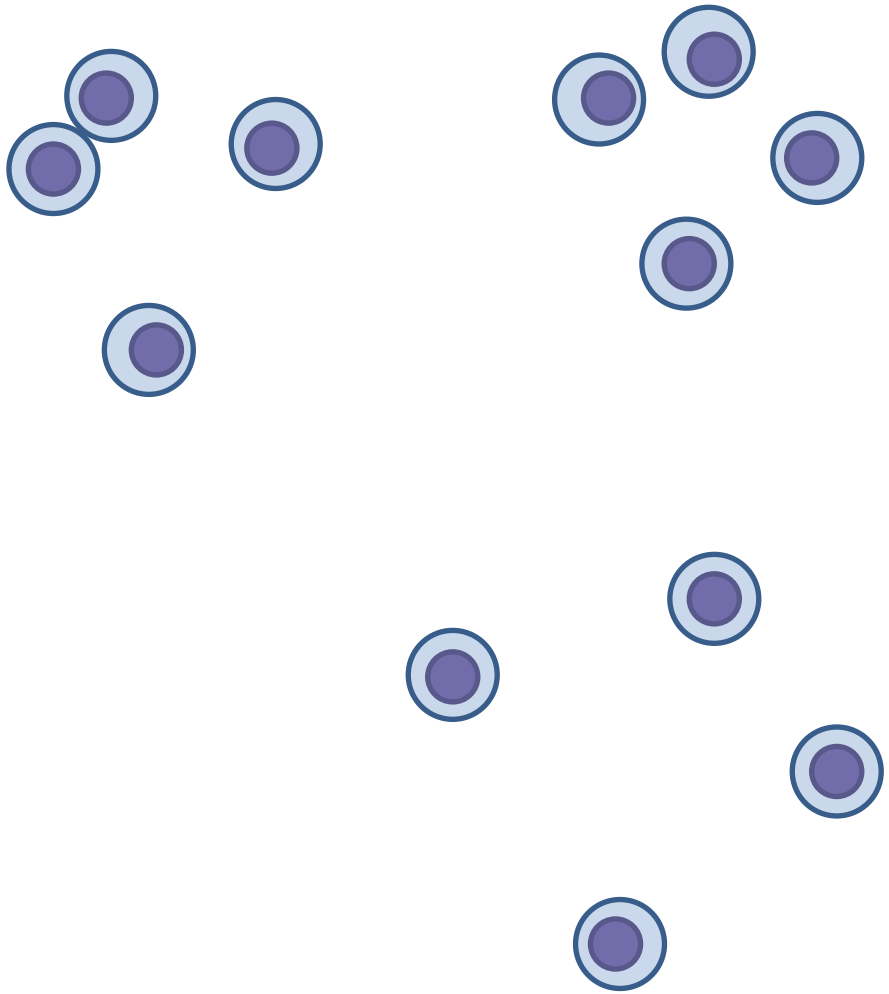
Виды иерархической кластеризации

- Аггломеративная – на каждой итерации объединяем два меньших кластера в один побольше
- Дивизивная – на каждой итерации делим один большой кластер на два поменьше

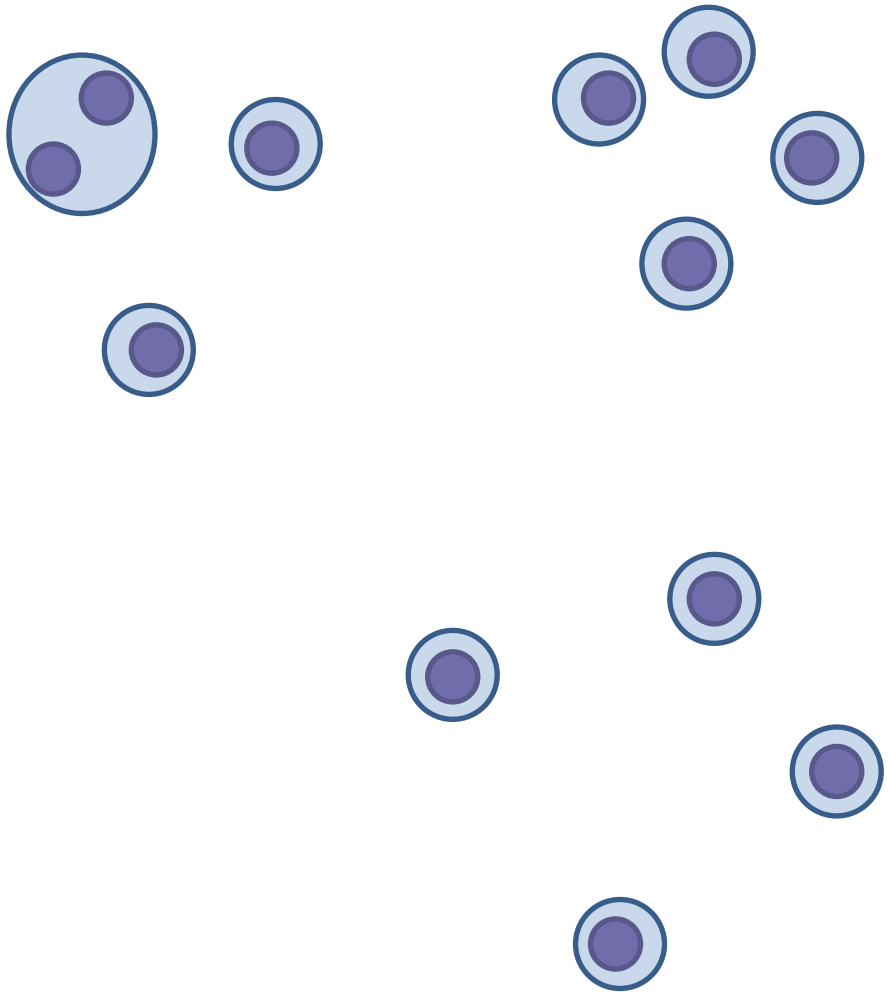
Агломеративная кластеризация



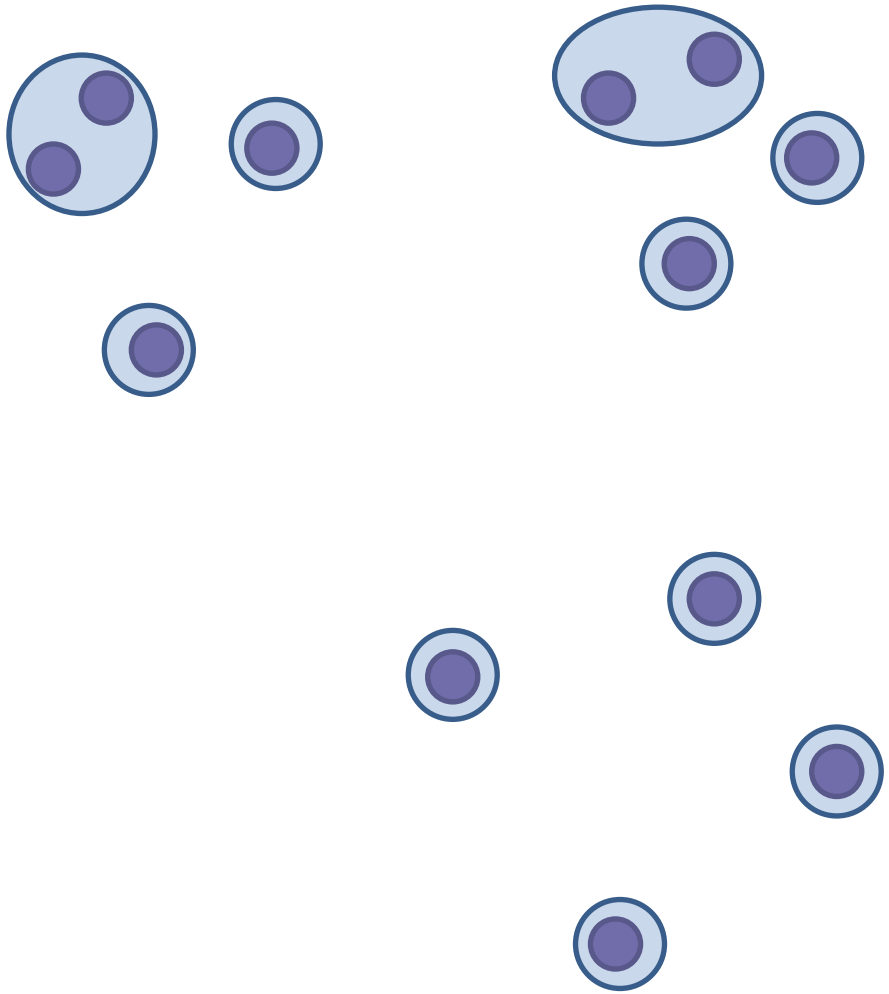
Агломеративная кластеризация



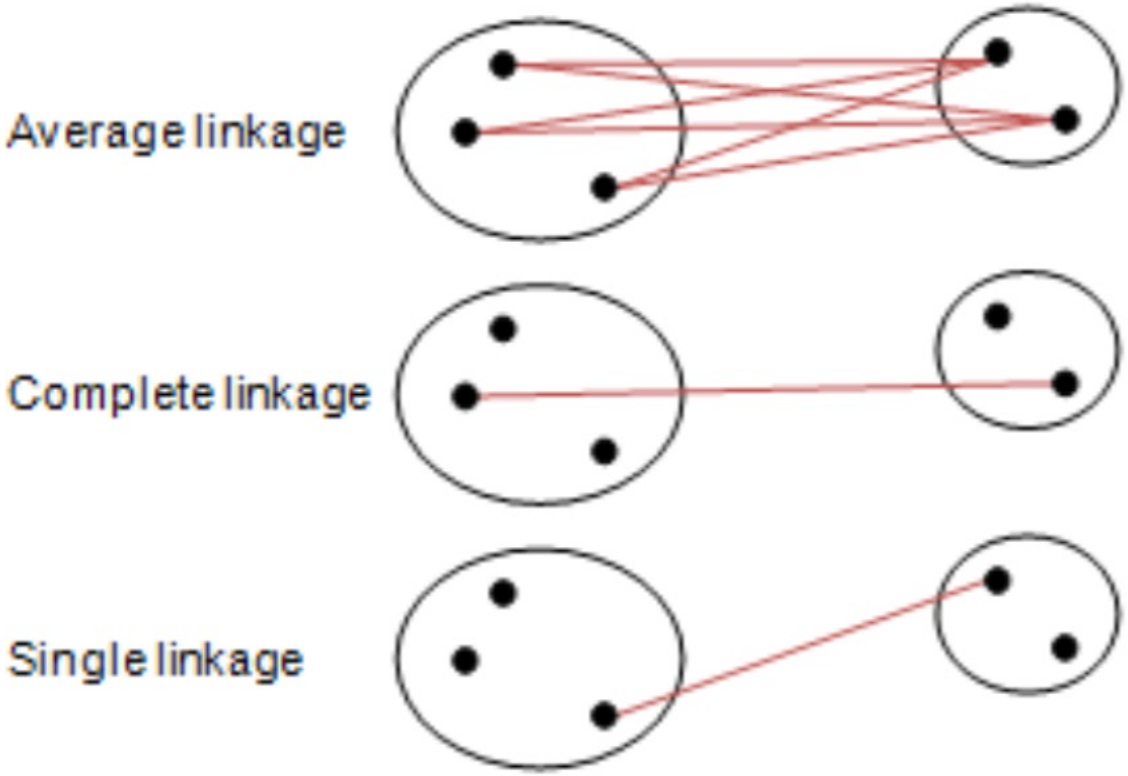
Агломеративная кластеризация



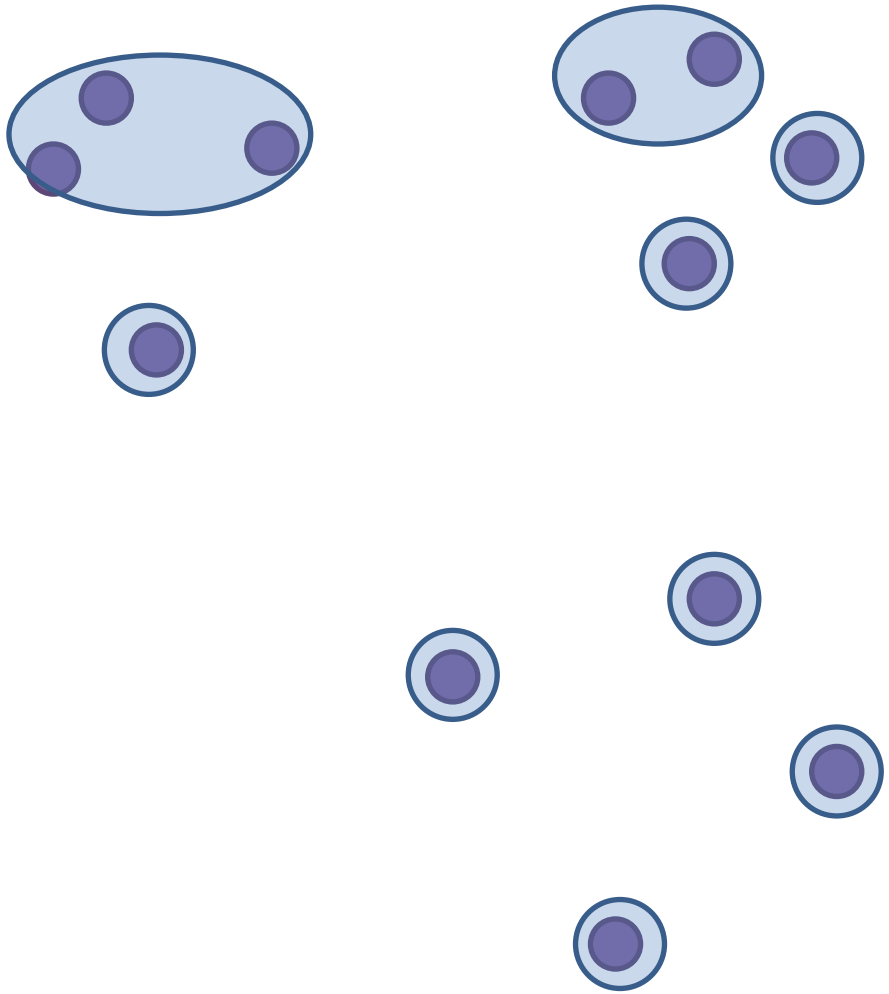
Агломеративная кластеризация



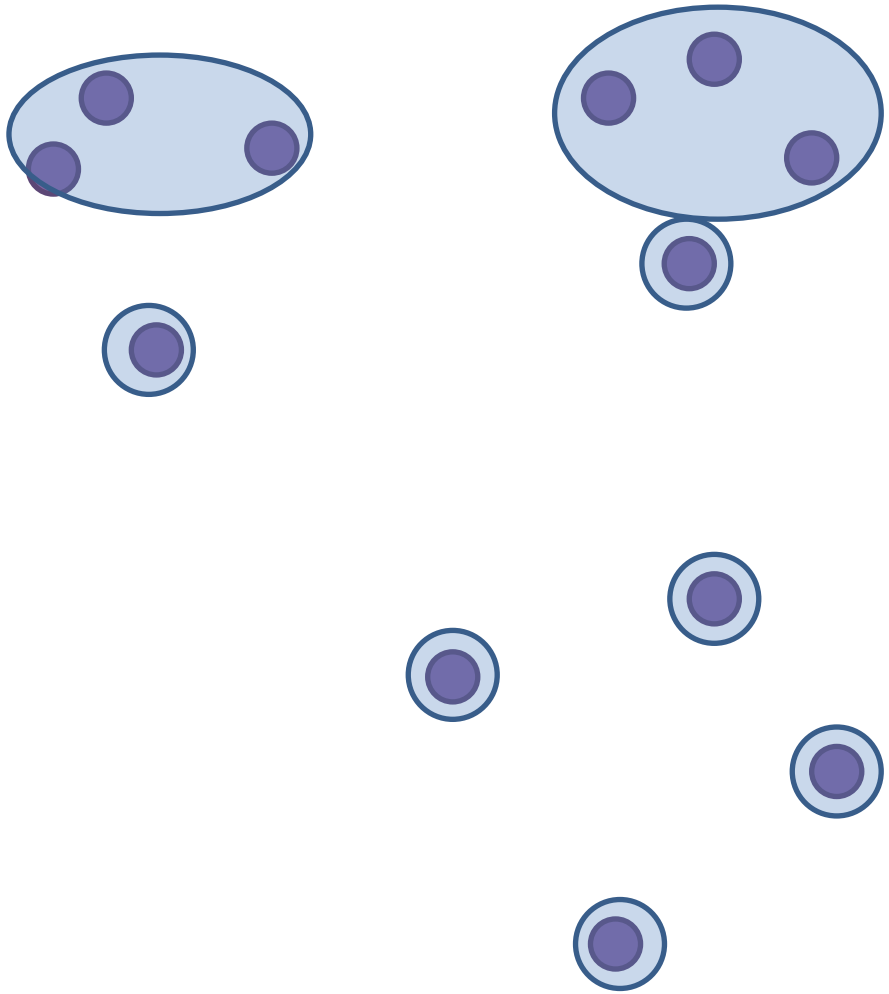
Расстояния между кластерами



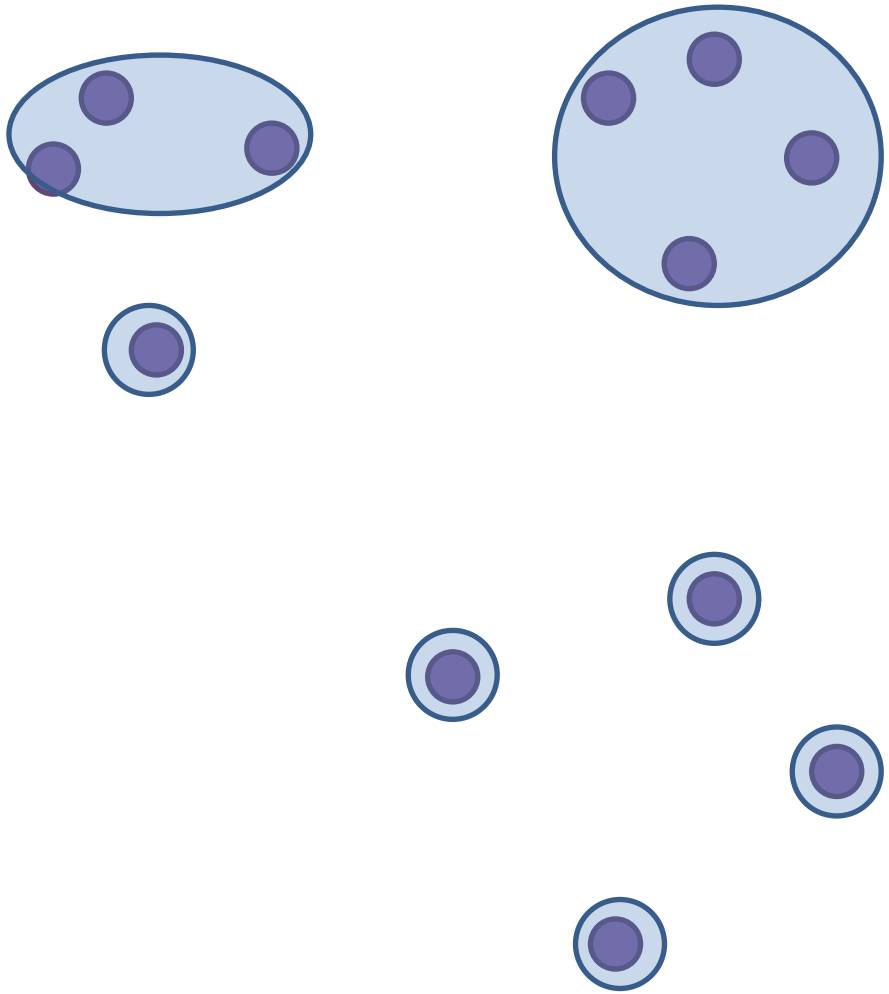
Агломеративная кластеризация



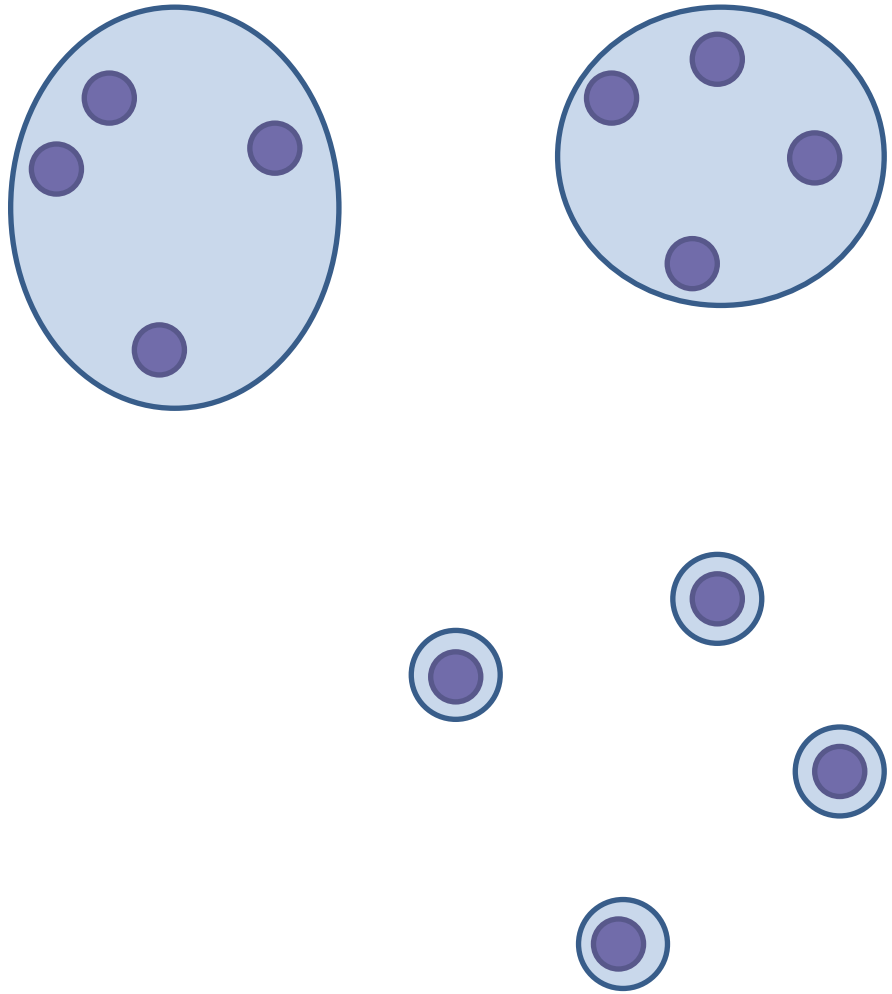
Агломеративная кластеризация



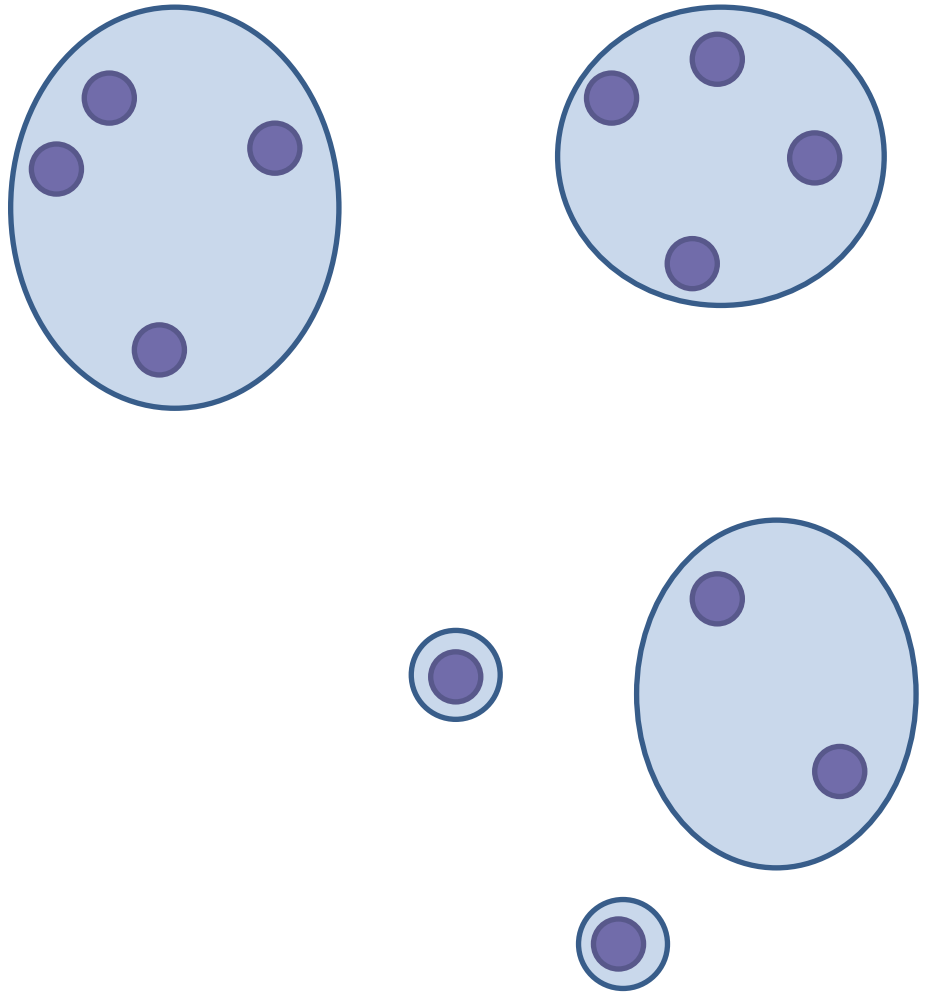
Агломеративная кластеризация



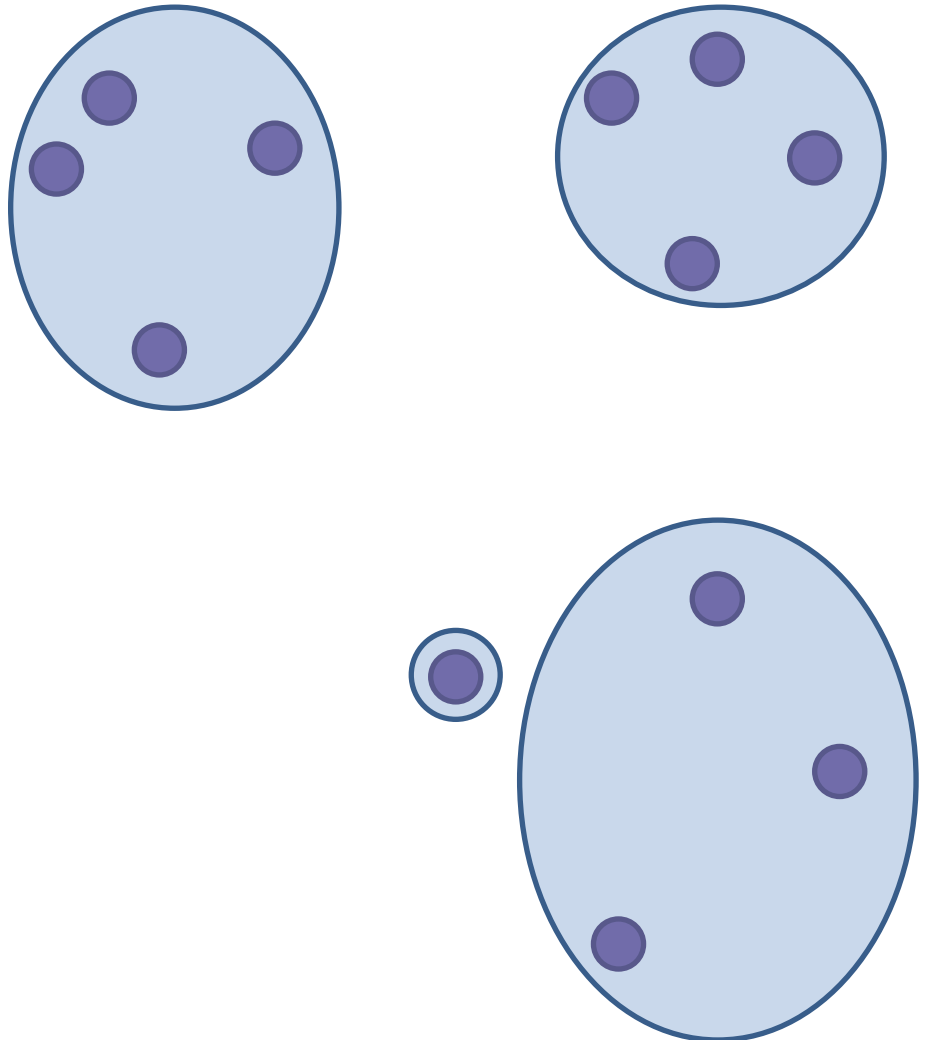
Агломеративная кластеризация



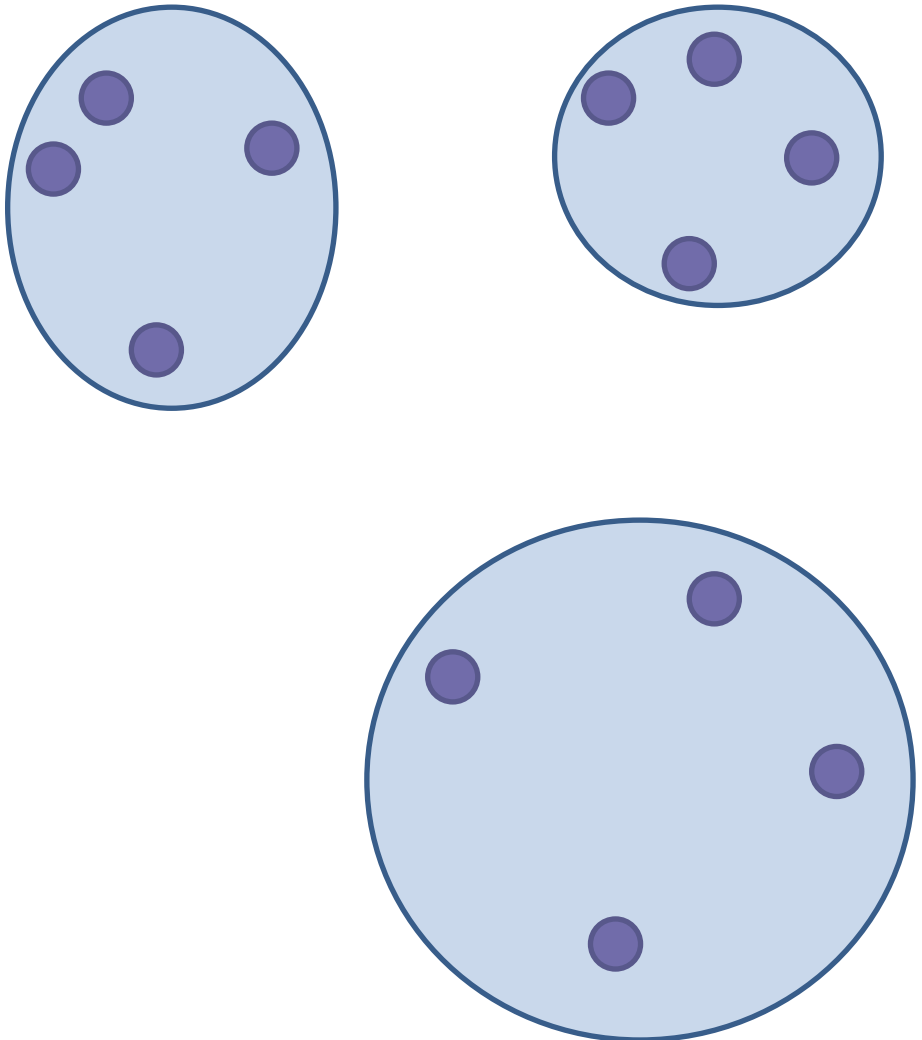
Агломеративная кластеризация



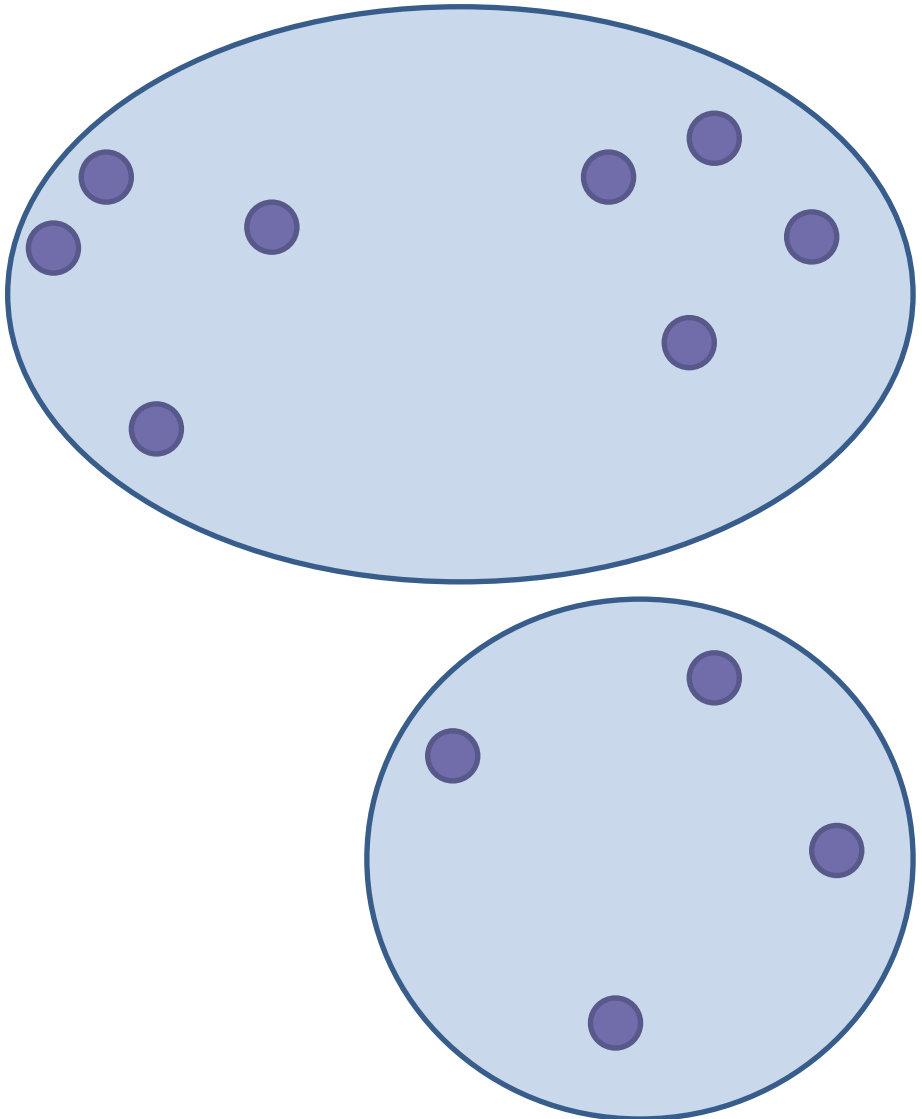
Агломеративная кластеризация



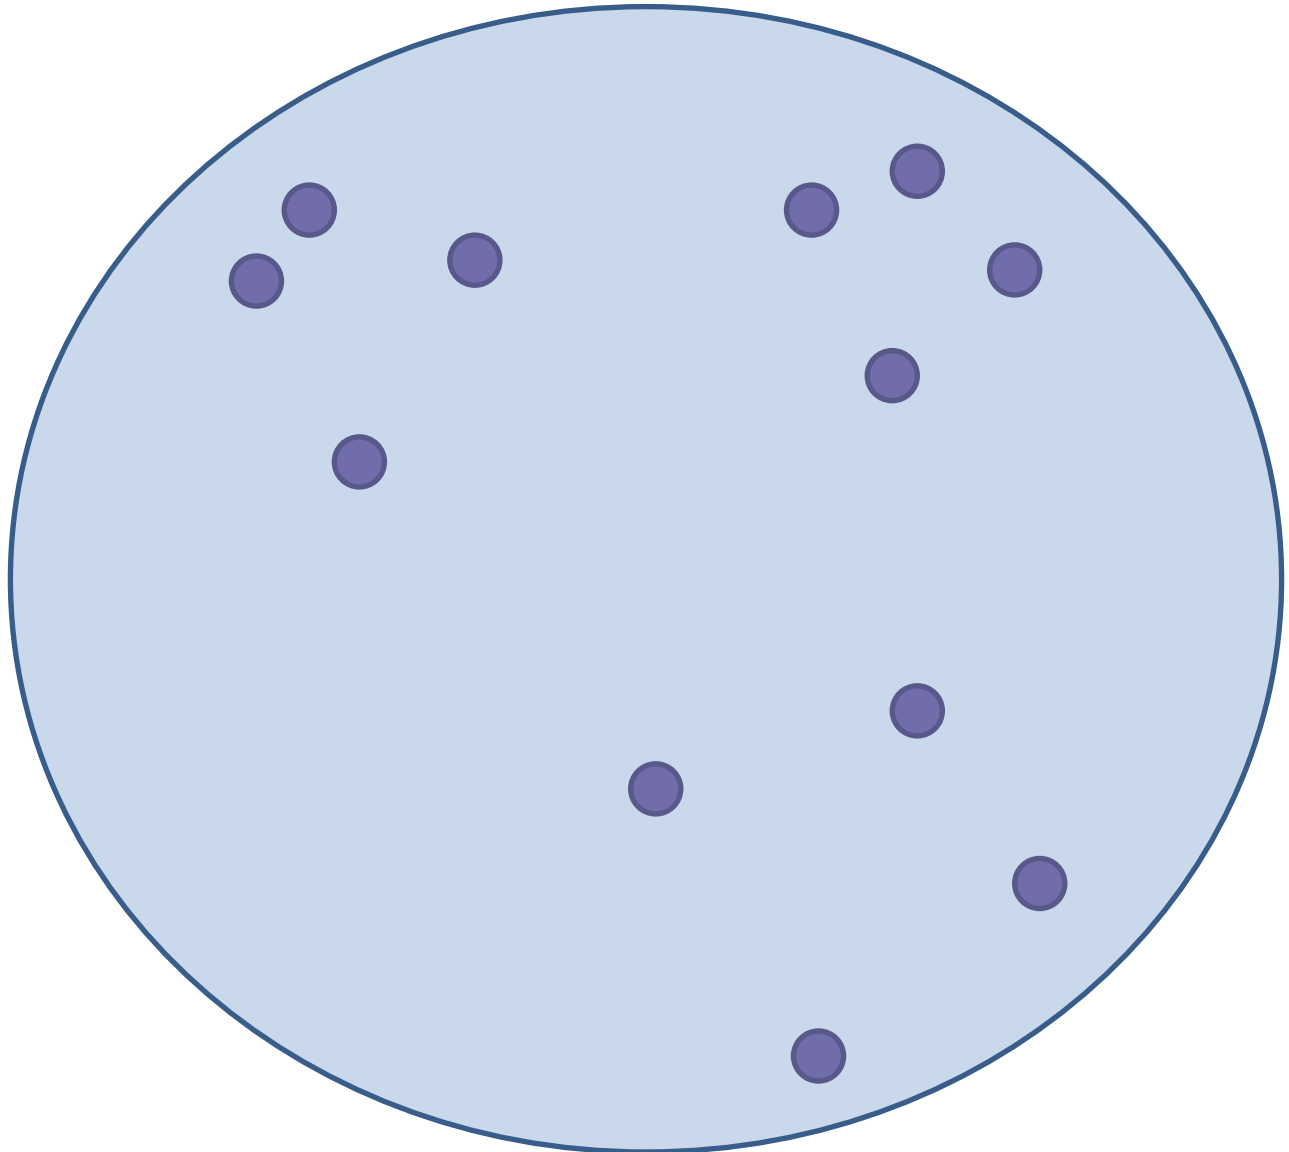
Агломеративная кластеризация



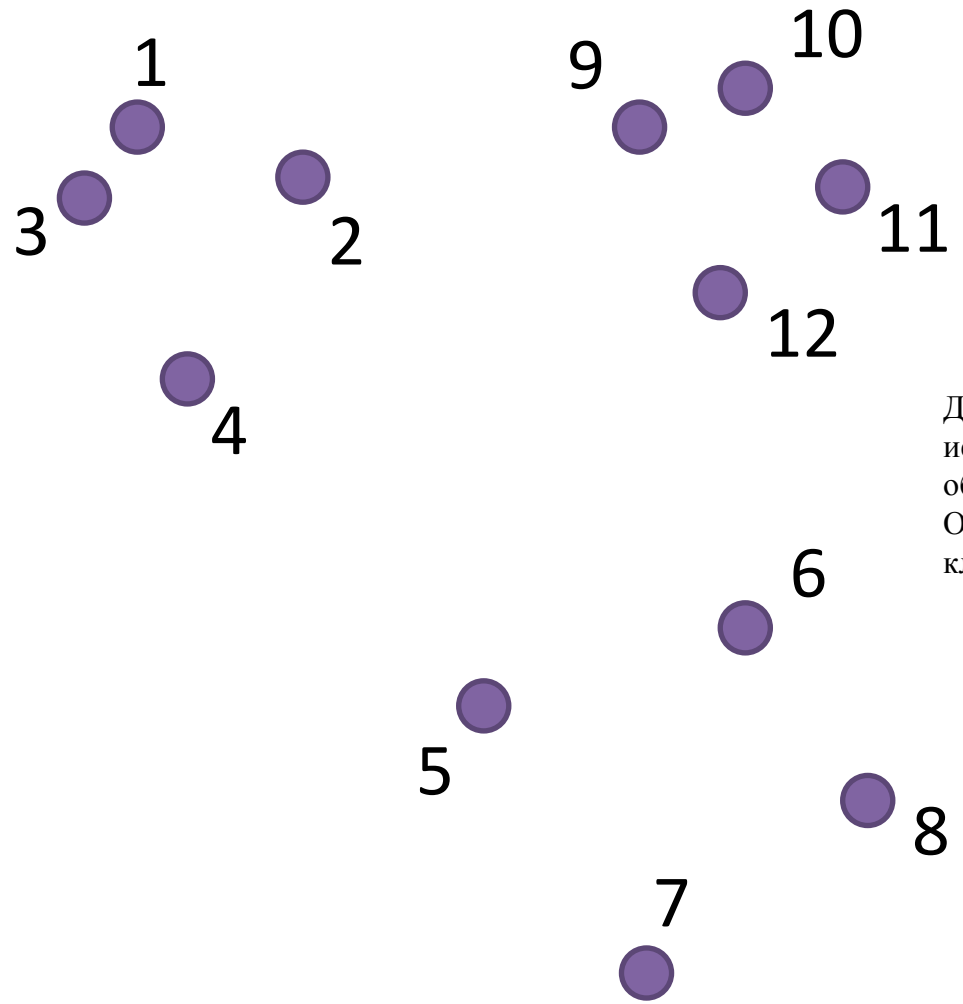
Агломеративная кластеризация



Агломеративная кластеризация

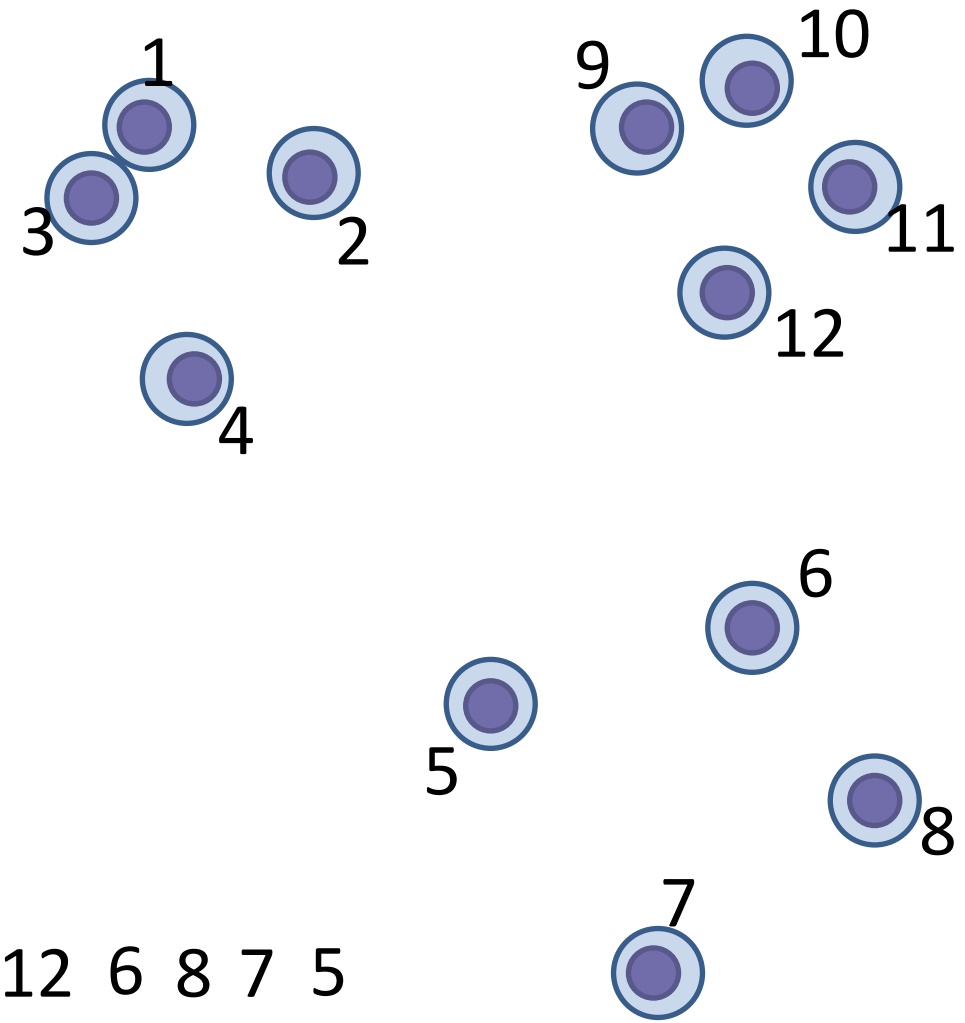


Дендрограмма



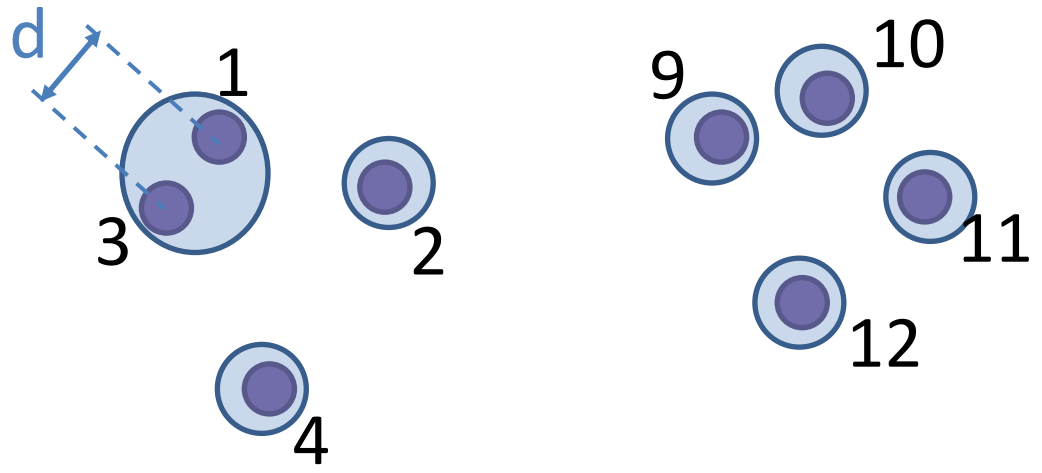
Дендрограмма — это графическое представление иерархической кластеризации, которое показывает, как объекты группируются в кластеры на разных уровнях. Она используется для визуализации результатов кластеризации и помогает понять структуру данных.

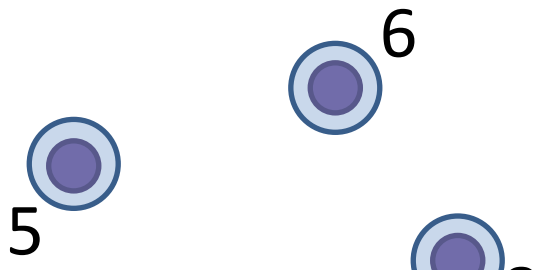
Дендрограмма

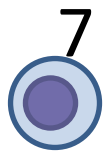


1 3 2 4 9 10 11 12 6 8 7 5

Дендрограмма



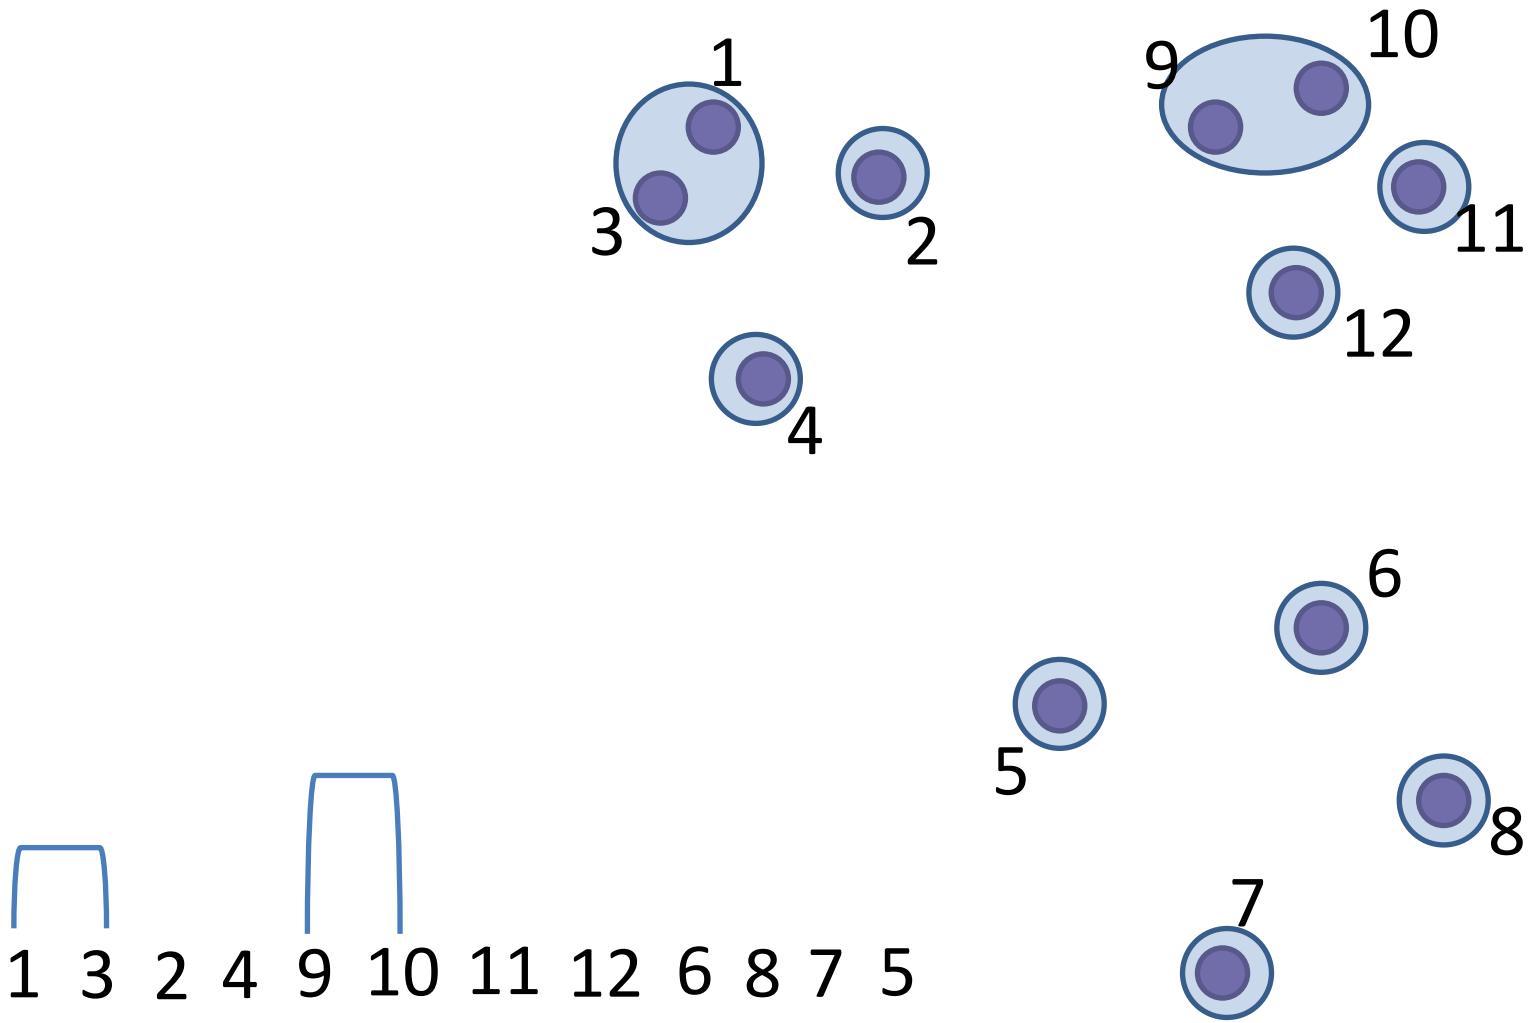




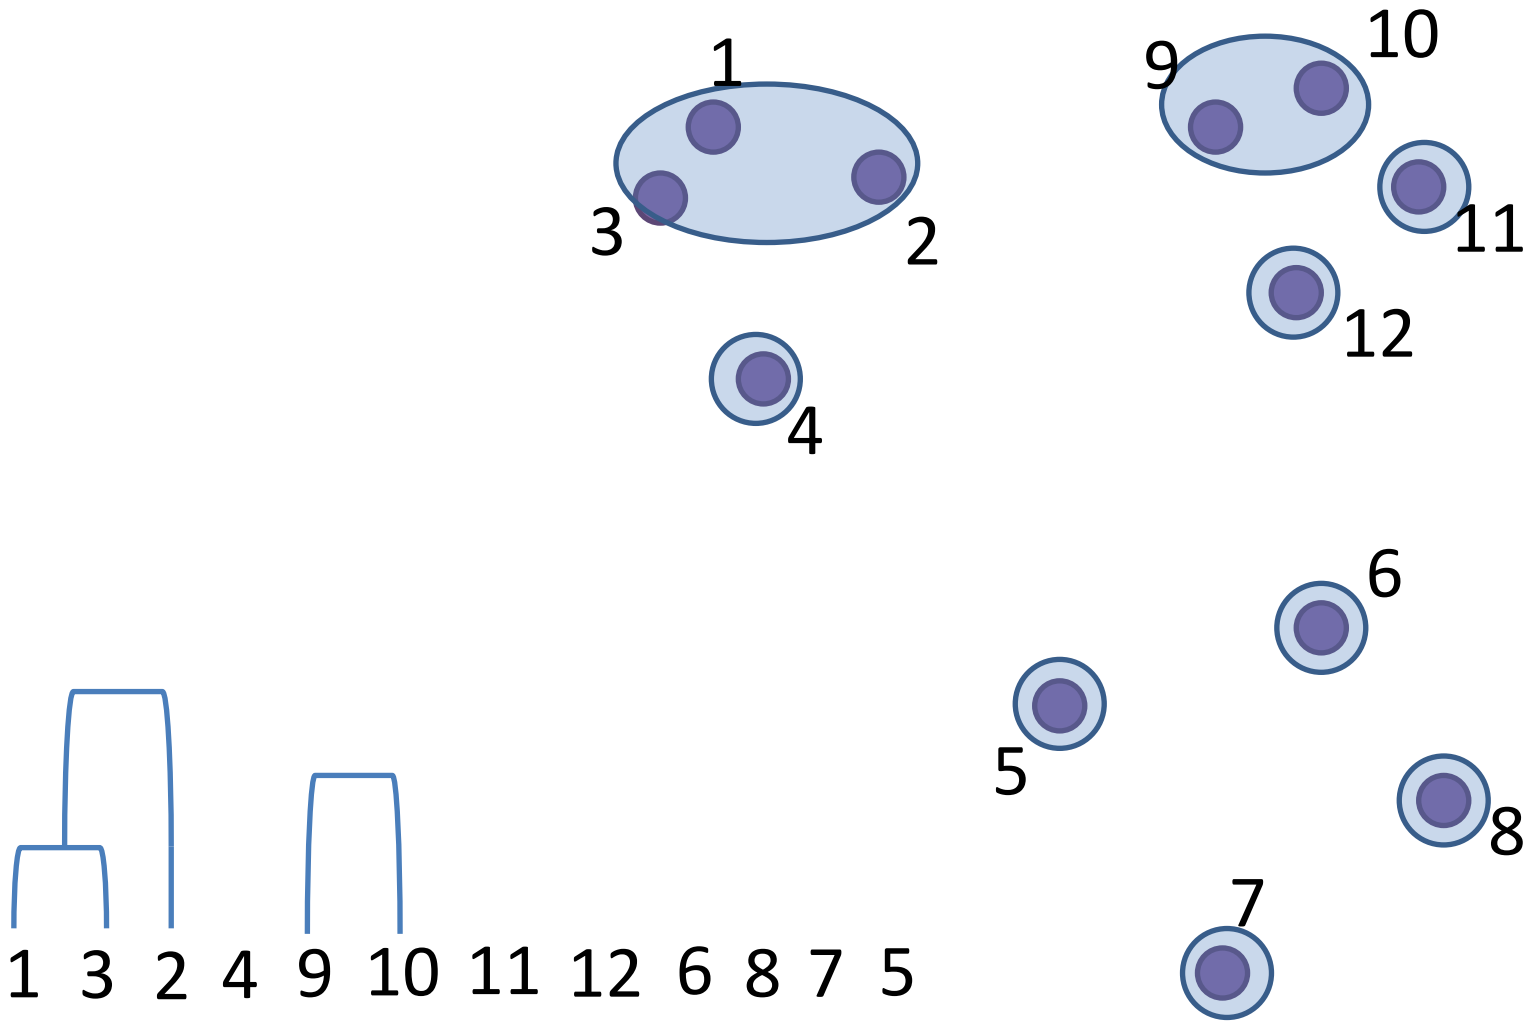


1 3 2 4 9 10 11 12 6 8 7 5

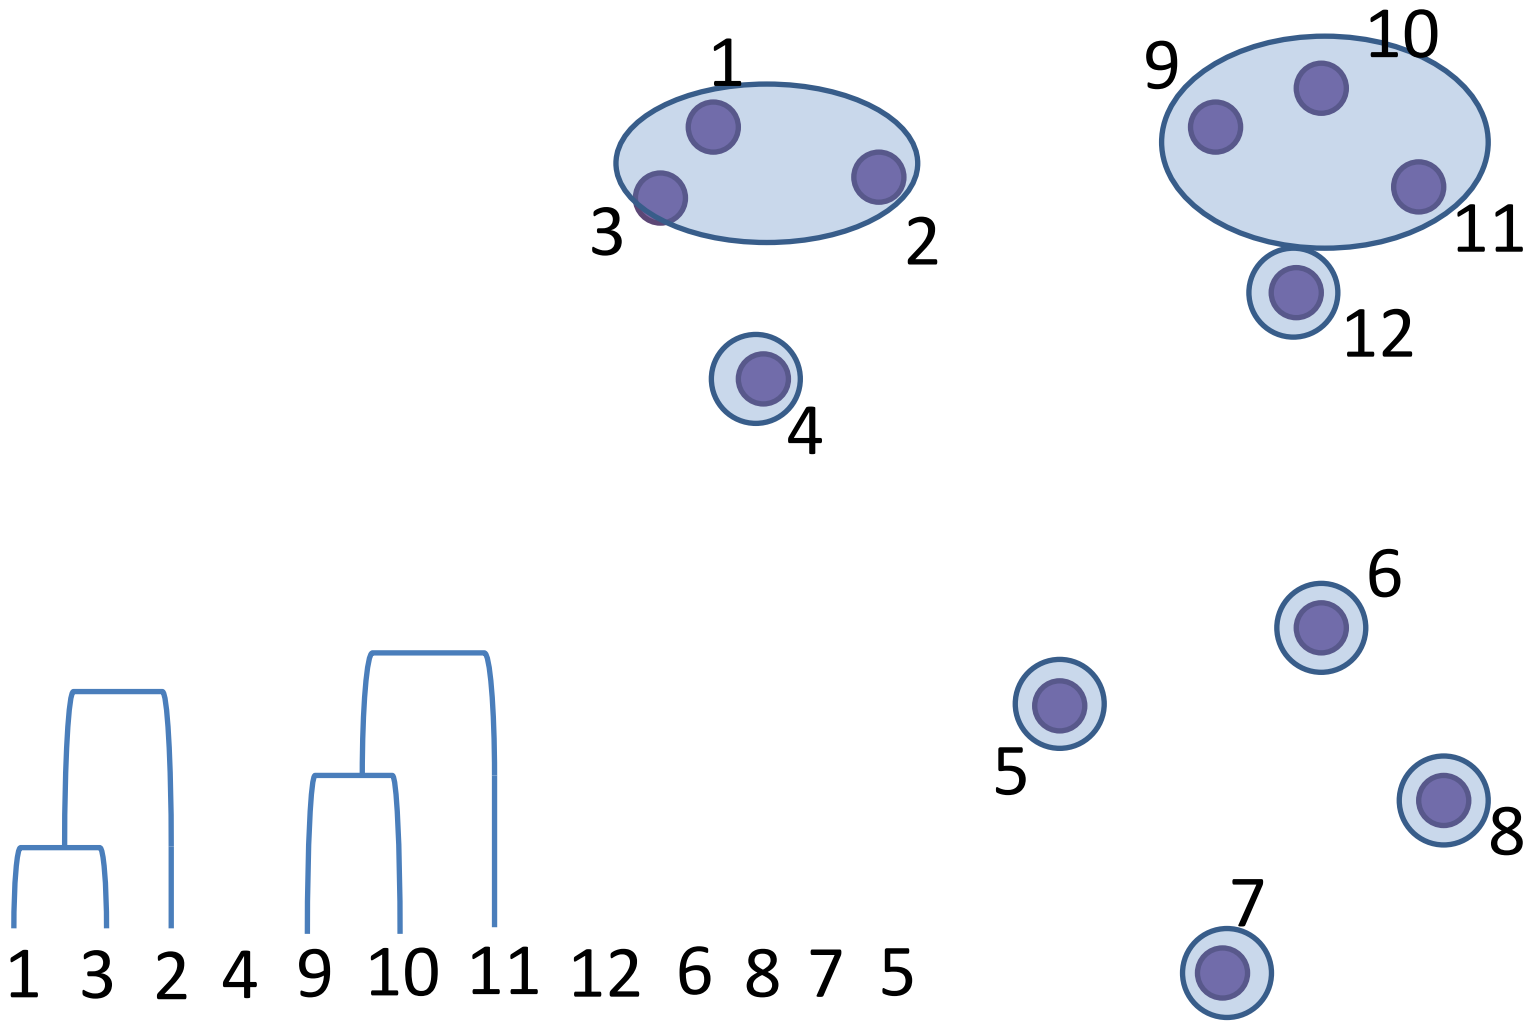
Дендрограмма



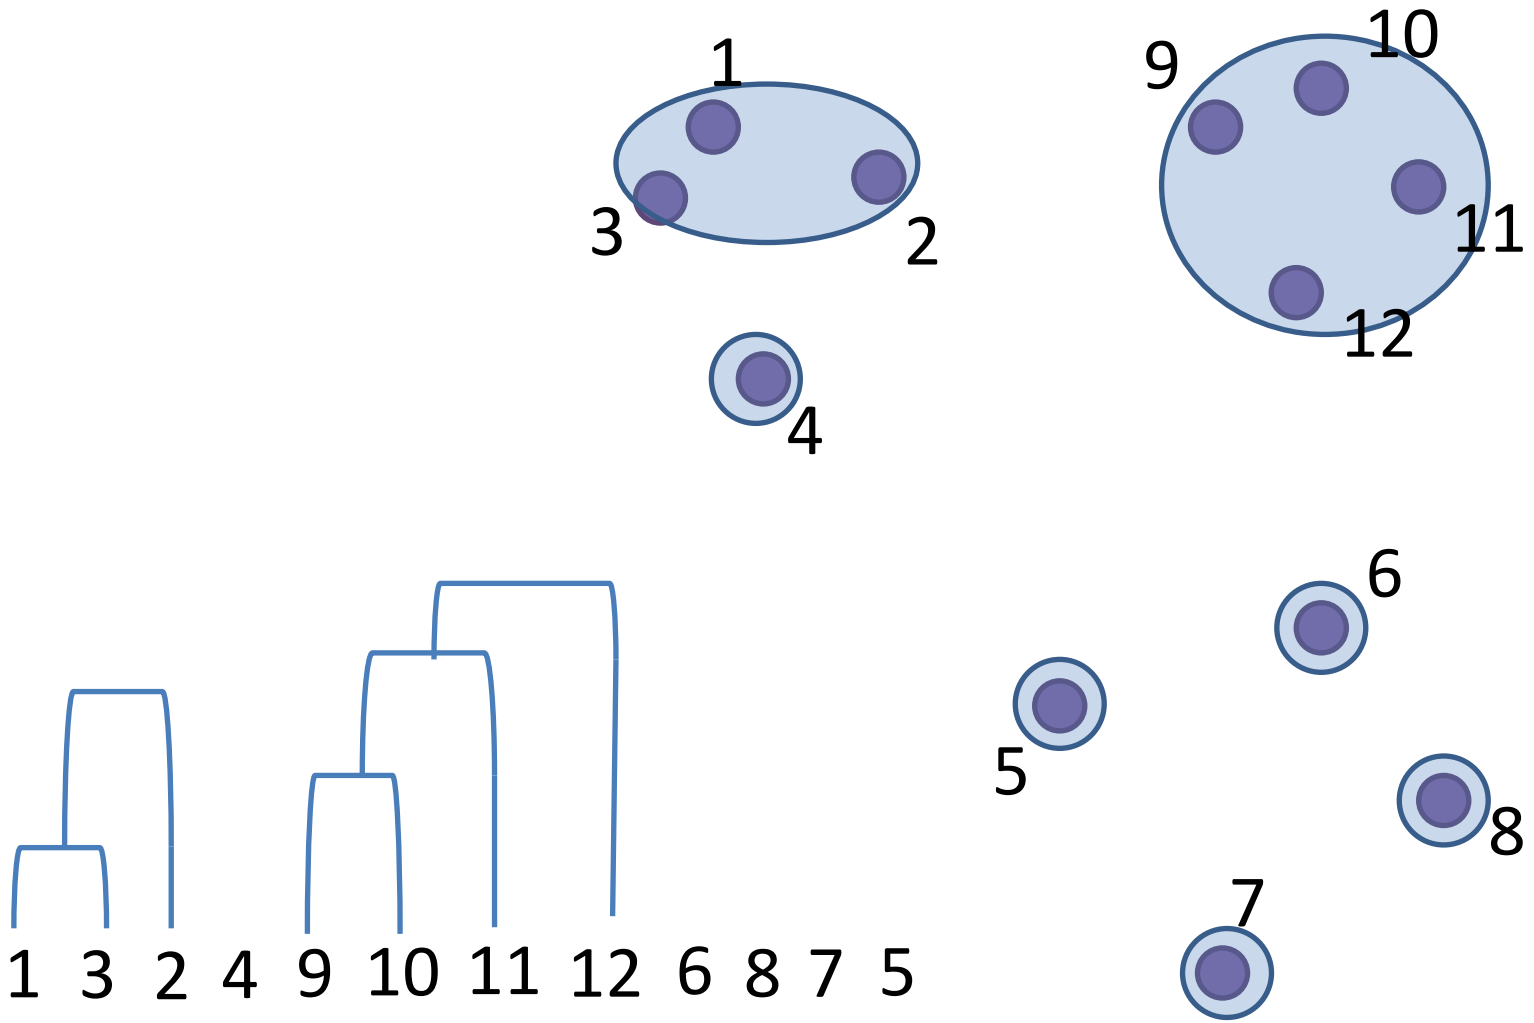
Дендрограмма



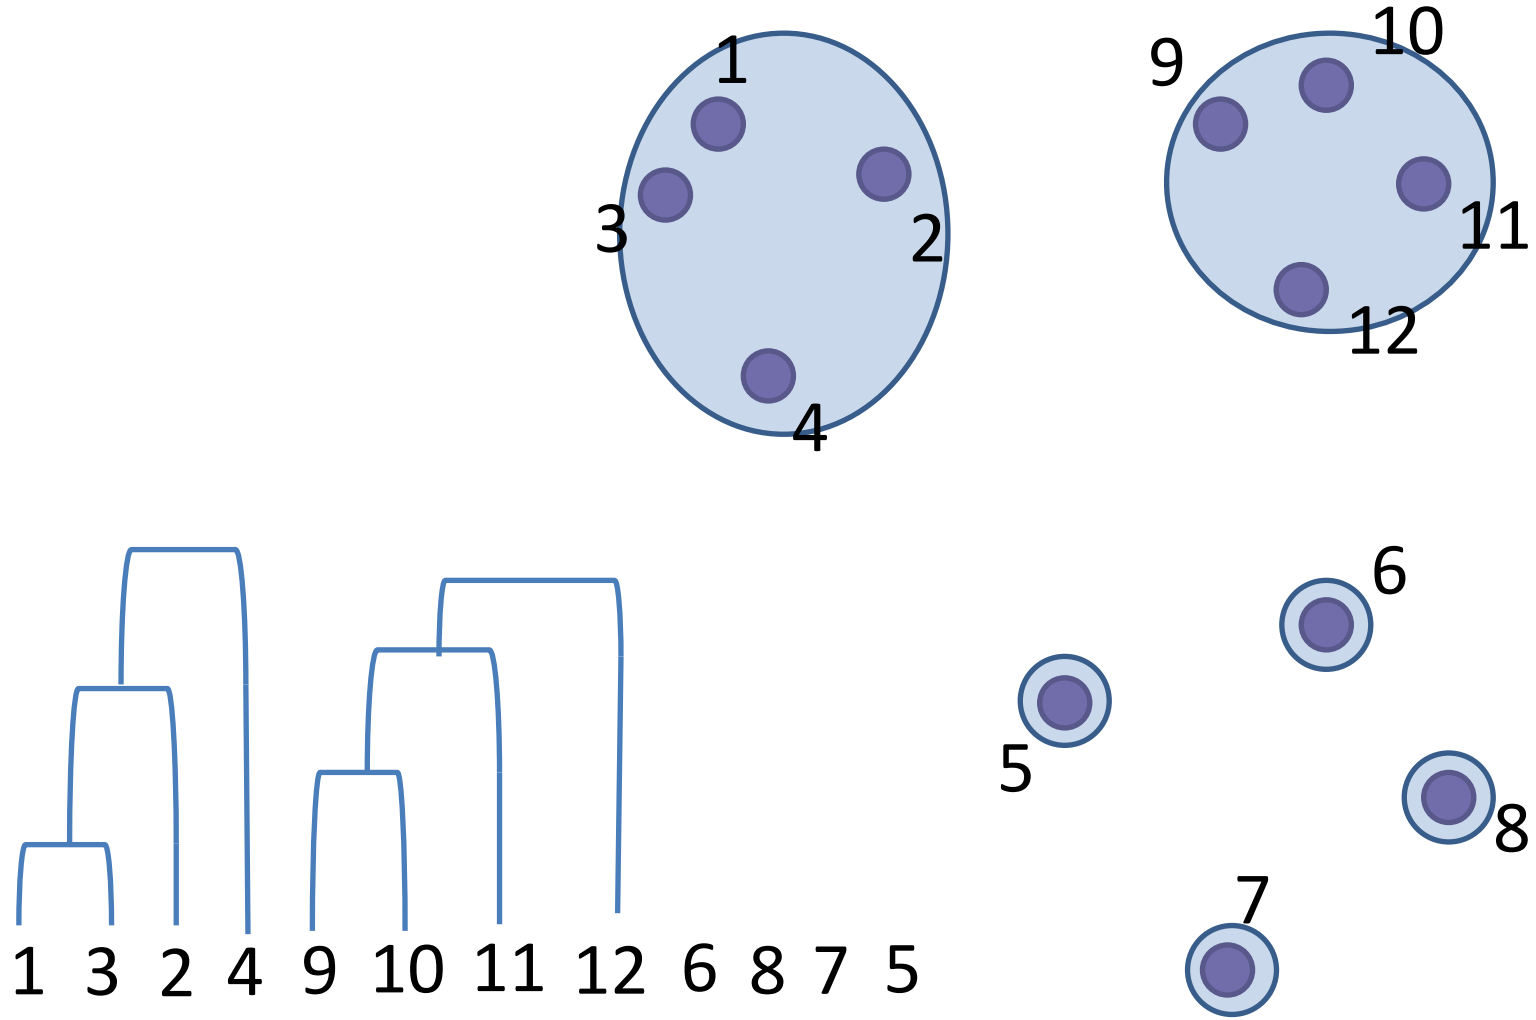
Дендрограмма



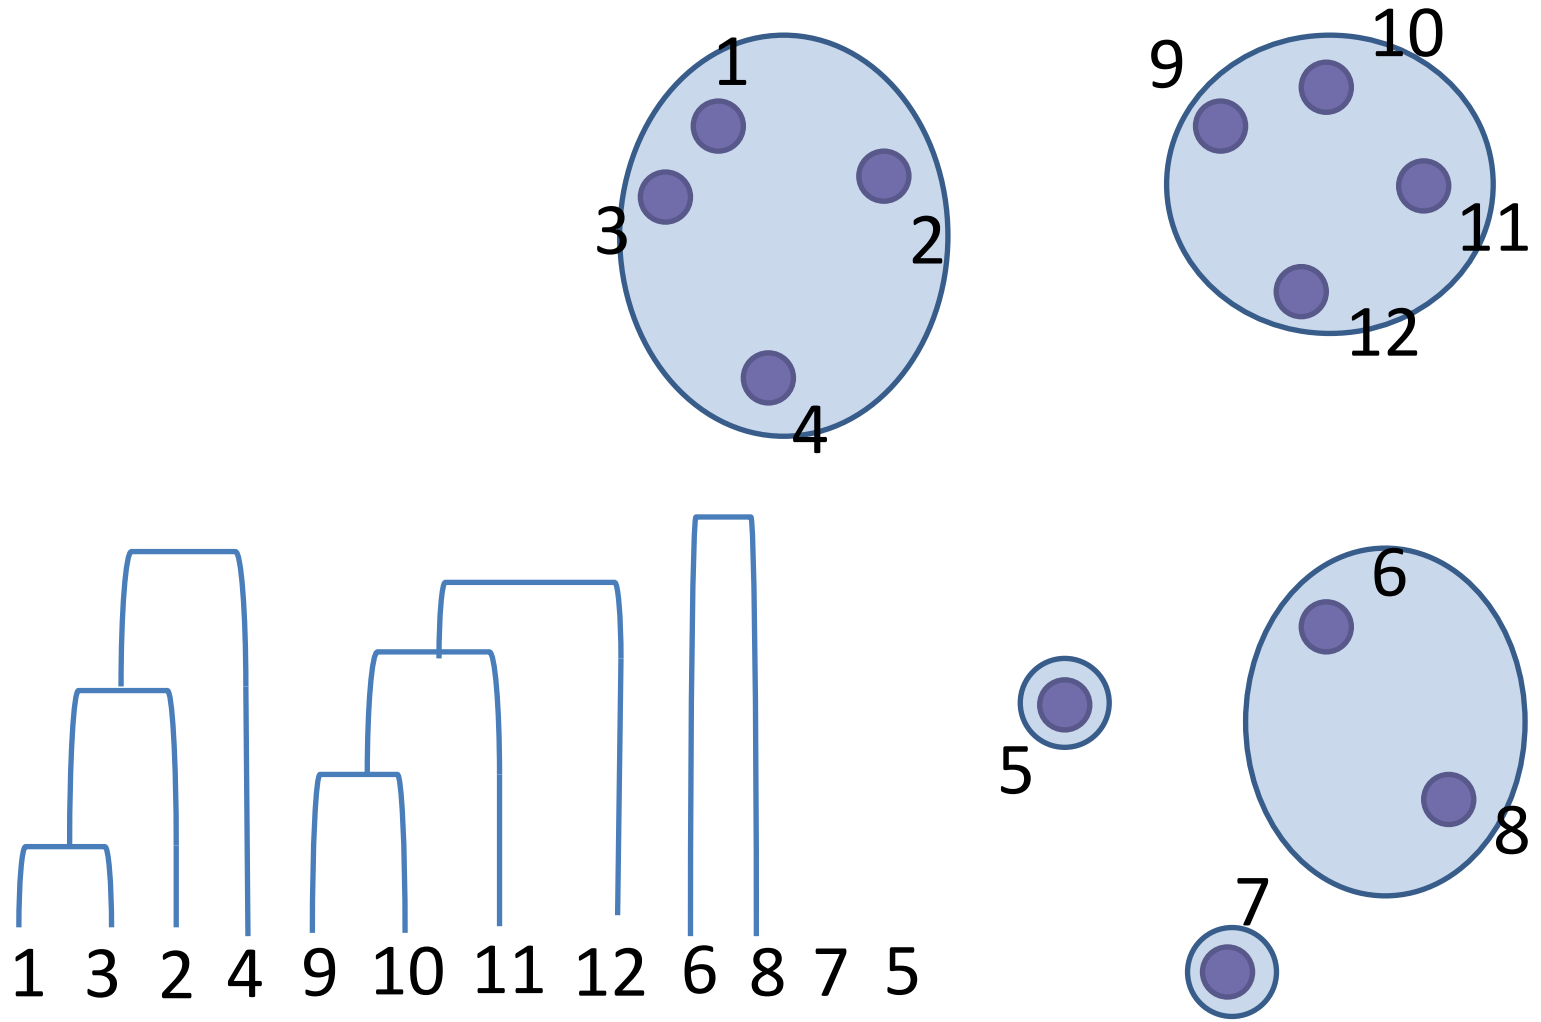
Дендрограмма



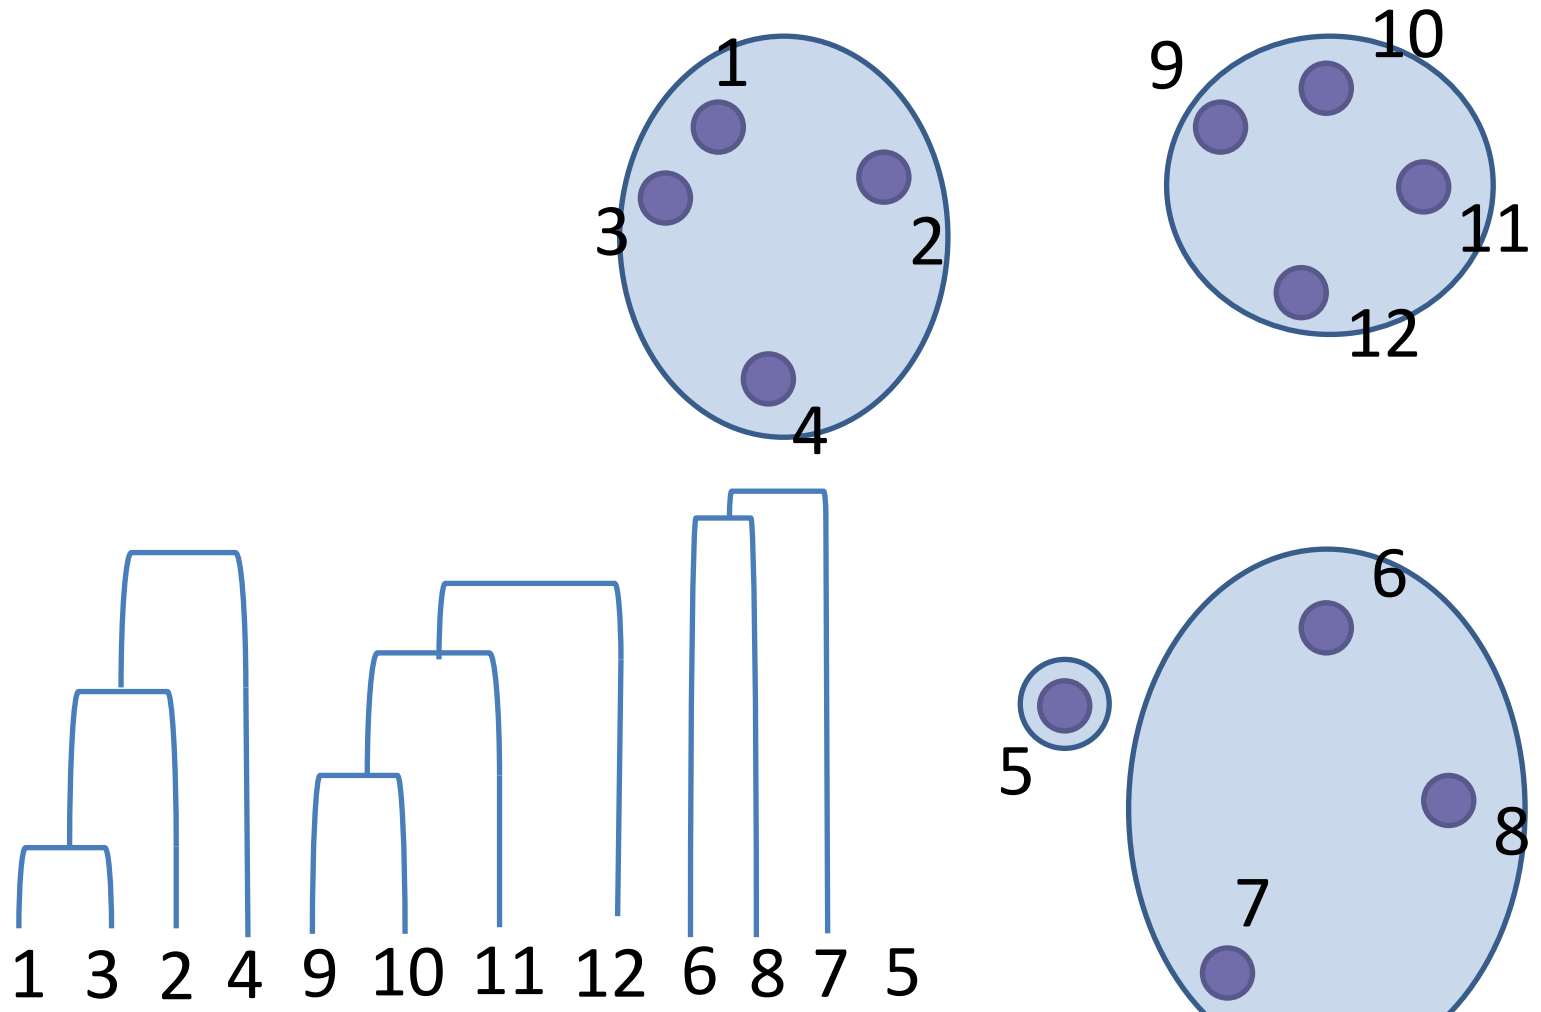
Дендрограмма



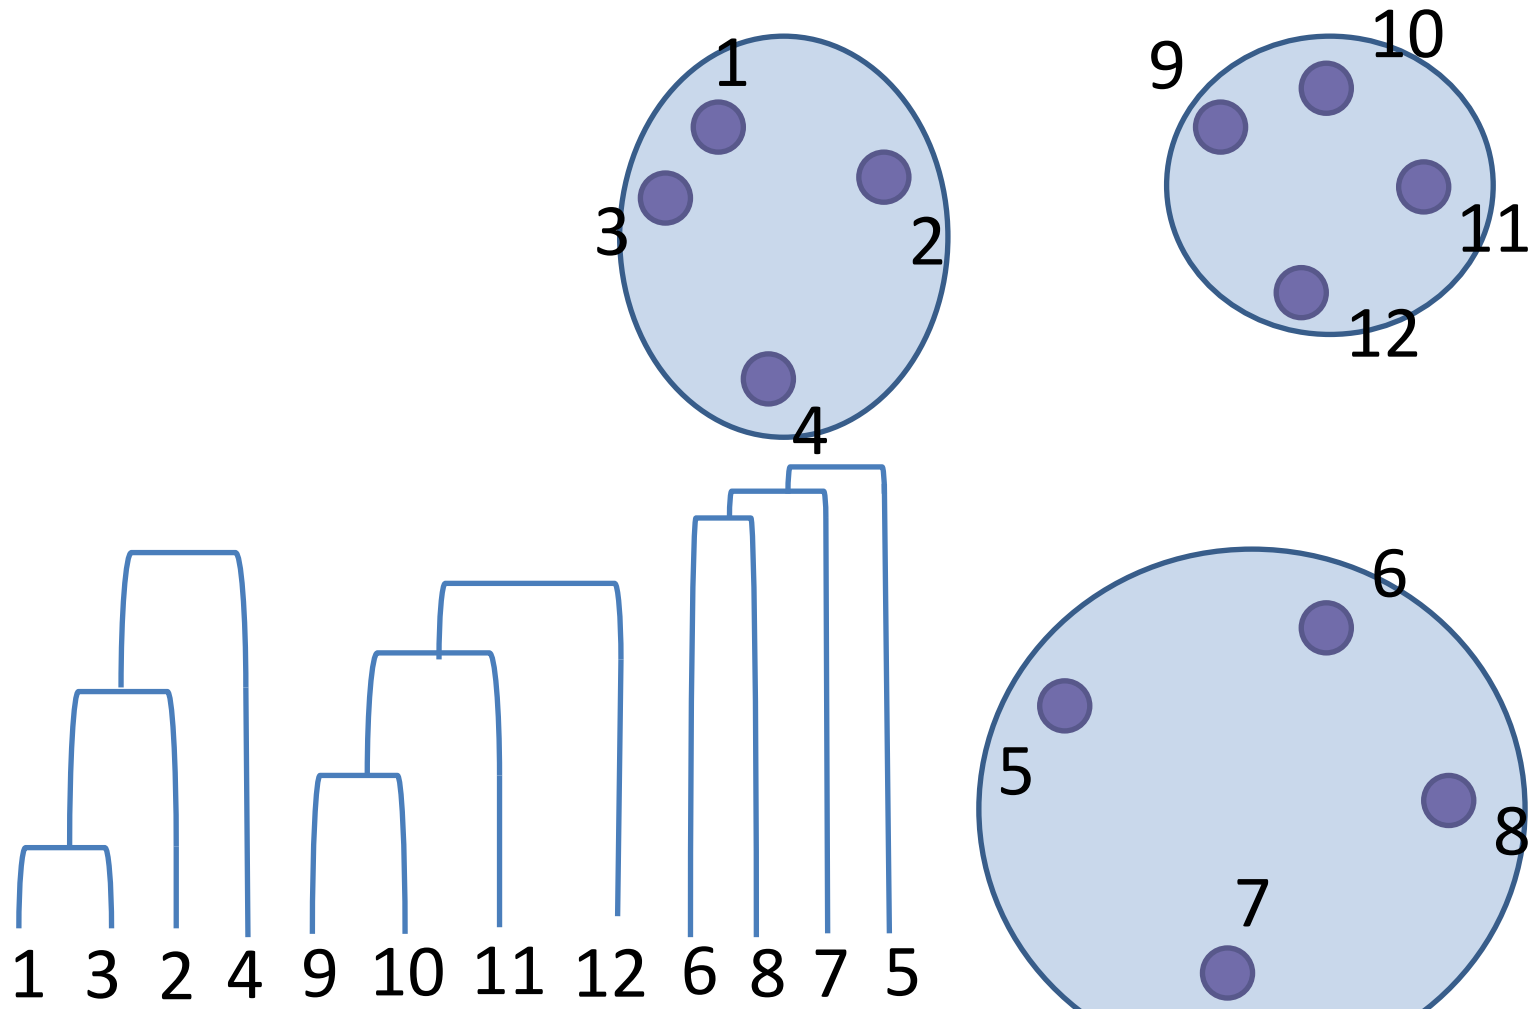
Дендрограмма



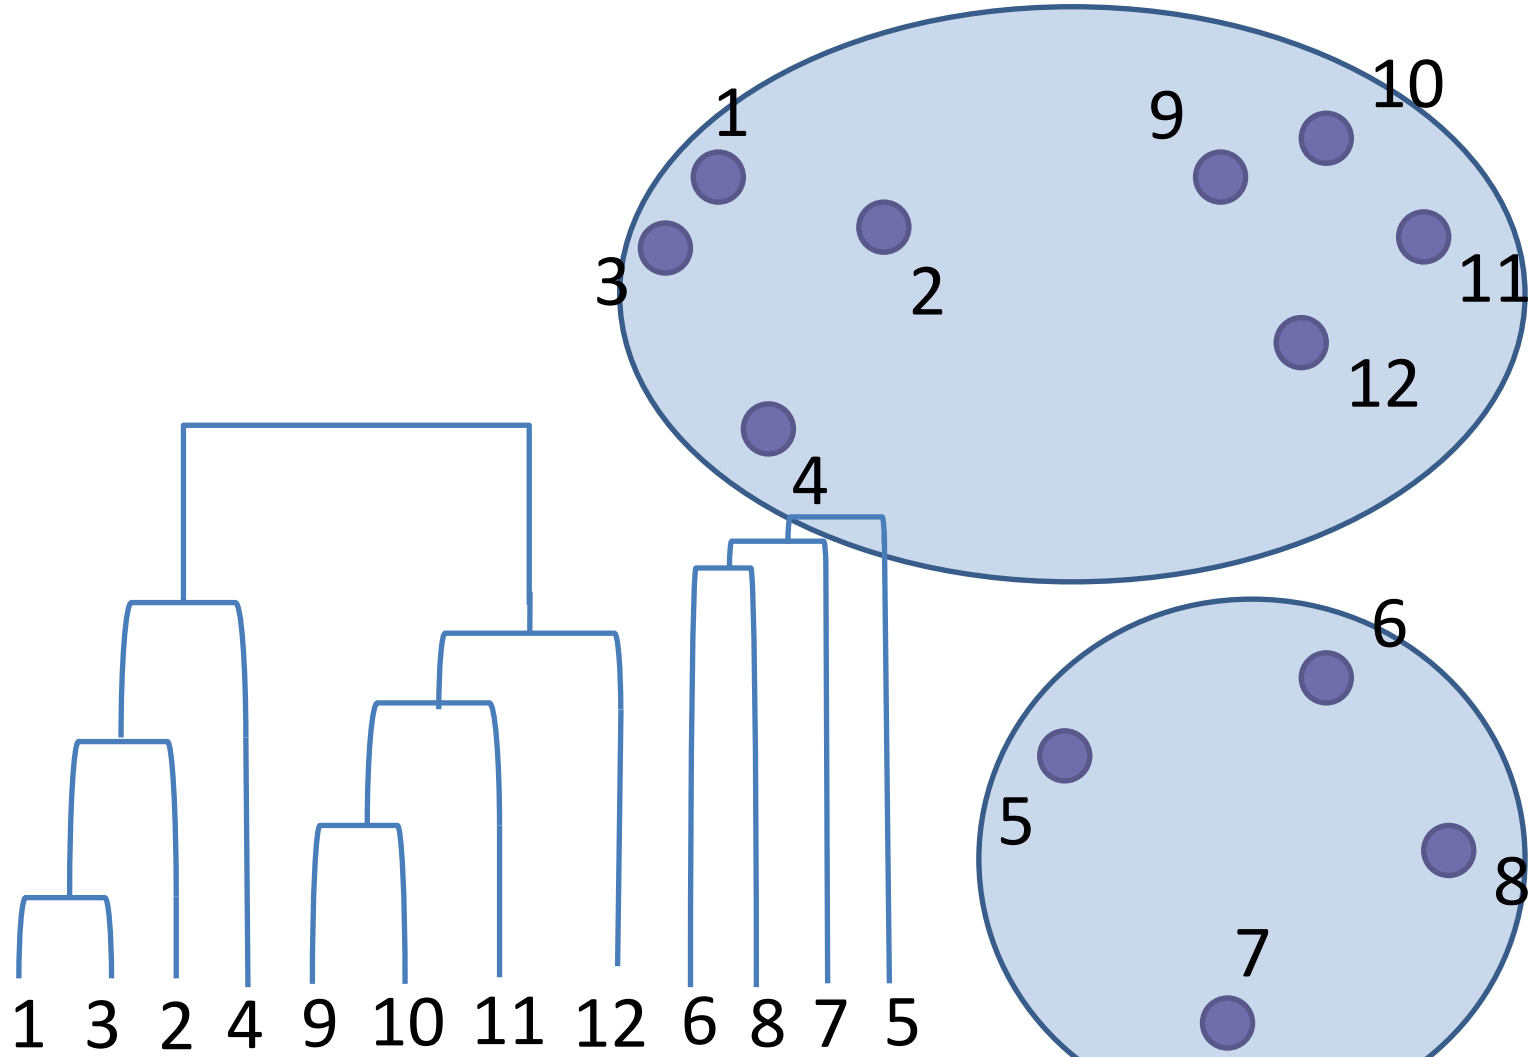
Дендрограмма



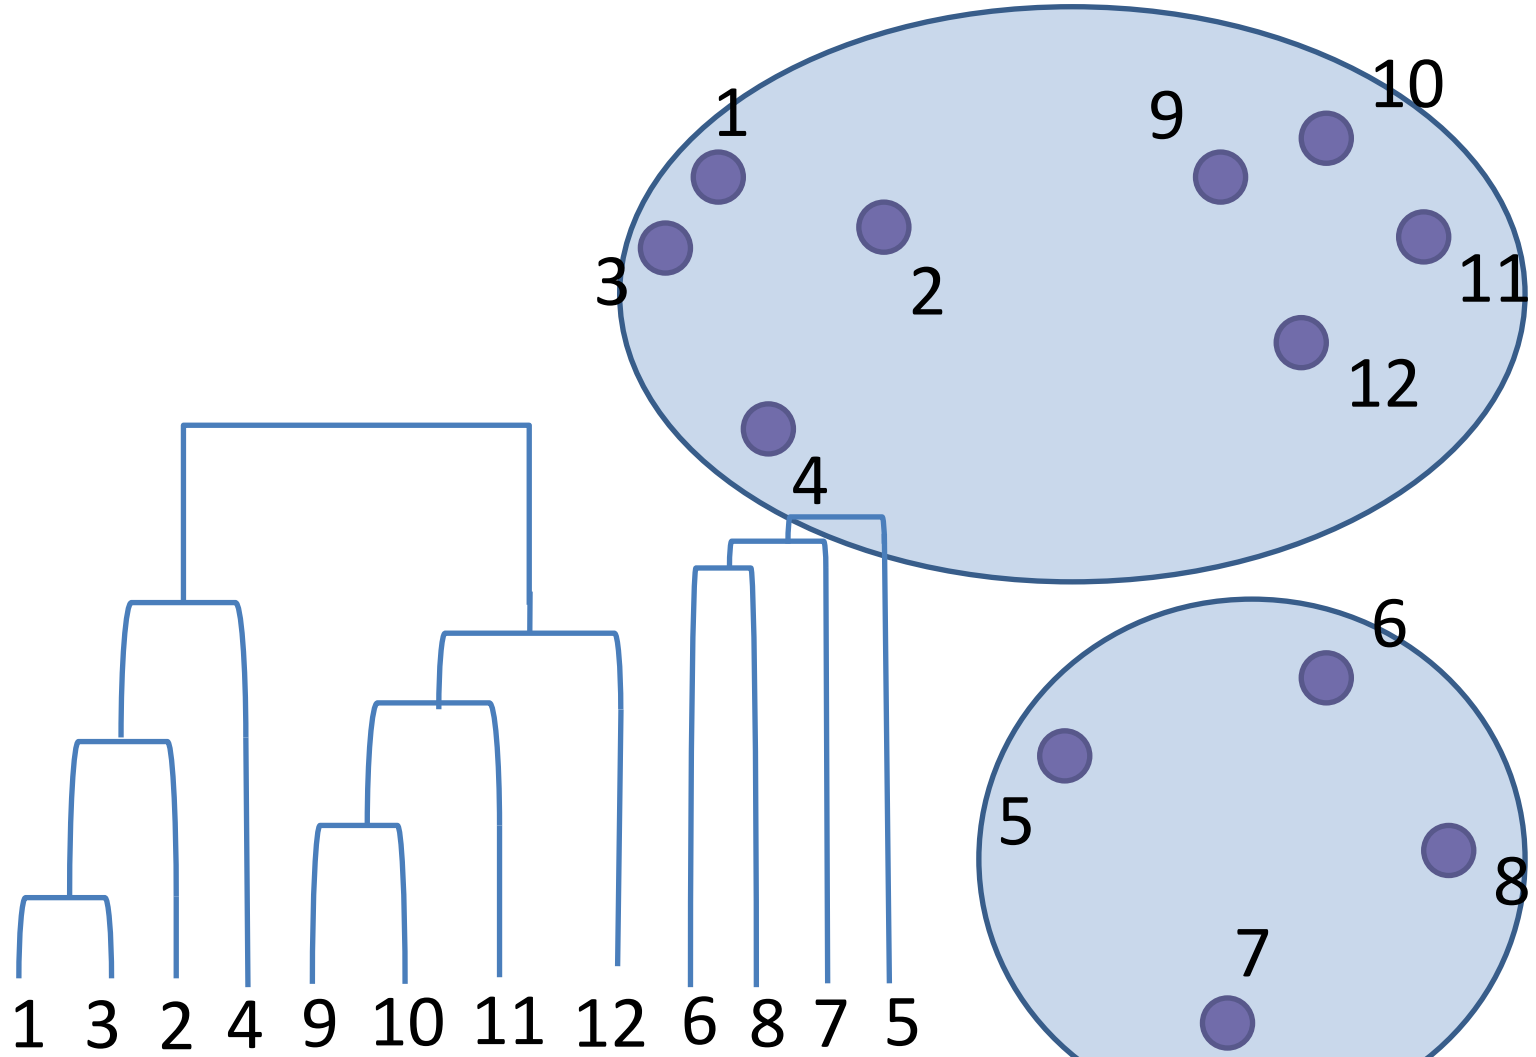
Дендрограмма



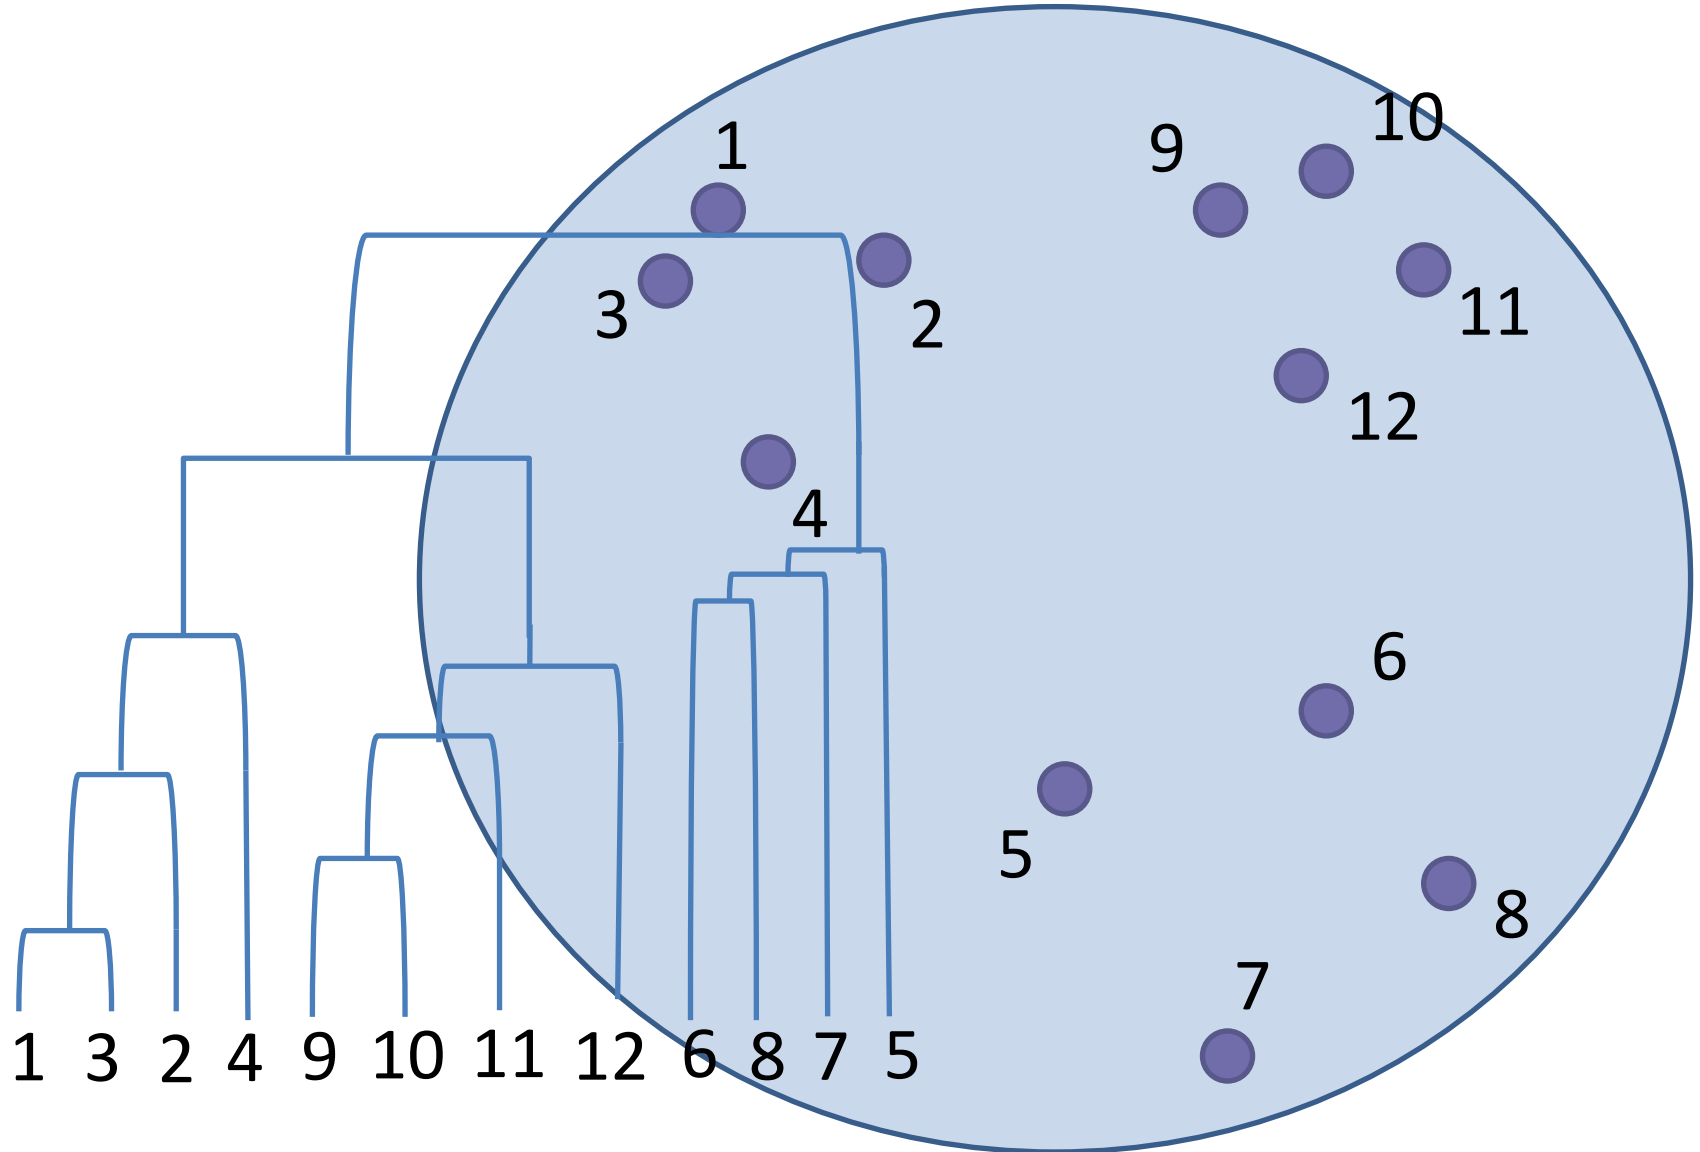
Дендрограмма



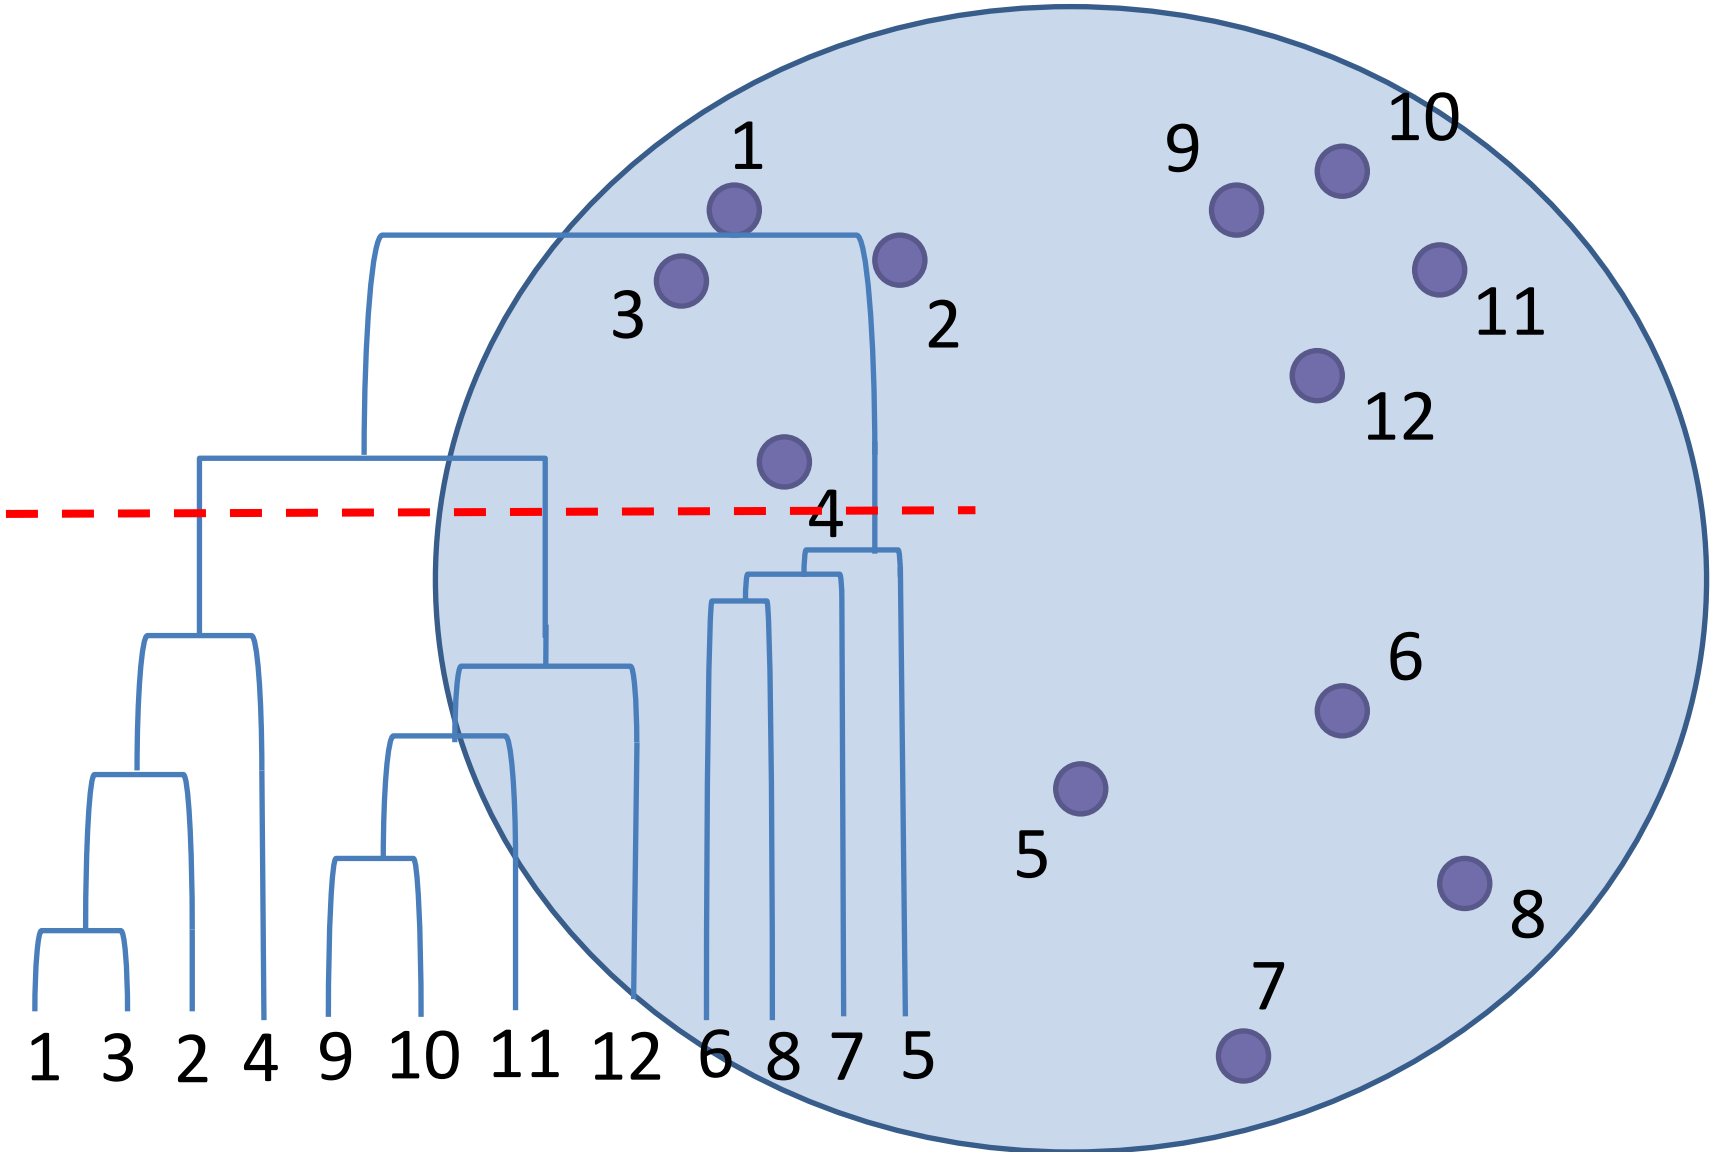
Дендрограмма



Дендрограмма



Дендрограмма



Аггломеративная кластеризация

1. Инициализация – каждая точка = кластер
2. Самые близкие (относительно какой-то метрики) кластеры объединяются
3. Повторяем до того момента, когда все точки будут в одном кластере
4. Останавливаемся, когда достигаем фиксированного числа кластеров, либо когда расстояние между кластерами больше заданного порога

Резюме

- Кластеризация — задача без строгой постановки и без строгих критериев качества
- Много разновидностей в подходах
- Методы: K-Means, DBSCAN, иерархическая кластеризация и т.д.