

Билеты для экзамена

1. Матричное дифференцирование. Определение матричной производной. Градиентный спуск (GD), стохастический градиентный спуск (SGD), mini-batch градиентный спуск: механика работы, достоинства и недостатки.
2. Подходы к процессу обучения в линейных моделях: точный аналитический метод и приближенный численный метод. Достоинства и недостатки. Число обусловленности.
3. Определение важности признаков для линейной модели.
4. Понятие переобучения. Способы борьбы с переобучением.
5. Кросс-валидация, ее виды.
6. Метрики и функционалы ошибки для задач классификации и регрессии.
7. Решающие деревья. Критерии ветвления, выбор оптимальных порогов. Способы борьбы с переобучением в решающих деревьях. Обработка категориальных признаков, обработка пропусков.
8. Линейные методы классификации и регрессии. Определение отступа. Log-loss, Hinge-loss. Обобщения линейных моделей для задачи классификации на K классов. Подходы One-vs-one и one-vs-all.
9. Логистическая регрессия. Вывод формулы логистической регрессии. Регуляризация функционала в логистической регрессии.
10. Калибровочная кривая. Методы калибровки вероятности.
11. Метрики качества классификации и регрессии. Матрица ошибок. Метрики в случае многоклассовой задачи классификации. ROC-кривая, алгоритм построения, площадь под ней, явная формула для ROC-кривой.
12. Кривая AUC-PRC. Алгоритм построения PR-кривой
13. SVM. Вывод оптимизационной задачи. Теория двойственности. Сильная и слабая двойственность. Вывод двойственной задачи в SVM.
14. Задача снижения размерности. Вывод постановки оптимизационной задачи PCA, её решение. Критерии отбора оптимального числа главных компонент. Нелинейные методы снижения размерности (MDS, SNE, t-SNE, etc)

15. Постановка задачи кластеризации. Критерии качества кластеризации.
16. Метод k-means, вывод его шагов.
17. Метод DBSCAN.
18. Байесовский подход в машинном обучении. Априорные и апостериорные распределения параметров. Виды точечных оценок параметров. EM-алгоритм.
19. Рекомендательные системы: общие подходы (эвристический, коллаборативная фильтрация, контентные модели, гибридные подходы, etc). LFM модели в рекомендациях на основе коллаборативной фильтрации (SVD, ALS). Двухшаговый подход в рекомендательных системах. Типы признаков для моделей второго шага.
20. Bias-variance decomposition (BVD). Примеры разложений ошибки для конкретных моделей (бустинг, бэггинг, etc).
21. Построение ансамблей. Бустинг, бэггинг, стекинг: примеры реализаций.
22. Случайный лес. Чем отличается от других ансамблей (к примеру, от бэггинга над решающими деревьями)
23. Out-of-bag оценка в бэггинге.
24. Извлечение признаков из текстовых данных. TF-IDF, Bag of Words.
25. Модели эмбедингов.

Теоретический минимум

- Градиентный спуск (GD), стохастический градиентный спуск (SGD), mini-batch градиентный спуск.
- Применение понятия антиградиента при обучении линейных моделей. Отличия от аналитического подхода.
- L1, L2-регуляризация в задачах линейной регрессии и классификации. Позволяет ли один из указанных способов отбирать признаки? Почему?
- Настройка гиперпараметров с помощью кросс-валидации. K-fold cross-validation, leave-one-out.
- Формула классификации и регрессии в модели kNN. Примеры весов. Примеры метрик.
- Определение линейного классификатора. Понятие отступа (margin). Примеры верхних оценок на долю ошибок. Как обучаются веса?
- Подходы one-vs-one и one-vs-rest для линейных классификаторов.
- Переобучение. Способы борьбы с переобучением.
- Матрица ошибок (confusion matrix). Определение accuracy, precision, recall, F1-score.
- ROC-кривая, AUC-ROC, Gini.
- Определение решающего дерева. Критерии ветвления для различных задач.
- Постановка задачи PCA. Как выбирать оптимальную размерность многомерного пространства?
- Постановка задачи кластеризации. Алгоритмы k-means, DBSCAN.
- Способы оценки качества кластеризации.
- Постановка задачи обучения логистической регрессии.
- Постановка задачи SVM.
- Байесовский подход в машинном обучении. Априорное и апостериорное распределение на параметры. Связь априорного распределения с регуляризацией. Виды точечных оценок (MAP-оценка, байесовская оценка)
- EM-алгоритм.

- Составляющие ошибки. Bias-variance-decomposition.
- Бэггинг, бустинг, стекинг.
- Алгоритм градиентного бустинга.
- TF-IDF и BoW - пошаговое описание алгоритмов векторизации.
- Процедура создания эмбедингов корпусов текста, Word2Vec.