



Решающие деревья


ПРИМЕР



ЛИНЕЙНАЯ МОДЕЛЬ



НЕЛИНЕЙНЫЙ АЛГОРИТМ



Линейные модели

$$a(x) = w_0 + \sum_{j=1}^d w_j x^j$$

- Веса можно интерпретировать, если признаки масштабированы

Пример

- Предсказание стоимости квартиры
- Признаки: площадь, этаж, число комнат

$$a(x) = 10 * (\text{площадь}) + 1.1 * (\text{этаж}) + 20 * (\text{число комнат})$$

Пример

- Зависимость от этажа вряд ли линейная
- Квадратичные признаки:

$$\begin{aligned} a(x) \\ = 10 * (\text{площадь}) + 1.1 * (\text{этаж}) + 20 * (\text{число комнат}) - 0.2 \\ * (\text{этаж})^2 + 0.5 * (\text{площадь} * \text{число комнат}) + \dots \end{aligned}$$

Пример

- С кубическими признаками будет ещё лучше
- Как интерпретировать признак этаж * (число комнат)²?
- Всего таких признаков 20

Пример

- Можно бинаризовать признаки: $[x^j > t]$
- (этаж > 1), (этаж > 2), ..., (этаж > 30)
- Признаков будет на порядки больше
- Легче интерпретировать:
– $2[\text{этаж} > 3][\text{площадь} < 40][\text{число комнат} < 3]$
- Можно использовать L_1 -регуляризацию

Логические правила


$[\text{этаж} > 3][\text{площадь} < 40][\text{число комнат} < 3]$

- Легко объяснить (если ≤ 5 условий)
- Позволяют извлекать знания из данных
- Не факт, что оптимальны с точки зрения качества

Логические правила

- Как строить?
- Линейные модели
- Перебор, жадное наращивание
- Решающие деревья

Медицинская диагностика



Принятие решений






Схема диалога с клиентом




Пассажиры Титаника



Решающее дерево


- Бинарное дерево
- В каждой внутренней вершине записано условие
- В каждом листе записан прогноз (решение)



РЕШАЮЩЕЕ ДЕРЕВО

Решающее дерево – это бинарное дерево, в котором:

1) каждой вершине v приписана функция (предикат) $\beta_v: X \rightarrow \{0,1\}$



Основные компоненты дерева решений:

Корень (Root): Это верхний узел дерева, который представляет весь набор данных. Он делится на два или более подузлов.

Ветви (Branches): Это соединения между узлами, которые представляют собой результаты тестов на признаках.

Узлы (Nodes): Каждый узел представляет собой тест на определенный признак. Внутренние узлы представляют собой тесты, а листья (leaf nodes) представляют собой конечные решения или классы.


Листья (Leaves): Это конечные узлы дерева, которые содержат предсказания или классы.

Предикат — это выражение, которое возвращает логическое значение (истина или ложь) в зависимости от значений его аргументов.

РЕШАЮЩЕЕ ДЕРЕВО

Решающее дерево – это бинарное дерево, в котором:

1) каждой вершине v приписана функция (предикат) $\beta_v: X \rightarrow \{0,1\}$



2) каждой листовой вершине v приписан прогноз $c_v \in Y$ (для классификации – класс или вероятность класса, для регрессии – действительное значение целевой переменной)

УСЛОВИЯ

- Самые популярные варианты:

$$[x^j \leq t] \quad \text{и} \quad [x^j = t]$$


Примеры:

- [этаж = 5]
- [площадь $\leq$ 30]

Прогноз в листе

- Регрессия:
 - Вещественное число
- Классификация:
 - Класс
 - Вероятности классов

Исход футбольного матча



ЖАДНЫЙ АЛГОРИТМ ПОСТРОЕНИЯ РЕШАЮЩЕГО ДЕРЕВА

1 шаг: найдем наилучшее разбиение всей выборки X на две части: $R_1(j, t) = \{x \mid x_j < t\}$ и $R_2(j, t) = \{x \mid x_j \geq t\}$ с точки зрения некоторого функционала $Q(X, j, t)$:


- найдем наилучшие j и t
- создадим корень дерева, поставив в него предикат $[x_j < t]$.

2 шаг: Для каждой из полученных подвыборок R_1 и R_2 рекурсивно применим шаг 1. И т.д.

В каждой вершине на каждом шаге проверяем, не выполнилось ли условие останова. Если выполнилось, то объявляем вершину листом и записываем в него предсказание.

ПРИМЕР


- Жадно найдем наилучший предикат



$$x_2 > 0.8$$

ПРИМЕР


- Жадно найдем наилучший предикат



$$x_1 > 0.5$$

ПРИМЕР



- Жадно найдем наилучший предикат



$$x_2 > 0.5$$



ПРИМЕР

- Нашли лучшее первое ветвление





ПРИМЕР

- Нашли лучшее первое ветвление





ПРИМЕР

- Нашли лучшее второе ветвление



ПРИМЕР

- Построили всё дерево



ПЕРЕОБУЧЕНИЕ

Для любой выборки можно построить решающее дерево, не допускающее на ней ни одной ошибки. Такое дерево скорее всего будет переобученным.



ОБРАБОТКА ПРОПУЩЕННЫХ ЗНАЧЕНИЙ И СТРИЖКА ДЕРЕВА

- Можно модифицировать процедуру разбиения выборки в вершине дерева так, чтобы была возможность обрабатывать пропущенные значения
- После того, как дерево построено, можно удалить несколько его вершин, чтобы понизить сложность алгоритма и снизить переобучение (стрижка дерева или *pruning*).

ЧТО ВЛИЯЕТ НА ПОСТРОЕНИЕ РЕШАЮЩЕГО ДЕРЕВА

- вид предикатов в вершинах
- функционал качества $Q(X, j, t)$
- критерий останова
- метод обработки пропущенных значений
- метод стрижки


ПРИМЕР



1 ошибка, но
скорее всего будет
лучше на тесте!



Жадное построение

- Растим дерево от корня к листьям




Энтропия

- Мера неопределённости распределения




Энтропия

- Мера неопределённости распределения



Высокая энтропия



Низкая энтропия

Энтропия

- Дискретное распределение
- Принимает n значений с вероятностями $p_1, \dots, p_n$
- Энтропия:

$$H(p_1, \dots, p_n) = - \sum_{i=1}^n p_i \log p_i$$


Энтропия

- $(0.2, 0.2, 0.2, 0.2, 0.2)$
- $H = 1.60944 \dots$

- $(0.9, 0.05, 0.05, 0, 0)$
- $H = 0.394398 \dots$

- $(0, 0, 0, 1, 0)$
- $H = 0$

Как сравнить разбиения?




0.693

0

- $(0.5, 0.5, 0)$ и $(0, 0, 1)$
- $H = 0.693 + 0 = 0.693$


1.09

1.09




- $(0.33, 0.33, 0.33)$ и $(0.33, 0.33, 0.33)$
- $H = 1.09 + 1.09 = 2.18$


А для регрессии?



А для регрессии?



А для регрессии?



А для регрессии?

- Выбираем разбиение с наименьшей суммарной дисперсией
- Чем меньше дисперсия, тем меньше неопределённости

Поиск разбиения


- Пусть в вершине t оказалась выборка X_m
- $Q(X_m, j, t)$ — критерий ошибки условия $[x^j \leq t]$
- Ищем лучшие параметры j и t перебором:

$$Q(X_m, j, t) \rightarrow \max_{j, t}$$

Критерий качества

$$Q(X_m, j, t) = H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r)$$

Разброс ответов в левом
листе



Разброс ответов в правом
листе

Критерий информативности

- $H(X)$
- Зависит от ответов на выборке X
- Чем меньше разброс ответов, тем меньше значение $H(X)$

Регрессия

$$\bar{y}(X) = \frac{1}{|X|} \sum_{i \in X} y_i$$

$$H(X) = \frac{1}{|X|} \sum_{i \in X} (y_i - \bar{y}(X))^2$$

Классификация

- Доля объектов класса k в выборке X :

$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$

Энтропийный критерий

$$H(X) = - \sum_{k=1}^K p_k \ln p_k$$

- Считаем, что $0 \ln 0 = 0$
- Если $p_1 = 1, p_2 = \dots = p_K = 0$, то $H(X) = 0$
- Мера отличия распределения классов от вырожденного

Поиск разбиения

- После того, как разбиение найдено:

- Разбиваем X_m на две части:

$$X_l = \{x \in X_m \mid [x^j \leq t]\}$$

$$X_r = \{x \in X_m \mid [x^j > t]\}$$

- Повторяем процедуру для дочерних вершин

Критерий останова

- В какой момент прекращать разбиение вершин?
- В вершине один объекты?
- В вершине объекты одного класса?
- Глубина превысила порог?

Ответ в листе

- Допустим, решили сделать вершину t листом
- Какой прогноз выбрать?
- Регрессия:

$$a_m = \frac{1}{|X_m|} \sum_{i \in X_m} y_i$$


- Классификация:

$$a_m = \arg \max_{y \in \mathbb{Y}} \sum_{i \in X_m} [y_i = y]$$


Жадный алгоритм построения дерева

1. Поместить в корень всю выборку: $X_1 = X$
2. Начать построение с корня: $m = 1$
3. Если выполнен критерий останова для вершины m , то выход
4. Найти лучшее разбиение $[x^j \leq t]$ для вершины m
5. Разбить вершину m на дочерние вершины l и r
6. Повторить шаги 3-6 для дочерних вершин l и r


Обучение деревьев




Признаки



Разбиения по признаку 1



Разбиения по признаку 1




$(1, 0)$
 $H(p) = 0$

$(1/2, 1/2)$
 $H(p) = 0.69$


$$\frac{3}{13}H(p_l) + \frac{10}{13}H(p_r) = 0.53$$

Разбиения по признаку 1




$$\frac{4}{13}H(p_l) + \frac{9}{13}H(p_r) = 0.65$$

Разбиения по признаку 1




$$\frac{5}{13}H(p_l) + \frac{8}{13}H(p_r) = 0.62$$

Разбиения по признаку 2



Разбиения по признаку 2




$(4/9, 5/9)$
 $H(p) = 0.69$

$(1, 0)$
 $H(p) = 0$

$$\frac{4}{13}H(p_l) + \frac{9}{13}H(p_r) = 0.47$$

Разбиения по признаку 2




$(4/6, 2/6)$
 $H(p) = 0.64$

$(4/7, 3/7)$
 $H(p) = 0.68$

$$\frac{7}{13}H(p_l) + \frac{6}{13}H(p_r) = 0.66$$

Разбиения по признаку 2




$(1/2, 1/2)$
 $H(p) = 0.69$

$(6/9, 3/9)$
 $H(p) = 0.46$

$$\frac{9}{13}H(p_l) + \frac{4}{13}H(p_r) = 0.53$$

Разбиения по признаку 2





$(4/9, 5/9)$
 $H(p) = 0.69$

$(1, 0)$
 $H(p) = 0$



$$\frac{4}{13}H(p_l) + \frac{9}{13}H(p_r) = 0.47$$

Лучшее разбиение!



Обучение деревьев





Обучение деревьев



Обучение деревьев




Обучение деревьев




Переобучение деревьев и
борьба с ним


Классификация




Классификация




Классификация




Классификация



Регрессия




Регрессия




Решающие деревья

- Восстанавливают сложные закономерности
- Могут построить сколь угодно сложную поверхность
- Чем больше глубина — тем сложнее поверхность
- Склонны к переобучению



Глубина деревьев



Переобучение деревьев



Переобучение деревьев



Переобучение деревьев


- Дерево может достичь нулевой ошибки на любой выборке
- Как правило, такое дерево окажется переобученным
- Выход — ограничивать глубину или число объектов в листе

Критерий останова

- Как понять, разбивать вершину или делать листовой?
- Способ борьбы с переобучением

Критерий останова




- Все объекты в вершине относятся к одному классу
- Простое условие
- Но приводит к переобучению



Число объектов в листе

- В вершину попало $\leq n$ объектов
- При $n = 1$ получаем максимально переобученные деревья
- n должно быть достаточно, чтобы построить надёжный прогноз
- Рекомендация: $n = 5$




Число объектов в листе



Глубина дерева

- Ограничение на глубину
- Достаточно грубый критерий



Глубина дерева




Неустойчивость деревьев

- Структура дерева очень сильно меняется даже при малом изменении выборки
- Пример: обучим два дерева по подвыборкам размером 90% от всего обучения

Неустойчивость деревьев



Усреднение деревьев




Резюме

- Решающее дерево — очень мощная модель
- Обучение эвристическое
- Много тонкостей с переобучением
- Обычно используется в композициях — на следующей лекции

Композиции алгоритмов

Majority vote

- Как выглядит логотип факультета компьютерных наук?



Majority vote

- Как выглядит логотип факультета компьютерных наук?
- Какой из двух логотипов более старый?



Majority vote

- Как выглядит логотип факультета компьютерных наук?
- Какой из двух логотипов более старый?
- Как выглядит корпус Вышки в Перми?



Majority vote

- Как выглядит логотип факультета компьютерных наук?
- Какой из двух логотипов более старый?
- Как выглядит корпус Вышки в Перми?
- Покоординатный спуск — это метод оптимизации 1-го или 2-го порядка?

Majority vote

- Дано: N базовых алгоритмов $b_1(x), \dots, b_N(x)$
- Каждый хотя бы немного лучше случайного угадывания
- Композиция: класс, за который проголосовало больше всего базовых алгоритмов

$$a(x) = \arg \max_{y \in \mathbb{Y}} \sum_{n=1}^N [b_n(x) = y]$$

Усреднение наблюдений

- Наблюдение: усреднение результатов повышает их точность
- Измерение артериального давления
- Измерение скорости света
- Усреднение соседних пикселей изображения

Усреднение наблюдений

- Сколько лет факультету компьютерных наук?

Усреднение наблюдений

- Сколько лет факультету компьютерных наук?
- Сколько метров в 1 сажени?

Усреднение наблюдений

- Сколько лет факультету компьютерных наук?
- Сколько метров в 1 сажени?
- Сколько лет лектору?

Усреднение наблюдений

- Сколько лет факультету компьютерных наук?
- Сколько метров в 1 сажени?
- Сколько лет лектору?
- Сколько всего стран в мире?

Усреднение наблюдений

- Дано: N базовых алгоритмов $b_1(x), \dots, b_N(x)$
- Каждый хотя бы немного лучше случайного угадывания
- Композиция:

$$a(x) = \frac{1}{N} \sum_{n=1}^N b_n(x)$$