Снижение размерности

Данила Кочнев

31.10.2026

Как сказал кто-то из великих

«Любая задача обучения без учителя – это шляпа полная. Старайтесь всегда уходить от нее в пользу задачи, где у вас есть понятная целевая переменная»

– Антон Андрейцев



Назначение снижения размерности

Задача: Имея *высокоразмерную* выборку $X \in \mathbb{R}^{n \times d}$ сформировать новую *низкоразмерную* выборку $Z \in \mathbb{R}^{n \times k}$, где $k \ll d$, сохранив *как можно больше информации о данных*.

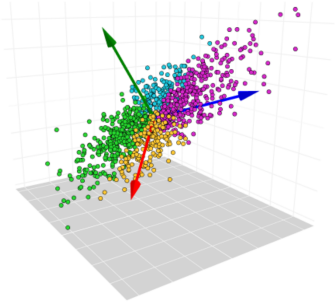
Назначение снижения размерности

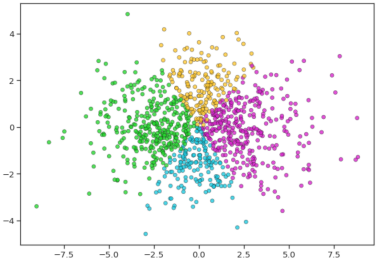
Задача: Имея *высокоразмерную* выборку $X \in \mathbb{R}^{n \times d}$ сформировать новую *низкоразмерную* выборку $Z \in \mathbb{R}^{n \times k}$, где $k \ll d$, сохранив *как можно больше информации о данных*.

Для чего это может быть полезно:

- Ускорение обучения и инференса моделей и сокращение затрат памяти ($\approx$)
- Борьба с проклятьем размерности, зашумленностью и мультиколлинеарностью в данных ($\approx$)
- Генерация новых фичей и подготовка данных к кластеризации
- Осмысленная визуализация X в $\mathbb{R}^2$ или $\mathbb{R}^3$

Геометрическая идея метода главных компонент





[source]

Идея: отыскать k-мерное линейное подпространство, *наиболее похожее* на наши данные X, и выбрать в нем ортонормированный базис.

Оптимизационная задача PCA – постановка

Формализация:

- Центрируем данные $X \mapsto X - \overline{X}$, чтобы была осмысленной именно задача поиска k-мерного *подпространства* L, а не многообразия

Оптимизационная задача PCA – постановка

Формализация:

- Центрируем данные $X \mapsto X - \overline{X}$, чтобы была осмысленной именно задача поиска k-мерного *подпространства* L, а не многообразия
- Если в подпространстве L выбран *ортонормированный базис* $\vec{\mathbf{v}}_1, \vec{\mathbf{v}}_2, \ldots, \vec{\mathbf{v}}_k$, то наилучшее приближение X векторами из L – это проекция $\hat{X}_i^\top = VV^\top X_i^\top$, то есть $\hat{X} = XVV^\top$ (ортонормированность базиса означает, что $V^\top V = I_k$)

Оптимизационная задача PCA – постановка

Формализация:

- Центрируем данные $X \mapsto X - \overline{X}$, чтобы была осмысленной именно задача поиска k-мерного *подпространства* L, а не многообразия
- Если в подпространстве L выбран *ортонормированный базис* $\vec{\mathbf{v}}_1, \vec{\mathbf{v}}_2, \ldots, \vec{\mathbf{v}}_k$, то наилучшее приближение X векторами из L – это проекция $\hat{X}_i^\top = VV^\top X_i^\top$, то есть $\hat{X} = XVV^\top$ (ортонормированность базиса означает, что $V^\top V = I_k$)
- Тогда новая *сжатая* выборка Z находится в виде линейного преобразования $Z = XV$ (где $V \in \mathbb{R}^{d \times k}$), то есть $z_{ij} = \sum x_{ik} v_{kj}$

Оптимизационная задача PCA – постановка

Формализация:

- Центрируем данные $X \mapsto X - \overline{X}$, чтобы была осмысленной именно задача поиска k-мерного *подпространства* L, а не многообразия
- Если в подпространстве L выбран *ортонормированный базис* $\vec{\mathbf{v}}_1, \vec{\mathbf{v}}_2, \ldots, \vec{\mathbf{v}}_k$, то наилучшее приближение X векторами из L – это проекция $\hat{X}_i^\top = VV^\top X_i^\top$, то есть $\hat{X} = XVV^\top$ (ортонормированность базиса означает, что $V^\top V = I_k$)
- Тогда новая *сжатая* выборка Z находится в виде линейного преобразования $Z = XV$ (где $V \in \mathbb{R}^{d \times k}$), то есть $z_{ij} = \sum x_{ik} v_{kj}$
- *Расстояние между* матрицами определим как $\|A - B\|_F = \sqrt{\sum (a_{ij} - b_{ij})^2}$ (*норма Фробениуса*)

Итоговая оптимизационная задача PCA:

$$\left\|X - \hat{X}\right\|_F^2 = \left\|X - XVV^\top\right\|_F^2 \longrightarrow \min_{V \in \mathbb{R}^{d \times k} \,:\, V^\top V = I_k}$$

Оптимизационная задача PCA – решение I

- Поскольку $\|A\|_F^2 = \operatorname{tr}(AA^\top)$, то

$$\begin{aligned}\left\|X - XVV^\top\right\|_F^2 &= \operatorname{tr}\left[\left(X - XVV^\top\right)\left(X^\top - VV^\top X^\top\right)\right] = \\ &= \operatorname{tr}\left[XX^\top - XVV^\top X^\top - \left(XVV^\top X^\top - XV\cancel{V^\top V}V^\top X^\top\right)\right] = \\ &= \operatorname{tr}\left(XX^\top\right) - \operatorname{tr}\left(XVV^\top X^\top\right) = \operatorname{tr}\left(XX^\top\right) - \operatorname{tr}\left(V^\top X^\top XV\right)\end{aligned}$$

- Значит, оптимизационная задача PCA эквивалентна задаче

$$\operatorname{tr}\left(V^\top X^\top XV\right) = \sum_{i=1}^{k} \vec{\mathbf{v}}_i^\top X^\top X \vec{\mathbf{v}}_i \longrightarrow \max_{V \in \mathbb{R}^{d\times k}\,:\, V^\top V = I_k} \equiv \max_{\substack{\vec{\mathbf{v}}_i^\top \vec{\mathbf{v}}_i = 1 \\ \vec{\mathbf{v}}_i^\top \vec{\mathbf{v}}_j = 0}}$$

Оптимизационная задача PCA – решение II

- Рассмотрим вспомогательную задачу $\vec{\mathbf{v}}^\top S\vec{\mathbf{v}} \to \max$ при условии $\vec{\mathbf{v}}^\top\vec{\mathbf{v}} = 1$:

$$\mathcal{L} = \vec{\mathbf{v}}^\top S\vec{\mathbf{v}} + \lambda(\vec{\mathbf{v}}^\top\vec{\mathbf{v}} - 1) \implies \nabla_{\vec{\mathbf{v}}}\mathcal{L} = 2S\vec{\mathbf{v}} + 2\lambda\vec{\mathbf{v}} = 0 \implies S\vec{\mathbf{v}} = -\lambda\vec{\mathbf{v}}$$

Оптимизационная задача PCA – решение II

- Рассмотрим вспомогательную задачу $\vec{\mathbf{v}}^\top S\vec{\mathbf{v}} \to \max$ при условии $\vec{\mathbf{v}}^\top\vec{\mathbf{v}} = 1$:

$$\mathcal{L} = \vec{\mathbf{v}}^\top S\vec{\mathbf{v}} + \lambda(\vec{\mathbf{v}}^\top\vec{\mathbf{v}} - 1) \implies \nabla_{\vec{\mathbf{v}}}\mathcal{L} = 2S\vec{\mathbf{v}} + 2\lambda\vec{\mathbf{v}} = 0 \implies S\vec{\mathbf{v}} = -\lambda\vec{\mathbf{v}}$$

- Получается, необходимому условию экстремума удовлетворяют только нормированные *собственные векторы* матрицы $S = X^\top X$ (которые из-за симметричности получаются автоматически ортогональны друг другу)

Оптимизационная задача PCA – решение II

- Рассмотрим вспомогательную задачу $\vec{\mathbf{v}}^\top S\vec{\mathbf{v}} \to \max$ при условии $\vec{\mathbf{v}}^\top\vec{\mathbf{v}} = 1$:

$$\mathcal{L} = \vec{\mathbf{v}}^\top S\vec{\mathbf{v}} + \lambda(\vec{\mathbf{v}}^\top\vec{\mathbf{v}} - 1) \implies \nabla_{\vec{\mathbf{v}}}\mathcal{L} = 2S\vec{\mathbf{v}} + 2\lambda\vec{\mathbf{v}} = 0 \implies S\vec{\mathbf{v}} = -\lambda\vec{\mathbf{v}}$$

- Получается, необходимому условию экстремума удовлетворяют только нормированные *собственные векторы* матрицы $S = X^\top X$ (которые из-за симметричности получаются автоматически ортогональны друг другу)
- Более того, максимальное достигнутое значение целевой функции и остаточная ошибка равны соответственно

$$\operatorname{tr}\left(V^\top X^\top XV\right) = \sum_{i=1}^{k} \vec{\mathbf{v}}_i^\top X^\top X\vec{\mathbf{v}}_i = \sum_{i=1}^{k}\lambda_i$$

$$\left\|X - XVV^\top\right\|_F^2 = \operatorname{tr}\left(XX^\top\right) - \operatorname{tr}\left(V^\top X^\top XV\right) = \sum_{i=k+1}^{d}\lambda_i$$

Алгоритм PCA – итог

Теорема (основная теорема метода главных компонент)

Если $k \leq \operatorname{rank} X$ и $X^\top \vec{\mathbf{1}} = \vec{\mathbf{0}}$, то $\min \left\| X - ZV^\top \right\|_F^2$ достигается, когда столбцы V – собственные векторы $X^\top X$, соответствующие k максимальным собственным числам $\lambda_1, \lambda_2, \ldots, \lambda_k$, а оптимально линейно сжатые данные имеют вид $Z = XV$.

Более того, новые данные некоррелированны: $Z^\top Z = \Lambda$, а минимальная остаточная ошибка равна сумме отброшенных собственных значений $\lambda_{k+1} + \lambda_{k+1} + \ldots + \lambda_d$.

Алгоритм PCA:

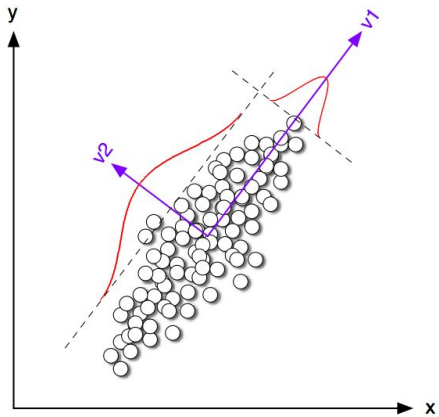
1. Центрируем столбцы матрицы $X \mapsto X - \overline{X}$
2. Вычисляем собственные числа и собственные векторы матрицы $X^\top X$
3. Формируем сжатые данные в виде $Z = XV$

Статистический смысл

1. Поскольку $Z = XV$, то

$$\vec{\mathbf{v}}_i^\top X^\top X \vec{\mathbf{v}}_i = \vec{\mathbf{z}}_i^\top \vec{\mathbf{z}}_i = \sum_{j=1}^{k} z_{ij}^2 = n \,\hat{\mathrm{var}}\, \vec{\mathbf{z}}_i$$

2. Задача выбора $\vec{\mathbf{v}}_i$ – это задача отыскания направления, в котором остаточная дисперсия выборки максимальна
3. Статистически $\frac{\lambda_i}{\sum \lambda_j}$ – доля дисперсии, объясненной i-ой главной компонентой $\vec{\mathbf{z}}_i$

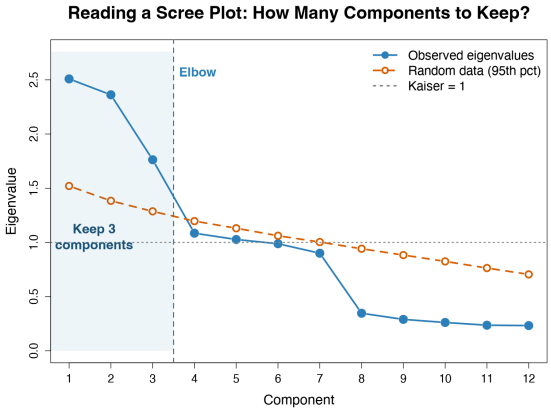


[source]

Выбор числа главных компонент

Варианты отбора числа компонент:

1. *Правило Кайзера–Гуттмана*: отбираются компоненты, для которых $\lambda_i > \frac{\mathrm{tr}(X^\top X)}{n}$
2. *Правило локтя Кеттела*: компоненты отбираются до «локтя» графика λ_i
3. *Правило сломанной трости*: отбираются те компоненты, для которых $\frac{\lambda_i}{\sum_{j=1}^{d} \lambda_j} > \frac{1}{d} \sum_{j=i}^{d} \frac{1}{j}$



[source]

Нюансы и приложения PCA

В содержательных экономических исследованиях PCA и родственные ему техники *факторного анализа* активно применяют, например,

1. В демографии [Shevky & Williams, 1950] и экономике развития [Schamberger et al., 2023]
2. В маркетинге [Desarbo et al., 2007] и финансах [Yang et al., 2015]

Важные особенности:

1. PCA требует предварительной нормировки данных и чувствителен к выбросам (но зато возвращает некорелированные признаки и быстро считается)
2. PCA сжимает данные линейно, поэтому не может точно воспроизвести сложную геометрию многомерного пространства
3. Иногда могут возникать *интерпретируемые* главные компоненты или *автоматическая кластеризация*

Сингулярное разложение матрицы – теорема

Теорема (об SVD-разложении)

Пусть дана матрица $A \in \mathbb{R}^{m \times n}$. Тогда существуют

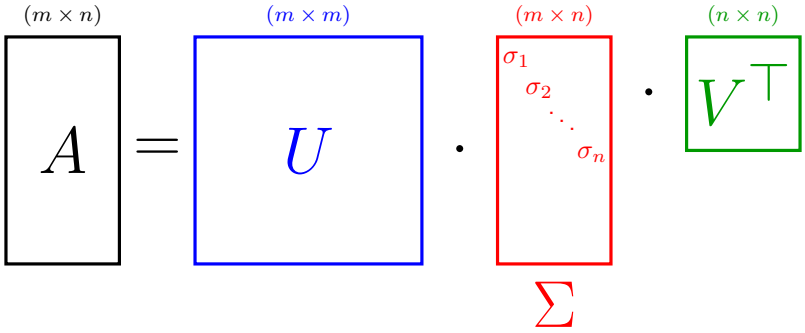
- Ортогональные матрицы $U \in \mathbb{R}^{m \times m}$ и $V \in \mathbb{R}^{n \times n}$ (то есть $U^\top U = UU^\top = I_m$ и $V^\top V = VV^\top = I_n$)
- Прямоугольная диагональная матрица $\Sigma \in \mathbb{R}^{m \times n}$ (того же размера, что и A) с неотрицательными числами на главной диагонали

Такие что имеет место представление $A = U\Sigma V^\top$.

В этом контексте

- Столбцы U называются *левыми сингулярными векторами* A
- Столбцы V называются *правыми сингулярными векторами* A
- Числа $\sigma_i = \Sigma_{ii}$ называются *сингулярными числами* A

Сингулярное разложение – структура



Усеченным SVD называется произведение $A_k = U_k \Sigma_k V_k^\top$, где матрицы U_k и V_k получаются из соответствующих матриц для SVD выбрасыванием всех столбцов, кроме первых k (предполагается, что $\sigma_1 \geq \sigma_2 \geq \ldots \geq \sigma_r \geq 0$).

Сингулярное разложение – рецепт из бабкиной поваренной книги

Если сингулярное разложение имеет место, то, вычисляя $AA^\top$ или $A^\top A$ с его помощью и замечая в результате спектральное разложение, можно увидеть, что

1. $AA^\top = U\left(\Sigma\Sigma^\top\right)U^{-1}$, то есть матрица $\Sigma\Sigma^\top$ – диагональная форма $AA^\top$

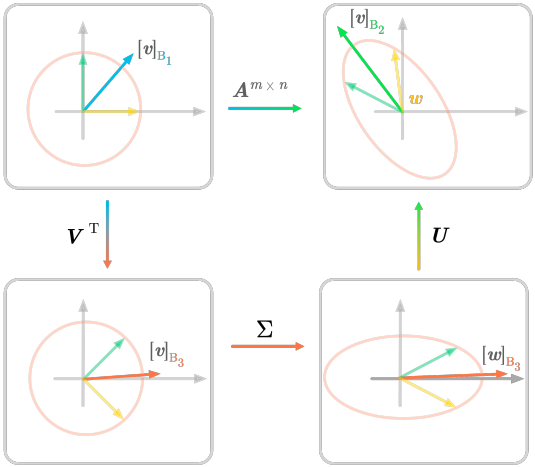
   Поэтому числа σ_i^2 совпадают с собственными значениями $AA^\top$ (и $A^\top A$)

   Более того, тогда столбцы матрицы U – (нормированные) собственные векторы матрицы $AA^\top$

2. Аналогично $A^\top A = V\left(\Sigma^\top\Sigma\right)V^{-1}$, то есть матрица $\Sigma^\top\Sigma$ – диагональная форма матрицы $A^\top A$

   Отсюда получается, что столбцы матрицы V (они же – строки матрицы $V^\top$) – (нормированные) собственные векторы матрицы $A^\top A$

Геометрия SVD



[source]

Связь с PCA и другие приложения SVD

Теорема (Эккарта–Янга–Мирского)

Решением задачи оптимального среднеквадратичного малорангового приближения

$$\left\|A - \hat{A}\right\|_F^2 \longrightarrow \min_{\hat{A}\,:\,\operatorname{rank}\hat{A}\leq k}$$

Является усеченное SVD-разложение $\hat{A} = U_k \Sigma_k V_k^\top$.

1. Из теоремы Э.–Я.–М. следует, что при центрировании данных усеченное SVD в точности дает оптимальное линейное сжатие, которое получается при решении задачи PCA (матрицы V в этих задачах совпадают)
2. Кроме того, это свойство SVD иногда используется в обработке сигналов и изображений для устранения шума или сжатия данных
3. Алгоритмы, связанные с SVD, встречаются в анализе естественного языка (LSA) и рекомендательных системах (коллаборативная фильтрация)

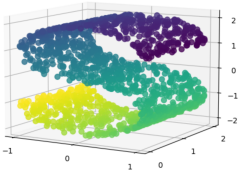
Metric MDS (multidimensional scaling)

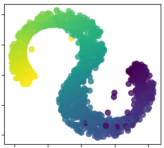
Метрическая идея: хорошее маломерное представление сохраняет *попарные расстояния* между точками, то есть $d_X(\vec{\mathbf{x}}_i, \vec{\mathbf{x}}_j) \approx d_Z(\vec{\mathbf{z}}_i, \vec{\mathbf{z}}_j)$

Тогда разумно поставить оптимизационную задачу вида

$$\text{stress}(Z \mid X) = \sum_{i<j} w_{ij}\big(d_X(\vec{\mathbf{x}}_i, \vec{\mathbf{x}}_j) - d_Z(\vec{\mathbf{z}}_i, \vec{\mathbf{z}}_j)\big)^2 \longrightarrow \min_Z$$

1. Классический MDS (когда обе метрики – евклидовы) сводится к PCA над преобразованной матрицей попарных расстояний
2. MDS страдает от *«проклятья размерности»* и *проблемы скучивания*



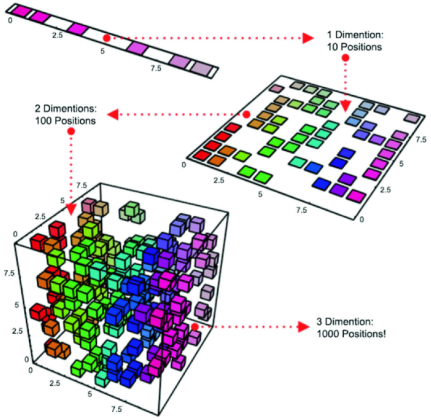


[source]

Curse of dimensionality and crowding problem

Плохая новость от геометров: в многомерном пространстве заметно легче уложить множество точек на околоравном расстоянии друг от друга, в то время как при переносе в маломерное пространство они неизбежно «скучиваются»

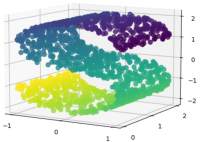
Например, в $\mathbb{R}^3$ можно уместить четыре точки, находящиеся друг от друга на расстоянии 1 каждая, а в $\mathbb{R}^2$ попарно равноудаленных точек находится не больше трех

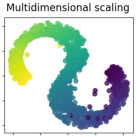


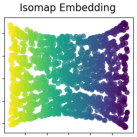
[source]

Isomap

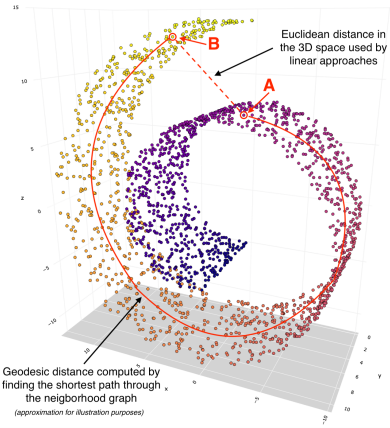
Метрическая идея получше: можно измерять расстояние d_X не как евклидово, а как *геодезическое*, предварительно превратив данные в граф и сосчитав кратчайшие пути между всеми парами точек, а затем запустив MDS.







[source]



[source]

t-SNE – условные вероятности и перплексия

Вероятностная идея: хорошее маломерное представление сохраняет *вероятности локального соседства*, то есть $\mathbb{P}(\vec{\mathbf{x}}_j \text{ рядом с } \vec{\mathbf{x}}_i) \approx \mathbb{P}(\vec{\mathbf{z}}_j \text{ рядом с } \vec{\mathbf{z}}_i)$.

1. Пусть log-вероятность $\vec{\mathbf{x}}_j$ оказаться по соседству с $\vec{\mathbf{x}}_i$ пропорциональна $-\|\vec{\mathbf{x}}_i - \vec{\mathbf{x}}_j\|^2$, то есть положим $p_{i|i} = 0$ и для $j \neq i$

$$p_{j|i} = \frac{\exp\left(-\frac{1}{2\sigma_i^2}\|\vec{\mathbf{x}}_i - \vec{\mathbf{x}}_j\|^2\right)}{\sum\limits_{k \neq i} \exp\left(-\frac{1}{2\sigma_i^2}\|\vec{\mathbf{x}}_i - \vec{\mathbf{x}}_k\|^2\right)}$$

t-SNE – условные вероятности и перплексия

Вероятностная идея: хорошее маломерное представление сохраняет *вероятности локального соседства*, то есть $\mathbb{P}(\vec{\mathbf{x}}_j \text{ рядом с } \vec{\mathbf{x}}_i) \approx \mathbb{P}(\vec{\mathbf{z}}_j \text{ рядом с } \vec{\mathbf{z}}_i)$.

1. Пусть log-вероятность $\vec{\mathbf{x}}_j$ оказаться по соседству с $\vec{\mathbf{x}}_i$ пропорциональна $-\|\vec{\mathbf{x}}_i - \vec{\mathbf{x}}_j\|^2$, то есть положим $p_{i|i} = 0$ и для $j \neq i$

$$p_{j|i} = \frac{\exp\left(-\frac{1}{2\sigma_i^2}\|\vec{\mathbf{x}}_i - \vec{\mathbf{x}}_j\|^2\right)}{\sum\limits_{k \neq i} \exp\left(-\frac{1}{2\sigma_i^2}\|\vec{\mathbf{x}}_i - \vec{\mathbf{x}}_k\|^2\right)}$$

2. Параметр σ_i^2 отвечает за плотность точек в окрестности $\vec{\mathbf{x}}_i$ (чем больше σ_i^2, тем плотнее выборка рядом с $\vec{\mathbf{x}}_i$) и подбирается как решение уравнения

$$-\sum_{j \neq i} p_{j|i} \log_2 p_{j|i} = \log_2(\text{perplexity})$$

t-SNE – симметризация и целевое распределение

1. Симметризуем распределение $p_{j|i}$ (иначе в итоговой оптимизационной задаче возникают нелогичные / несправедливые штрафы):

$$\mathbb{P}(\vec{\mathbf{x}}_j \text{ рядом с } \vec{\mathbf{x}}_i) = p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

t-SNE – симметризация и целевое распределение

1. Симметризуем распределение $p_{j|i}$ (иначе в итоговой оптимизационной задаче возникают нелогичные / несправедливые штрафы):

$$\mathbb{P}(\vec{\mathbf{x}}_j \text{ рядом с } \vec{\mathbf{x}}_i) = p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

2. Деление на n в знаменателе возникает из соображений нормировки:

$$\sum_{i,j} p_{ij} = \frac{1}{2n}\left[\sum_{i,j} p_{j|i} + \sum_{i,j} p_{i|j}\right] = \frac{n+n}{2n} = 1$$

t-SNE – симметризация и целевое распределение

1. Симметризуем распределение $p_{j|i}$ (иначе в итоговой оптимизационной задаче возникают нелогичные / несправедливые штрафы):

$$\mathbb{P}(\vec{\mathbf{x}}_j \text{ рядом с } \vec{\mathbf{x}}_i) = p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

2. Деление на n в знаменателе возникает из соображений нормировки:

$$\sum_{i,j} p_{ij} = \frac{1}{2n}\left[\sum_{i,j} p_{j|i} + \sum_{i,j} p_{i|j}\right] = \frac{n+n}{2n} = 1$$

3. Во избежание *скучивания* будем для расстояний в маломерном пространстве использовать многомерное распределение Коши: $q_{ii} = 0$ и при $i \neq j$

$$\mathbb{P}(\vec{\mathbf{z}}_i \text{ рядом с } \vec{\mathbf{z}}_j) = q_{ij} = \frac{\left(1 + \|\vec{\mathbf{z}}_i - \vec{\mathbf{z}}_j\|^2\right)^{-1}}{\sum\limits_k \sum\limits_{l \neq k} \left(1 + \|\vec{\mathbf{z}}_k - \vec{\mathbf{z}}_l\|^2\right)^{-1}}$$

KL-расхождение

Будем подбирать Z так, чтобы $\mathbb{P}(\vec{\mathbf{x}}_j$ рядом с $\vec{\mathbf{x}}_i) \approx \mathbb{P}(\vec{\mathbf{z}}_j$ рядом с $\vec{\mathbf{z}}_i)$. Для этого введем классическую меру отличия между распределениями – *KL-расхождение (или дивергенцию Кульбака–Лейблера)*:

$$\mathrm{D}_{\mathrm{KL}}(P \parallel Q) = \mathbb{E}_{\sim p} \log \frac{p}{q} = \int_{-\infty}^{+\infty} p(x) \log \frac{p(x)}{q(x)} dx \quad \text{или} \quad \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)}$$

KL-расхождение

Будем подбирать Z так, чтобы $\mathbb{P}(\vec{\mathbf{x}}_j \text{ рядом с } \vec{\mathbf{x}}_i) \approx \mathbb{P}(\vec{\mathbf{z}}_i \text{ рядом с } \vec{\mathbf{z}}_j)$. Для этого введем классическую меру отличия между распределениями – *KL-расхождение (или дивергенцию Кульбака–Лейблера)*:

$$\mathrm{D}_{\mathrm{KL}}(P \parallel Q) = \mathbb{E}_{\sim p} \log \frac{p}{q} = \int_{-\infty}^{+\infty} p(x) \log \frac{p(x)}{q(x)} dx \quad \text{или} \quad \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)}$$

Полезные свойства KL-расхождения:

1. KL-расхождение неотрицательно (*неравенство Гиббса*)
2. KL-расхождение несимметрично относительно P и Q, поэтому **не** задает метрику ($\mathrm{D}_{\mathrm{KL}}(P \parallel Q) \neq \mathrm{D}_{\mathrm{KL}}(Q \parallel P)$)
3. KL-расхождение между P и Q измеряет то, насколько *«пробное»* распределение Q удачно приближает *«истинное»* распределение P

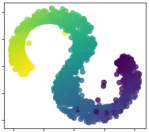
Обучение и особенности t-SNE – I

Оптимизационная задача t-SNE:

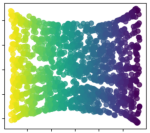
$$\mathrm{D}_{\mathrm{KL}}(P \parallel Q) = \sum_j \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}} \longrightarrow \min_Z$$

1. Для t-SNE очень свойственна автоматическая кластеризация (в том числе *ложная*)
2. t-SNE может хорошо чувствовать сложную геометрию и удачно изображать сложные многомерные данные
3. Оптимум t-SNE может быть неединственным, поэтому результат, вообще говоря, трудно воспроизводим
4. t-SNE вычислительно сложен и требует подбора perplexity (причем без четкого критерия качества)

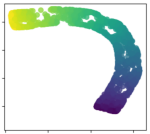
Multidimensional scaling



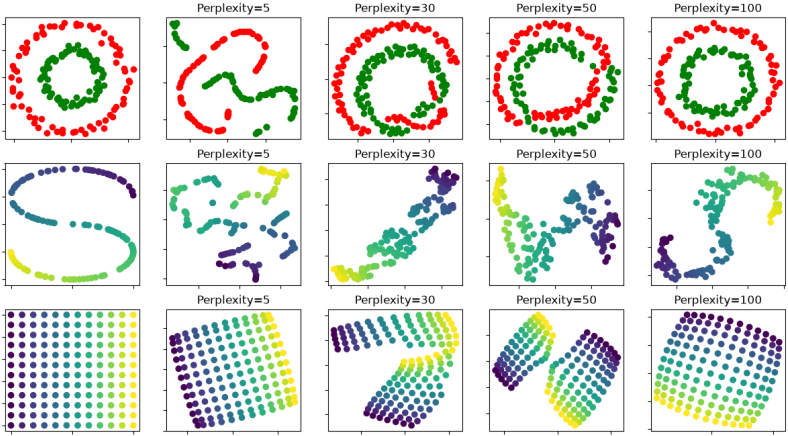
Isomap Embedding



T-distributed Stochastic Neighbor Embedding



Обучение и особенности t-SNE – II



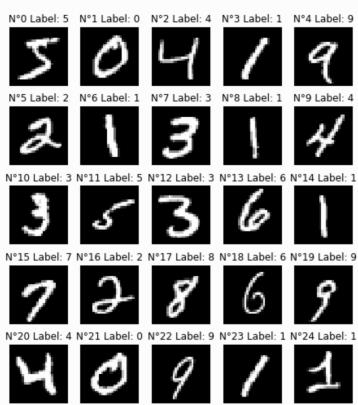
[source]

MNIST dataset

MNIST (*Modified National Institute of Standards and Technology*) – громадный датасет, сформированный в 1980-1990-х годах

Содержит десятки тысяч образцов рукописных цифр в виде картинок 28 × 28 пикселей в оттенках серого (одноканальное изображение)

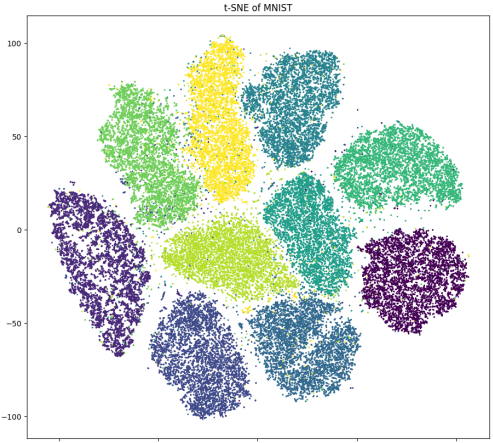
Если «вытянуть» картинку 28 × 28 пикселей в длинный вектор из 784 фичей, получим очень высокоразмерный датасет, на котором интересно сравнить PCA и t-SNE



[source]

Dimensionality Reduction on MNIST – I





[source]

Dimensionality Reduction on MNIST – II (actually, not MNIST really hehe)



[source]

О чем еще можно почитать

- Ценители линейной алгебры могут поинтересоваться, как именно sklearn вычисляет PCA и SVD, а также почитать, кто такой факторный анализ и что его роднит с PCA
- После лекции по SVM можно будет почитать, как работает ядерный PCA (kernel PCA) и как с ним связаны Metric MDS и Isomap
- Можно попробовать разобраться, как работает UMAP (достаточно замороченный метод, похожий на t-SNE, но имеющий за душой больше математического бэкграунда)
- В рамках курса по DL в следующем семестре можно поинтересоваться, какие DL-модели используют для снижения размерности (например, автокодировщики)

Спасибо за внимание

Буду рад ответить на ваши вопросы