Понижение размерности

Отбор признаков и понижение размерности

Анализ данных ЭЭГ

- Энцефалограф: 64 датчика, частота сигнала 256 Гц
- Объект: результаты измерений для одного пациента
- За 5 секунд измерений: $64 * 256 * 5 = 81\,920$ признаков



Электроэнцефалография, ЭЭГ — раздел электрофизиологии, изучающий закономерности суммарной электрической активности мозга

Задача понижения размерности

- Дано: матрица «объекты-признаки» $\boldsymbol{X}$ размера $\ell \times \boldsymbol{D}$
- Найти: новую матрицу «объекты-признаки» $\boldsymbol{Z}$ размера $\ell \times \boldsymbol{d}$
- $d < D$

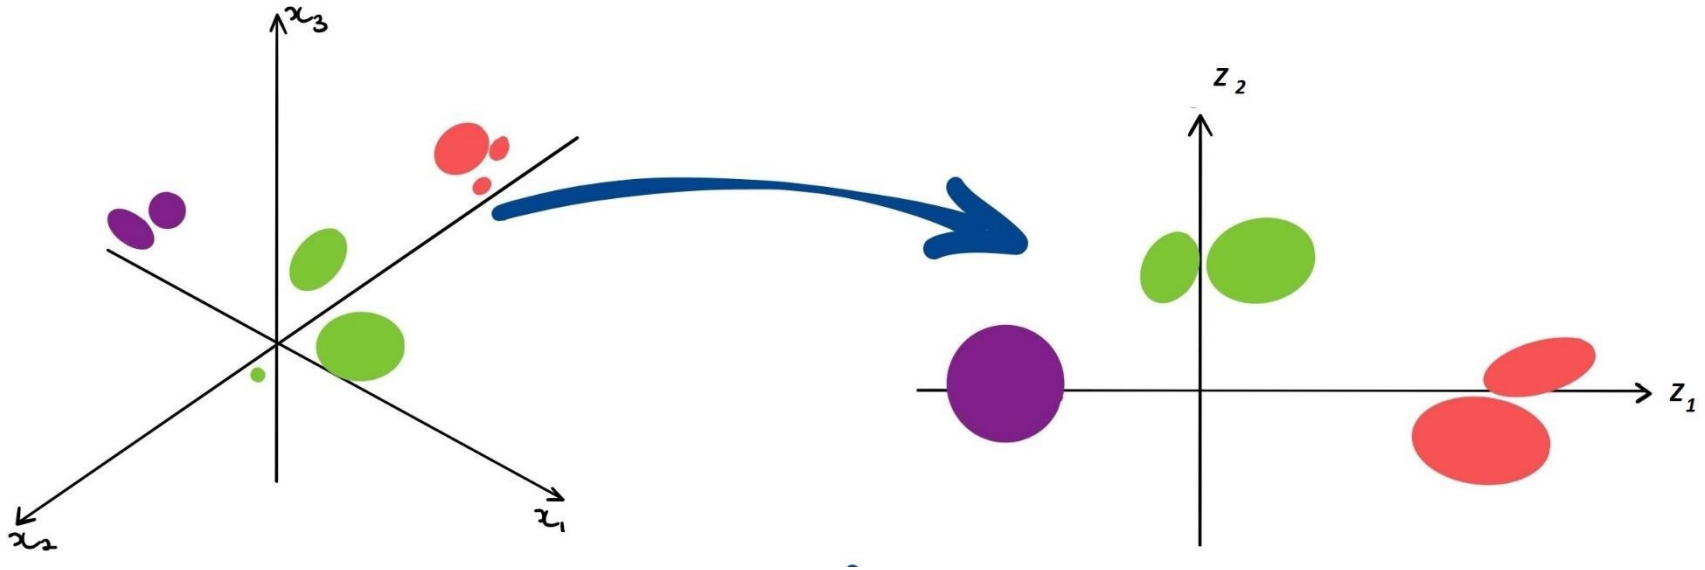
Методы понижения размерности

- Отбор признаков (feature selection)
  - Выбрать d самых важных признаков
- **Извлечение признаков (feature extraction)**
  - Найти d новых признаков, выражающихся через исходные

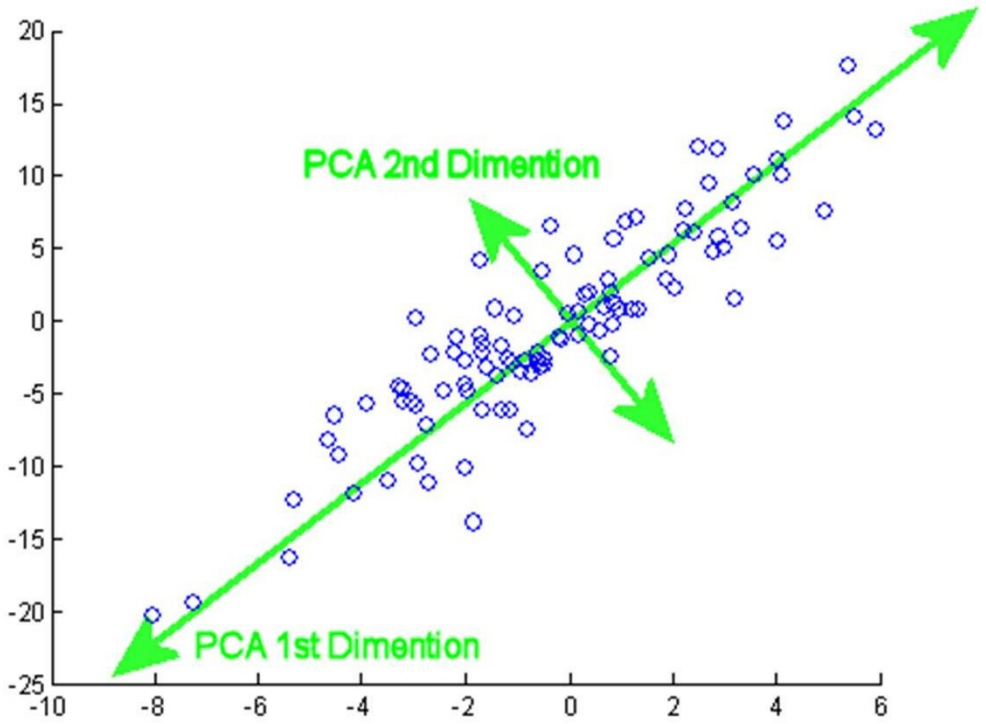
Метод главных компонент

Метод главных компонент

- Principal component analysis (PCA)
- Проецирует данные в пространство меньшей размерности
- Относится к **методам извлечения признаков**



Извлечение признаков



Метод главных компонент

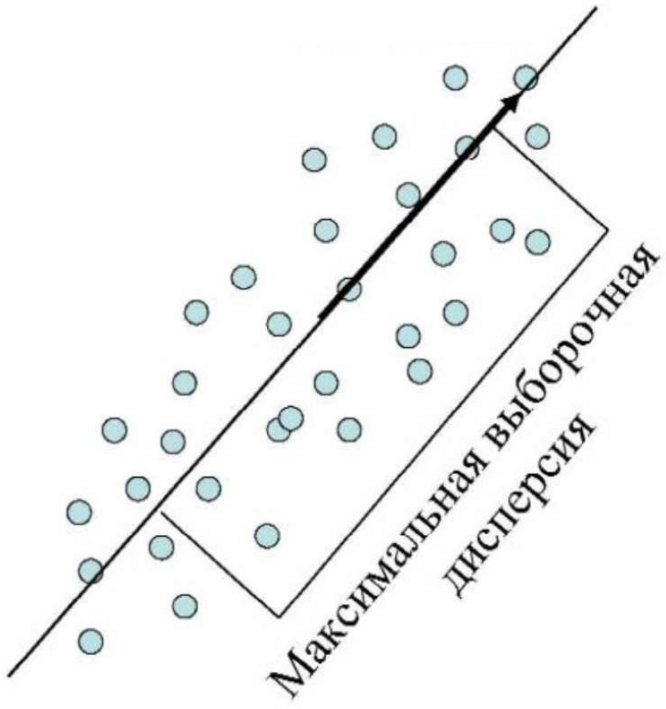
- Матричная запись:

$$Z = XW^T$$

- j-й столбец W — коэффициенты при исходных признаках для вычисления нового j-го признака

Principal Component Analysis 1

Идея 1: давайте выделять в пространстве признаков направления, вдоль которых разброс точек наибольший (они кажутся наиболее информативными)



ПРИМЕР: FACES DATASET



FACES DATASET (ГЛАВНЫЕ КОМПОНЕНТЫ)

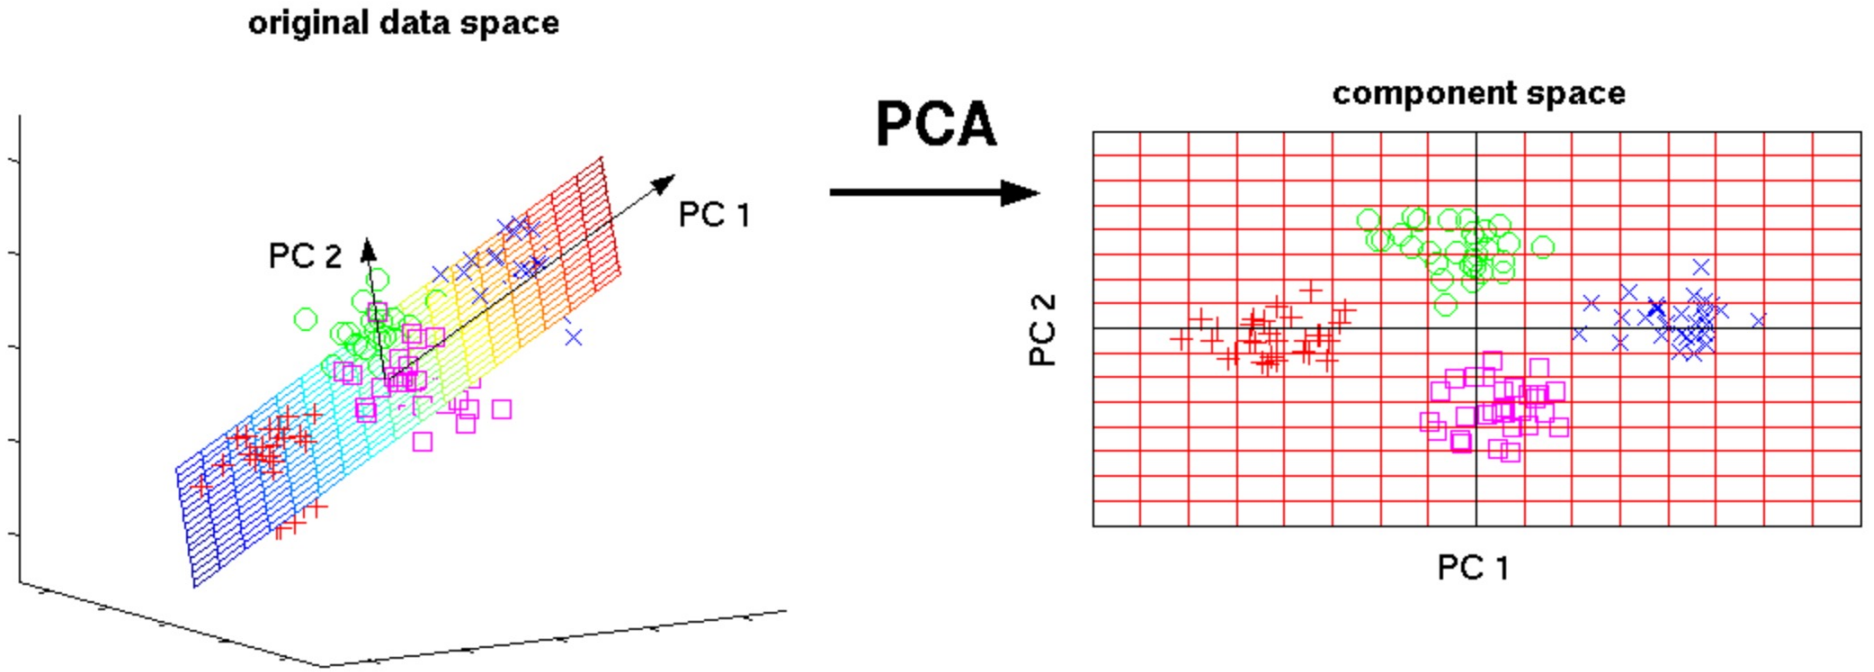


ВОССТАНОВЛЕННОЕ ИЗОБРАЖЕНИЕ



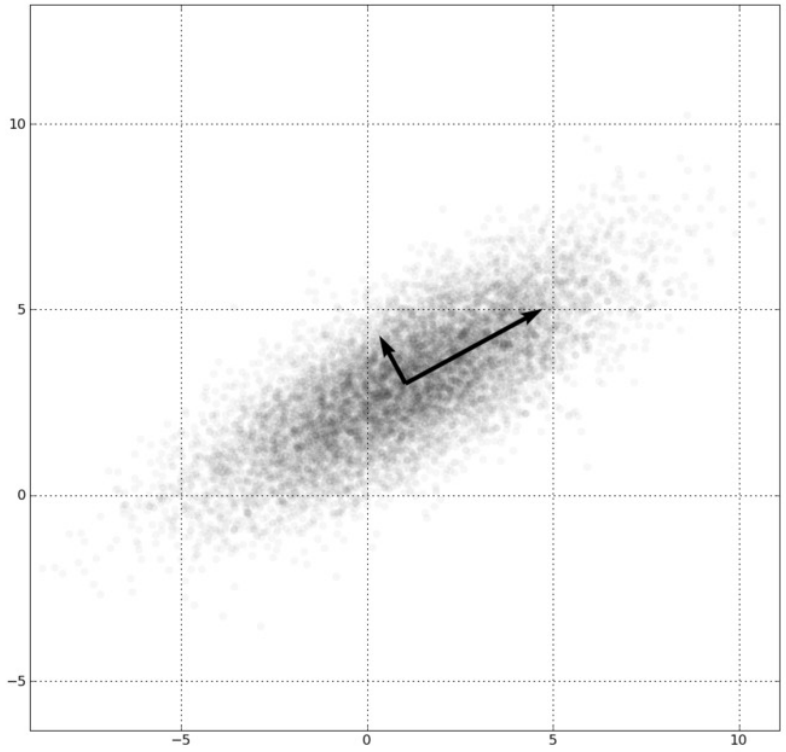
PCA (интерпретация 2)

Идея 2: давайте строить проекцию выборки на линейное подпространство меньшей размерности. А выбирать его так, чтобы квадраты отклонений точек от проекций были минимальны.

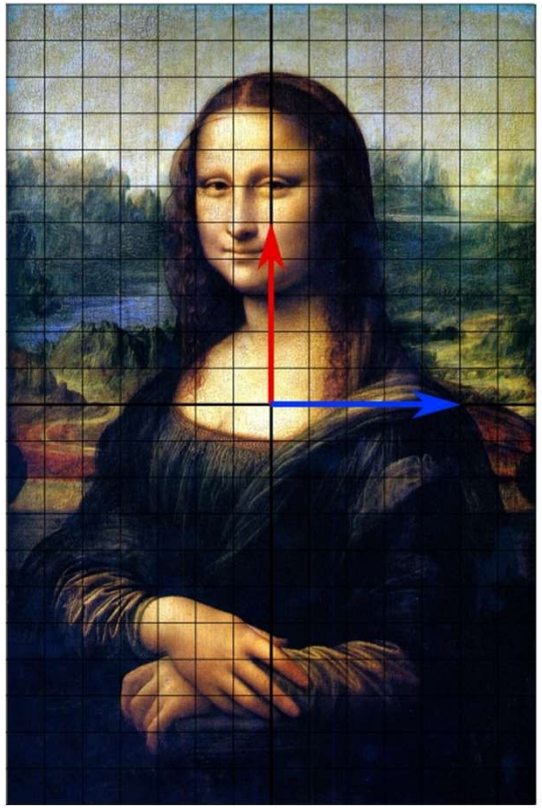


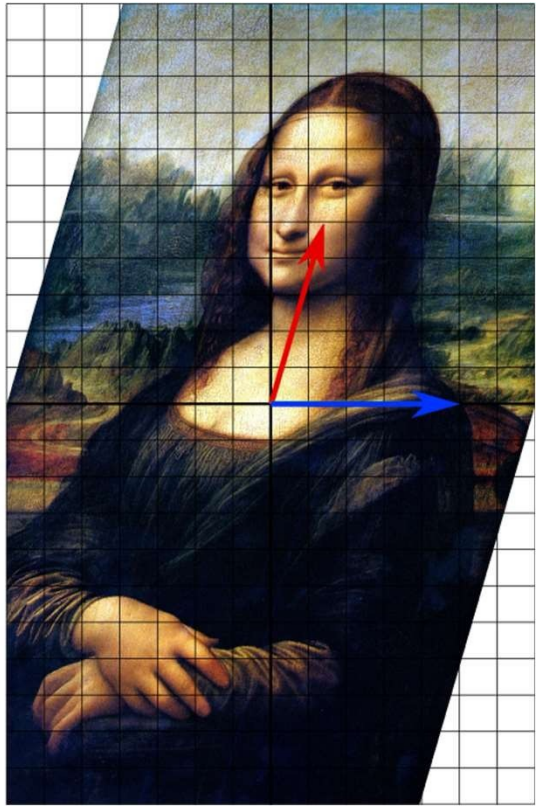
PCA (интерпретация 3)

Идея 3. Переход в базис, в котором матрица ковариаций диагональна



Собственные векторы





Со́бственный ве́ктор — понятие в линейной алгебре, определяемое для произвольного линейного оператора как ненулевой вектор, применение к которому оператора даёт коллинеарный вектор — тот же вектор, умноженный на некоторое скалярное значение (которое может быть равно 0). Скаляр, на который умножается собственный вектор под действием оператора, называется собственным числом (или собственным значением) линейного оператора, соответствующим данному собственному вектору.

Собственные векторы

- A — матрица размера $n \times n$
- Пусть $Ax = \lambda x$
- Тогда x — собственный вектор, λ — собственное значение
- x — вектор, который не меняет направление под воздействием матрицы

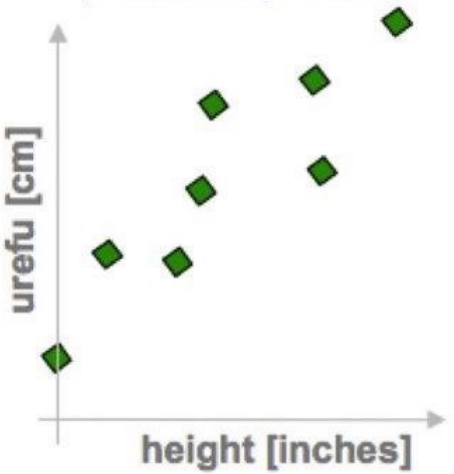
Решение

- Столбцы W — собственные векторы матрицы $X^T X$, соответствующие наибольшим собственным значениям $\lambda_1, \lambda_2, \ldots, \lambda_d$
- $\frac{\sum_{i=1}^{d} \lambda_i}{\sum_{i=1}^{D} \lambda_i}$ — доля дисперсии, сохранённой при понижении размерности

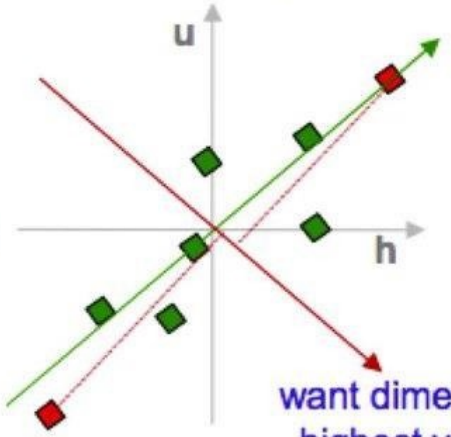
PCA in a nutshell

1. correlated hi-d data

("urefu" means "height" in Swahili)



2. center the points



want dimension of highest variance

3. compute covariance matrix

	h	u
h	2.0	0.8
u	0.8	0.6

$$\text{cov}(h,u) = \frac{1}{n}\sum_{i=1}^{n} h_i u_i$$

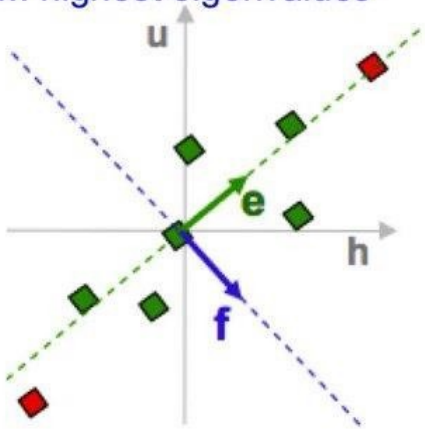
4. eigenvectors + eigenvalues

$$\begin{pmatrix} 2.0 & 0.8 \\ 0.8 & 0.6 \end{pmatrix} \begin{pmatrix} e_h \\ e_u \end{pmatrix} = \lambda_e \begin{pmatrix} e_h \\ e_u \end{pmatrix}$$

$$\begin{pmatrix} 2.0 & 0.8 \\ 0.8 & 0.6 \end{pmatrix} \begin{pmatrix} f_h \\ f_u \end{pmatrix} = \lambda_f \begin{pmatrix} f_h \\ f_u \end{pmatrix}$$

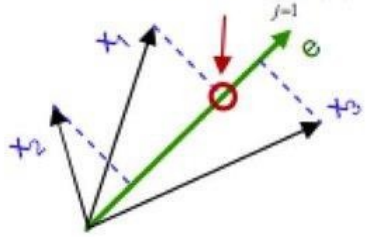
```
eig(cov(data))
```

5. pick m<d eigenvectors w. highest eigenvalues

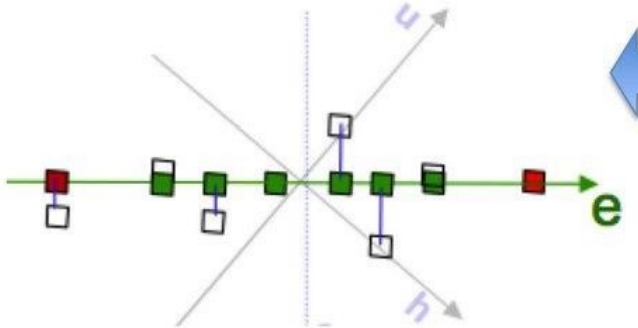


6. project data points to those eigenvectors

$$x_e' = x^T e = \sum_{j=1}^{d} x_{ij} e_j$$



7. uncorrelated low-d data



Copyright © 2014 Victor Lavrenko

PCA (интерпретация 4)

Приблизим исходную матрицу признаков произведением двух матриц:

$$\underset{l\times n}{X} \approx \underset{l\times k}{U} \cdot \underset{k\times n}{V^T}$$

$$\left|\left|X - U \cdot V^T\right|\right| \to min$$

PCA: как сделать?

Центрируем выборку (из каждого признака вычитаем среднее значение), получаем матрицу X с новыми значениями признаков

Делаем SVD-разложение матрицы X:

$$X \approx A \cdot \Lambda \cdot B^T$$

Выбираем $U = A \cdot \Lambda, \quad V = B$

SVD

SVD = Singular Vector Decomposition (сингулярное разложение матриц)

Позволяет получить наилучшее приближение исходной матрицы X матрицей X’ ранга k.

Применяется для снижения размерности пространства признаков.

SVD

