



Решающие деревья

ПРИМЕР




НЕЛИНЕЙНЫЙ АЛГОРИТМ




ПРИМЕР

- Жадно найдем наилучший предикат




ПРИМЕР

- Жадно найдем наилучший предикат





ПРИМЕР

- Жадно найдем наилучший предикат





ПРИМЕР

- Нашли лучшее первое ветвление





ПРИМЕР

- Нашли лучшее первое ветвление




ПРИМЕР

- Нашли лучшее второе ветвление




ПРИМЕР

- Построили всё дерево




ПРИМЕР: РЕШАЮЩЕЕ ДЕРЕВО В ЗАДАЧЕ КЛАССИФИКАЦИИ

Предположим, что в лист дерева попало несколько объектов. В каждом листе дерево предсказывает класс объекта. Какой класс выгоднее всего выдать в качестве ответа?




ПРИМЕР: РЕШАЮЩЕЕ ДЕРЕВО В ЗАДАЧЕ КЛАССИФИКАЦИИ



Разумнее всего в качестве ответа в листе выдавать самый представительный класс.





ПРИМЕР ПОСТРОЕНИЯ РЕШАЮЩЕГО ДЕРЕВА В ЗАДАЧЕ РЕГРЕССИИ



ПРИМЕР ПОСТРОЕНИЯ РЕШАЮЩЕГО ДЕРЕВА В ЗАДАЧЕ РЕГРЕССИИ




ПРИМЕР ПОСТРОЕНИЯ РЕШАЮЩЕГО ДЕРЕВА В ЗАДАЧЕ РЕГРЕССИИ




ПРИМЕР: РЕШАЮЩЕЕ ДЕРЕВО В ЗАДАЧЕ РЕГРЕССИИ

Предположим, что в лист дерева попало несколько объектов. В каждом листе дерево предсказывает константу. Какую константу выгоднее всего выдать в качестве ответа?




ПРИМЕР: РЕШАЮЩЕЕ ДЕРЕВО В ЗАДАЧЕ РЕГРЕССИИ


Если в качестве функционала ошибки в листе использовать среднеквадратичную ошибку, то в качестве ответа надо выдавать среднее значение целевых переменных всех объектов, попавших в лист.




ПРИМЕР: ДЕРЕВО ГЛУБИНЫ 2



ПРИМЕР: ДЕРЕВО ГЛУБИНЫ 5



ПРИМЕР



Объекты в этом примере имеют два признака с вещественными значениями: XX и YY . Решение о том, к какому классу будет отнесён текущий объект выборки, будет приниматься с помощью прохода от корня дерева к некоторому листу.



В каждом узле этого дерева находится предикат. Если предикат верен для текущего примера из выборки, мы переходим в правого потомка, если нет — в левого. В данном примере все предикаты — это просто взятие порога по значению какого-то признака:

$$B(x, j, t) = [x_j \leq t]$$

В листьях записаны предсказания (например, метки классов). Как только мы дошли до листа, мы присваиваем объекту ответ, записанный в вершине.

ПРИМЕР

На картинке ниже визуализирован процесс построения решающих поверхностей, порождаемых деревом (правая часть картинки):




ОПРЕДЕЛЕНИЕ

Пусть задано бинарное дерево, в котором:

- каждой внутренней вершине v приписан предикат $B_v : \mathbb{X} \rightarrow \{0, 1\}$;
- каждой листовой вершине v приписан прогноз $c_v \in \mathbb{Y}$, где $\mathbb{Y}$ — область значений целевой переменной (в случае классификации листу может быть также приписан вектор вероятностей классов).

Медицинская диагностика



Принятие решений






Схема диалога с клиентом




Пассажиры Титаника



Прогноз в листе


- Регрессия:
 - Вещественное число
- Классификация:
 - Класс
 - Вероятности классов

Жадное построение




- Как разбить вершину?


Жадное построение




Жадное построение




Жадное построение




Жадное построение




Жадное построение



Как сравнить разбиения?





или




Энтропия

- Мера неопределённости распределения




Энтропия

- Мера неопределённости распределения



Высокая энтропия



Низкая энтропия

Энтропия

- Дискретное распределение
- Принимает n значений с вероятностями $p_1, \dots, p_n$
- Энтропия:

$$H(p_1, \dots, p_n) = - \sum_{i=1}^n p_i \log p_i$$


Энтропия

- $(0.2, 0.2, 0.2, 0.2, 0.2)$
- $H = 1.60944 \dots$

- $(0.9, 0.05, 0.05, 0, 0)$
- $H = 0.394398 \dots$

- $(0, 0, 0, 1, 0)$
- $H = 0$

Как сравнить разбиения?




0.693

0

- $(0.5, 0.5, 0)$ и $(0, 0, 1)$
- $H = 0.693 + 0 = 0.693$


1.09

1.09




- $(0.33, 0.33, 0.33)$ и $(0.33, 0.33, 0.33)$
- $H = 1.09 + 1.09 = 2.18$


А для регрессии?



А для регрессии?



А для регрессии?



А для регрессии?

- Выбираем разбиение с наименьшей суммарной дисперсией
- Чем меньше дисперсия, тем меньше неопределённости

Поиск разбиения


- Пусть в вершине t оказалась выборка X_m
- $Q(X_m, j, t)$ — критерий ошибки условия $[x^j \leq t]$
- Ищем лучшие параметры j и t перебором:

$$Q(X_m, j, t) \rightarrow \max_{j, t}$$

Критерий качества

$$Q(X_m, j, t) = H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r)$$

Разброс ответов в левом
листе



Разброс ответов в правом
листе

Критерий информативности

- $H(X)$
- Зависит от ответов на выборке X
- Чем меньше разброс ответов, тем меньше значение $H(X)$

Регрессия

$$\bar{y}(X) = \frac{1}{|X|} \sum_{i \in X} y_i$$

$$H(X) = \frac{1}{|X|} \sum_{i \in X} (y_i - \bar{y}(X))^2$$

Классификация

- Доля объектов класса k в выборке X :

$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$

Энтропийный критерий

$$H(X) = - \sum_{k=1}^K p_k \ln p_k$$

- Считаем, что $0 \ln 0 = 0$
- Если $p_1 = 1, p_2 = \dots = p_K = 0$, то $H(X) = 0$
- Мера отличия распределения классов от вырожденного

Информативность в задаче классификации: критерий Джини

Пусть предсказание модели — это распределение вероятностей классов $(c_1, \dots, c_k)$. Вместо логарифма правдоподобия в качестве критерия можно выбрать, например, метрику Бриера (за которой стоит всего лишь идея посчитать MSE от вероятностей). Тогда информативность получится равной

$$H(X_m) = \min_{\sum_k c_k = 1} \frac{1}{|X_m|} \sum_{(x_i, y_i) \in X_m} \sum_{k=1}^K (c_k - \mathbb{I}[y_i = k])^2$$

Можно показать, что оптимальное значение этой метрики, как и в случае энтропии, достигается на векторе c , состоящем из выборочных оценок частот классов $(p_1, \dots, p_k)$, $p_i = \frac{1}{|X_m|} \sum_i \mathbb{I}[y_i = k]$. Если подставить $(p_1, \dots, p_k)$ в выражение выше и упростить его, получится **критерий Джини**:

$$H(X_m) = \sum_{k=1}^K p_k(1 - p_k)$$

Критерий информативности в задаче классификации: misclassification error

Пусть в нашей задаче K классов, а p_k — доля объектов класса k в текущей вершине X_m :

$$p_k = \frac{1}{|X_m|} \sum_{(x_i, y_i) \in X_m} \mathbb{I}[y_i = k]$$

Допустим, мы заботимся о доле верно угаданных классов, то есть функция потерь — это индикатор ошибки:

$$L(y_i, c) = \mathbb{I}[y_i \neq c]$$

Критерий информативности в задаче классификации: misclassification error

Пусть также предсказание модели в листе — один какой-то класс. Информативность для такой функции потерь выглядит так:

$$H(X_m) = \min_{c \in Y} \frac{1}{|X_m|} \sum_{(x_i, y_i) \in X_m} \mathbb{I}[y_i \neq c]$$

Ясно, что оптимальным предсказанием в листе будет наиболее частотный класс k_* , а выражение для информативности упростится следующим образом:

$$H(X_m) = \frac{1}{|X_m|} \sum_{(x_i, y_i) \in X_m} \mathbb{I}[y_i \neq k_*] = 1 - p_{k_*}$$

Поиск разбиения

- После того, как разбиение найдено:

- Разбиваем X_m на две части:

$$X_l = \{x \in X_m \mid [x^j \leq t]\}$$

$$X_r = \{x \in X_m \mid [x^j > t]\}$$

- Повторяем процедуру для дочерних вершин

Критерий останова


- В какой момент прекращать разбиение вершин?
- В вершине один объекты?
- В вершине объекты одного класса?
- Глубина превысила порог?

Жадный алгоритм построения дерева


1. Поместить в корень всю выборку: $X_1 = X$
2. Начать построение с корня: $m = 1$
3. Если выполнен критерий останова для вершины m , то выход
4. Найти лучшее разбиение $[x^j \leq t]$ для вершины m
5. Разбить вершину m на дочерние вершины l и r
6. Повторить шаги 3-6 для дочерних вершин l и r

Переобучение деревьев и
борьба с ним


Классификация




Классификация




Классификация




Классификация



Регрессия




Регрессия




Решающие деревья

- Восстанавливают сложные закономерности
- Могут построить сколь угодно сложную поверхность
- Чем больше глубина — тем сложнее поверхность
- Склонны к переобучению



Глубина деревьев



Переобучение деревьев



Переобучение деревьев



Переобучение деревьев


- Дерево может достичь нулевой ошибки на любой выборке
- Как правило, такое дерево окажется переобученным
- Выход — ограничивать глубину или число объектов в листе

Критерий останова

- Как понять, разбивать вершину или делать листовой?
- Способ борьбы с переобучением

Критерий останова




- Все объекты в вершине относятся к одному классу
- Простое условие
- Но приводит к переобучению



Число объектов в листе

- В вершину попало $\leq n$ объектов
- При $n = 1$ получаем максимально переобученные деревья
- n должно быть достаточно, чтобы построить надёжный прогноз
- Рекомендация: $n = 5$




Число объектов в листе



Глубина дерева

- Ограничение на глубину
- Достаточно грубый критерий



Глубина дерева




Неустойчивость деревьев

- Структура дерева очень сильно меняется даже при малом изменении выборки
- Пример: обучим два дерева по подвыборкам размером 90% от всего обучения

Неустойчивость деревьев



Усреднение деревьев



Бэггинг

Идея:

- Обучим много деревьев $b_1(x), \dots, b_N(x)$
- Выберем ответ по большинству:

$$a(x) = \arg \max_{y \in \mathbb{Y}} \sum_{n=1}^N [b_n(x) = y]$$

Пример

- Прогнозы деревьев: $-1, -1, 1, -1, 1, -1$

$$a(x) = ?$$

Пример

- Прогнозы деревьев: $-1, -1, 1, -1, 1, -1$

$$a(x) = -1$$

Рандомизация

- Как сделать деревья разными?
- Обучать по подвыборкам!

Рандомизация

- Популярный подход: бутстрап
- Выбираем из обучающей выборки ℓ объектов с возвращением
- Пример: $\{x_1, x_2, x_3, x_4\} \rightarrow \{x_1, x_2, x_2, x_4\}$

Рандомизация

- Этого недостаточно
- Как можно рандомизировать сам процесс построения дерева?

Случайный лес (Random forest)

1. Для $n = 1, \dots, N$:
2. Сгенерировать выборку $\tilde{X}$ с помощью бутстрапа
3. Построить решающее дерево $b_n(x)$ по выборке $\tilde{X}$
4. Дерево строится, пока в каждом листе не окажется не более n_{min} объектов
5. Оптимальное разбиение ищется среди q случайных признаков

Случайный лес (Random forest)

1. Для $n = 1, \dots, N$:
2. Сгенерировать выборку $\tilde{X}$ с помощью бутстрапа
3. Построить решающее дерево $b_n(x)$ по выборке $\tilde{X}$
4. Дерево строится, пока в каждом листе не окажется не более n_{min} объектов
5. Оптимальное разбиение ищется среди q случайных признаков

Выбираются заново при каждом разбиении!

Случайный лес

- Регрессия:

$$a(x) = \frac{1}{N} \sum_{n=1}^N b_n(x)$$

- Классификация:

$$a(x) = \arg \max_{y \in \mathbb{Y}} \sum_{n=1}^N [b_n(x) = y]$$

Ошибка на тесте

- Ошибка сначала убывает, а затем остаётся примерно на одном уровне
- Случайный лес не переобучается при росте N

