

ML recap

Постановка задачи: обучение с учителем

Объекты	$x_1, \dots, x_n$	Ответы	$y_1, \dots, y_n$
---------	-------------------	--------	-------------------

Постановка задачи: обучение с учителем

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n$

Функция потерь $L(y, \hat{y})$

Постановка задачи: обучение с учителем

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n$

Алгоритм предсказания $f(x, \theta)$

Функция потерь $L(y, \hat{y})$

Задача: настроить θ

Постановка задачи: обучение с учителем

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n$

Алгоритм предсказания $f(x, \theta)$

Функция потерь $L(y, \hat{y})$

Задача: настроить θ

$$E_{(x,y)} L(y, f(x, \theta)) \rightarrow \min_{\theta}$$

Постановка задачи: обучение с учителем

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n$

Алгоритм предсказания $f(x, \theta)$

Функция потерь $L(y, \hat{y})$

Задача: настроить θ

$$E_{(x,y)} L(y, f(x, \theta)) \rightarrow \min_{\theta}$$

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta} \quad \text{эмпирический риск}$$

Пример: бинарная классификация

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta)$

Функция потерь $L(y, \hat{y})$

Задача: настроить θ





Логистическая регрессия

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$

$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$



Логистическая регрессия

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$



$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Функция потерь

$$L(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_i [y_i \log P(y = 1 | X, \theta) + (1 - y_i) \log(1 - P(y = 1 | X, \theta))]_i$$

Логистическая регрессия

какие признаки?

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0, 1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$



$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Функция потерь

$$L(y, \hat{y}) = - \sum_i [y_i \log P(y = 1 | X, \theta) + (1 - y_i) \log(1 - P(y = 1 | X, \theta))]_i$$

Логистическая регрессия

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$



$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Функция потерь

$$L(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_i [y_i \log P(y = 1 | X, \theta) + (1 - y_i) \log(1 - P(y = 1 | X, \theta))]_i$$

Логистическая регрессия

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$




$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Функция потерь

$$L(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_i [y_i \log P(y = 1 | X, \theta) + (1 - y_i) \log(1 - P(y = 1 | X, \theta))]_i$$

для линейно разделяемых классов

Логистическая регрессия



[Image credit](#)



Логистическая регрессия

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$



$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Последовательное применение операций:

$$x \longrightarrow \theta^T x \longrightarrow \sigma(\theta^T x) \longrightarrow P(y = 1 | x, \theta)$$

Логистическая регрессия

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$



$$P(y = 1 | x, \theta) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Последовательное применение операций:



Простейшая нейросеть

Объекты $x_1, \dots, x_n$ Ответы $y_1, \dots, y_n \in [0,1]$

Алгоритм предсказания $f(x, \theta) = P(y = 1 | x, \theta) > \frac{1}{2}$




Последовательное применение операций:



**Нейросеть - это сложная
функция**

- Основной компонент нейронной сети – *перцептрон*:



- Линейная комбинация входов, потом нелинейность:

$$y = h(w^{\top}x) = h\left(\sum_i w_i x_i\right).$$

- Обучение *градиентным спуском*.
- Для исходного перцептрона Розенблатта ($h = \text{id}$):

$$E_P(\mathbf{w}) = - \sum_{x \in M} y(\mathbf{x}) (\mathbf{w}^\top x),$$

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla_{\mathbf{w}} E_P(\mathbf{w}) = \mathbf{w}^{(\tau)} + \eta t_n \mathbf{x}_n.$$

- Или, к примеру, можно делать классификацию, подставляя в качестве функции активации логистический сигмоид $h(x) = \sigma(x) = \frac{1}{1+e^{-x}}$:


$$E(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N (y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))).$$

- По сути это просто логистическая регрессия.

Простейшая нейросеть



Простейшая нейросеть



Нейросеть - это сложная функция

Можно не придумывать сложные признаки (feature engineering)

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:

Блок - слой нейросети, вычисляющий определенную функцию

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:

Блок - слой нейросети, вычисляющий определенную функцию

Linear

линейный слой

$$x_{output} = W \cdot x_{input}$$

параметры: W - матрица размера $d1 \times d2$ - веса линейного слоя

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:


Блок - слой нейросети, вычисляющий определенную функцию

Sigmoid

нелинейность или функция активации (сигмоида)

$$x_{output} = \sigma(x_{input}) = \frac{1}{1 + e^{-x_{input}}}$$

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:


Блок - слой нейросети, вычисляющий определенную функцию

Sigmoid

нелинейность или функция активации (сигмоида)


$$x_{output} = \sigma(x_{input}) = \frac{1}{1 + e^{-x_{input}}}$$

Простейшая нейросеть



Эта часть есть в почти всех современных нейросетях!

Простейшая нейросеть




Multiclass case

Softmax

$$x_{output_i} = \frac{e^{x_{input_i}}}{\sum_j e^{x_{input_j}}}$$


Простейшая нейросеть



Linear


параметры: W - матрица размера $d \times n_classes$

Простейшая нейросеть



Multiclass case

Transformer last layers



Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:

Блок - слой нейросети, вычисляющий определенную функцию

Как обучать?

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:

Блок - слой нейросети, вычисляющий определенную функцию

Как обучать?

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta} \quad \text{задача оптимизации}$$

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:

Блок - слой нейросети, вычисляющий определенную функцию

Как обучать?

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

задача оптимизации

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

методы оптимизации
1го порядка

КЛЮЧЕВЫЕ АСПЕКТЫ ОБУЧЕНИЯ

Инициализация весов: В самом начале обучения параметры персептрона (веса нейронов) устанавливаются случайным образом. Это необходимо для того, чтобы сеть могла начать процесс настройки и адаптации к входным данным.

Алгоритм обратного распространения ошибки (Backpropagation): Одним из основополагающих методов является механизм обратного распространения ошибки. Он позволяет корректировать веса на основе разницы между ожидаемым и полученным результатами, сокращая ошибку сети.

Функция активации: Функции активации преобразуют входные сигналы в выходные, обеспечивая переход от линейных к нелинейным преобразованиям. Выбор функции активации может значительно влиять на скорость и качество обучения.

Нормализация данных: Подготовка данных важных для обучения шаг включает нормализацию входных данных. Это помогает улучшить сходимость алгоритма и повысить точность результатов.

Простейшая нейросеть



Нейросеть - это сложная функция

Можно представить в виде вычислительного графа:

Блок - слой нейросети, вычисляющий определенную функцию

Как обучать?

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

Как посчитать градиенты?

Обучение нейросети

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

Численные методы: $\frac{df(x, \theta)}{d\theta} = \frac{f(x, \theta + eps) - f(x, \theta - eps)}{2eps}$ - конечные разности

Обучение нейросети

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

Численные методы:

$$\frac{df(x, \theta)}{d\theta} = \frac{f(x, \theta + eps) - f(x, \theta - eps)}{2eps}$$

- конечные разности

хороший unit test

Обучение нейросети

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

Обычно блоки дифференцируемые - можно посчитать “на бумаге”

Обучение нейросети


$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

Обычно блоки дифференцируемые - можно посчитать “на бумаге”

Блоков может быть очень много



Backpropagation

$$\frac{1}{n} \sum_i L(y_i, f(x_i, \theta)) \rightarrow \min_{\theta}$$

Градиентный спуск:

$$\theta_{t+1} = \theta_t - \alpha \frac{dL}{d\theta}$$

Chain rule (дифференцирование сложной функции):

$$\frac{dL}{d\theta} = \frac{dL}{dz} \frac{dz}{d\theta}$$

Backpropagation: простой пример

Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$


Backpropagation: простой пример

Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y$$

$$f = qz$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y$$

$$f = qz$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример

Дано: $f(x, y, z) = (x + y)z$


Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$

Forward pass



Backpropagation: простой пример

Дано: $f(x, y, z) = (x + y)z$


Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$

Forward pass



Backpropagation: простой пример

Дано: $f(x, y, z) = (x + y)z$


Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$

Forward pass



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$

$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation: простой пример


Дано: $f(x, y, z) = (x + y)z$

Вычислить: $\frac{df}{dx}, \frac{df}{dy}, \frac{df}{dz}$

$$q = x + y = 1 - 2 = -1$$


$$f = qz = -1 \cdot 3 = -3$$

$$x = 1, y = -2, z = 3$$



Backpropagation в нейросетях

Представление нейросети в виде вычислительного графа




$$\begin{aligned} s &= u^T h \\ h &= f(z) \\ z &= Wx + b \\ x &\text{ (input)} \end{aligned}$$

Backpropagation в нейросетях

Представление нейросети в виде вычислительного графа

Forward pass: вычисление результатов всех операций




$$\begin{aligned} s &= u^T h \\ h &= f(z) \\ z &= Wx + b \\ x &\text{ (input)} \end{aligned}$$

Backpropagation в нейросетях

Представление нейросети в виде вычислительного графа

Forward pass: вычисление результатов всех операций

Backward pass: вычисление всех градиентов



$$\begin{aligned}s &= u^T h \\ h &= f(z) \\ z &= Wx + b \\ x &\text{ (input)}\end{aligned}$$

DL frameworks



Josh Tobin
@josh_tobin_



Why do people always ask what ML framework to use? It's easy:

- jax is for researchers
- pytorch is for engineers
- tensorflow is for boomers



Josh Tobin @josh_tobin_ · 12 map.
Keras is for infants



Josh Tobin @josh_tobin_ · 12 map.
mxnet is for no one



Josh Tobin @josh_tobin_ · 12 map.
matlab is for professors



Итог

- Нейросеть - сложная функция
- Обучение - методы оптимизации 1го порядка
 - Градиентный спуск
- Backpropagation - способ подсчета градиентов в нейросетях
- Linear + Softmax = вероятности классов на выходе нейросети